Numeeriset menetelmät

Toni Karvonen
toni.karvonen@lut.fi

Lappeenrannan–Lahden teknillinen yliopisto LUT

27. maaliskuuta 2026

Sisällys

1 Liukuluvut **1**
1.1 Kantalukujärjestelmät . . . 1
1.2 Liukuluvut . . . 2
1.3 IEEE 754 -liukulukustandardi . . . 2
1.4 Pyöristys ja tarkkuus . . . 5
1.5 Numeerinen vakaus . . . 7

2 Virhe **8**
2.1 Pyöristys- ja katkaisuvirhe . . . 8
2.2 Approksimaation tarkkuus . . . 9
2.3 Absoluuttinen ja suhteellinen virhe . . . 9
2.4 Iso-O-notaatio . . . 10
2.5 Iso-O-notaation ominaisuuksia . . . 12

3 Numeeristen menetelmien rakentaminen **15**
3.1 Taylorin polynomi . . . 15
3.2 Linearisointi . . . 17
3.3 Taulukko-ohjelmointi . . . 19

4 Numeerinen integrointi **21**
4.1 Keskipistesääntö . . . 21
4.2 Puolisuunnikassääntö . . . 26
4.3 Simpsonin sääntö . . . 28

5 Yhtälöryhmien ratkaiseminen **32**
5.1 Newtonin menetelmä . . . 33
5.2 Newtonin menetelmä yhtälöryhmille . . . 36
5.3 Kiintopistemenetelmä . . . 43
5.4 Jacobin menetelmä lineaarisille yhtälöryhmille . . . 49

6 Differentiaaliyhtälöt **55**
6.1 Eulerin menetelmä . . . 55
6.2 Runge–Kutta-menetelmät . . . 55

7 Optimointi **56**
7.1 Optimoinnin peruskäsitteitä . . . 56
7.2 Gradienttimenetelmä . . . 56
7.3 Automaattinen derivointi . . . 56

1 Liukuluvut

Tämä osio käsittelee tapoja esittää reaalilukuja tietokoneessa. Koska reaalilukuja on ääretömän paljon, ei niitä kaikkia ole mahdollista esittää ja on välttämätöntä tehdä kompromisseja.

1.1 Kantalukujärjestelmät

Tutussa *kymmenjärjestelmässä* luvut esitetään kymmenen potenssien avulla. Esimerkiksi luku 1453,529 voidaan kirjoittaa muodossa

$$1453{,}529 = 1 \cdot 10^3 + 4 \cdot 10^2 + 5 \cdot 10^1 + 3 \cdot 10^0 + 5 \cdot 10^{-1} + 2 \cdot 10^{-2} + 9 \cdot 10^{-3}.$$

Tällaisessa *paikkajärjestelmässä* numeron vaikutus luvun arvoon on sen arvon tulo valitun *kantaluvun* (kymmenjärjestelmässä kanta on 10) potenssin kanssa. Numeron sijainti määrää kantaluvun eksponentin. Sijainti lasketaan *desimaalierottimesta* siten, että vasemmalla puolella potenssit ovat epänegatiivisia ja oikealla puolella negatiivisia. Koska 5 on toinen numero erottimesta vasemmalle luvussa 1453,529, sen eksponentiksi tulee 1 (sillä ensimmäinen potenssi desimaalierottimen vasemmalla puolella on 0). Täten numeron 5 vaikutus tämän luvun arvoon on $5 \cdot 10^1 = 50$. Vastaavasti koska 9 on kolmas numero desimaalierottimen oikealla puolella, sen eksponentti on -3 ja panos $9 \cdot 10^{-3} = 0{,}009$.

Määritelmä 1.1 (Kantalukujärjestelmä)**.** Olkoon $b \geq 2$ kokonaisluku, jota kutsutaan *kantaluvuksi*. Kannassa b luvut kirjoitetaan muodossa

$$(a_n a_{n-1} \cdots a_0{,}c_1 c_2 \cdots)_b = a_n \cdot b^n + a_{n-1} \cdot b^{n-1} + \cdots + a_0 \cdot b^0 + c_1 \cdot b^{-1} + c_2 \cdot b^{-2} + \cdots,$$

missä *numerot* $a_0, \ldots, a_n$ ja $c_1, c_2, \ldots$ ovat kokonaislukuja välillä lukujen 0 ja $b-1$ välillä.

Alaindeksiä b ei yleensä käytetä kymmenjärjestelmässä (eli kun $b = 10$) muutoin kuin selvyyden vuoksi.

Esimerkki 1.2. Oktaaliluvun (eli $b = 8$) $(35{,}07)_8$ muuntaminen kymmenjärjestelmään tapahtuu seuraavasti:

$$(35{,}07)_8 = 3 \cdot 8^1 + 5 \cdot 8^0 + 0 \cdot 8^{-1} + 7 \cdot 8^{-2} = 3 \cdot 8 + 5 + \frac{0}{8} + \frac{7}{8^2} = 29{,}109375.$$

Esimerkki 1.3. Heksadesimaalijärjestelmässä (eli kantaluku $b = 16$) kirjaimia A–F käytetään numeroiden 10–15 esittämiseen. Luvun $(\mathrm{AE{,}1B})_{16}$ muuntaminen kymmenjärjestelmään tapahtuu seuraavasti:

$$\begin{aligned}(\mathrm{AE{,}1B})_{16} &= 10 \cdot 16^1 + 14 \cdot 16^0 + 1 \cdot 16^{-1} + 11 \cdot 16^{-2} \\ &= 10 \cdot 16 + 14 + \frac{1}{16} + \frac{11}{256} \\ &= 174{,}10546875.\end{aligned}$$

Esimerkki 1.4. Muuntaaksemme luvun $(220{,}1)_3$ kymmenjärjestelmään kirjoitamme

$$(220{,}1)_3 = 2 \cdot 3^2 + 2 \cdot 3^1 + 0 \cdot 3^0 + 1 \cdot 3^{-1} = 2 \cdot 9 + 2 \cdot 3 + \frac{1}{3} = 24{,}333\ldots$$

Huomaa, kantalukuesitys voi olla päättyvä yhdessä kannassa $[(220,1)_3]$ mutta päättymätön toisessa $(24{,}333\ldots)$.

Esimerkki 1.5. Kymmenjärjestelmän luku 33,25 voidaan muuntaa binäärijärjestelmään (eli kantaluku $b = 2$) seuraavasti:

$$\begin{aligned}(33{,}25)_{10} = 32 + 1 + \frac{1}{4} &= 1\cdot 2^5 + 0\cdot 2^4 + 0\cdot 2^3 + 0\cdot 2^2 + 0\cdot 2^1 + 1\cdot 2^0 + 0\cdot 2^{-1} + 1\cdot 2^{-2} \\ &= (100001{,}01)_2.\end{aligned}$$

Binäärijärjestelmä. Binäärijärjestelmän numerot (eli 0 ja 1) ovat binäärinumeroita eli *bittejä*. Esimerkiksi binääriluvussa $(110{,}1)_2 = 6{,}5$ on neljä bittiä. Suurin luku, joka voidaan esittää n bitillä, on

$$(1\underbrace{0\cdots 00}_{n \text{ kertaa}})_2 - (1)_2 = (\underbrace{11\cdots 11}_{n \text{ kertaa}})_2 = 1\cdot 2^{n-1} + 1\cdot 2^{n-2} + \cdots + 1\cdot 2^1 + 1\cdot 2^0 = 2^n - 1. \tag{1.1}$$

1.2 Liukuluvut

Vaikka kaikki reaaliluvut pystyykin esittämään missä tahansa kannassa (esitys voi tosin olla päättymätön), käytännössä tämä on mahdotonta, sillä tietokoneiden muisti on rajallista. Kun lukuja toteutetaan tietokoneessa, on valittava, mitkä luvut esitetään ja miten. Tähän käytetään liukulukuesitystä.

Määritelmä 1.6 (Liukuluku)**.** *Liukuluku* $a \in \mathbb{R}$ kannassa b on muotoa

$$a = s\cdot c\cdot b^e,$$

missä $s \in \{-1, 1\}$ on luvun *etumerkki*, $c \in \mathbb{R}_{\geq 0}$ *mantissa* ja $e \in \mathbb{Z}$ *eksponentti*.

Liukulukuesitys ei ole yksikäsitteinen. Esimerkiksi 123,45 voidaan kirjoittaa

$$12345\cdot 10^{-2} \quad \text{tai} \quad 1234{,}5\cdot 10^{-1}$$

tai äärettömän monella muulla tavalla kymmenkantaisena (eli $b = 10$) liukulukuna. Jotta liukulukuja voidaan esittää tietokoneessa, on valittava äärellinen määrä mahdollisia mantissan ja eksponentin arvoja. Nämä valinnat määräävät syntyvän liukulukumuodon tarkkuuden ja muistinkulutuksen.

1.3 IEEE 754 -liukulukustandardi

IEEE-standardi liukulukulaskennalle (IEEE 754) määrittelee joukon liukulukumuotoja, joita käytetään käytännössä kaikessa laskennassa. Binääriset IEEE 754 -liukuluvut ovat muotoa

$$a = s\cdot(1+f)\cdot 2^{e-e_{\text{bias}}}, \tag{1.2}$$

missä e_{bias}, *eksponentin bias*, on positiivinen kokonaisluku ja $f \in (0,1)$ määrittää mantissan (kutsumme tätä lukua *mantissan murto-osaksi*). Sekä $f \in (0,1)$ että $e \in \mathbb{Z}_{\geq 0}$ tallennetaan binäärilukuina käyttäen valittua määrää bittejä. Toisin sanoen

$$f = (0{,}\bar{b}_1\bar{b}_2\cdots\bar{b}_p)_2 \quad \text{ja} \quad e = (\hat{b}_1\hat{b}_2\cdots\hat{b}_q)_2$$

joillekin positiivisille kokonaisluvuille p ja q sekä biteille $\bar{b}_i, \hat{b}_j \in \{0,1\}$. Etumerkki ilmoitetaan bitillä b_s muodossa $s = (-1)^{b_s}$, jolloin

$$b_s = 0 \implies s = 1 \qquad \text{ja} \qquad b_s = 1 \implies s = -1.$$

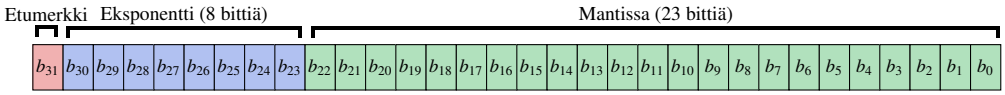

Kuva 1.1: 32-bittisten IEEE 754 -liukulukujen bittijako. Katso taulukko 1.1.

Tässä muodossa liukuluvun esittämiseen käytetään $n = p+q+1$ bittiä (p bittiä mantissalle, q eksponentille ja yksi etumerkille), jotka järjestetään seuraavasti:

$$(b_s\hat{b}_q\hat{b}_{q-1}\cdots\hat{b}_1\bar{b}_p\bar{b}_{p-1}\cdots\bar{b}_1)_2 = (b_{p+q}b_{p+q-1}\cdots b_0)_2. \tag{1.3}$$

Kuva 1.1 havainnollistaa bittijakoa. IEEE 754 -esityksessä käytetään arvoa $e_{\text{bias}} = 2^{q-1}-1$ kaavan (1.2) kokonaisluvulle e_{bias} kaavassa (1.2). Tämä arvo määrää luvun 2 *varsinaisen eksponentin* $e - e_{\text{bias}} = e - 2^{q-1}$. Tästä seuraa, että varsinainen eksponentti vaihtelee [ks. (1.1)]

$$\text{luvusta } e_{\min} = 0 - e_{\text{bias}} = -2^{q-1}+1 \text{ lukuun } e_{\max} = 2^q - 1 - e_{\text{bias}} = 2^{q-1}(2-1) = 2^{q-1}. \tag{1.4}$$

Esimerkki 1.7. Tarkastellaan IEEE 754 -muotoisia liukulukuja, joissa mantissalle on varattu $p = 3$ ja eksponentille $q = 2$ bittiä. Bittien kokonaismäärä on siis $n = p+q+1 = 6$. Tässä esitystavassa binääriluku $(101110)_2$ esittää muodon (1.2) mukaista liukulukua, jossa $s = (-1)^1 = -1$, $e = (01)_2 = 1$ ja $f = (0{,}110)_2 = 0{,}75$. Koska $e_{\text{bias}} = 2^{q-1}-1 = 1$, $(101110)_2$ esittää kaavan (1.2) nojalla kymmenjärjestelmän luvun

$$s\cdot(1+f)\cdot 2^{e-e_{\text{bias}}} = (-1)\cdot(1+0{,}75)\cdot 2^{1-1} = -1{,}75.$$

IEEE 754 -standardin erikoistapaukset. Eksponenteilla $e = (0\cdots0)_2$ ja $e = (1\cdots1)_2$ on erityistulkinnat:

- Jos eksponentti on nolla, eli $e = (0\cdots0)_2$:
  - Jos *mantissan murto-osa on nolla*, eli $f = (0.0\cdots0)_2$, luku tulkitaan nollaksi. Etumerkkibitti määrää, onko nolla "positiivinen" vai "negatiivinen", mikä ei vaikuta useimpiin laskutoimituksiin. Toisin sanoen,

    $$\text{“positiivinen” nolla} = (10\cdots0)_2 \quad \text{ja} \quad \text{“negatiivinen” nolla} = (00\cdots0)_2.$$

  - Jos *mantissan murto-osa ei ole nolla*, liukulukua kutsutaan *alinormaaliksi* (engl. *subnormal*) ja se esittää kymmenjärjestelmän luvun

    $$a_{\text{subnormal}} = s\cdot f\cdot 2^{-e_{\text{bias}}+1}. \tag{1.5}$$

    Tämä poikkeaa kaavan (1.2) antamasta *normaalista* luvusta siten, että $1+f \in (1,2)$ korvautuu termillä $f \in (0,1)$. Alinormaaleilla luvuilla voidaan esittää pienempiä lukuja kuin pelkillä normaaleilla luvuilla olisi mahdollista.
- Jos eksponentti on suurin mahdollinen, eli $e = (1\cdots1)_2$:
  - Jos *mantissan murto-osa on nolla*, eli $f = (0.0\cdots0)_2$, luku tulkitaan etumerkkibitin mukaan positiiviseksi äärettömäksi (∞) tai negatiiviseksi äärettömäksi ($-\infty$).
  - Jos *murto-osa ei ole nolla*, luku tulkitaan *epäluvuksi* (NaN), eli arvo on määrittelemätön. Tämä voi tapahtua esimerkiksi laskettaessa $0/0$.

IEEE 754 -binäärimuodot. Taulukko 1.1 sisältää kolmen yleisimmän IEEE 754 -standardin binäärisen liukulukumuodon määritykset ja keskeiset ominaisuudet. Näihin viitataan tyypillisesti nimillä *puolitarkkuus* (engl. *half-precision*; 16 bittiä), *perustarkkuus* (engl. *float* tai *single-precision*; 32 bittiä) ja *kaksoistarkkuus* (engl. *double* tai *double-precision*; 64 bittiä).

Taulukko 1.1: IEEE 754 -standardin puolitarkkuus- (half), yksittäistarkkuus- (float) ja kaksoistarkkuuslukujen (double) keskeiset ominaisuudet. Huomaa, että jokaisessa muoto käyttää eksponentti- ja mantissabittien lisäksi yhden bitin etumerkin esittämiseen. *Kone-epsilon* kuvaa liukulukujärjestelmän tarkkuutta. Se on luvun 1 ja seuraavan sitä suuremman liukuluvun erotusta. Voidaan näyttää, että $\varepsilon = 2^{-p}$, missä p on mantissabittien lukumäärä. *Mantissan bittien määrä määrittää tarkkuuden ja eksponentin bittien määrä määrittää, kuinka pieniä ja suuria lukuja on mahdollista esittää.*

Ominaisuus	**Half (16 bittiä)**	**Float (32 bittiä)**	**Double (64 bittiä)**
Bittejä yhteensä	16	32	64
Bittejä eksponentissa (q)	5	8	11
Bittejä mantissassa (p)	10	23	52
Eksponentin bias (e_{bias})	15	127	1023
Pienin pos. normaali luku	2^{-14}	2^{-126}	2^{-1022}
Pienin pos. alinormaali luku	2^{-24}	2^{-149}	2^{-1074}
Suurin äärellinen luku ($\approx$)	$6{,}55 \times 10^4$	$3{,}40 \times 10^{38}$	$1{,}80 \times 10^{308}$
Kone-epsilon (ε)	2^{-10}	2^{-23}	2^{-52}

Esimerkki 1.8. Etsitään kymmenjärjestelmän luvun $a = -3{,}75$ perustarkkuusesitys (eli 32-bittinen esitys). Koska etumerkki $s = (-1)^{b_s}$, etumerkkibitti on yksi, eli $b_s = 1$. Kaavan (1.4) mukaan eksponentin bias on $e_{\text{bias}} = 2^{q-1} - 1 = 2^7 - 1 = 127$. Koska $1 + f \in (1,2)$ ja $(1+f) \cdot 2^1 \in (2,4)$, varsinaisen eksponentin täytyy olla 1, eli $1 = e - e_{\text{bias}} = e - 127$. Tästä saadaan $e = 128 = 2^7 = (10\cdots0)_2$, missä nollia on seitsemän. Yhtälöstä $3{,}75 = (1+f) \cdot 2$ ratkaistaan $f = \frac{1}{2} \cdot 3{,}75 - 1 = 0{,}875 = (0,111)_2$. Täten luvun $-3{,}75$ perustarkkuusesitys 32 bitillä on

$$11000000011100000000000000000000,$$

missä käytämme samoja värejä kuin kuvassa 1.1: etumerkki, eksponentti ja mantissan murto-osa, ja olemme lisänneet mantissan murto-osaan nollia varmistaaksemme, että esityksessä on 32 bittiä.

Esimerkki 1.9. Edetään toiseen suuntaan ja selvitetään, mitä kymmenjärjestelmän lukua a vastaa 32-bittinen perustarkkuusesitys

$$00001010001100000000000000000000.$$

Etumerkkibitti (sign) on nolla ($b_s = 0$), joten etumerkki on positiivinen, sillä $s = (-1)^{b_s} = (-1)^0 = 1$. Eksponentti on $e = (00010100)_2 = 2^4 + 2^2 = 20$. Mantissan murto-osa on $f = (0.01100000000000000000000)_2 = 2^{-2} + 2^{-3} = 0{,}375$. Siispä

$$a = s \cdot (1+f) \cdot 2^{e - e_{\text{bias}}} = 1 \cdot (1 + 0{,}375) \cdot 2^{20-127} = 1{,}375 \cdot 2^{-107} \approx 8{,}47 \times 10^{-33}.$$

Esimerkki 1.10. Johdetaan joitakin taulukossa 1.1 lueteltuja ominaisuuksia perustarkkuusluvuille (32 bittiä). Kaavan (1.4) mukaan eksponentin bias on $e_{\text{bias}} = 2^{q-1} - 1 = 2^7 - 1 = 127$. Pienin mahdollinen positiivinen normaali luku on pienin positiivinen liukuluku, joka on esitettävissä muodossa (1.2). Täten meidän on määritettävä (a) mahdollisimman pieni mantissan murto-osa ja (b) mahdollisimman piene *positiivinen* eksponentti (luku on alinormaali,

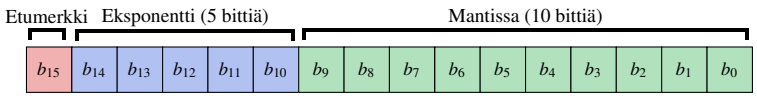

Kuva 1.2: 16-bittisten IEEE 754 -liukulukujen bittijako. Katso taulukko 1.1.

jos eksponentti on nolla). Täten

$$f = (0.\underbrace{0\cdots0}_{\text{23 kertaa}})_2 = 0 \quad \text{ja} \quad e = (\underbrace{0\cdots0}_{\text{7 kertaa}}1)_2 = 1.$$

Siispä pienin positiivinen *normaali* perustarkkuusluku on

$$a = 1\cdot(1+f)\cdot 2^{e-e_{\text{bias}}} = 1\cdot(1+0)\cdot 2^{1-127} = 2^{-126} \approx 1,18\times 10^{-38}.$$

Pienimmän positiivisen *alinormaalin* luvun saamme asettamalla eksponentin nollaksi, valitsemalla pienimmän positiivisen mantissan murto-osan $f = (0.0\cdots01)_2 = 2^{-23}$ ja käyttämällä alinormaalin luvun määrittävää kaavaa (1.5). Näin saamme

$$a = 1\cdot f\cdot 2^{-127+1} = 2^{-23}\cdot 2^{-126} = 2^{-149} \approx 1{,}40\times 10^{-45}.$$

Suurimmalla äärellisellä perustarkkuusluvulla on mahdollisimman suuri mantissan murto-osa ja eksponentti, joka on yhtä pienempi kuin suurin mahdollinen (koska suurin eksponentti tulkitaan äärettömyydeksi tai epäluvuksi). Siispä

$$f = (0.\underbrace{1\cdots1}_{\text{23 kertaa}})_2 = \sum_{k=1}^{23} 2^{-k} = 1-2^{-23} \quad \text{ja} \quad e = (\underbrace{1\cdots1}_{\text{7 kertaa}}0)_2 = \sum_{k=1}^{7} 2^{k} = 254.$$

Näin saadaan suurimmaksi äärelliseksi perustarkkuusluvuksi

$$a = 1\cdot(1+f)\cdot 2^{e-e_{\text{bias}}} = (2-2^{-23})\cdot 2^{127} \approx 3{,}40\times 10^{38}.$$

Liukuluvut Pythonissa. Pythonissa liukuluvun 32-bittisen esityksen voi tulostaa seuraavasti:

```
import numpy as np
a = -3.75
res = np.binary_repr(np.float32(a).view(np.int32), width=32)
print(res)
```

Näiden koodirivien suorittaminen tulostaa `11000000011100000000000000000000`, mikä on täsmälleen esimerkissä 1.8 laskemamme esitys. Huomaa kuitenkin, että Pythonissa termillä “float” viitataan kaksoistarkkuuden, eli 64 bitin liukulukuihin.

1.4 Pyöristys ja tarkkuus

Liukulukulaskennalla on *äärellinen tarkkuus*. Toisin sanoen kaikkia reaalilukuja ei voida esittää täsmälleen ja laskutoimitusten tulokset voivat poiketa *täsmällisen laskennan* tuloksista. Esimerkiksi tuttu kymmenjärjestelmän luku 0,1 ei ole esitettävissä täsmällisesti äärellisen monella bitillä, sillä sen binääriesitys on päättymätön:

$$(0{,}1)_{10} = (0{,}00011001100110011\ldots)_2.$$

Tästä seuraa, että tällaisia lukuja ei voida esittää täsmällisesti binäärisinä liukulukuina, vaan ne pyöristetään esitettävissä olevaan liukulukuun IEEE 754 -standardin määrittelemien pyöristys-

sääntöjen mukaisesti. Tähän törmää usein yksinkertaisissakin laskuissa. Esimerkiksi Pythonissa yksinkertainen kertolasku, jonka täsmällinen arvo on 653082380,34, ei tuotakaan täsmällistä arvoa:

```
>>> print(27869.01 * 23434)
653082380.3399999
```

Sama ilmiö havaitaan tulostettaessa 50 desimaalia esimerkiksi luvulle $a = 0{,}1$:

```
>>> a = 0.1
>>> print(f"{a:.{50}f}")
0.10000000000000000555111512312578270211815834045410
```

Tarkkuus. Liukulukujen *tarkkuus riippuu niiden kokoluokasta*. Tämä on sekä etu (liukuluvuilla voidaan esittää hyvin erikokoisia lukuja) että haitta (pyöristysvirheitä tulee väistämättä, kun operoidaan suurilla luvuilla). Esimerkiksi kaksoistarkkuusluvuilla (64 bittiä) voidaan esittää luvut välillä 1 ja 2 tarkkuudella 2^{-52}, eli kaikki luvut välillä $[1,2]$ pyöristyvät luvun 2^{-52} monikertoihin. Tarkkuus heikkenee lukujen kasvaessa: se on 2^{-51} lukujen välillä 2 ja 4 ja lopulta 2^{971} lukujen välillä 2^{1023} ja 2^{1024}. Tämän näkee havaitsee Pythonissa, joka käyttää oletuksena kaksoistarkkuuslukuja. Seuraavat laskutoimitukset palauttavat positiiviset arvot kuten niiden kuuluukin:

```
>>> b = 1.0
>>> a = 1.0 + 2.0**(-52)
>>> print(a - b)
2.220446049250313e-16
>>> b = 2.0**1023
>>> a = 2.0**1023 + 2.0**971
>>> print(a - b)
1.99584030953472e+292
```

Huomaa, että jälkimmäisessä laskussa on olennaista kirjoittaa “`2.0`” eikä “2”, jotta Python tulkitsee annetut luvut liukuluvuiksi, ei kokonaisluvuiksi (joita se käsittelee eri tavoin). Jos kuitenkin teemme luvusta a hieman pienemmän, se pyöristyykin luvuksi b ja erotuksesta tulee nolla, mitä ei tapahtuisi täsmällisessä laskennassa:

```
>>> b = 1.0
>>> a = 1.0 + 0.5*2.0**(-52)
>>> print(a - b)
0.0
>>> b = 2.0**1023
>>> a = 2.0**1023 + 0.5*2.0**971
>>> print(a - b)
0.0
```

Alivuoto ja ylivuoto. Samankaltaisia ilmiöitä esiintyy laskettaessa luvuilla, jotka ovat pienempiä kuin *alivuototaso* (pienimmät positiiviset alinormaalit luvut taulukossa 1.1), jolloin laskutoimituksen tulos pyöristyy nollaan, tai suurempia kuin *ylivuototaso* (suurimmat äärelliset luvut taulukossa 1.1), jolloin tulos pyöristyy äärettömyyteen tai aiheuttaa virheen. 64-bittisillä kaksoistarkkuusluvuilla ali- ja ylivuototasot ovat 2^{-1074} ja noin $1{,}80 \times 10^{308}$.

1.5 Numeerinen vakaus

Liukulukujen luontaiset rajoitteet on otettava huomioon numeerisia algoritmeja suunniteltaessa. Algoritmin tai numeerisen menetelmän *numeerinen vakaus* (tai *stabiilisuus*) tarkoittaa sen kykyä "sietää" numeerisia virheitä. Erityistä varovaisuutta tulee noudattaa vähennettäessä toisiaan lähellä olevia liukulukuja. Mikäli mahdollista, tätä tulee välttää.

Esimerkki 1.11. Lauseke $\sqrt{1+x}-\sqrt{x}>0$ on altis numeerisille kumoutumisille, kun x on suuri, koska tällöin sekä $\sqrt{1+x}$ että $\sqrt{x}$ ovat suuria ja hyvin lähellä toisiaan mutta kaukana lähimmistä esitettävissä olevista liukuluvuista (ks. osio 1.4). Esimerkiksi sijoitus $x=2^{60}$ lausekkeeseen $\sqrt{1+x}-\sqrt{x}$ tuottaa arvon nolla Pythonin käyttämässä 64-bittisessä kaksoistarkkuuslaskennassa. Sen sijaan yhtäpitävä muoto

$$\sqrt{1+x}-\sqrt{x}=\frac{(\sqrt{1+x}-\sqrt{x})(\sqrt{1+x}+\sqrt{x})}{\sqrt{1+x}+\sqrt{x}}=\frac{1}{\sqrt{1+x}+\sqrt{x}},$$

joka käyttää identiteettiä $(a-b)(a+b)=a^2-b^2$, tuottaa positiivisen arvon jopa sijoitukselle $x=2^{1023}$.

Esimerkki 1.12. Samanlainen ilmiö voi esiintyä laskettaessa a^2-b^2, kun a ja b ovat suuria. Laskua voidaan vakauttaa käyttämällä yhtälöä $(a-b)(a+b)=a^2-b^2$. Vaikka tämä uusi muoto sisältääkin vähennyslaskun $a-b$, vähennettävät luvut ovat pienempiä kuin alkuperäisessä lausekkesssa a^2-b^2 kun $a,b>1$. Pyöristysvirhettäkin tulee näin vähemmän.

Seuraava koodinpätkä Pythonia havainnollistaa esimerkkiä 1.12:

```
>>> a = 2.0**50
>>> b = a - 1.0
>>> print(a**2 - b**2)
2251799813685248.0
>>> print((a - b)*(a + b))
2251799813685247.0
```

Kun $a=2^{50}$ ja $b=2^{50}-1$, lausekkeen a^2-b^2 täsmällinen arvo on 2251799813685247, jonka saimme liukuluvuilla käyttäen numeerisesti vakaampaa muotoa $(a-b)(a+b)$.

2 Virhe

Tämä osio käsittelee numeeristen virheiden luonnetta ja esitystapoja laskennassa.

2.1 Pyöristys- ja katkaisuvirhe

Numeeriset virheet johtuvat sekä äärellistarkkuisen liukulukulaskennan luontaisesta epätarkkuudesta että matemaattisten approksimaatioiden käytöstä.

Määritelmä 2.1 (Pyöristysvirhe)**.** *Pyöristysvirhe* on virhe, joka aiheutuu äärellistarkkuisen laskennane (esim. liukulukulaskennan) käytöstä.

Esimerkki 2.2. Osioissa 1.4 ja 1.5 käsitellyt pyöristys- ja tarkkuusongelmat ovat esimerkkejä pyöristysvirheistä.

Määritelmä 2.3 (Katkaisuvirhe)**.** *Katkaisuvirhe* on virhe, joka aiheutuu matemaattisen prosessin numeerisesta approksimaatiosta.

Esimerkki 2.4. Eksponenttivakion $e \approx 2.718$ sarjaesityksen

$$e = \sum_{k=0}^{\infty} \frac{1}{k!},$$

pitäisi olla tuttu matematiikan peruskursseilta. Tässä esityksessä $n! = 1 \cdot 2 \cdots (n-1) \cdot n$ on kokonaisluvun n kertoma, jolle on määritelty $0! = 1$. Vakion e approksimoimiseksi voidaan tämä sarja katkaista termin n kohdalla (tässä $n \in \{0,1,2,3\}$):

$$\begin{aligned}
e \approx e_0 &= \sum_{k=0}^{0} \frac{1}{k!} = \frac{1}{0!} = \frac{1}{1} = 1, \\
e \approx e_1 &= \sum_{k=0}^{1} \frac{1}{k!} = \frac{1}{0!} + \frac{1}{1!} = \frac{1}{1} + \frac{1}{1} = 2, \\
e \approx e_2 &= \sum_{k=0}^{2} \frac{1}{k!} = \frac{1}{0!} + \frac{1}{1!} + \frac{1}{2!} = \frac{1}{1} + \frac{1}{1} + \frac{1}{2} = 2,5, \\
e \approx e_3 &= \sum_{k=0}^{3} \frac{1}{k!} = \frac{1}{0!} + \frac{1}{1!} + \frac{1}{2!} + \frac{1}{3!} = \frac{1}{1} + \frac{1}{1} + \frac{1}{2} + \frac{1}{2 \cdot 3} = 2,666\ldots
\end{aligned}$$

Jokainen erotuksista $e - e_n$ ($n \in \{0,1,2,3\}$) on katkaisuvirhe.

Katkaisuvirheellä ei kuitenkaan viitata ainoastaan ilmiselvään katkaisuun kuten esimerkissä 2.4, vaan yleensäkin numeerisiin approksimaatioihin.

Esimerkki 2.5. Palautetaan mieleen analyysistä, että funktion $f\colon \mathbb{R} \to \mathbb{R}$ derivaatta pisteessä $x_0 \in \mathbb{R}$ määritellään erotusosamäärän $[f(x_0+h) - f(x_0)]/h$ raja-arvona

$$f'(x_0) = \lim_{h \to 0} \frac{f(x_0+h) - f(x_0)}{h}.$$

Derivaattaa voi siis approksimoida laskemalla erotusosamäärän arvon jollakin pienellä luvulla h. Esimerkiksi funktion $f(x) = x^2$ derivaatta kohdassa $x_0 = 1$ voidaan approksimoida

seuraavasti käyttäen lukua $h = 1/10$:

$$f'(x_0) \approx \frac{f(x_0+h) - f(x_0)}{h} = \frac{(1+1/10)^2 - 1^2}{1/10} = \frac{21}{10}.$$

Koska $f'(x) = 2x$, todellinen derivaatta on $f'(x_0) = f'(1) = 2$. Virhe

$$f'(x_0) - \frac{21}{10} = 2 - \frac{21}{10} = -\frac{1}{10}$$

on katkaisuvirhe, vaikka mitään sarjaa ei katkaistakaan. Kuitenkin tässäkin tapauksessa voidaan erotusosamäärään perustuvaa approksimaatiota pitää eräänlaisena katkaisuna, sillä sitä käyttäen "katkaistaan raja-arvoprosessi $h \to 0$" valitsemalla jokin pieni h raja-arvon itsensä käyttämisen sijaan.

2.2 Approksimaation tarkkuus

Määritelmä 2.6 (Approksimaation tarkkuus)**.** Olkoon $\tilde{x}$ approksimaatio luvulle x. Tällöin $\tilde{x}$ approksimoi lukua x *d:n desimaalin tarkkuudella*, jos

$$|x - \tilde{x}| < \frac{1}{2}10^{-d}.$$

Jos haluamme, että $\tilde{x}$ approksimoi lukua x kokonaislukujen tarkkuudella (eli nollan desimaalin tarkkuudella), täytyy päteä $|x - \tilde{x} < |0{,}5$. Tämä tarkoittaa, että lukujen x ja $\tilde{x}$ välinen etäisyys on nolla lähimpään kokonaislukuun pyöristettäessä. Tämä ei kuitenkaan tarkoita sitä, että molemmat luvut pyöristyvät samaan kokonaislukuun. Esimerkiksi jos $x = 0{,}51$ ja $\tilde{x} = 0{,}49$, niin $|0{,}51 - 0{,}49| = 0{,}02 < 0{,}5$, mutta $x \approx 1$ ja $\tilde{x} \approx 0$. Huomaa myös, että jos $\tilde{x}$ approksimoi lukua xd:n desimaalin tarkkuudella, se approksimoi sitä myös $(d-1)$:n desimaalin tarkkuudella ja niin edelleen. Olennaista on toki suurin mahdollinen desimaalitarkkuus, eli suurin d.

Esimerkki 2.7. Luku 3,14 approksimoi piitä (π) kahden desimaalin tarkkuudella, sillä

$$|\pi - 3{,}14| = 0{,}00159\ldots = 0{,}159\ldots \cdot 10^{-2} < 0{,}5 \cdot 10^{-2}.$$

Luku 3,14 approksimoi piitä myös yhden desimaalin tarkkuudella, sillä

$$|\pi - 3{,}14| = 0{,}00159\ldots = 0{,}0159\ldots \cdot 10^{-1} < 0{,}5 \cdot 10^{-1}.$$

Luku 3,14 *ei* kuitenkaan approksimoi piitä kolmen desimaalin tarkkuudella, sillä

$$|\pi - 3{,}14| = 0{,}00159\ldots = 1{,}59\ldots \cdot 10^{-3} > 0{,}5 \cdot 10^{-3}.$$

2.3 Absoluuttinen ja suhteellinen virhe

Virhe voidaan mitata joko absoluuttisena tai suhteellisena.

Määritelmä 2.8 (Absoluuttinen ja suhteellinen virhe)**.** Olkoon $\tilde{x}$ luvun x approksimaatio. Tällöin

$$\textit{absoluuttinen virhe} = |x - \tilde{x}| \quad \text{ja} \quad \textit{suhteellinen virhe} = \left|\frac{x - \tilde{x}}{x}\right|.$$

Absoluuttinen virhe on luvun x ja sen approksimaation $\tilde{x}$ erotuksen itseisarvo. Suhteellinen virhe mittaa virhettä *suhteessa luvun x suuruuteen*. Huomaa, että suhteellista virhettä laskettaessa

jaetaan approksimoitavan luvun (eli x) itseisarvolla, ei approksimaation (eli $\tilde{x}$) itseisarvolla. Suhteellinen virhe ilmaistaan usein prosentteina.

Esimerkki 2.9. Jos lukua $x = \pi$ approksimoidaan kahden desimaalin tarkkuudella kuten esimerkissä 2.7 (vaikkapa $\tilde{x} = 3,14$), niin approksimaation absoluuttinen virhe on

$$|\pi - 3{,}14| = 0{,}00159\ldots$$

ja suhteellinen virhe

$$\left|\frac{\pi - 3.14}{\pi}\right| = 0.000507\ldots = 0.0507\ldots\,\%.$$

Suhteellinen virhe on usein näistä virheistä hyödyllisempi.

Esimerkki 2.10. Osiossa 1.4 havaitsimme, että Pythonin 64-bittisessä kaksoistarkkuuslaskennassa luku

$$x = 2^{1023} + 0{,}5 \cdot 2^{971} \quad \text{pyöristyy lukuun} \quad \tilde{x} = 2^{1023}.$$

Täten absoluuttinen pyöristysvirhe on

$$|x - \tilde{x}| = |2^{1023} + 0{,}5 \cdot 2^{971} - 2^{1023}| = 0{,}5 \cdot 2^{971} \approx 9{,}9792 \cdot 10^{291}.$$

Tämä verrattain suuri virhe on kuitenkin hyvin pieni suhteessa luvun x kokoon, sillä suhteellinen pyöristysvirhe on mitättömän pieni:

$$\left|\frac{x - \tilde{x}}{x}\right| = \left|\frac{2^{1023} + 0.5 \cdot 2^{971} - 2^{1023}}{2^{1023} + 0.5 \cdot 2^{971}}\right| \approx 1.11 \cdot 10^{-16} = 1.11 \cdot 10^{-14}\,\%.$$

2.4 Iso-O-notaatio

Kätevää iso-O-notaatiota käytetään approksimaatioiden asymptoottisen, eli raja-arvokäyttäytymisen, ilmaisemiseen.

Määritelmä 2.11 (Iso-O-notaatio funktioille)**.** Olkoon $x_0 \in (a,b)$ ja olkoot $f, g\colon (a,b) \to \mathbb{R}$ funktioita. Kirjoitamme

$$f(x) = O(g(x)) \quad \text{kun} \quad x \to x_0,$$

jos on olemassa $C \geq 0$ ja $\delta > 0$ siten, että $|f(x)| \leq Cg(x)$ kaikilla $x \in (x_0 - \delta, x_0 + \delta)$.

Palautetaan mieliin, että jono $(a_n)_{n=1}^{\infty} = (a_1, a_2, \ldots)$ on reaalilukujen järjestetty kokoelma.

Määritelmä 2.12 (Iso-O-notaatio jonoille)**.** Olkoot $(a_n)_{n=1}^{\infty}$ ja $(b_n)_{n=1}^{\infty}$ kaksi jonoa. Kirjoitamme

$$a_n = O(b_n) \quad \text{kun} \quad n \to \infty,$$

jos on olemassa $C \geq 0$ siten, että $|a_n| \leq Cb_n$ kaikilla $n \geq 1$.

Merkintä $O(g(x))$ luetaan esimerkiksi "suuruusluokkaa $g(x)$", "iso oo $g(x)$" tai "oo $g(x)$". Raja-arvo (joko $x \to x_0$ tai $n \to \infty$) jätetään usein merkitsemättä, mikäli se selviää asiayhteydestä.

Tällä kurssilla käytämme iso-O-notaatiota kuvaamaan numeerisen approksimaation käyttäytymistä. Notaatio on kuitenkin hyvin monipuolinen ja sitä käytetään myös algoritmien aika- ja tilavaativuuden kuvaamiseen.[1] Jos $g(x) \to 0$ kun $x \to x_0$ (tai $b_n \to 0$ kun $n \to \infty$), väite $f(x) = O(g(x))$ kertoo, kuinka nopeasti $f(x)$ lähestyy nollaa, kun $x \to x_0$. Tarkemmin sanottuna tämä tarkoittaa, että $f(x)$ lähestyy nollaa *vähintään* yhtä nopeasti kuin $g(x)$. Tällaisessa tilanteessa pyritään löytämään g, joka lähestyy nollaa mahdollisimman nopeasti siten, että $f(x) = O(g(x))$ on totta.

Esimerkki 2.13. Määritetään funktion $f(x) = x^2 + x^3$ suuruusluokka, kun $x \to 0$ (eli $x_0 = 0$). Määritelmän 2.11 mukaan meidän tulee löytää funktio g ja vakiot $C \geq 0$ ja $\delta > 0$ siten, että $|f(x)| \leq Cg(x)$ kaikille $x \in (-\delta, \delta)$. Valitaan $\delta = 1$ (mikä tahansa muukin $\delta \leq 1$ toimisi). Tällöin kaikilla $x \in (-1, 1)$ pätee

$$|f(x)| = x^2 + |x|^3 \leq x^2 + |x|^2 = 2x^2,$$

missä käytimme epäyhtälöä $|a|^n \leq |a|^m$, joka pätee kaikilla $|a| \leq 1$ ja $n \geq m$. Voimme siis valita $C = 2$ ja $g(x) = x^2$, mikä tarkoittaa, että $f(x)$ on suuruusluokkaa x^2 [$f(x) = O(x^2)$], kun $x \to 0$. Huomaa kuitenkin, että myös

$$|f(x)| = x^2 + |x|^3 \leq x^2 + |x|^2 \leq |x| + |x| = 2|x|,$$

joten olisimme voineet valita $g(x) = |x|$, jolloin $f(x) = O(|x|)$.

Esimerkissä 2.13 valinta $g(x) = x^2$ on parempi kuin $g(x) = |x|$, koska se kuvaa paremmin funktion f käyttäytymistä pisteen $x_0 = 0$ ympäristössä. Nimittäin, kun $x \to 0$,

$$f(x) = O(x^2) \quad \text{ja} \quad f(x) = O(|x|)$$

mutta

$$x^2 = O(|x|) \quad \text{ja} \quad |x| \neq O(x^2),$$

missä $|x| \neq O(x^2)$ tarkoittaa, että $|x|$ ei ole suuruusluokkaa x^2 kun $x \to 0$. Sanallisesti ilmaistuna nämä neljä iso-O-väitettä ovat

$f(x)$ lähestyy nollaa vähintään yhtä nopeasti kuin x^2
ja $f(x)$ lähestyy nollaa vähintään yhtä nopeasti kuin $|x|$

mutta

x^2 lähestyy nollaa vähintään yhtä nopeasti kuin $|x|$
ja $|x|$ lähestyy nollaa *hitaammin* kuin x^2.

Kuva 2.1 havainnollistaa iso-O-notaatiota polynomeille pisteen $x_0 = 0$ läheisyydessä.

Huomautus 2.14. Notaation $f(x) = O(g(x))$ kanssa on syytä olla tarkkana. Koska yhtäsuuruus ("=") on muualla matematiikassa vaihdannainen (eli $a = b$ on sama kuin $b = a$), $f(x) = O(g(x))$ antaa ymmärtää, että voitaisiin kirjoittaa $O(g(x)) = f(x)$, mitä on kuitenkin vaikea tulkita mielekkäästi. Täsmällisesti ilmaistuna $f(x) = O(g(x))$ kun $x \to x_0$ tarkoittaa, että *f kuuluu niiden funktioiden joukkoon, jotka ovat ylhäältä rajoitettuja jonkin vakion ja funktion g tulolla pisteen x_0 ympäristössä.* Merkintä on siis tulkittava vain kätevänä lyhennyksenä.

[1] *Data Structures and Algorithms* (BM40A1500).

Toisinaan käytetään merkintätapaa

$$f(x) = g(x) + O(r(x)) \quad \text{kun} \quad x \to x_0.$$

Tällä tarkoitetaan sitä, että funktion f on summa funktiosta g ja sellaisesta funktiosta, joka on suuruusluokkaa $r(x)$ kun $x \to x_0$. Esimerkiksi käyköön funktio $f(x) = 3 + x^2 + x^3$, jonka voimme tätä merkintätapaa käyttäen kirjoittaa muodossa

$$f(x) = 3 + O(x^2) \quad \text{kun} \quad x \to 0,$$

sillä esimerkissä 2.13 päättelimme, että $x^2 + x^3 = O(x^2)$ kun $x \to 0$.

2.5 Iso-O-notaation ominaisuuksia

Seuraava lause osoittaa, että iso-O-notaatio on *transitiivinen*. Käytännössä lauseessa ei ole kyse muusta kuin siitä perustuloksesta, että $a \le c$ jos $a \le b$ ja $b \le c$.

Lause 2.15. *Jos $f(x) = O(g_1(x))$ ja $g_1(x) = O(g_2(x))$ kun $x \to x_0$, niin*

$$f(x) = O(g_2(x)) \quad \textit{kun} \quad x \to x_0.$$

Todistus. Määritelmän 2.11 nojalla on olemassa $C_1, C_2 \ge 0$ ja $\delta_1, \delta_2 > 0$ siten, että

$$|f(x)| \le C_1 g_1(x) \quad \text{kaikilla} \quad x \in (x_0 - \delta_1, x_0 + \delta_1)$$

ja

$$|g_1(x)| \le C_2 g_2(x) \quad \text{kaikilla} \quad x \in (x_0 - \delta_2, x_0 + \delta_2).$$

Nämä kaksi epäyhtälöä pätevät samanaikaisesti, kun $x \in (x_0 - \delta, x_0 + \delta)$, missä $\delta = \min\{\delta_1, \delta_2\}$. Täten kaikilla $x \in (x_0 - \delta, x_0 + \delta)$ pätee

$$|f(x)| \le C_1 g_1(x) \le C_1 |g_1(x)| \le C_1 \cdot C_2 g_2(x),$$

joten voimme asettaa $g = g_2$, $C = C_1 \cdot C_2$ ja $\delta = \min\{\delta_1, \delta_2\}$ määritelmässä 2.11. □

Seuraava lause osoittaa, ettei määritelmän 2.11 vakio C vaikuta suuruusluokkaan.

Lause 2.16. *Jos $f(x) = O(g_1(x))$ kun $x \to x_0$ ja $g_1(x) = C_{12} g_2(x)$ jollakin $C_{12} \ge 0$, niin $f(x) = O(g_2(x))$ kun $x \to x_0$.*

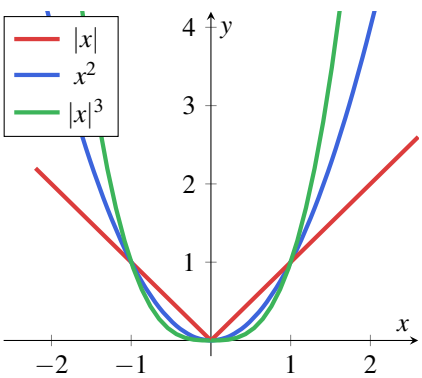

Kuva 2.1: Funktiot $|x|$, x^2 ja $|x|^3$ pisteen $x_0 = 0$ läheisyydessä. Koska $|x|$ on x^2:n yläpuolella kun $x \in (-1, 1)$ ja x^2 on $|x|^3$:n yläpuolella, kuva havainnollistaa, että $x^2 = O(|x|)$ ja $|x|^3 = O(x^2)$, kun $x \to 0$. *Huomaa, että kuvaajien järjestys muuttuu, kun* $|x| > 1$. Jos tarkasteltaisiin pistettä x_0, jolle $|x_0| > 1$ (esim. $x_0 = 2$), iso-O-suhteet pitäisi kääntää: $|x| = O(x^2)$ ja $x^2 = O(|x|^3)$, kun $x \to 2$. Huomaa, että käytämme itseisarvoja $|x|$ ja $|x|^3$, sillä x ja x^3 ovat negatiivisia kun $x < 0$, mutta $f(x) = O(g(x))$ on väite ylärajasta itseisarvolle $|f(x)| \ge 0$, ei funktiolle $f(x)$.

Todistus. Määritelmän 2.11 nojalla on olemassa $C_1 \geq 0$ ja $\delta > 0$ siten, että $|f(x)| \leq C_1 g_1(x)$ kaikilla $x \in (x_0 - \delta, x_0 + \delta)$. Oletuksesta $g_1(x) = C_{12} g_2(x)$ seuraa, että kaikilla $x \in (x_0 - \delta, x_0 + \delta)$ pätee

$$|f(x)| \leq C_1 g_1(x) = C_1 \cdot C_{12} g_2(x),$$

joten voimme valita $C = C_1 \cdot C_{12}$ ja $g = g_2$ määritelmässä 2.11. □

Lauseilla 2.15 ja 2.16 on luonnolliset vastineet jonoille (Määritelmä 2.12). Seuraava esimerkki havainnollistaa varsin tyypillistä iso-O-notaation käyttöä numeerisessa approksimaatiossa, jossa ollaan yleensä kiinnostuneita virheen käyttäytymisestä jonkin *diskretointiparametrin* h lähestyessä nollaa.

Esimerkki 2.17. Esimerkissä 2.5 approksimoimme funktion $f(x) = x^2$ derivaattaa kohdassa $x_0 = 1$ käyttäen erotusosamäärää

$$q(h) = \frac{f(x_0 + h) - f(x_0)}{h}.$$

Lasketaan nyt tämän approksimaation absoluuttisen virheen suuruusluokka kun $h \to 0$. Koska $f'(x) = 2x$ ja $x_0 = 1$, absoluuttinen virhe $\varepsilon(h)$ on

$$\begin{aligned}\varepsilon(h) = |f'(x_0) - q(h)| = \left| f'(x_0) - \frac{f(x_0 + h) - f(x_0)}{h} \right| &= \left| 2 - \frac{(1+h)^2 - 1}{h} \right| \\ &= \left| 2 - \frac{2h + h^2}{h} \right| \\ &= |2 - (2 + h)| \\ &= |h|,\end{aligned}$$

missä käytimme identiteettiä $(a+b)^2 = a^2 + 2ab + b^2$. Täten $\varepsilon(h) = O(|h|)$, mikä tarkoittaa sitä, että erotusosamäärän avulla muodostetun approksimaation $f'(x_0) \approx q(h)$ virhe on suuruusluokaltaan *lineaarinen* kun $h \to 0$. Huomaa, että suhteellinen virhe $\rho(h)$ on samaa suuruusluokkaa, sillä

$$\rho(h) = \left| \frac{f'(x_0) - q(h)}{f'(x_0)} \right| = \frac{1}{|f'(x_0)|} \varepsilon(h),$$

missä $1/|f'(x_0)| = 1/2 > 0$. Lauseesta 2.16 seuraa nyt, että $\rho(h) = O(|h|)$.

Keskitymme pääosin virheisiin $\varepsilon(h)$, joilla on *polynominen suuruusluokka* kun $h \to 0$. Jos funktio on polynomi, pienimmän asteluvun termin kerroin määrää suuruusluokan.

Lause 2.18. *Jos* $\varepsilon(h) = a_n h^n + a_{n+1} h^{n+1} + \cdots + a_{n+m} h^{n+m}$, *missä* $n, m \in \mathbb{N} \cup \{0\}$ *ja* $a_n, \ldots, a_{n+m} \in \mathbb{R}$, *niin*

$$\varepsilon(h) = O(|h|^n) \quad \textit{kun} \quad h \to 0.$$

Todistus. Huomaa, että $x_0 = 0$. Valitaan $\delta = 1$. Kun $h \in (x_0 - \delta, x_0 + \delta) = (-1, 1)$,

$$|\varepsilon(h)| = |a_n h^n + a_{n+1} h^{n+1} + \cdots + a_{n+m} h^{n+m}| \leq |a_n||h|^n + \cdots + |a_{n+m}||h|^{n+m},$$

missä käytimme kolmioepäyhtälöä $|a + b| \leq |a| + |b|$. Koska $|h|^{n+m} \leq |h|^n$ kun $h \in (-1, 1)$, saamme epäyhtälön

$$|\varepsilon(h)| \leq (|a_n| + \cdots + |a_{n+m}|)|h|^n,$$

missä vakio $C = |a_n| + \cdots + |a_{n+m}|$ on epänegatiivinen (eli ≥ 0). Määritelmästä 2.11 seuraa nyt, että $\varepsilon(h) = O(|h|^n)$. □

Emme ole vielä käsitelleet määritelmää 2.12, eli iso-O-notaatiota jonoille. Tällä kurssilla käytämme tätä notaatiota kuvaamaan numeeristen menetelmien virhettä kun n, *diskretisointipisteiden* tai *aika-askelten* lukumäärä, kasvaa.

Esimerkki 2.19. Palataan esimerkkiin 2.4, jossa approksimoimme eksponenttivakiota $e \approx 2.718$ katkaistulla sarjakehitelmällä $e = \sum_{k=0}^{\infty} 1/k!$ n:

$$e \approx e_n = \sum_{k=0}^{n} \frac{1}{k!}.$$

Määritetään tämän approksimaation suuruusluokka (eli virheen $\varepsilon_n = |e - e_n|$ suuruusluokka), kun $n \to \infty$. Saamme

$$\varepsilon_n = |e - e_n| = \left| \sum_{k=0}^{\infty} \frac{1}{k!} - \sum_{k=0}^{n} \frac{1}{k!} \right| = \left| \sum_{k=n+1}^{\infty} \frac{1}{k!} \right| = \sum_{k=n+1}^{\infty} \frac{1}{k!}. \tag{2.1}$$

Mille tahansa $m \geq 1$ voimme kirjoittaa

$$(n+m)! = 1 \cdot 2 \cdots (n+1) \cdot (n+2) \cdots (n+m) = (n+1)! \cdot (n+2) \cdots (n+m), \tag{2.2}$$

missä tulo $(n+2) \cdots (n+m)$ tulkitaan ykköseksi, jos $m = 1$. Sijoittamalla yhtälön (2.2) yhtälöön (2.1) saamme

$$\varepsilon_n = \sum_{k=n+1}^{\infty} \frac{1}{k!} = \sum_{m=1}^{\infty} \frac{1}{(n+m)!} = \frac{1}{(n+1)!} \left(1 + \sum_{m=2}^{\infty} \frac{1}{(n+2) \cdots (n+m)} \right).$$

Viimeinen sarja suppenee (ohitamme todistuksen), mistä seuraa, että voimme valita

$$a_n = \varepsilon_n, \quad b_n = \frac{1}{(n+1)!} \quad \text{ja} \quad C = 1 + \sum_{m=2}^{\infty} \frac{1}{(n+2) \cdots (n+m)}$$

määritelmässä 2.12. Täten

$$\varepsilon_n = |e - e_n| = O\left(\frac{1}{(n+1)!} \right).$$

3 Numeeristen menetelmien rakentaminen

Tämä osio käsittelee numeeristen menetelmien rakentamisen ja implementoinni peruskäsitteistöä ja -työkaluja.

3.1 Taylorin polynomi

Monet numeeriset menetelmät hyödyntävät sileän (eli riittävän monta kertaa derivoituvan) funktion Taylorin polynomeja.

Määritelmä 3.1 (Taylorin polynomit)**.** Olkoon $f\colon (a,b) \to \mathbb{R}$ funktio, joka on n kertaa derivoituva pisteessä $x_0 \in (a,b)$. Funktion f *kertaluvun n Taylorin polynomi* pisteessä x_0 on

$$P_n(x) = f(x_0) + f'(x_0)(x-x_0) + \frac{f''(x_0)}{2!}(x-x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}(x-x_0)^n. \tag{3.1}$$

Palautetaan mieliin, että $f^{(n)}(x)$ tarkoittaa funktion f kertaluvun n derivaattaa pisteessä x, eli

$$f^{(n)}(x) = \frac{\mathrm{d}^n}{\mathrm{d}x^n} f(x).$$

Lisäksi nollas derivaatta on funktio itse: $f^{(0)}(x) = f(x)$. Taylorin polynomit voidaan siis kirjoittaa käyttäen summamerkintää:

$$P_n(x) = \sum_{k=0}^{n} \frac{f^{(k)}(x_0)}{k!}(x-x_0)^k.$$

Esimerkki 3.2. Muodostetaan kertalukujen $n \in \{1,3,5\}$ Taylorin polynomit funktiolle $f(x) = \sin(x)$ pisteessä $x_0 = 0$. Tarvitsemme tätä varten funktion f derivaattojen arvot viidenteen kertalukuun saakka pisteessä $x_0 = 0$. Muistamalla, että funktion $\sin(x)$ derivaatta

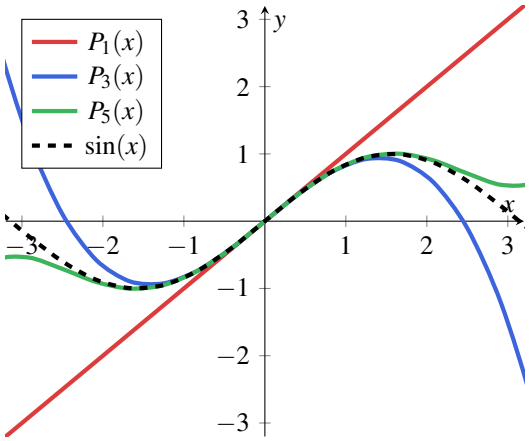

Kuva 3.1: Funktio $f(x) = \sin(x)$ sekä sen Taylorin polynomit P_1, P_3 ja P_5, joiden kertaluvut ovat $n \in \{1,3,5\}$. Taylorin polynomit määritellään yhtälössä (3.1) ja lasketaan sinifunktiolle esimerkissä 3.2. Kuvasta havaitsemme, että Taylorin polynomin kertaluvun kasvattaminen parantaa approksimaation $f(x) \approx P_n(x)$ tarkkuutta. Polynomi P_1 on kelvollinen approksimaatio kun $|x| < 1$, kun taas P_5 toimii hyvin kun $|x| < 2.5$.

on $\cos(x)$ ja funktion $\cos(x)$ derivaatta on $-\sin(x)$, saamme

$$\begin{aligned}
f^{(0)}(x) &= f(x) = \sin(x) &&\Longrightarrow && f^{(0)}(0) = 0,\\
f'(x) &= \cos(x) &&\Longrightarrow && f'(0) = 1,\\
f''(x) &= -\sin(x) &&\Longrightarrow && f''(0) = 0,\\
f^{(3)}(x) &= -\cos(x) &&\Longrightarrow && f^{(3)}(0) = -1,\\
f^{(4)}(x) &= \sin(x) &&\Longrightarrow && f^{(4)}(0) = 0,\\
f^{(5)}(x) &= \cos(x) &&\Longrightarrow && f^{(5)}(0) = 1.
\end{aligned}$$

Sijoittamalla nämä arvot kaavaan (3.1) saamme Taylorin polynomit

$$\begin{aligned}
P_1(x) &= f(x_0) + f'(x_0)(x - x_0) = f(0) + f'(0)x = x,\\
P_3(x) &= f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + \frac{f^{(3)}(0)}{3!}x^3 = x - \frac{1}{6}x^3,\\
P_5(x) &= f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + \frac{f^{(3)}(0)}{3!}x^3 + \frac{f^{(4)}(0)}{4!}x^4 + \frac{f^{(5}(0)}{5!}x^5\\
&= x - \frac{1}{6}x^3 + \frac{1}{120}x^5.
\end{aligned}$$

Näet nämä polynomit kuvassa 3.1.

Esimerkki 3.2 ja kuva 3.1 viittaavat siihen, että Taylorin polynomin kertaluvun tuottaa paremman approksimaation funktiolle f. Matemaattisesta analyysistä tuttu Taylorin lause selittää tämän havainnon.

Lause 3.3 (Taylorin lause)**.** *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja $n+1$ kertaa derivoituva välillä (a,b). Olkoon $x_0 \in (a,b)$. Tällöin jokaisella $x \in [a,b]$ pätee*

$$f(x) - P_n(x) = R_{n+1}(x),$$

missä jäännöstermi R_{n+1} *on*

$$R_{n+1}(x) = \frac{f^{(n+1)}(c_x)}{(n+1)!}(x - x_0)^{n+1}$$

jollakin pisteellä c_x, joka on pisteiden x_0 ja x välillä.

Luvun c_x arvo Taylorin lauseessa riippuu pisteestä x ja kertaluvusta n. Iso-O-notaatiotalla (osio 2.4) voimme kirjoittaa Taylorin lauseen yksinkertaisemmin, mikäli funktion f kertaluvun $(n+1)$ derivaatta on rajoitettu.

Korollaari 3.4. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja $n+1$ kertaa derivoituva välillä (a,b). Olkoon $x_0 \in (a,b)$. Jos on olemassa vakio $L \geq 0$, jolla $|f^{(n+1)}(x)| \leq L$ kaikilla $x \in (a,b)$, niin*

$$R_{n+1}(x) \leq \frac{L}{(n+1)!}|x - x_0|^{n+1} = O(|x - x_0|^{n+1}) \quad \text{as} \quad x \to x_0. \tag{3.2}$$

Todistus. Taylorin lause ja oletus $|f^{(n+1)}(x)| \leq L$ kaikilla $x \in (a,b)$ antavat

$$|R_{n+1}(x)| = \left|\frac{f^{(n+1)}(c_x)}{(n+1)!}(x - x_0)^{n+1}\right| = \frac{|f^{(n+1)}(c_x)|}{(n+1)!}|x - x_0|^{n+1} \leq \frac{L}{(n+1)!}|x - x_0|^{n+1}$$

kaikilla $x \in (a,b)$. Koska $x_0 \in (a,b)$, on olemassa $\delta > 0$ siten, että $(x_0 - \delta, x + \delta) \subset (a,b)$, jolloin yllä oleva epäyhtälö pätee kaikilla $x \in (x_0 - \delta, x + \delta)$. Täten voimme valita $f(x) = R_{n+1}(x)$, $g(x) = |x - x_0|^{n+1}$ ja $C = L/(n+1)!$ määritelmässä 2.11. Tämä todistaa väitteen (3.2). □

Valitsemalla $x = x_0 + h$ (jolloin $x - x_0 = h$) voidaan (3.2) kirjoittaa muotoon

$$R_{n+1}(x_0 + h) = O(|h|^{n+1}) \quad \text{kun} \quad h \to 0,$$

mikä korostaa jäännöstermin pienenmistä tarkasteltaessa pisteen x_0 läheisyydessä olevia pisteitä (eli tapausta $h \to 0$).

Esimerkki 3.5. On tärkeää ymmärtää, että jäännöstermi R_{n+1} on pieni vain pisteen x_0 läheisyydessä. Tarkastellaan esimerkiksi kertaluvun $n = 2$ Taylorin polynomia pisteessä $x_0 = 1$ funktiolle $f(x) = x^4 + 2x^2$. Koska f on määritelty koko reaaliakselilla $\mathbb{R}$, voimme valita minkä tahansa välin, joka sisältää x_0:n, ja käyttää sitä korollaarissa 3.4. Valitaan $[a,b] = [0,2]$. Tällöin (koska $n + 1 = 3$)

$$|f^{(3)}(x)| = \left| \frac{\mathrm{d}^2}{\mathrm{d}x^2}(4x^3 + 4x) \right| = \left| \frac{\mathrm{d}}{\mathrm{d}x}(12x^2 + 4) \right| = |24x| \leq 48 \quad \text{kaikilla} \quad x \in [0,2].$$

Siksi voimme soveltaa korollaaria 3.4 arvoilla $n = 2$, $x_0 = 1$ ja $L = 48$ ja päätellä, että

$$f(x) - P_2(x) = R_3(x) = O(|x - 1|^3) \quad \text{kun} \quad x \to 1,$$

mistä seuraa, että kertaluvun kaksi Taylorin polynomin P_2 virhe on suuruusluokaltaan *kuutiollinen* kun $x \to x_0 = 1$. Tilanne muuttuu kuitenkin täysin, kun liikutaan poispäin pisteestä $x_0 = 1$. Koska $n = 2$, nähdään Taylorin polynomin määritelmästä (3.1), että P_2 on *toisen* asteen polynomi, eli $P_2(x) = \alpha x^2 + \beta x + \gamma$ joillakin $\alpha, \beta, \gamma \in \mathbb{R}$. Koska $f(x) = x^4 + 2x^2$, tästä seuraa, että

$$f(x) - P_2(x) = x^4 + (2 - \alpha)x^2 - \beta x - \gamma,$$

joka on *neljännen* asteen polynomi, korkeimman asteen termin kerroin on positiivinen (eli asteen 4 termin kerroin on 1). Tästä seuraa, että

$$f(x) - P_2(x) \to \infty \quad \text{kun} \quad x \to \infty \text{ tai } x \to -\infty.$$

Näin ollen virheestä voidaan tehdä mielivaltaisen suuri valitsemalla x, joka on riittävän kaukana pisteestä $x_0 = 1$.

3.2 Linearisointi

Taylorin polynomi (Määritelmä 3.1) tapauksessa $n = 1$ on eräs tärkeimmistä työkaluista numeeristen menetelmien kehityksessä.

Määritelmä 3.6 (Lineaarinen approksimaatio)**.** Olkoon $f\colon (a,b) \to \mathbb{R}$ derivoituva pisteessä $x_0 \in (a,b)$. Funktion f *lineaarinen approksimaatio* pisteessä x_0 on lineaarinen polynomi

$$L(x) = P_1(x) = f(x_0) + f'(x_0)(x - x_0). \tag{3.3}$$

Lineaarisen approksimaation L laskemista ja käyttämistä funktion f approksimointiin kutsutaan *linearisoinniksi*.

Lineaarinen approksimaatio on korkeamman kertaluvun Taylorin polynomeja helpompi laskea ja käyttää, sillä sen laskemiseen tarvitaan ainoastaan $f(x_0)$ ja $f'(x_0)$. Sovelluksissa korkeamman

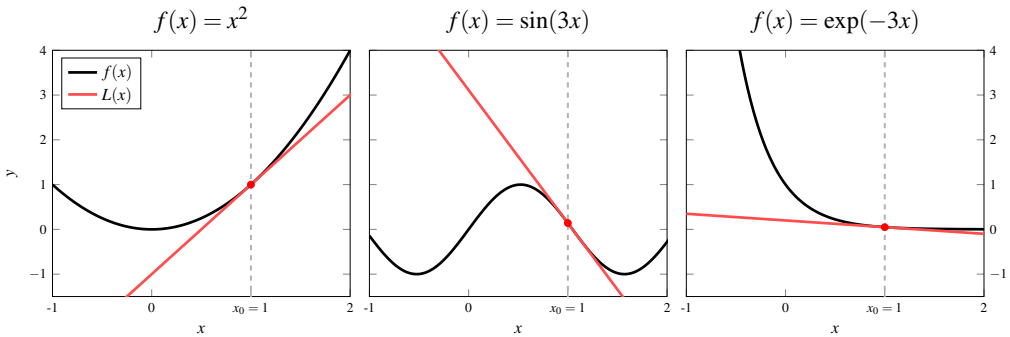

Kuva 3.2: Lineaariset approksimaatiot (punainen) kolmelle funktiolle $f(x) = x^2$, $f(x) = \sin(3x)$ ja $f(x) = \exp(-3x)$ pisteessä $x_0 = 1$. Havaitaan, että lineaariset approksimaatiot ovat *tangenttisuoria* pisteessä $x_0 = 1$. Toisin sanoen lineaarinen approksimaatio on suora, jonka kulmakerroin on funktion f derivaatta pisteessä x_0.

kertaluvun derivaattojen laskeminen on usein hankalaa tai jopa mahdotonta. Lisäksi linearisointi yleistyy helposti useamman muuttujan funktioihin $f\colon \mathbb{R}^d \to \mathbb{R}$ *gradientin* avulla ja tuottaa numeerisia menetelmiä, joiden implementointi on suoraviivaista ja joiden toimintaa on helppo ymmärtää.

Esimerkki 3.7. Muodostetaan lineaariset approksimaatiot funktioille

$$f_1(x) = -x^2, \quad f_2(x) = \sin(\tfrac{\pi}{2}x) \quad \text{ja} \quad f_3(x) = e^x - x^2$$

pisteessä $x_0 = 1$. Funktiolle f_1 saadaan

$$f_1(1) = -1 \text{ ja } f_1'(1) = -2 \quad \Longrightarrow \quad L(x) = f(1) + f'(1)(x-1) = -2x+1.$$

Funktiolle f_2 saadaan [muista trigonometriasta $\sin(\frac{\pi}{2}) = 1$]

$$f_2(1) = 1 \text{ ja } f_2'(1) = 0 \quad \Longrightarrow \quad L(x) = f(1) + f'(1)(x-1) = 1.$$

Funktiolle f_3 saadaan

$$f_3(1) = e-1 \text{ ja } f_3'(1) = e-2 \quad \Longrightarrow \quad L(x) = f(1) + f'(1)(x-1) = (e-2)x+1.$$

Kuva 3.2 näyttää lineaariset approksimaatiot pisteessä $x_0 = 1$ kolmelle samankaltaiselle funktiolle.

Esimerkki 3.7 ja kuva 3.2 osoittavat, että linearisointi vastaa sellaisen suoran piirtämistä, joka (a) kulkee pisteen $(x_0, f(x_0))$ kautta ja (b) jonka kulmakerroin on $f'(x_0)$.

Lause 3.8. *Lineaarinen approksimaatio on ainoa suora, joka kulkee pisteen $(x_0, f(x_0))$ kautta ja jonka kulmakerroin on $f'(x_0)$.*

Todistus. Jokaisen suoran voi esittää yhtälöllä $y = \alpha x + \beta$ joillakin $\alpha, \beta \in \mathbb{R}$, missä α on suoran kulmakerroin. Se, että suora kulkee pisteen $(x_0, f(x_0))$ kautta, tarkoittaa että $f(x_0) = \alpha x_0 + \beta$. Se, että suoran kulmakerroin on $f'(x_0)$, tarkoittaa että $\alpha = f'(x_0)$. Siispä

$$f(x_0) = \alpha x_0 + \beta = f'(x_0)x_0 + \beta \quad \Longrightarrow \quad \beta = f(x_0) - f'(x_0)x_0.$$

Täten kaikilla väitteen suorilla on $\alpha = f'(x_0)$ ja $\beta = f(x_0) - f'(x_0)x_0$. Toisin sanoen on täsmälleen yksi suora, joka kulkee pisteen $(x_0, f(x_0))$ kautta ja jonka kulmakerroin on $f'(x_0)$. Tämän suoran yhtälö on

$$y = \alpha x + \beta = f'(x_0)x + f(x_0) - f'(x_0)x_0 = f(x_0) + f'(x_0)(x - x_0),$$

joka on täsmälleen kaavan (3.3) lineaarinen approksimaatio. □

Kuvasta 3.2 näemme, että linearisointi antaa hyvän approksimaation kun x on lähellä pistettä x_0, mutta approksimaation tarkkuus voi heikentyä nopeasti, kun liikutaan kauemmas tästä pisteestä. Seuraavan tuloksen mukaan lineaarisen approksimaation virhe on *neliöllistä* kertaluokkaa kun $x \to x_0$, jos f on kahdesti derivoituva.

Lause 3.9. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja kahdesti derivoituva välillä (a,b). Olkoon $x_0 \in (a,b)$. Jos on olemassa vakio $L \geq 0$, jolla $|f''(x)| \leq L$ kaikilla $x \in (a,b)$, niin*

$$f(x) - L(x) = O(|x - x_0|^2) \quad \textit{kun} \quad x \to x_0.$$

Todistus. Koska $L(x) = P_1(x)$, väite seuraa asettamalla $n = 1$ korollaarissa 3.4. □

3.3 Taulukko-ohjelmointi

Taulukko-ohjelmointi, eli *vektorisointi*, tarkoittaa ohjelmointityyliä, jossa matemaattisia operaatioita sovelletaan kerralla kaikkiin taulokon arvoihin (vektoriin) sen sijaan, että niitä sovellettaisiin jokaiseen arvoon erikseen (eli silmukalla). Taulukko-ohjelmoinnilla toteutetut algoritmit vat yleensä *helppolukuisempia* kuin vastaavat silmukoin toteutetut algoritmit. Monissa korkean abstraktion kielissä, kuten Pythonissa ja MATLABissa, taulukko-ohjelmointi on myös *huomattavasti nopeampaa* kuin silmukat ja sitä kannattaa hyödyntää aina. Oletetaan, että haluamme korottaa neliöön (eli laskea x^2) kymmenen miljoonaa lukua x välillä nollasta yhteen käyttäen Pythonia. Taulukko-ohjelmointiin käytämme Pythonin `numpy`-kirjastoa.

```
>>> import numpy as np
>>> import time
>>> # an array of ten million numbers between 0 and 1
>>> a = np.linspace(start=0, stop=1, num=int(1e7))
>>> # use loop to square each number
>>> start1 = time.perf_counter()
>>> b1 = [x**2 for x in a]
>>> end1 = time.perf_counter()
>>> # square each number using array programming
>>> start2 = time.perf_counter()
>>> b2 = a**2
>>> end2 = time.perf_counter()
>>> # print elapsed times
>>> print(end1 - start1)
0.5299568176269531
>>> print(end2 - start2)
0.007016181945800781
```

Vaikka kulunut aika riippuu tietokoneesta ja ajokerrasta, taulukko-ohjelmointi on aina nopeampaa.

Esimerkki 3.10. Monte Carlo -integrointi on yksinkertainen menetelmä funktion integraalin approksimoimiseen. Oletetaan, että haluamme approksimoida jonkin funktion $f\colon [0,1] \to \mathbb{R}$ integraalia $\int_0^1 f(x)\,\mathrm{d}x$. Monte Carlo -integroinnissa arvotaan n lukua $x_1, \ldots, x_n$ tasaisesti välillä $[0,1]$ ja approksimoidaan integraalia funktion näiden pisteiden avulla laskettulla

keskiarvolla:

$$\int_0^1 f(x)\,\mathrm{d}x \approx \frac{1}{n}\sum_{i=1}^{n} f(x_i). \tag{3.4}$$

Taulukko-ohjelmointia tukevissa ohjelmointikielissä Monte Carlo -approksimaation (3.4) laskeminen onnistuu ilman yhtäkään silmukkaa.

Pythonissa approksimaatio ($n = 200$) funktion $f(x) = x^{3.4} + \sin(x)$ integraalille voidaan laskea esimerkiksi näin:

```
>>> import numpy as np
>>> rng = np.random.default_rng()
>>> # draw n = 200 random numbers on [0, 1]
>>> n = 200
>>> samples = rng.random(size=n)
>>> # evaluate f at these point and compute average
>>> evals = np.power(samples, 3.4) + np.sin(samples)
>>> mc_approx = np.sum(evals) / n
>>> print(mc_approx)
0.692222065735476
```

Lopputulos vaihtelee ajokerrasta toiseen, koska 200 pistettä x_i arvotaan satunnaisesti. MATLABissa tämän voi tehdä seuraavasti:

```
>>> # draw n = 200 random numbers on [0, 1]
>>> n = 200;
>>> samples = rand(n, 1);
>>> # evaluate f at these point and compute average
>>> evals = samples.^(3.4) + sin(samples);
>>> mc_approx = sum(evals) / n
mc_approx =

   0.6686
```

Tässä käytimme MATLABin pistepotenssia (eli alkioittaista potenssi), joka laskee potenssin $x^{3.4}$ jokaiselle satunnaisluvulle x.

4 Numeerinen integrointi

Palautetaan mieleen, että funktion f *integraalifunktio* (tai *määräämätön integraali* tai *antiderivaatta*) on funktio F, jolla

$$F'(x) = f(x).$$

Olkoon $a < b$. Funktion f *määrätty integraali* pisteestä a pisteeseen b kuvaa funktion f kuvaajan ja x-akselin välistä pinta-alaa. Määrätty integraali voidaan ilmaista antiderivaatan avulla muodossa

$$\int_a^b f(x)\,\mathrm{d}x = F(b) - F(a)$$

analyysin peruslauseen nojalla. Derivointi on helppoa. Esimerkiksi ketjusäännön ja eksponenttifunktioiden, polynomien sekä trigonometristen funktioiden derivointisääntöjen avulla funktion $f(x) = \exp(-x^2 + \sin(x))$ derivointi ei tuota vaikeuksia. Sen sijaan integrointi on yleensä vaikeaa tai suorastaan mahdotonta. Funktion $f(x) = \exp(-x^2 + \sin(x))$ integraalifunktiota ei ole mahdollista ilmaista suljetussa muodossa tuttujen alkeisfunktioiden[2] avulla. Tämän vuoksi numeeriset menetelmät ovat välttämättömiä useimpien määrättyjen integraalien laskemiseksi. Integraalifunktion laskemiseen täytyy käyttää *symbolista laskentaa*, jota ei käsitellä tällä kurssilla. Huomaa, että funktiolla, jonka integraalifunktio ei ole esitettävissä alkeisfunktioiden avulla, voi silti olla yksinkertainen määrätty integraali. Esimerkiksi käy hyvin vaikkapa

$$\int_{-\infty}^{\infty} \exp(-x^2)\,\mathrm{d}x = \sqrt{\pi}.$$

On hyödyllistä ajatella määrättyjä integraaleja pinta-aloina ja *numeerisen integroinnin* menetelmiä pinta-aloja arvioivina menetelminä. Tällaisia menetelmiä kutsutaan kvadratuurisäännöiksi (tai yksinkertaisesti säännöiksi). Terminologia juontaa latinan sanasta *quadratus*, joka tarkoittaa neliötä (tämä on erityisen osuvaa keskipistesäännöstä puhuttaessa, ks. osio 4.1).

Määritelmä 4.1 (Kvadratuurisääntö)**.** Olkoon $n \in \mathbb{N}$. *Kvadratuurisääntö* on integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{i=1}^{n} w_i f(t_i), \tag{4.1}$$

missä $w_1, \ldots, w_n \in \mathbb{R}$ ovat *painoja* ja $t_1, \ldots, t_n \in [a,b]$ ja *solmupisteitä*.

Painojen ja solmupisteiden valinta määrää, kuinka hyvä kvadratuurisääntö on. Tässä luvussa käsitellään kolmea kvadratuurisääntöä: keskipistesääntöä, puolisuunnikassääntöä ja Simpsonin sääntöä.

4.1 Keskipistesääntö

Olkoot $x_i = a + (b-a)i/n$, missä $i \in \{0, 1, \ldots, n\}$, tasavälisiä pisteitä välillä $[a,b]$. Muistetaan integraalilaskennan kurssilta, että riittävän säännöllisen (eli Riemann-integroituvan) funktion integraali saadaan Riemannin summan raja-arvona:

$$\int_a^b f(x)\,\mathrm{d}x = \lim_{n\to\infty} \sum_{i=1}^{n} (x_i - x_{i-1}) f(t_i) = \lim_{n\to\infty} \frac{b-a}{n} \sum_{i=1}^{n} f(t_i), \tag{4.2}$$

missä $t_i \in [x_{i-1}, x_i]$. Jokainen summan termi on sellaisen *suorakulmion pinta-ala*, jonka kannan leveys on $(x_i - x_{i-1}) = (b-a)/n$ ja korkeus $f(t_i)$. Suorakulmioiden korkeudet voidaan laskea

[2] Funktiota pidetään tyypillisesti *alkeisfunktiona*, jos se koostuu äärellisen monesta vakiosta, polynomista, funktioista exp, log, trigonometrisistä ja hyperbolisista funktioista (sin, cos, tan, sinh, cosh, tanh ja niin edelleen) sekä trigonometristen ja hyperbolisten funktioiden käänteisfunktioista.

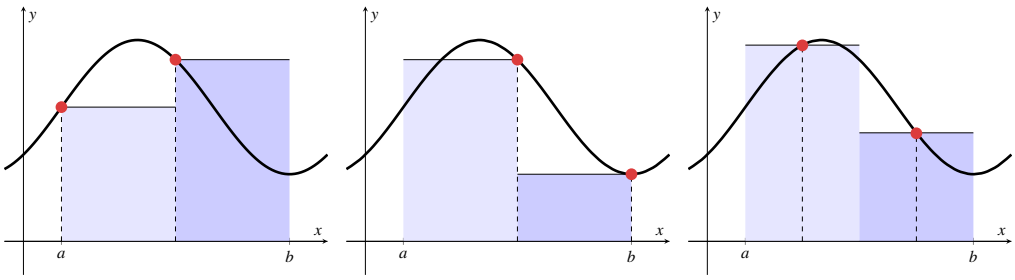

Kuva 4.1: Määrätyn integraalin $\int_a^b f(x)\,\mathrm{d}x$ approksimaatiot kahdella suorakulmiolla, joiden korkeudet lasketaan kunkin osavälin alkupisteessä (*vasemmalla*), päätepisteessä (*keskellä*) ja keskipisteessä (*oikealla*). Määritelmän 4.2 keskipistesääntö vastaa oikeanpuoleista kuvaa.

käyttäen funktion arvoa missä tahansa osavälin $[x_{i-1}, x_i]$ pisteessä. Yksinkertaisin lähestymistapa olisi laskea korkeus välin päätepisteessä, mikä tarkoittaa termin $f(t_i)$ korvaamista termillä $f(x_{i-1})$ tai $f(x_i)$ yhtälössä (4.2). Näitä kolmea vaihtoehtoa havainnollistetaan kuvassa 4.1. Korvaamalla termit $f(t_i)$ termeillä $f(\frac{1}{2}(x_i + x_{i-1}))$, missä $\frac{1}{2}(x_i + x_{i-1})$ on osavälin $[x_{i-1}, x_i]$ *keskipiste*, ja raja-arvo yhtälössä (4.2) äärellisellä luvun n arvolla saadaan keskipistesääntö, joka on käsitteellisesti samankaltainen kuin esimerkin 2.5 erotusosamääräapproksimaatio siinä mielessä, että approksimaatio muodostetaan ”katkaisemalla raja-arvoprosessi”.

Määritelmä 4.2 (Keskipistesääntö)**.** Olkoot $x_i = a + (b-a)i/n$, missä $i \in \{0, 1, \ldots, n\}$. *Keskipistesääntö* (eli *suorakulmiosääntö*) on integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{n} \sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) = h \sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right), \tag{4.3}$$

missä $h = x_{i-1} - x_i = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Vertaamalla yhtälöä (4.3) yhtälöön (4.1) nähdään, että keskipistesääntö on kvadratuurisääntö solmupisteillä $t_i = \frac{1}{2}(x_i + x_{i-1})$ ja yhtäsuuruisilla painoilla $w_i = (b-a)/n$. Kuva 4.2 havainnollistaa kahden osavälin (eli $n = 2$) keskipistesääntöä.

Huomautus 4.3. Olisimme voineet käyttää epätasavälisiä pisteitä $a = x_0 < x_1 < \cdots < x_{n-1} < x_n = b$ keskipistesäännön muodostamiseen. Tuloksena oleva sääntö on

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{i=1}^{n} (x_i - x_{i-1}) f\left(\frac{x_i + x_{i-1}}{2}\right).$$

Kaikki tässä osiossa määritellyt kvadratuurisäännöt voidaan muodostaa epätasavälisin pistein. Yksinkertaisuuden vuoksi käytämme kuitenkin aina tasavälisiä pisteitä.

Esimerkki 4.4. Käytetään keskipistesääntöä neljällä osavälillä (eli $n = 4$) integraalin $\int_0^4 x^3\,\mathrm{d}x = 4^4/4 = 64$ approksimoimiseen. Yhtälön (4.3) oikean puolen laskemiseksi tarvitaan (a) osavälien pituus $h = (b-a)/n$ ja (b) keskipisteet $\frac{1}{2}(x_i + x_{i-1})$. Koska $n = 4$, $b = 4$ ja $a = 0$, saadaan

$$\frac{b-a}{n} = \frac{4-0}{4} = 1 \tag{4.4}$$

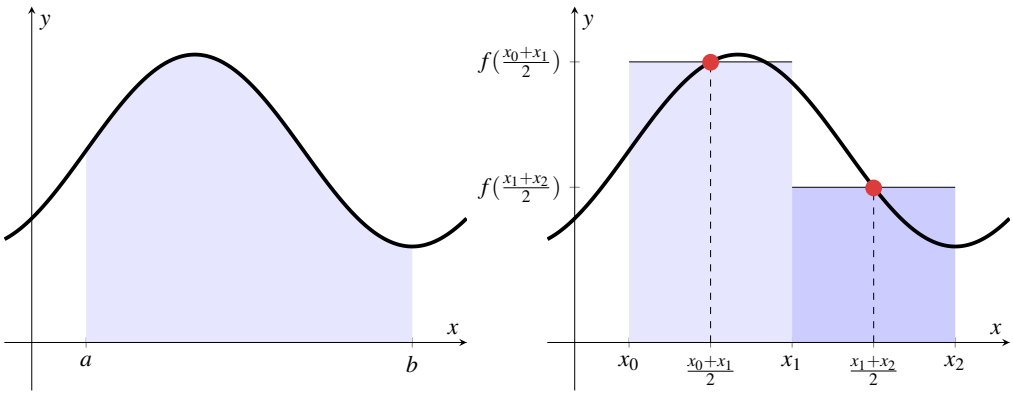

Kuva 4.2: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio kahden (eli $n = 2$) osavälin keskipistesäännöllä.

ja

$$x_i = a + \frac{(b-a)i}{n} = 0 + \frac{(4-0)i}{4} = i.$$

Täten keskipisteet ovat

$$\frac{x_i + x_{i-1}}{2} = \frac{i + (i-1)}{2} = i - \frac{1}{2}. \tag{4.5}$$

Sijoittamalla (4.4) ja (4.5) yhtälöön (4.3) saadaan

$$\begin{aligned}\int_0^4 x^3\,\mathrm{d}x \approx 1 \cdot \sum_{i=1}^{4} f\left(i - \frac{1}{2}\right) &= 1 \cdot f\left(\frac{1}{2}\right) + 1 \cdot f\left(\frac{3}{2}\right) + 1 \cdot f\left(\frac{5}{2}\right) + 1 \cdot f\left(\frac{7}{2}\right) \\ &= \left(\frac{1}{2}\right)^3 + \left(\frac{3}{2}\right)^3 + \left(\frac{5}{2}\right)^3 + \left(\frac{7}{2}\right)^3 \\ &= 62.\end{aligned}$$

Täten keskipistesäännön suhteellinen virhe (muista määritelmä 2.8) on

$$\left|\frac{\int_0^4 x^3\,\mathrm{d}x - 62}{\int_0^4 x^3\,\mathrm{d}x}\right| = \left|\frac{64-62}{64}\right| = \frac{1}{32} = 3{,}125\ \%.$$

Kvadratuurisäännön sanotaan olevan *tarkka* funktiolle f, jos sääntö antaa integraalin todellisen arvon.

Lause 4.5. *Keskipistesääntö on tarkka jokaiselle polynomille, jonka aste on enintään yksi.*

Todistus. Jokainen polynomi, jonka aste on enintään yksi, on muotoa $f(x) = \alpha + \beta x$ joillakin vakioilla $\alpha, \beta \in \mathbb{R}$. Haluamme osoittaa, että

$$\int_a^b f(x)\,\mathrm{d}x = \frac{b-a}{n} \sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right)$$

tällaiselle funktiolle f. Integraali on

$$\int_a^b f(x)\,\mathrm{d}x = \int_a^b (\alpha + \beta x)\,\mathrm{d}x = (b-a)\alpha + \frac{(b^2 - a^2)\beta}{2}. \tag{4.6}$$

Koska $x_i = a + (b-a)i/n$, keskipisteet ovat

$$\frac{x_i + x_{i-1}}{2} = a + \frac{(b-a)i/n + (b-a)(i-1)/n}{2} = a + \frac{(b-a)i}{n} - \frac{b-a}{2n}.$$

Täten keskipistesääntö on

$$\begin{aligned}
\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) &= \frac{b-a}{n}\left(\alpha n + \beta \sum_{i=1}^{n}\left[a + \frac{(b-a)i}{n} - \frac{b-a}{2n}\right]\right) \\
&= (b-a)\alpha + \frac{b-a}{n}\beta\left(na - \frac{b-a}{2} + \frac{b-a}{n}\sum_{i=1}^{n} i\right) \\
&= (b-a)\alpha + (b-a)a\beta - \frac{(b-a)^2\beta}{2n} + \frac{(b-a)^2\beta}{n^2}\sum_{i=1}^{n} i.
\end{aligned}$$

Muistamalla aritmeettisen summan kaava $\sum_{i=1}^{n} i = n(n+1)/2$ saadaan

$$\begin{aligned}
\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) &= (b-a)\alpha + \frac{(b-a)a\beta}{n} - \frac{(b-a)^2\beta}{2n} + \frac{(b-a)^2\beta}{n^2}\cdot\frac{n(n+1)}{2} \\
&= (b-a)\alpha + (b-a)a\beta - \frac{(b-a)^2\beta}{2n} + (n+1)\frac{(b-a)^2\beta}{2n} \\
&= (b-a)\alpha + (b-a)a\beta + \frac{(b-a)^2\beta}{2} \\
&= (b-a)\alpha + (b-a)a\beta + \frac{(b^2 - 2ab + a^2)\beta}{2} \\
&= (b-a)\alpha + \frac{(2(b-a)a + b^2 - 2ab + a^2)\beta}{2} \\
&= (b-a)\alpha + \frac{(b^2 - a^2)\beta}{2}.
\end{aligned}$$

Tämä on yhtä suuri kuin (4.6). Täten keskipistesääntö on tarkka kaikille funktioille, jotka ovat muotoa $f(x) = \alpha + \beta x$. □

Keskipistesääntö *ei* ole tarkka kaikille toisen asteen polynomeille. Tämän osoittamiseksi riittää löytää yksi toisen asteen polynomi, jolle (4.3) ei ole yhtäsuuruus. Valitaan $f(x) = x^2$ ja tarkastellaan yksinkertaisuuden vuoksi tapausta $a = 0$. Tällöin

$$\int_a^b f(x)\,\mathrm{d}x = \int_0^b x^2\,\mathrm{d}x = \frac{b^3}{3} \tag{4.7}$$

ja (kuten lauseen 4.5 todistuksessa)

$$\begin{aligned}
\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) = \frac{b-a}{n}\sum_{i=1}^{n}\left(a + \frac{(b-a)i}{n} - \frac{b-a}{2n}\right)^2 &= \frac{b}{n}\sum_{i=1}^{n}\left(\frac{bi}{n} - \frac{b}{2n}\right)^2 \\
&= \frac{b^3}{n^3}\sum_{i=1}^{n}\left(i - \frac{1}{2}\right)^2 \\
&= \frac{b^3}{n^3}\sum_{i=1}^{n}\left(i^2 - i + \frac{1}{4}\right).
\end{aligned}$$

Palautetaan mieliin summakaavat

$$\sum_{i=1}^{n} i = \frac{n(n+1)}{2} \quad \text{and} \quad \sum_{i=1}^{n} i^2 = \frac{n(n+1)(2n+1)}{6},$$

joilla saadaan

$$\begin{aligned}\frac{b^3}{n^3}\sum_{i=1}^{n}\left(i^2-i+\frac{1}{4}\right) &= \frac{b^3}{n^3}\left(\frac{n(n+1)(2n+1)}{6}-\frac{n(n+1)}{2}+\frac{n}{4}\right)\\ &= \frac{b^3}{n^3}\cdot\frac{n}{12}[2n(n+1)(2n+1)-6n(n+1)+3n]\\ &= \frac{b^3(4n^3+6n^2+2n-6n^2-6n+3n)}{12n^2}\\ &= \frac{b^3(4n^2-1)}{12n^2}.\end{aligned}$$

Täten

$$\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i+x_{i-1}}{2}\right) = \frac{b^3}{3}\left(1-\frac{1}{4n^2}\right),$$

mikä ei ole yhtä suuri kuin yhtälössä (4.7) annettu todellinen integraali millään $n \in \mathbb{N}$, koska $1-1/(4n^2) \neq 1$.

Lause 4.6. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja kahdesti derivoituva välillä (a,b). Jos on olemassa vakio $L \geq 0$ siten, että $|f''(x)| \leq L$ kaikilla $x \in (a,b)$, niin keskipistesäännön virheelle pätee*

$$\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^{n} h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right| \leq \frac{(b-a)^3L}{24n^2} = \frac{(b-a)L}{24}h^2,$$

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1},x_i]$ pituus.

Todistus. Jakamalla integrointiväli n osaväliin voimme kirjoittaa keskipistesäännön virheen muodossa

$$\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^{n} h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right) = \sum_{i=1}^{n}\left(\int_{x_{i-1}}^{x_i} f(x)\,\mathrm{d}x - h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right). \tag{4.8}$$

Olkoon $t_i = \frac{1}{2}(x_i+x_{i-1})$ osavälin $[x_{i-1},x_i]$ keskipiste. Tällöin

$$\begin{aligned}\int_{x_{i-1}}^{x_i}[f(t_i)+f'(t_i)(x-t_i)]\,\mathrm{d}x &= f(t_i)(x_i-x_{i-1}) + \frac{f'(t_i)}{2}(x_i^2-x_{i-1}^2) - f'(t_i)t_i(x_i-x_{i-1})\\ &= (x_i-x_{i-1})\left[f(t_i)+\frac{f'(t_i)}{2}(x_i+x_{i-1}) - f'(t_i)t_i\right]\\ &= (x_i-x_{i-1})[f(t_i)-f'(t_i)t_i+f'(t_i)t_i]\\ &= (x_i-x_{i-1})f(t_i)\\ &= h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right).\end{aligned}$$

Täten (4.8) saa muodon

$$\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^{n} h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right) = \sum_{i=1}^{n}\int_{x_{i-1}}^{x_i}[f(x)-f(t_i)-f'(t_i)(x-t_i)]\,\mathrm{d}x.$$

Huomataan, että $f(x)-f(t_i)-f'(t_i)(x-t_i) = f(x)-P_{1,t_i}(x) = R_{2,t_i}(x)$, missä P_{1,t_i} ja R_{2,t_i} ovat (osio 3.1) ensimmäisen asteen Taylorin polynomi ja sen jäännöstermi, kun $x_0 = t_i$. Taylorin

lauseesta (lause 3.3) ja korollaarista 3.4, kun $n+1=2$, seuraa sitten, että

$$\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^n h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = \left|\sum_{i=1}^n \int_{x_{i-1}}^{x_i} R_{2,t_i}(x)\,\mathrm{d}x\right| \le \sum_{i=1}^n \int_{x_{i-1}}^{x_i} \frac{L}{2!}(x-t_i)^2\,\mathrm{d}x$$
$$= \frac{L}{2}\sum_{i=1}^n \int_{-h/2}^{h/2} y^2\,\mathrm{d}y,$$

missä viimeisessä yhtälössä käytettiin muuttujanvaihtoa $y = x - t_i$ ja sitä, että t_i on välin $[x_{i-1}, x_i]$ keskipiste. Täten

$$\begin{aligned}\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^n h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = \frac{L}{2}\sum_{i=1}^n \int_{-h/2}^{h/2} y^2\,\mathrm{d}y &= \frac{L}{2}\sum_{i=1}^n \frac{1}{3}\cdot[(h/2)^3-(-h/2)^3] \\ &= \frac{L}{24}\sum_{i=1}^n h^3 \\ &= \frac{L}{24}nh^3 \\ &= \frac{L}{24}n\left(\frac{b-a}{n}\right)^3 \\ &= \frac{(b-a)^3L}{24n^2}.\end{aligned}$$

□

Käyttäen iso-O-notaatiota osiosta 2.4 voimme kirjoittaa lauseen 4.6 muodossa

$$\left|\int_a^b f(x)\,\mathrm{d}x - \frac{b-a}{n}\sum_{i=1}^n f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = O(n^{-2}) \quad \text{kun} \quad n\to\infty.$$

Tämä antaa tietoa integrointivirheen suuruusluokasta osavälien lukumäärän (n) kasvaessa. Vastaavasti voimme kirjoittaa

$$\left|\int_a^b f(x)\,\mathrm{d}x - h\sum_{i=1}^n f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = O(h^2) \quad \text{as} \quad h\to 0,$$

mikä kuvaa virheen käyttäytymistä, kun osavälien pituus, $h=(b-a)/n$, lähestyy nollaa.

4.2 Puolisuunnikassääntö

Keskipistesääntö käytti suorakulmioita integraalin approksimoimiseen. Puolisuunnikassääntö käyttää *puolisuunnikkaita*, jotka ovat suorakulmioita yleisempiä. Suorakulmion molemmat sivuparit ovat yhdensuuntaiset, kun taas puolisuunnikkaalla on vähintään yksi yhdensuuntaisten sivujen pari. Suorakulmion, jonka kannan pituus on h ja korkeus a, pinta-ala on $a\cdot h$; puolisuunnikkaan, jonka kannan pituus on h ja korkeudet b_1 ja b_1, pinta-ala on $\frac{1}{2}(b_1+b_2)\cdot h$ (ks. kuva 4.3). Korvaamalla suorakulmiot, joiden korkeudet lasketaan funktion f arvoista osavälien keskipisteissä $\frac{1}{2}(x_i+x_{i-1})$, puolisuunnikkailla, joiden sivujen korkeudet ovat funktion f arvot osavälien päätepisteissä x_{i-1} ja x_i, saadaan puolisuunnikassääntö.

Määritelmä 4.7 (Puolisuunnikassääntö)**.** Olkoot $x_i = a+(b-a)i/n$, missä $i\in\{0,1,\dots,n\}$. *Puolisuunnikassääntö* integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{n}\sum_{i=1}^n \frac{f(x_i)+f(x_{i-1})}{2} = h\sum_{i=1}^n \frac{f(x_i)+f(x_{i-1})}{2}, \tag{4.9}$$

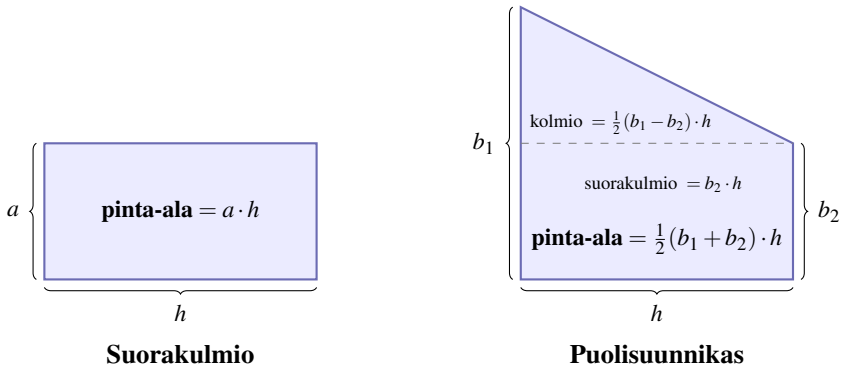

Kuva 4.3: Suorakulmion ja puolisuunnikkaan pinta-alat, kun puolisuunnikkaassa on kaksi suoraa kulmaa.

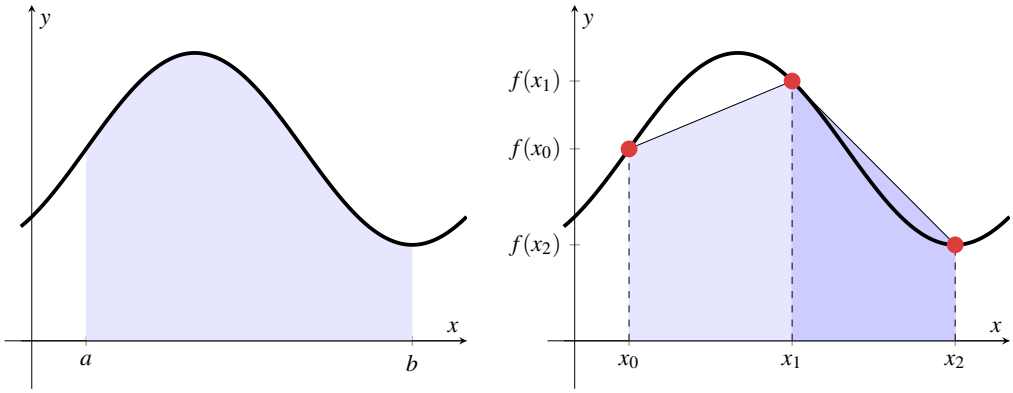

Kuva 4.4: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio kahden ($n = 2$) osavälin puolisuunnikassäännöllä.

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Huomaamalla, että $f(x_0)$ ja $f(x_n)$ esiintyvät kerran ja kaikki muut funktioiden arvot kahdesti yhtälössä (4.9), voimme kirjoittaa puolisuunnikassäännön muodossa

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{h}{2}[f(x_0) + 2f(x_1) + \cdots + 2f(x_{n-1}) + f(x_n)]. \tag{4.10}$$

Täten puolisuunnikassääntö on kvadratuurisääntö [muistetaan (4.1)] solmupisteillä $t_i = x_i$, missä $i \in \{0, \ldots, n\}$, ja painoilla $w_0 = w_n = \frac{1}{2}h$ sekä $w_1 = \cdots = w_{n-1} = h$. Kuva 4.4 havainnollistaa puolisuunnikassääntöä.

Esimerkki 4.8. Käytetään puolisuunnikassääntöä neljällä osavälillä (eli $n = 4$) integraalin $\int_0^4 x^3\,\mathrm{d}x = 4^4/4 = 64$ approksimoimiseen. Yhtälön (4.9) oikean puolen laskemiseksi tarvitaan (a) osavälien pituus $h = (b-a)/n$ ja (b) pisteet x_i. Koska $n = 4$, $b = 4$ ja $a = 0$, saadaan

$$h = \frac{b-a}{n} = \frac{4-0}{4} = 1 \tag{4.11}$$

ja

$$x_i = a + \frac{(b-a)i}{n} = 0 + \frac{(4-0)i}{4} = i. \tag{4.12}$$

Sijoittamalla (4.11) ja (4.12) yhtälöön (4.10) saadaan

$$\begin{aligned}\int_0^4 x^3 \,\mathrm{d}x &\approx \frac{h}{2}[f(x_0)+2f(x_1)+2f(x_2)+2f(x_3)+f(x_4)] \\ &= \frac{1}{2}[f(0)+2f(1)+2f(2)+2f(3)+f(4)] \\ &= \frac{1}{2}[0^3+2\cdot 1^3+2\cdot 2^3+2\cdot 3^3+4^3] \\ &= 68.\end{aligned}$$

Täten puolisuunnikassäännön suhteellinen virhe (muistetaan määritelmä 2.8) on

$$\left|\frac{\int_0^4 x^3\,\mathrm{d}x - 68}{\int_0^4 x^3\,\mathrm{d}x}\right| = \left|\frac{64-68}{64}\right| = \frac{1}{16} = 6{,}25\ \%.$$

Puolisuunnikassääntö käyttäytyy samalla tavalla kuin keskipistesääntö. Vertaa seuraavia lauseita lauseisiin 4.5 ja 4.6.

Lause 4.9. *Puolisuunnikassääntö on tarkka kaikille polynomeille, joiden aste on enintään yksi.*

Todistus. Samankaltainen kuin lauseen 4.5 todistus. Jätetään harjoitustehtäväksi. □

Lause 4.10. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja kahdesti derivoituva välillä (a,b). Jos on olemassa vakio $L \geq 0$ siten, että $|f''(x)| \leq L$ kaikilla $x \in (a,b)$, niin puolisuunnikassäännön virheelle pätee*

$$\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^n h\cdot\frac{f(x_i)+f(x_{i-1})}{2}\right| \leq \frac{(b-a)^3L}{12n^2} = \frac{(b-a)L}{12}h^2,$$

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1},x_i]$ pituus.

Todistus. Todistus jätetään pois; se on samankaltainen kuin lauseen 4.6 todistus. □

4.3 Simpsonin sääntö

Keskipistesääntö käyttää suorakulmioita ja puolisuunnikassääntö puolisuunnikkaita integraalin approksimoimiseen. Keskipistesääntö muodostetaan käyttäen yhtä funktion f arvoa kullakin osavälillä $[x_{i-1},x_i]$ (eli arvoa keskipisteessä), kun taas puolisuunnikassääntö käyttää kahta arvoa (arvot päätepisteissä). Simpsonin sääntö käyttää kolmea arvoa kullakin osavälillä, eli sekä päätepisteitä että keskipistettä. Kolme funktion f arvoa annetuissa pisteissä määrittää yksikäsitteisen toisen asteen polynomin (eli toisen asteen *interpolointifunktion*), jolla on sama arvo kuin funktiolla f näissä pisteissä ja jonka integraalia (eli polynomin kuvaajan alle jäävää pinta-alaa) voidaan käyttää funktion f integraalin approksimoimiseen.

Oletetaan, että meillä on vain yksi osaväli $[a,b]$. Keskipiste on $(a+b)/2$. Toisen asteen polynomi $\alpha+\beta x+\gamma x^2$, jolla on sama arvo kuin funktiolla f päätepisteissä a ja b sekä keskipisteessä $c = (a+b)/2$, toteuttaa kolme yhtälöä

$$\alpha + \beta c + \gamma c^2 = f(c),$$

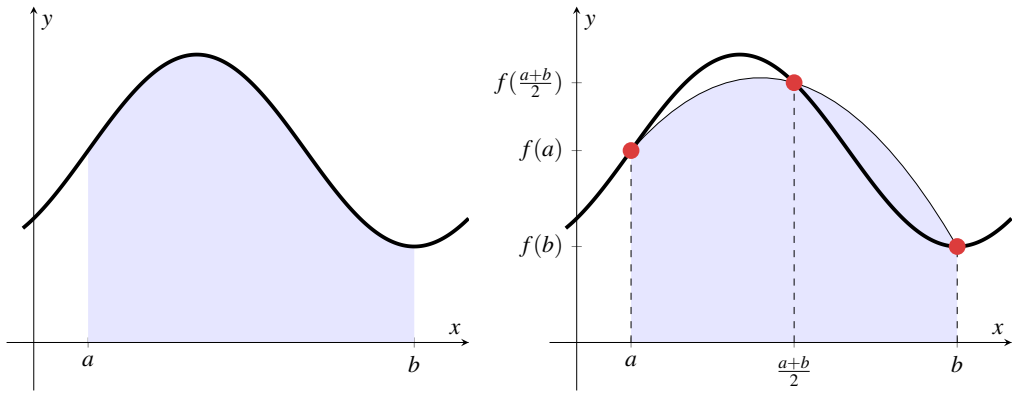

Kuva 4.5: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio Simpsonin säännöllä yhtälön (4.14) mukaisesti käyttäen kolmea pistettä.

$$\begin{aligned} \alpha + \beta a + \gamma a^2 &= f(a), \\ \alpha + \beta b + \gamma b^2 &= f(b). \end{aligned} \tag{4.13}$$

Koska meillä on kolme yhtälöä kolmelle tuntemattomalle (α, β ja γ), on suoraviivaista ratkaista (sivuutamme laskut) yksikäsitteiset kertoimet, joilla nämä kolme yhtälöä pätevät. Koska

$$\int_a^b (\alpha + \beta x + \gamma x^2)\,\mathrm{d}x = (b-a)\alpha + \frac{(b^2-a^2)\beta}{2} + \frac{(b^3-a^3)\gamma}{3}$$

kaikilla $\alpha, \beta, \gamma \in \mathbb{R}$, voimme approksimoida integraalia käyttäen juuri laskemiamme kertoimia:

$$\int_a^b f(x)\,\mathrm{d}x \approx (b-a)\alpha + \frac{(b^2-a^2)\beta}{2} + \frac{(b^3-a^3)\gamma}{3}.$$

Yhtälöt (4.13) ratkaiseville kertoimille oikea puoli sievenee huomattavasti, jolloin lopulta saadaan

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{6}\left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right]. \tag{4.14}$$

Kuva 4.5 havainnollistaa tätä approksimaatiota. Useampaa kuin kolmea funktion f arvoa käyttävän approksimaation muodostamiseksi voimme yhdistää useita tämäntyyppisiä approksimaatioita. Olkoon n parillinen ja $x_i = a + hi$, missä $h = (b-a)/n$. Tällöin

$$\int_a^b f(x)\,\mathrm{d}x = \sum_{k=1}^{\frac{n}{2}} \int_{x_{2k-2}}^{x_{2k}} f(x)\,\mathrm{d}x \approx \sum_{k=1}^{\frac{n}{2}} \frac{x_{2k} - x_{2k-2}}{6}[f(x_{2k-2}) + 4f(x_{2k-1}) + f(x_{2k})],$$

missä sovelsimme yhtälöä (4.14) sijoituksilla $a = x_{2k-2}$ ja $b = x_{2k}$ kuhunkin integraaliin ja hyödynsimme tässä tapauksessa pätevää yhtälöä $\frac{1}{2}(a+b) = x_{2k-1}$ (eli *kahta* osaväliä vastaa *yksi* toisen asteen interpolointifunktio). Ryhmittelemällä parittomia ja parillisia indeksejä vastaavat termit saadaan Simpsonin sääntö.

Määritelmä 4.11 (Simpsonin sääntö)**.** Olkoon $n \in \mathbb{N}$ parillinen ja $x_i = a + (b-a)i/n$, missä $i \in \{0, 1, \ldots, n\}$. *Simpsonin sääntö* on integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{h}{3}[f(x_0) + 4f(x_1) + 2f(x_2) + \cdots + 2f(x_{n-2}) + 4f(x_{n-1}) + f(x_n)], \tag{4.15}$$

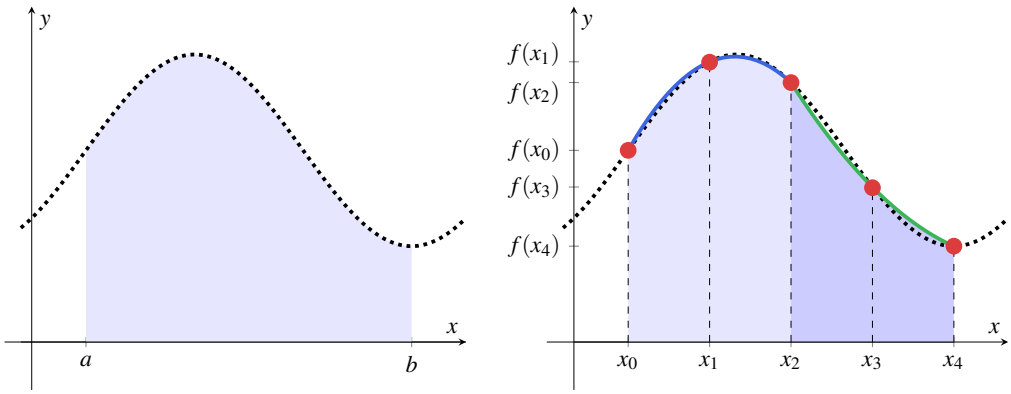

Kuva 4.6: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio Simpsonin säännöllä yhtälön (4.12) mukaisesti, kun $n = 4$. Huomaa, että kaksi toisen asteen polynomia on sovitettu osaväleille $[x_0, x_2]$ ja $[x_2, x_4]$.

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Summamerkinnällä voimme kirjoittaa Simpsonin säännön muodossa

$$\int_a^b f(x)\,\mathrm{d}x = \frac{h}{3}\left(f(x_0) + f(x_n) + 4\sum_{i=1}^{\frac{n}{2}} f(x_{2i-1}) + 2\sum_{i=1}^{\frac{n}{2}-1} f(x_{2i})\right).$$

Tästä nähdään, että välin $[a,b]$ päätepisteet saavat painot $\frac{1}{3}h$, parittomat pisteet (x_{2i-1}) painot $\frac{4}{3}h$ ja parilliset pisteet (x_{2i}) painot $\frac{2}{3}h$.

Esimerkki 4.12. Käytetään Simpsonin sääntöä arvolla $n = 4$ integraalin $\int_0^4 x^3\,\mathrm{d}x = 4^4/4 = 64$ approksimoimiseen. Yhtälön (4.9) oikean puolen laskemiseksi tarvitaan (a) osavälien pituus $h = (b-a)/n$ ja (b) pisteet x_i. Koska $n = 4$, $b = 4$ ja $a = 0$, saadaan

$$h = \frac{b-a}{n} = \frac{4-0}{4} = 1 \tag{4.16}$$

ja

$$x_i = a + \frac{(b-a)i}{n} = 0 + \frac{(4-0)i}{4} = i. \tag{4.17}$$

Sijoittamalla (4.16) ja (4.17) yhtälöön (4.12) saadaan

$$\begin{aligned}\int_0^4 x^3\,\mathrm{d}x &\approx \frac{h}{3}[f(x_0) + 4f(x_1) + 2f(x_2) + 4f(x_3) + \cdots + 4f(x_{n-1}) + f(x_n)] \\ &= \frac{1}{3}[f(0) + 4f(1) + 2f(2) + 4f(3) + f(1)] \\ &= \frac{1}{3}[0^3 + 4\cdot 1^3 + 2\cdot 2^3 + 4\cdot 3^3 + 4^3] \\ &= 64.\end{aligned}$$

Täten Simpsonin säännön suhteellinen virhe (muistetaan määritelmä 2.8) on

$$\left|\frac{\int_0^4 x^3\,\mathrm{d}x - 64}{\int_0^4 x^3\,\mathrm{d}x}\right| = \left|\frac{64-64}{64}\right| = 0 = 0\,\%.$$

Ei ole sattumaa, että Simpsonin sääntö oli tarkka esimerkissä (4.12).

Lause 4.13. *Simpsonin sääntö on tarkka kaikille polynomeille, joiden aste on enintään kolme.*

Todistus. Samankaltainen mutta monimutkaisempi kuin lauseen 4.5 todistus. □

Olkoon

$$E_n(f) = \left|\int_a^b f(x)\,\mathrm{d}x - \frac{h}{3}\left(f(x_0) + f(x_n) + 4\sum_{i=1}^{\frac{n}{2}} f(x_{2i-1}) + 2\sum_{i=1}^{\frac{n}{2}-1} f(x_{2i})\right)\right|$$

Simpsonin säännön absoluuttinen virhe.

Lause 4.14. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja neljästi derivoituva välillä (a,b). Jos on olemassa vakio $L \geq 0$ siten, että $|f^{(4)}(x)| \leq L$ kaikilla $x \in (a,b)$, niin Simpsonin säännön virheelle pätee*

$$E_n(f) \leq \frac{(b-a)^5 L}{180 n^4} = \frac{(b-a)L}{180} h^4,$$

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Todistus. Sivuutetaan. □

Jos f on riittävän sileä (eli riittävän monta kertaa derivoituva), lauseet 4.6, 4.10 ja 4.14 osoittavat, että keskipiste- ja puolisuunnikassääntöjen virheet ovat suuruusluokka h^2, kun taas Simpsonin säännön virhe on suuruusluokkaa h^4. Täten Simpsonin sääntö voi olla tarkempi kuin keskipiste- tai puolisuunnikassääntö, jos f on riittävän sileä.

5 Yhtälöryhmien ratkaiseminen

Monet matematiikan opiskelussa vastaan tulevat ongelmat voidaan ratkaista suljetussa muodossa. Tämä saattaa antaa vaikutelman, että jokainen yhtälö voidaan ratkaista tarkasti. Päinvastoin: useimpia yhtälöitä ei voida ratkaista suljetussa muodossa käyttäen äärellistä määrää alkeisfunktioita. Näin on lähes aina, kun yhtälö sisältää useita erilaisia alkeisfunktioita. Esimerkiksi yhtälön

$$e^x = 2$$

ratkaisu on $x = \log 2 \approx 0.693$. Mutta yhtälön

$$e^x + x = 2$$

ratkaisu on $x = 2 - W(e^2) \approx 0.442$, missä W on *Lambertin W-funktio*, eli eräs erikoisfunktio. Yhtälön

$$e^x + x + \sin(x) = 2,$$

ratkaisu, joka on $x \approx 0.316$, ei ole ilmaistavissa minkään tunnetun alkeis- tai erikoisfunktion avulla. Yhtälöt, joita ei voida ratkaista suljetussa muodossa, täytyy ratkaista numeerisesti.

Jos f ja g ovat yhden reaalimuuttujan reaaliarvoisia funktioita, $x^* \in \mathbb{R}$ on yhtälön

$$f(x) = g(x)$$

ratkaisu, jos $f(x^*) = g(^*)$. Vastaavasti, jos $\mathbf{f}, \mathbf{g} \colon \mathbb{R}^m \to \mathbb{R}^n$, $\mathbf{x}^* \in \mathbb{R}^m$ on ratkaisu yhtälölle

$$\mathbf{f}(\mathbf{x}) = \mathbf{g}(\mathbf{x})$$

jos $\mathbf{f}(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*)$. Yhtälön ratkaisu *ratkaisee* yhtälön.

Esimerkki 5.1. Tarkastellaan yhtälöä $x^2 + 1 = 2$, joten $f(x) =^2 +1$ ja $g(x) = 2$. Reaaliluku $x = -1$ on yhtälön $x^2 + 1 = 2$ ratkaisu, koska

$$f(-1) = (-1)^2 + 1 = 1 + 1 = 2 = g(-1),$$

mutta $x = 2$ ei ole ratkaisu, koska

$$f(2) = 2^2 + 1 = 4 + 1 = 5 \neq 2 = g(2).$$

Graafisesti yhtälön ratkaisut vastaavat x-akselilla olevia pisteitä, joissa funktioiden f ja g kuvaajat leikkaavat. Esimerkiksi yhtälön $x^2 + 1 = 2$ ratkaisut ovat $x_0 = \pm 1$, koska näissä pisteissä funktioiden $f(x) = x^2 + 1$ ja $g(x) = 2$ kuvaajat ovat samalla korkeudella. Funktiot f ja g voidaan myös valita eri tavalla, sillä yhtälöt voidaan kirjoittaa useaan yhtäpitävään muotoon. Esimerkiksi yhtälö $x^2 + 1 = 2$ voidaan kirjoittaa muotoon $x^2 - 1 = 0$, jolloin $f(x) = x^2 - 1$ ja $g(x) = 0$. Tämä johtaa vastaavuuteen ratkaisujen ja nollakohtien välillä. $x^* \in \mathbb{R}$ on funktion $f \colon \mathbb{R} \to \mathbb{R}$ *nollakohta* (tai *juuri*), jos $f(x^*) = 0$. Graafisesti nollakohdat ovat ne x-akselilla olevat pisteet, joissa funktion f kuvaaja leikkaa x-akselin. Vastaavasti $\mathbf{x}^* \in \mathbb{R}^n$ on funktion $f \colon \mathbb{R}^m \to \mathbb{R}^n$ nollakohta, jos $\mathbf{f}(\mathbf{x}^*) = \mathbf{0}$.

Lause 5.2. *Olkoon $\mathbf{f}, \mathbf{g} \colon \mathbb{R}^n \to \mathbb{R}^m$. Piste $\mathbf{x}^* \in \mathbb{R}^n$ on ratkaisu yhtälölle $\mathbf{f}(\mathbf{x}) = \mathbf{g}(\mathbf{x})$ jos ja vain jos se on funktion $\mathbf{f} - \mathbf{g}$ nollakohta.*

Todistus. Oletetaan, että $\mathbf{x}^*$ ratkaisee yhtälön. Täten $\mathbf{f}(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*)$, mikä on yhtäpitävää yhtälön $\mathbf{f}(\mathbf{x}^*) - \mathbf{g}(\mathbf{x}^*) = \mathbf{0}$ kanssa. Tämä osoittaa, että $\mathbf{x}^*$ on funktion $\mathbf{f} - \mathbf{g}$ nollakohta. Kääntäen, jos $\mathbf{x}^*$ on funktion $\mathbf{f} - \mathbf{g}$ nollakohta, pätee $\mathbf{f}(\mathbf{x}^*) - \mathbf{g}(\mathbf{x}^*) = \mathbf{0}$. Tämä on yhtäpitävää yhtälön $\mathbf{f}(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*)$ kanssa, joten $\mathbf{x}^*$ ratkaisee yhtälön. □

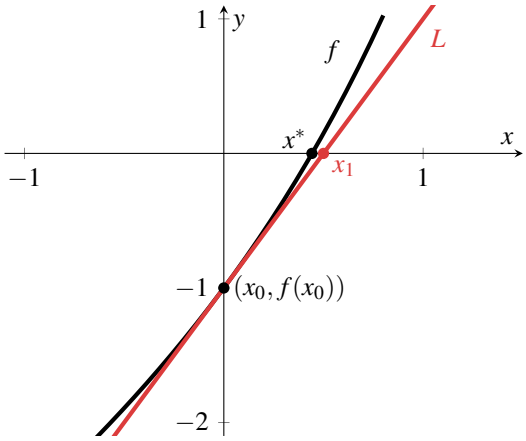

Kuva 5.1: *Newtonin menetelmän idea*: Lineaarisen approksimaation (eli tangentin) L_{x_0} nollakohta x_1 funktiolle $f(x) = e^x + x - 2$ toimii approksimaationa funktion nollakohdalle x^* edellyttäen, että kehityspiste (eli tangenttipiste) x_0 on lähellä todellista nollakohtaa.

Täten yhtälön ratkaiseminen vastaa alkuperäisen yhtälön puolten erotuksesta saadun funktion nollakohtien etsintää.

Funktiolla voi olla nolla, yksi tai useita nollakohtia. Vastaavasti yhtälöllä voi olla nolla, yksi tai useita ratkaisuja. Esimerkiksi esimerkin 5.1 yhtälöllä oli kaksi ratkaisua ($x_0 \pm 1$). Yhtälöllä $x^2 = 0$ on yksi ratkaisu ($x^* = 0$) ja yhtälöllä $x^2 + 1 = 0$ ei ole ratkaisuja[3] (koska x^2 on aina ei-negatiivinen). Matemaattisesta analyysista tuttua Bolzanon lausetta voidaan käyttää sen selvittämiseen, onko jatkuvalla funktiolla ainakin yksi ratkaisu.

Lause 5.3 (Bolzanon lause)**.** *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva. Jos $f(a)$ ja $f(b)$ ovat erimerkkisiä, niin $f(c) = 0$ jollekin $c \in [a,b]$.*

Jos $f(a)$ ja $f(b)$ ovat erimerkkisiä, niin joko (i) $f(a) < 0$ ja $f(b) > 0$ tai (ii) $f(a) > 0$ ja $f(b) < 0$. Nämä voidaan yhdistää yhdeksi ehdoksi $f(a)f(b) < 0$, koska positiivisen ja negatiivisen luvun tulo on negatiivinen. Huomaa, että välillä $[a,b]$ voi olla nollakohtia, vaikka ehto $f(a)f(b) < 0$ ei pätisi. Lisäksi $f(a)f(b) < 0$ takaa vain, että on *ainakin yksi nollakohta* (eli nollakohtia voi olla yksi tai useita).

5.1 Newtonin menetelmä

Muistetaan osiosta 3.2, että funktion f lineaarinen approksimaatio (tai ensimmäisen kertaluvun Taylorin polynomi) pisteessä x_0 on tangenttisuora

$$L_{x_0}(x) = f(x_0) + f'(x_0)(x - x_0). \tag{5.1}$$

Taylorin lauseen mukaan (ks. lause 3.3 ja korollaari 3.4) lineaarinen approksimaatio on hyvä approksimaatio funktiolle f arvoilla x, jotka ovat lähellä kehityspistettä x_0. Näin ollen, jos funktiolla f on nollakohta lähellä pistettä x_0, myös lineaarisella approksimaatiolla on nollakohta lähellä pistettä x_0, ja tätä nollakohtaa voidaan käyttää approksimoimaan funktion f nollakohtaa. Kuva 5.1 havainnollistaa tätä funktiolle $f(x) = e^x + x - 2$, kun $x_0 = 0$. Jos sen sijaan tangenttipiste x_0 *ei* ole lähellä funktion f nollakohtaa, tangentin nollakohta x_1 on usein silti lähempänä funktion nollakohtaa kuin x_0. Tästä seuraa, että jos tangentit muodostetaan iteratiivisesti edellisen tangentin nollakohdassa, saatavat nollakohdat x_1, x_2, x_3, … lähestyvät usein funktion f nollakohtaa. Kuva 5.2 havainnollistaa asiaa.

[3] Ellei oteta huomioon kompleksilukuja, jolloin ratkaisut ovat $x^* = \pm i$. Emme käytä kompleksilukuja tällä kurssilla.

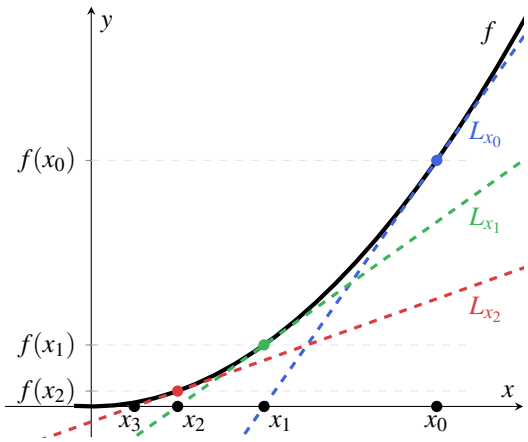

Kuva 5.2: Tangenttien nollakohdat x_k lähestyvät funktion nollakohtaa pisteessä $x = 0$.

Tangentin nollakohdat x_k toimivat yleisesti yhä tarkempina approksimaatioina funktion nollakohdalle kun k kasvaa. Näin saatavaa menetelmää kutsutaan Newtonin menetelmäksi. Johdetaan nyt iteraatiokaava, joka mahdollistaa seuraavan approksimaation x_{k+1} laskemisen edellisestä approksimaatiosta x_k. Pisteessä x_0 muodostetun lineaarisen approksimaation (5.1) nollakohta x_1 saadaan seuraavasti:

$$L_{x_0}(x_1) = 0 \quad \Longleftrightarrow \quad f(x_0) + f'(x_0)(x_1 - x_0) = 0 \quad \Longleftrightarrow \quad x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}.$$

Vastaavalla päättelyllä pisteessä x_1 muodostetun tangentin nollakohta x_2 saadaan kaavasta

$$x_2 = x_1 - \frac{f(x_1)}{f'(x_1)},$$

ja yleisemmin pisteessä x_k muodostetun tangentin nollakohta x_{k+1} saadaan kaavasta

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}. \tag{5.2}$$

Huomaa, että tämä kaava olettaa, että $f'(x_k) \neq 0$. Jos $f'(x_k) = 0$, lineaarinen approksimaatio $L_{x_k}(x) = f(x_k) + f'(x_k)(x - x_k) = f(x_k)$ vastaa vaakasuoraa viivaa, jolla ei ole nollakohtaa, mikä tarkoittaa, että iteraatiota ei voida jatkaa, koska ei ole seuraavaa nollakohtaa x_{k+1}, jonka kohdalle muodostaa lineaarinen approksimaatio. Kaavan (5.2) avulla voidaan laskea uusia approksimaatioita rekursiivisesti, kun x_0 on valittu. Pistettä x_0 kutsutaan alkuarvaukseksi. Mitä lähempänä alkuarvaus on funktion f nollakohtaa x^*, sitä luotettavammin Newtonin menetelmä toimii ja sitä nopeammin approksimaatiot suppenevat ratkaisuun.

Määritelmä 5.4 (Newtonin menetelmä)**.** Olkoon $f\colon \mathbb{R} \to \mathbb{R}$ derivoituva funktio ja $x_0 \in \mathbb{R}$ *alkuarvaus*. *Newtonin menetelmä* on jono approksimaatioita funktion f nollakohdalle, joka saadaan iteraatiolla

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \tag{5.3}$$

missä $k \geq 0$.

Esimerkki 5.5. Käytetään Newtonin menetelmää alkuarvauksella $x_0 = 4$ laskemaan approksimaatiot x_1 ja x_2 yhtälön $x^2 = 0$ nollakohdalle, joka on $x^* = 0$. Koska $f(x) = x^2$ ja $f'(x) = 2x$, Newtonin menetelmän iteraatiokaava (5.3) on

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_{k+1})} = x_k - \frac{x_k^2}{2x_k}. \tag{5.4}$$

Siten

$$\begin{aligned} x_0 &= 4, \\ x_1 &= x_0 - \frac{f(x_0)}{f'(x_0)} = 4 - \frac{4^2}{2 \cdot 4} = 2, \\ x_2 &= x_1 - \frac{f(x_1)}{f'(x_1)} = 2 - \frac{2^2}{2 \cdot 2} = 1. \end{aligned}$$

Tässä tapauksessa iteraatiokaava (5.4) yksinkertaistuu muotoon

$$x_{k+1} = x_k - \frac{x_k^2}{2x_k} = x_k - \frac{1}{2}x_k = \frac{1}{2}x_k,$$

joten

$$x_{k+1} = \frac{1}{2}x_k = \frac{1}{2} \cdot \frac{1}{2}x_{k-1} = \cdots = \frac{1}{2^{k+1}x_0}.$$

Toisin sanoen tässä tapauksessa jokainen x_k olisi voitu laskea suoraan arvosta x_0 ilman iteraatiota. *Näin käy käytännössä hyvin harvoin.*

Edellisessä esimerkissä kuvattu prosessi, jossa *samat vaiheet* toistetaan yhä uudelleen, kutsutaan *iteraatioksi*. Yhtä iteraatiovaihetta kutsutaan *iteraatioaskeleeksi*. Iteraatiolla laskettuja arvoja, kuten yllä olevaa lukua x_k, kutsutaan *iteraateiksi*. Siten Newtonin menetelmä perustuu iteraatioon, ja kaava (5.3) on Newtonin menetelmän kaava, rekursiivinen kaava tai *iteraatiokaava*.

Newtonin menetelmä ei aina toimi:

- Vaikka iteraatit suppenevat, ne eivät vältämättä suppene oikeaa nollakohtaa kohti.
- Geometrisesti on ilmeistä, että voi käydä niin, että iteraatit jäävät toistamaan kahta perättäistä arvoa. Näin on esimerkiksi funktion $f(x) = x^2 + x + 1$ tapauksessa, kun alkuarvaus tai jokin myöhempi iteraatti on 0 tai -1.
- Iteraatiokaava ei selvästi toimi, jos derivaatta joudutaan laskemaan sellaisessa kohdassa, jossa se menee nollaksi.
- Iteraatiokaava ei selvästi toimi, jos derivaatta joudutaan laskemaan sellaisessa kohdassa, jossa sitä ei ole olemassa, kuten funktiolla $f(x) = \left|x^2 - 1\right| - 1$ kohdissa $x = \pm 1$. Vähemmän selvästi ongelmia voi tulla myös tällaisten kohtien ympäristössä, kuten funktiolla $f(x) = \sqrt[3]{x}$ kohdan $x = 0$ ympäristössä.
- Joissakin tapauksissa iteraatit hajaantuvat, jos alkuarvaus on liian kaukana nollakohdasta, kuten funktion $f(x) = x/(x^2 + 1)$ tapauksessa,

Seuraava lause antaa riittävät ehdot Newtonin menetelmän toimimiselle.

Lause 5.6. *Olkoon $f(c) = 0$ ja $f'(c) \neq 0$. Oletetaan, että f on kahdesti jatkuvasti deri-*

voituva välillä $[c-a, c+a]$ jollekin $a > 0$. Tällöin Newtonin menetelmän iteraatiokaava suppenee lukuun c, jos alkuarvaus x_0 on riittävän lähellä lukua c.

Todistus. Sivuutetaan. □

Huomaa, ettei lause kata kaikkia funktioita, joille Newtonin menetelmä toimii. Esimerkiksi funktiolle $f(x) = x^2$ pätee $f'(x) = 0$, joten lauseen oletukset eivät ole voimassa, mutta edellä on nähty, että Newtonin menetelmä toimii kyseiselle funktiolle.

Lause ei anna luvun c arvoa tarkasti, mutta tieto siitä, että alkuarvauksen tulee olla riittävän lähellä, on silti hyödyllinen. Esimerkiksi funktio $f(x) = x/(x^2+1)$ toteuttaa lauseen oletukset, joten Newtonin menetelmä toimii sille varmasti, kunhan alkuarvaus valitaan sopivasti. Sen sijaan $f(x) = \sqrt[3]{x}$ ei ei toteuta lauseen oletuksia (Miksei?), joten Newtonin menetelmä ei välttämättä toimi, vaikka alkuarvaus valittaisiin kuinka lähelle nollakohtaa hyvänsä.

Jos Newtonin menetelmä ei toimi ensimmäisellä yrityksellä, niin ei ole syytä luovuttaa, vaan tulee kokeilla uutta alkuarvausta. Nollakohta voidaan myös selvittää ensin karkeasti vaikka puolitusmenetelmällä. Tästä syystä kehittyneemmissä algoritmeissa, kuten MATLABin `fzero`-funktiossa, sovelletaan useampaa menetelmää.

5.2 Newtonin menetelmä yhtälöryhmille

Newtonin menetelmä yhtälöryhmille on lähes identtinen yhden muuttujan tapauksen kanssa, kun se muotoillaan vektoriarvoisia funktioita käyttäen. Tätä varten tulee tutustua käsitteeseen nimeltä *Jacobin matriisi*, joka on gradientin yleistys vektoriarvoisille funktioille. Kerrataan ennen sen esittelyä myös muita tarpeellisia käsitteitä.

5.2.1 Epälineaariset yhtälöryhmät

Yhtälöryhmä on lineaarinen, jos se on muotoa

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \tag{5.5}$$
$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \tag{5.6}$$
$$\vdots \tag{5.7}$$
$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m, \tag{5.8}$$

missä a_{ij} ja b_i ovat vakioita ja x_j muuttujia. Muissa tapauksissa yhtälöryhmä on *epälineaarinen*. Yhtälöryhmä on siis epälineaarinen, jos siinä on yksikin termi, joka ei vakio tai muotoa vakio · muuttuja. Esimerkiksi yhtälöryhmä

$$\begin{aligned} 4xy + y &= 1 \\ x - 2y &= 3 \end{aligned}$$

on epälineaarinen termin $4xy$ vuoksi ja yhtälöryhmä

$$\begin{aligned} 4x + y &= 1 \\ x - 2\sin(y) &= 3 \end{aligned}$$

termin $-2\sin(y)$ vuoksi.

Lineaaariset yhtälöryhmät voidaan kirjoittaa muotoon $\mathbf{Ax} = \mathbf{b}$, missä $\mathbf{A}$ on vakiomatriisi, ja niillä on aina joko täsmälleen 1, 0 tai ääretön ratkaisua. Ne voidaan kaikki ratkaista Gaussin algoritmilla, ja niille on olemassa myös Gaussian algoritmia ja erityisesti Newtonin menetelmää tehokkaampia numeerisia ratkaisumenetelmiä.

Epälineaarisia yhtälöryhmiä ei voida kirjoittaa muotoon $\mathbf{Ax} = \mathbf{b}$, missä $\mathbf{A}$ on vakiomatriisi, ja niiden ratkaisujen lukumäärä voi olla muukin kuin 1, 0 tai ääretön. Niiden ratkaiseminen on merkittävästi vaikeampaa kuin lineaaristen yhtälöryhmien.

5.2.2 *Usean muuttujan funktion nollakohdat*

Yhden muuttujan funktion nollakohdat ovat niitä x-akselin pisteitä, joissa funktion kuvaaja, joka on usein jokin käyrä, leikkaa x-akselin. Nämä ovat usein erillisiä pisteitä ja niitä on usein äärellinen määrä.

Kahden muuttujan reaaliarvoisen funktion nollakohdat ovat niitä xy-tason pisteitä, joissa funktion kuvaaja, joka on usein jokin pinta, leikkaa xy-tason. Nämä muodostavat yleensä jonkin käyrän, ja tällöin näitä pisteitä on äärettömästi. Esimerkiksi funktion $f(x,y) = x^2 + y^2 - 1$ nollakohdille pätee

$$\begin{aligned} f(x,y) &= 0 \\ x^2 + y^2 - 1 &= 0 \\ x^2 + y^2 &= 1, \end{aligned}$$

joten ne muodostavat origokeskisen 1-säteisen ympyrän. Kahden muuttujan tapauksessa saatetaan puhua nollakohtien sijaan myös tasa-arvokäyristä $f(x,y) = 0$, jotka siis tarkoittavat niiden xy-tason pisteiden muodostamia käyriä, joissa funktion korkeus on nolla (Vertaa tasa-arvokäyriä karttojen korkeuskäyriin).

Kolmen muuttujan reaaliarvoisen funktion nollakohdat muodostavat yleensä pintoja. Esimerkiksi funktion $f(x,y) = x^2 + y^2 + z^2 - 1$ nollakohdat muodostavat origokeskisen 1-säteisen pallon $x^2 + y^2 + z^2 = 1$. Kolmen muuttujan tapauksessa saatetaan puhua nollakohtien sijaan myös tasa-arvopinnoista $f(x,y,z) = 0$.

5.2.3 *Tangenttitaso*

Kahden muuttujan funktioilla tangenttisuoraa vastaava käsite on tangenttitaso. Kahden muuttujan funktiolle f pisteeseen (x_0, y_0) muodostettu lineaarinen approksimaatio eli tangenttitaso eli 1. asteen Taylorin polynomi on muotoa

$$L(x,y) = f(x_0,y_0) + f_x(x_0,y_0)(x - x_0) + f_y(x_0,y_0)(y - y_0).$$

Kahden muuttujan funktion nollakohtia voidaan arvioida nollakohdan lähelle muodostetun tangenttitason nollakohdilla hieman vastaavasti kuin yhden muuttujan nollakohtia tangenttisuoran nollakohdilla. Erona on kuitenkin se, että vain osa tangenttitason nollakohdista, jotka siis muodostavat suoran, arvioivat hyvin osaa funktion nollakohdista. Oheisessa kuvassa on esitetty funktion $f(x,y) = 3 - x^2 - y^2$ sekä sille pisteeseen $(1,1)$ muodostetun tangenttitason $L(x,y) = 1 - 2(x-1) - 2(y-1)$ nollakohtia. Huomaa, että vain osa suoran pisteistä arvioi hyvin osaa funktion nollakohdista.

5.2.4 *Vektoriarvoiset funktiot*

Vektoriarvoiset funktiot ovat yhden tai useamman muuttujan funktioita, joiden arvot ovat vektoreita. Esimerkiksi

$$\mathbf{f}\colon \mathbb{R} \to \mathbb{R}^3, \quad \mathbf{f}(t) = \begin{bmatrix} t^2 \\ t^2 \\ 3 \end{bmatrix}$$

on yhden muuttujan vektoriarvoinen funktio, jonka arvot ovat kolmiulotteisia vektoreita. Tällainen funktio voisi esimerkiksi kuvata kappaleen (kolmiulotteista) paikkaa ajan t funktiona. Funktio

$$\mathbf{f}\colon \mathbb{R}^3 \to \mathbb{R}^3, \quad \mathbf{f}(x,y,z) = \begin{bmatrix} xz \\ y+1 \\ x - 2z + \sin(y) \end{bmatrix}$$

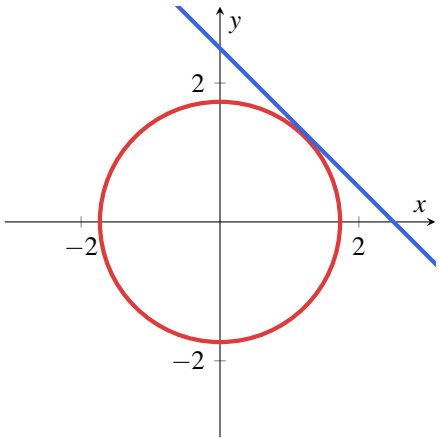

Kuva 5.3: Funktio $f(x,y) = 3 - x^2 - y^2$ sekä tangenttitaso $L(x,y) = 1 - 2(x-1) - 2(y-1)$ pisteessä $(1,1)$ ja sen nollakohdat.

puolestaan on kolmen muuttujan vektoriarvoinen funktio, jonka arvot ovat kolmiulotteisia vektoreita. Tällainen funktio voisi esimerkiksi esittää tuulen nopeusvektoria paikan (x,y,z) funktiona.

Yleisesti vektoriarvoiset funktiot ovat muotoa

$$\mathbf{f}\colon D \to \mathbb{R}^n,\ D \subset \mathbb{R}^m, \quad \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x}) \end{bmatrix},$$

ja funktioita f_i kutsutaan *komponenttifunktioiksi*. Voidaan myös merkitä $\mathbf{f}(x_1, x_2, \ldots, x_m)$, mutta vektorimerkintä muuttujille on selvästi lyhempi usean muuttujan tapauksessa.

Vektoriarvoisen funktion nollakohdilla tarkoitetaan niiden muuttujan arvojen, joille pätee $\mathbf{f}(\mathbf{x}) = \mathbf{0}$, muodostamaa joukkoa. Tästä seuraa, että yhtälöryhmän ratkaiseminen voidaan tulkita yhtäpitävästi myös vektoriarvoisen funktion nollakohtien ratkaisemiseksi. Esimerkiksi voidaan kirjoittaa

$$\begin{aligned} x^2 + y^2 &= 3 \\ (x-2)^2 + (y-1)^2 &= 2, \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} x^2 + y^2 - 3 &= 0 \\ (x-2)^2 + (y-1)^2 - 2 &= 0 \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} f(x,y) &= 0 \\ g(x,y) &= 0, \end{aligned}$$

ja määritellä funktio

$$\mathbf{f}(x,y) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix} = \begin{bmatrix} x^2 + y^2 - 3 \\ (x-2)^2 + (y-1)^2 - 2 \end{bmatrix},$$

jolloin alkuperäinen yhtälöpari voidaan tulkita yhtälöksi $\mathbf{f}(x,y) = \mathbf{0}$.

Kun Newtonin menetelmää yhtälöryhmille yleistettäessä ajatellaan, että ollaan ratkaisemassa vektoriarvoisen funktion nollakohtia, iteraatiokaava saadaan lähes identtiseen muotoon yhden muuttujan tapauksen kanssa. Tällöin x_k ja x_{k+1} korvautuvat vektoreilla $\mathbf{x}_k$ ja $\mathbf{x}_{k+1}$ ja reaaliarvoinen funktio f vektoriarvoisella funktiolla $\mathbf{f}$.

5.2.5 *Jacobin matriisi*

Reaaliarvoisen kahden muuttujan funktion $f\colon D \to \mathbb{R}$, $D \subset \mathbb{R}^2$, *gradientti* on funktio

$$\nabla f(x,y) = \begin{bmatrix} f_x(x,y) \\ f_y(x,y) \end{bmatrix},$$

joka on lyhyesti sanottuna eräänlainen derivaatan yleistys. Yleisesti usean muuttujan funktion $f\colon D \to \mathbb{R}$, $D \subset \mathbb{R}^n$, gradientti on funktio

$$\nabla f(\mathbf{x}) = \begin{bmatrix} f_{x_1}(\mathbf{x}) \\ f_{x_2}(\mathbf{x}) \\ \vdots \\ f_{x_n}(\mathbf{x}) \end{bmatrix}.$$

Kahden muuttujan vektoriarvoisen funktion

$$\mathbf{f}\colon D \to \mathbb{R}^2,\ D \subset \mathbb{R}^2, \quad \mathbf{f}(x,y) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix},$$

Jacobin matriisi on matriisiarvoinen funktio

$$\mathrm{J}_{\mathbf{f}}(x,y) = \begin{bmatrix} f_x(x,y) & f_y(x,y) \\ g_x(x,y) & g_y(x,y) \end{bmatrix}.$$

Esimerkiksi funktion

$$\mathbf{f}(x,y) = \begin{bmatrix} x^2 y \\ x + 2y^3 \end{bmatrix}$$

Jacobin matriisi on

$$\mathrm{J}_{\mathbf{f}}(x,y) = \begin{bmatrix} 2xy & x^2 \\ 1 & 6y^2 \end{bmatrix}.$$

Yleisesti usean muuttujan vektoriarvoisen funktion

$$\mathbf{f}\colon D \to \mathbb{R}^m,\ D \subset \mathbb{R}^n, \quad \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix},$$

Jacobin matriisi on matriisiarvoinen funktio

$$\mathrm{J}_{\mathbf{f}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}.$$

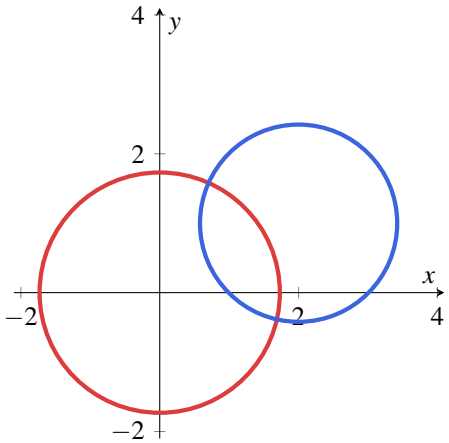

Kuva 5.4: Yhtälöt $x^2+y^2=3$ ja $(x-2)^2+(y-1)^2=2$ pätevät samanaikaisesti vain silloin, kun vastaavat käyrät leikkaavat toisensa.

Kun myöhemmin Newtonin menetelmä laajennetaan yhtälöryhmille, niin yhden muuttujan iteraatiokaavassa $x_{k+1}=x_k-f(x_k)/f'(x_k)$ esiintyvä derivaatalla $f'(x_k)$ jakaminen korvataan Jacobin matriisin käänteismatriisilla $\mathbf{J_f}(\mathbf{x})^{-1}$ kertomisella.

5.2.6 Newtonin menetelmän geometrinen idea yhtälöparille

Yhtälöparin ratkaisemissa on kyse tasokäyrien leikkuaspisteiden ratkaisemisesta. Esimerkiksi yhtälöparin

$$x^2+y^2=3 \tag{5.9}$$
$$(x-2)^2+(y-1)^2=2 \tag{5.10}$$

ratkaisut ovat oheisen kuvan käyrien leikkauspisteet. Jotta nähdään, miksi Newtonin menetelmää voidaan soveltaa myös yhtälöparien ratkaisemiseen, yhtälöparia joudutaan kuitenkin tarkastelemaan hieman eri näkökulmasta.

Edellinen yhtälöpari voidaan kirjoittaa muodossa

$$x^2+y^2-3=0$$
$$(x-2)^2+(y-1)^2-2=0,$$

missä yhtälöiden vasemmat puolet voidaan tulkita funktioiksi $f(x,y)=x^2+y^2-3$ ja $g(x,y)=(x-2)^2+(y-1)^2-2$. Näin tulkittuna yhtälöparissa

$$f(x,y)=0$$
$$g(x,y)=0$$

etsitään kahden muuttujan funktioiden f ja g yhteisiä nollakohtia.

Kahden muuttujan funktion nollakohtia voidaan arvioida nollakohdan lähelle pisteeseen (x_0,y_0) muodostetun tangenttitason nollakohdilla vastaavasti kuin yhden muuttujan nollakohtia tangenttisuoran nollakohdilla. Täten funtioiden f ja g yhteisiä nollakohtia voidaan arvioida funktioille muodostettujen tangenttitasojen nollakohtien muodostamien suorien leikkauspisteillä. Oheisessa kuvassa on esitetty funktioiden f ja g nollakohdat sekä niille pisteeseen $(x_0,y_0)=(1,1)$ muodostettujen tangenttitasojen nollakohdat. Suorien leikkauspiste (x_1,y_1) siis arvioi karkeasti yhtälöparin (5.9) ylempää nollakohtaa.

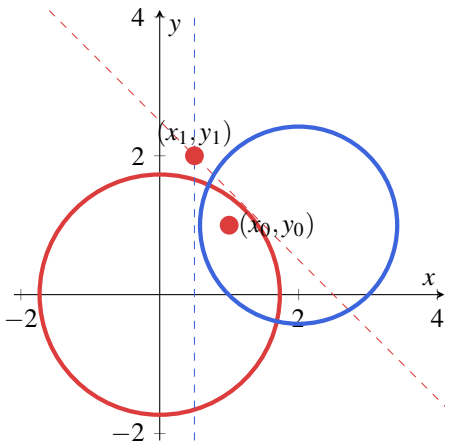

Kuva 5.5: Funktioiden $f(x,y) = x^2 + y^2 - 3$ ja $g(x,y) = (x-2)^2 + (y-1)^2 - 2$ tangenttitasojen nollakohtien muodostamien suorien leikkauspistettä voidaan käyttää funktioiden f ja g yhteisen nollakohdan approksimoimiseen.

Kun edellisen kuvan suorien leikkauspisteeseen (x_1, y_1) muodostetaan uudet tangenttitasot ja lasketaan niiden nollakohtien muodostamien leikkaussuorien leikkauspiste (x_2, y_2), saadaan parempi arvio yhtälöparin ratkaisulle. Tätä prosessia voidaan toistaa loputtomiin, ja usein leikkauspisteet (x_k, y_k) suppenevat kohti yhtälöparin erästä ratkaisua. Tämä on Newtonin menetelmän geometrinen idea kahden muuttujan yhtälöparille. Siirrytään seuraavaksi tarkastelemaan asiaa laskennallisesti.

5.2.7 Newtonin menetelmän kaava yhtälöryhmille

Johdetaan Newtonin menetelmän kaava kahden muuttujan yhtälöparin tapauksessa. Kaikki kahden muuttujan yhtälöparit voidaan kirjoittaa muotoon

$$\begin{aligned} f(x,y) &= 0 \\ g(x,y) &= 0. \end{aligned}$$

Arvioidaan yhtälöparin ratkaisua tangenttitasojen avulla edellisessä luvussa kuvatulla tavalla. Aloitetaan määrittämällä tangenttitasot pisteessä (x_0, y_0). Tangettitasojen yhtälöt ovat

$$L_f(x,y) = f(x_0,y_0) + f_x(x_0,y_0)(x-x_0) + f_y(x_0,y_0)(y-y_0)$$

ja

$$L_g(x,y) = g(x_0,y_0) + g_x(x_0,y_0)(x-x_0) + g_y(x_0,y_0)(y-y_0).$$

Niiden ja xy-tason leikkaussuorat puolestaan ovat $L_f(x,y) = 0$ ja $L_g(x,y) = 0$. Yhtälöparin ratkaisua voidaan arvioida näiden suorien leikkauspisteellä. Se voidaan ratkaista yhtälöparista

$$\begin{aligned} L_f(x,y) &= 0 \\ L_g(x,y) &= 0 \end{aligned}$$

joka on yhtäpitävästi

$$\begin{aligned} f(x_0,y_0) + f_x(x_0,y_0)(x-x_0) + f_y(x_0,y_0)(y-y_0) &= 0 \\ g(x_0,y_0) + g_x(x_0,y_0)(x-x_0) + g_y(x_0,y_0)(y-y_0) &= 0, \end{aligned}$$

josta saadaan

$$\begin{aligned} f_x(x_0,y_0)x + f_y(x_0,y_0)y &= f_x(x_0,y_0)x_0 + f_y(x_0,y_0)y_0 - f(x_0,y_0) \\ g_x(x_0,y_0)x + g_y(x_0,y_0)y &= g_x(x_0,y_0)x_0 + g_y(x_0,y_0)y_0 - g(x_0,y_0), \end{aligned}$$

kun muuttujat ja vakiot siirretään omille puolilleen. Näissä yhtälöissä x ja y ovat siis tuntemattomia ja kaikki muu kertoimet ja termit vakioita.

Yhtälöpari voitaisiin ratkaista suoraviivaisesti, mutta ennen kuin tehdään niin, kiinnitetään huomiota siihen, että yhtälöpari vaikuttaa jollakin tapaa erittäin säännönmukaiselta. Tämä säännönmukaisuus saadaan selkeämmin esille, kun kirjoitetaan yhtälö matriiseja käyttäen:

$$\begin{bmatrix} f_x(x_0,y_0) & f_y(x_0,y_0) \\ g_x(x_0,y_0) & g_y(x_0,y_0) \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} f_x(x_0,y_0) & f_y(x_0,y_0) \\ g_x(x_0,y_0) & g_y(x_0,y_0) \end{bmatrix} \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} - \begin{bmatrix} f(x_0,y_0) \\ g(x_0,y_0) \end{bmatrix}.$$

Tämä voidaan kirjoittaa vielä näppärämmin, kun siirrytään käyttämään merkintöjä

$$\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}, \quad \mathbf{x}_0 = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} \quad \text{ja} \quad \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix}.$$

Samalla havaitaan, että kerroinmatriisi on itse asiassa funktion $\mathbf{f}$ Jacobin matriisi eli että pätee

$$\begin{bmatrix} f_x(x_0,y_0) & f_y(x_0,y_0) \\ g_x(x_0,y_0) & g_y(x_0,y_0) \end{bmatrix} = \mathbf{J_f}(\mathbf{x}).$$

Näitä merkintöjä käyttäen matriisiyhtälö saadaan muotoon

$$\mathbf{J_f}(\mathbf{x}_0)\mathbf{x} = \mathbf{J_f}(\mathbf{x}_0)\mathbf{x}_0 - \mathbf{f}(\mathbf{x}_0),$$

ja olettaen Jacobin matriisi kääntyväksi yhtälöparin ratkaisuksi saadaan

$$\mathbf{x} = \mathbf{x}_0 - \mathbf{J_f}^{-1}(\mathbf{x}_0)\mathbf{f}(\mathbf{x}_0).$$

Alkuarvausta $\mathbf{x}_0$ seuraava iteraatti on siis $\mathbf{x}_1 = \mathbf{x}_0 - \mathbf{J_f}^{-1}(\mathbf{x}_0)\mathbf{f}(\mathbf{x}_0)$ ja seuraava $\mathbf{x}_2 = \mathbf{x}_1 - \mathbf{J_f}^{-1}(\mathbf{x}_1)\mathbf{f}(\mathbf{x}_1)$, ja niin edelleen. Yleisesti meillä on siis $\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{J_f}^{-1}(\mathbf{x}_k)\mathbf{f}(\mathbf{x}_k)$.

Edellinen päätttely yleistyy vastaavalla tavalla myös $n \times n$-yhtälöryhmille.

Määritelmä 5.7 (Newtonin menetelmä yhtälöryhmille)**.** Newtonin menetelmässä yhtälöryhmän $\mathbf{f}(\mathbf{x}) = \mathbf{0}$ likimääräisiä ratkaisuja lasketaan iteraatiolla

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{J_f}^{-1}(\mathbf{x}_k)\mathbf{f}(\mathbf{x}_k),$$

lähtien liikkeelle itse valittavasta arvosta $\mathbf{x}_0$, jota kutsutaan alkuarvaukseksi.

Huomaa, että Newtonin menetelmän kaava yhtälöryhmille on lähes identtinen yhden muuttujan tapauksen kanssa, nyt vain funktiot ja muuttujat ovat vektoreita ja derivaatan paikalla on Jacobin matriisi. Erityisesti tulee muistaa, että Jacobin matriisilla pitää kertoa *vasemmalta*.

Esimerkki 5.8. Käytetään Newtonin menetelmää yhtälöryhmän

$$\begin{aligned} x^2 + y^2 &= 3 \\ (x-2)^2 + (y-1)^2 &= 2 \end{aligned}$$

ratkaisun approksimaation $\mathbf{x}_1$ laskemiseen, kun alkuarvaus on $\mathbf{x}_0 = (1,1)$. Iteraatioon tarvittavat tiedot:

$$\mathbf{f}(x,y) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix} = \begin{bmatrix} x^2 + y^2 - 3 \\ (x-2)^2 + (y-1)^2 - 2 \end{bmatrix}.$$

$$\mathbf{J_f}(x,y) = \begin{bmatrix} 2x & 2y \\ 2(x-2) & 2(y-1) \end{bmatrix}$$

$$\mathbf{J_f}^{-1}(x,y) = \frac{1}{4x(y-1)-4y(x-2)} \begin{bmatrix} 2(y-1) & -2y \\ -2(x-2) & 2x \end{bmatrix}.$$

Ensimmäinen iteraatti:

$$\begin{aligned}
\mathbf{x}_1 &= \mathbf{x}_0 - \mathbf{J_f}^{-1}(\mathbf{x}_0)\mathbf{f}(\mathbf{x}_0) \\
&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{4(1-1)-4(1-2)} \begin{bmatrix} 2(1-1) & -2 \\ -2(1-2) & 2 \end{bmatrix} \begin{bmatrix} 1^2+1^2-3 \\ (1-2)^2+(1-1)^2-2 \end{bmatrix} \\
&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 0 & -2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 2 \\ -4 \end{bmatrix} \\
&= \begin{bmatrix} \frac{1}{2} \\ 2 \end{bmatrix}.
\end{aligned}$$

5.3 Kiintopistemenetelmä

Kiintopistemenetelmä on Newtonin menetelmän kaltainen numeerinen menetelmä yhtälön ratkaisemiseksi.

5.3.1 Kiintopiste

Yleensä muuttujan arvot eivät pysy kuvauksessa samana, vaan kuvautuvat joksikin eri arvoksi. Esimerkiksi funktio $f(x) = x^2$ kuvaa muuttujan arvon $x = 2$ funktion arvoksi $f(x) = 4$. Kyseisellä funktiolla on myös kaksi muuttujan arvoa, jotka eivät muutu kuvauksessa eli $x = 0$ ja $x = 1$. Ne ovat funktion f kiintopisteet.

Määritelmä 5.9 (Kiintopiste)**.** Funktion $f\colon D \to \mathbb{R}$, missä $D \subset \mathbb{R}$, kiintopisteet ovat pisteet $c \in D$, joille $f(c) = c$.

Funktiolla voi edellisen esimerkin tapaan olla useampikin kiintopiste, tai niitä ei välttämättä ole yhtään. Kiintopisteen geometrinen tulkinta on suoran $y = x$ ja funktion f kuvaajan leikkauspisteen x-koordinaatti (joka on toisaalta sama kuin kyseisen pisteen y-koordinaatti). Funktion kiintopisteet voidaan määrittää ratkaisemalla ne yhtälöstä $f(x) = x$. Kokeile funktion $f(x) = x^2$ tapauksessa.

5.3.2 Geometrinen idea

Kiintopistemenetelmä pohjautuu Newtonin menetelmän tapaan hyvin havainnolliseen geometriseen ideaan. Aloitetaan toteamalla vertailun vuoksi, että yhtälö $e^x = -x$ ratkaistaan graafisesti Newtonin menetelmällä seuraavilla vaiheilla, joita on havainnollistettu oheisessa kuvassa:

1. Yhtälö kirjoitetaan muotoon $e^x + x = 0$, eli siirretään kaikki termit samalle puolelle.
2. Piirretään funktion $f(x) = e^x + x$ kuvaaja, jolloin alkuperäisen yhtälön ratkaisut ovat funktion f nollakohdat.
3. Valitaan alkuarvaus x_0, joka on ensimmäinen arvio funktion f nollakohdalle.

4. Piirretään funktiolle f kohtaan x_0 tangentti.
5. Määritetään tangentin nollakohta x_1. Tästä tulee toinen arvio funktion f nollakohdalle.
6. Toistetaan tangenttisuorien piirtämistä vaiheiden 4 ja 5 mukaisesti korvaten aiempi iteraatti x_k uudemmalla x_{k+1}.
7. Tietyissä tapauksissa iteraatit suppenevat kohti funktion f nollakohtaa.

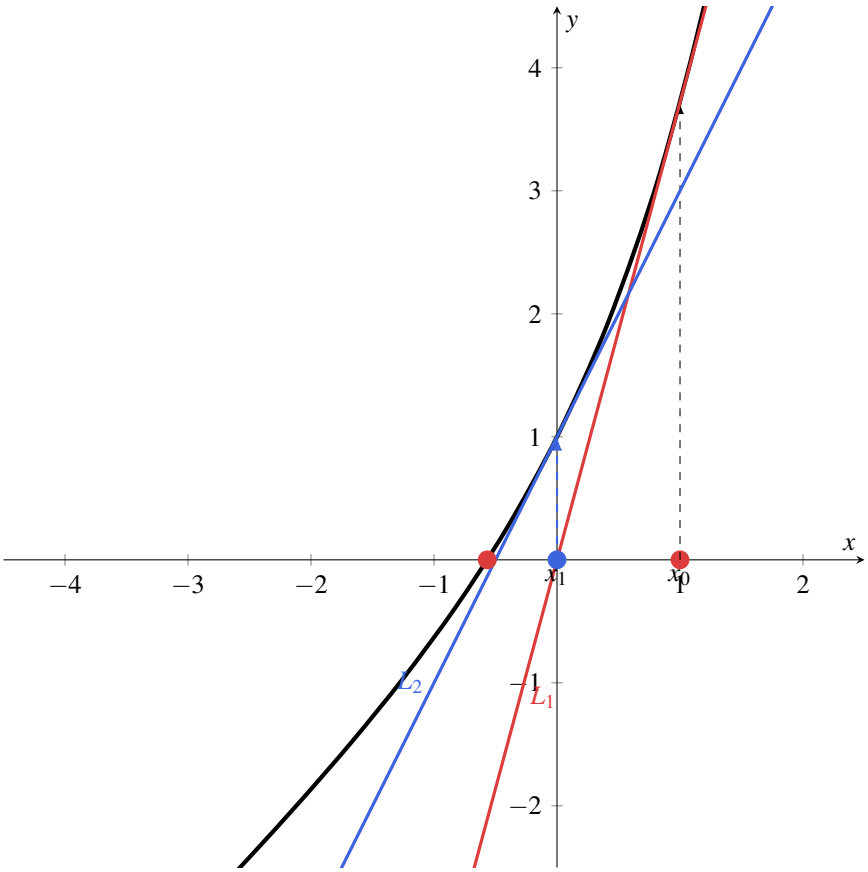

Yhtälö $e^x = -x$ ratkaistaan graafisesti kiintopistemenetelmällä seuraavilla vaiheilla, joita on havainnollistettu oheisessa kuvassa:

1. Yhtälö kirjoitetaan muotoon $x = -e^x$ eli muotoon, jossa toisella puolella on vain x. Tähän on erilaisia valintoja, mitä käsitellään lisää myöhemmin.
2. Piirretään suora $y = x$ ja funktion $g(x) = -e^x$ kuvaaja eli yhtälön molempien puolien kuvaat, jolloin alkuperäisen yhtälön ratkaisut ovat piirrettyjen käyrien leikkauspisteiden vaakakoordinaatit.
3. Valitaan alkuarvaus x_0, joka on ensimmäinen arvio yhtälön ratkaisulle.
4. Siirrytään kohdassa x_0 pystysuunnassa korkeudelle $g(x_0)$.
5. Siirrytään korkeudella $g(x_0)$ vaakasuunnassa suoralle $y = x$ eli pisteeseen $\Big(g(x_0), g(x_0)\Big)$. Pisteen x-koordinaatista tulee uusi arvio x_1 yhtälön ratkaisulle.
6. Toistetaan vaiheiden 4 ja 5 pysty- ja vaakasuuntaisia siirtymiä korvaten aiempi iteraatti x_k uudemmalla x_{k+1}.

7. Tietyissä tapauksissa iteraatit suppenevat kohti yhtälön ratkaisua.

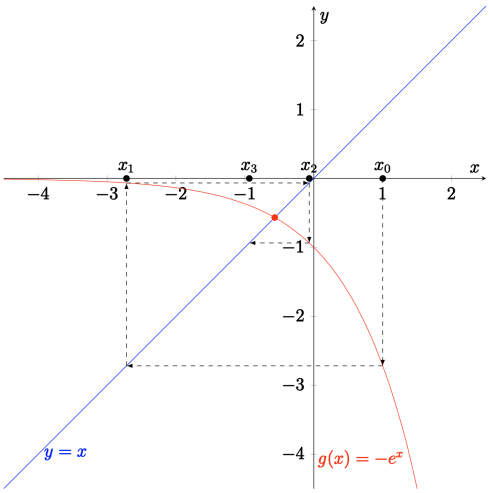

Edellä kiintopistemenetelmää käytettäessä yhtälö $e^x = -x$ olisi voitu ratkaista myös muotoon $x = \ln(-x)$, jolloin tarkasteltu funktio olisikin ollut $g(x) = \ln(-x)$. Tämä on esimerkki siitä, että funktio g ei ole yksikäsitteinen vaan voidaan itse asiassa valita äärettömän monella eri tavalla. Esimerkiksi edellä voidaan kirjoittaa

$$\begin{aligned} -x &= e^x \\ ax - x &= e^x + ax \\ x &= \frac{e^x + ax}{a-1} \end{aligned}$$

jolloin jokaista parametrin a arvoa vastaa eri funktio

$$g(x) = \frac{e^x + ax}{a-1}.$$

Edellä todettiin, että iteraatit suppenevat kohti ratkaisua *tietyissä tilanteissa*. Kiintopistemenetelmä ei siis aina toimi vastaavasti kuin Newtonin menetelmäkään ei aina toiminut. Yhtälön $-x = e^x$ ratkaiseminen valinnalla $g(x) = \ln(-x)$ epäonnistuu jo siksi, että joudutaan tarkastelemaan funktiota g kohdissa, joissa sitä ei ole määritelty (Piirrä kuva ja kokeile eri alkuarvauksia). Iteraatio voi kuitenkin myös epäonnistua, vaikka g olisi määritelty kaikkialla. Esimerkiksi jos yhtälöä

$$x - \frac{x}{2} = 0$$

yritetään ratkaista kirjoittamalla se ensin muotoon $x = 2x$, jolloin siis $g(x) = 2x$, iteraatit hajaantuvat oheisen kuvan mukaisesti.

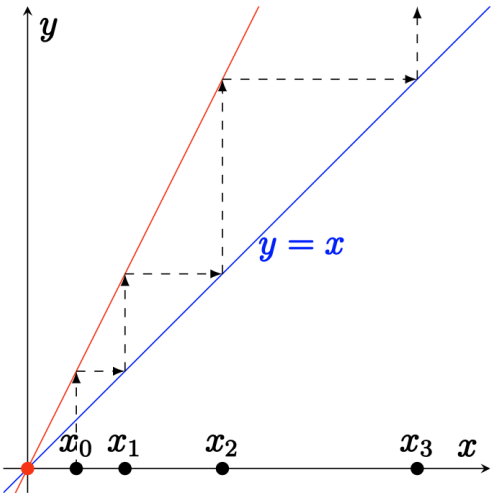

Jos sen sijaan samaa yhtälöä yritetään ratkaista kirjoittamalla se ensin muotoon $x = \frac{x}{2}$, jolloin siis $g(x) = \frac{x}{2}$, iteraatit suppenevatkin oheisen kuvan mukaisesti.

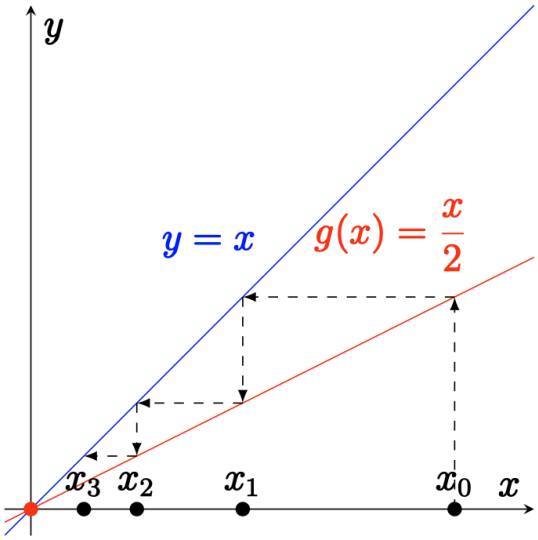

Ilmeinen ero edellä eri tavalla käyttäytyvien funktioiden g välillä on ainakin se, että ensimmäinen on jyrkempi kuin toinen. Vastaavia tarkasteluja toistamalla voi havaita, että juuri funktion g jyrkkyys näyttäisi olevan kriittinen tekijä suppenemisen kannalta. Kiintopistemenetelmä voi epäonnistua myös siksi, että iteraatit eivät suppene oikeaa arvoa kohti. Näin kuitenkin voi käydä vain, jos funktio g ei ole jatkuva.

Lause 5.10. *Olkoon g jatkuva funktio. Jos kiintopisteiteraation $x_{k+1} = g(x_k)$ iteraatit suppenevat, niin ne suppenevat kohti kiintopistettä.*

Todistus. Sivuutetaan. □

Vastaesimerkiksi siitä, miksi funktion g jatkuvuus on oleellinen, käy funktio

$$g(x) = \begin{cases} \frac{x}{2}, & x \neq 0 \\ -1, & x = 0 \end{cases}.$$

5.3.3 *Iteraatiokaava*

Johdetaan kiintopistemenetelmän iteraatiokaava. Tulee siis päätellä, miten x_{k+1} saadaan lasketuksi edellisen arvon x_k perusteella (tai useamman edellisen arvon kuten x_k ja x_{k-1} perusteella, jos tämä osoittautuu tarpeelliseksi). Vertailun vuoksi muistutettakoon, että Newtonin menetelmässä iteraatiokaava oli muotoa

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}.$$

Lähdetään tarkastelemaan ensimmäisiä iteraatioita edellä käsitellyn kuvan mukaisesti.

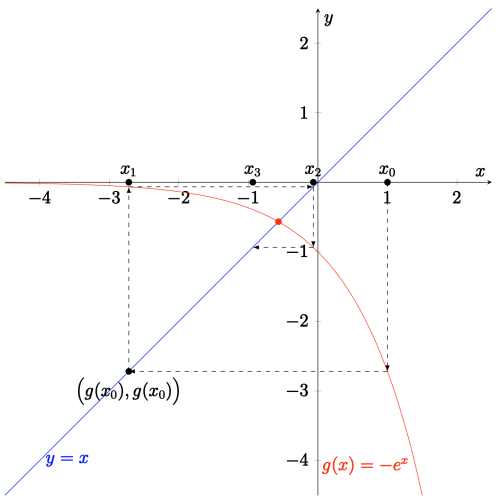

Alkuarvaus x_0 valitaan itse. Tämän jälkeen siirrytään korkeudelle $g(x_0)$, liikutaan suoralle $y = x$ pisteeseen $\big(g(x_0), g(x_0)\big)$ ja otetaan tämän pisteen vaakakoordinaatti uudeksi iteraatiksi x_1. Pätee siis $x_1 = g(x_0)$. Vastaavalla päättelyllä havaitaan, että pätee $x_2 = g(x_1)$, $x_3 = g(x_2)$ ja niin edelleen, eli yleisesti pätee $x_{k+1} = g(x_k)$.

Määritelmä 5.11 (Kiintopistemenetelmä)**.** *Kiintopistemenetelmässä* funktion $x - g(x)$ nollakohtaa approksimoidaan iteraatiokaavalla

$$x_{k+1} = g(x_k),$$

lähtien liikkeelle alkuarvauksesta x_0.

Otetaan yksinkertainen mutta havainnollinen esimerkki, jota on jo tarkasteltu edellä graafisesti.

Esimerkki 5.12. Ratkaistaan yhtälö

$$x - \frac{x}{2} = 0$$

kiintopistemenetelmällä. Ilmeinen valinta on kirjoittaa yhtälö muotoon $x = \frac{x}{2}$, jolloin iteraatiokaavaksi saadaan siis $x_{k+1} = \frac{x_k}{2}$, eli tällöin $g(x) = \frac{x}{2}$. Jos alkuarvaukseksi valitaan $x_0 = 4$, saadaan

$$\begin{aligned}
x_0 &= 4 \\
x_1 &= g(x_0) = g(4) = \frac{4}{2} = 2 \\
x_2 &= g(x_1) = g(2) = \frac{2}{2} = 1 \\
x_3 &= g(x_2) = g(1) = \frac{1}{2} \\
&\vdots
\end{aligned}$$

Saadaan siis lukujono, joka näyttäisi suppenevan kohti nollaa. Sijoittamalla tai ratkaisemalla voidaan tarkastaa, että tämä on oikea ratkaisu. Katso myös edellisen luvun kuva asiasta tai piirrä oma kuva.

Toinen ilmeinen valinta on kirjoittaa yhtälö muotoon $x = 2x$, jolloin iteraatiokaavaksi saadaan $x_{k+1} = 2x_k$. Tässä tapauksessa iteraatio hajaantuu jokaisella nollasta poikkeavalla alkuarvauksella. Esimerkiksi tapauksessa $x_0 = 4$ pätee:

$$\begin{aligned}
x_0 &= 4 \\
x_1 &= g(x_0) = g(4) = 2 \cdot 4 = 8 \\
x_2 &= g(x_1) = g(8) = 2 \cdot 8 = 16 \\
x_3 &= g(x_2) = g(16) = 2 \cdot 16 = 32 \\
&\vdots
\end{aligned}$$

Kiintopistemenetelmän nopea tarkastelu voidaan tehdä samalla tavoin kuin Newtonin menetelmässä, tallentamalla alkuarvaus muuttujaan `ans` ja toistuvasti suorittamalla komentoa `g(ans)`. Huolellisempi tarkastelu tehdään parhaiten silmukan avulla.

Newtonin menetelmä voidaan itse asiassa tulkita kiintopistemenetelmäksi, jossa

$$g(x) = x - \frac{f(x)}{f'(x)}.$$

Tämä mahdollistaa myös Newtonin menetelmän teorian käsittelemisen kiintopistemenetelmän teorian avulla, mitä ei toistaiseksi tehdä tällä kurssilla, sillä kiintopistemenetelmän teorian käsittely jäi tänä vuonna varsin suppeaksi.

5.3.4 Suppenemisesta

Edellä todettiin, että kiintopisteiteraatio näyttäisi suppenevan, kun funktion g kuvaaja nouse tai laskee riittävän loivasti. Seuraava tulos antaa tarkan ehdon.

Lause 5.13. *Olkoon c funktion g kiintopiste. Oletetaan, että g on derivoituva pisteessä c. Jos $\left|g'(c)\right| < 1$, kiintopisteiteraatio suppenee, kunhan x_0 valitaan riittävän läheltä kiintopistettä. Tässä tapauksessa kiintopistettä kutsutaan vetäväksi eli attraktiiviseksi. Toisaalta, jos $\left|g'(c)\right| > 1$, kiintopiste-iteraatio suppenee vain tapauksessa, jossa $x_n = c$. Tässä tapauksessa kiintopistettä kutsutaan hylkiväksi eli repulsiiviseksi.*

Todistus. Sivuutetaan. □

Lausetta ei todisteta, mutta havainnollistetaan iteraattien muutoksen ja derivaatan välistä yhteyttä hyvin karkeasti. Jotta iteraatio suppenisi, kuvissa nähtyjen vaakasuuntaisten siirtymien pitäisi pienetä. Tämä tarkoittaa, että tulisi päteä

$$\frac{|x_{k+2} - x_{k+1}|}{|x_{k+1} - x_k|} < K$$

jollakin $K \in (0,1)$ eli että seuraava vaakasuuntainen siirtymä on edellistä pienempi. Tämä ehto voidaan kirjoittaa myös muotoon

$$\left| \frac{g(x_{k+1}) - g(x_k)}{x_{k+1} - x_k} \right| < K,$$

mikä tarkoittaa, että välin (x_k, x_{k+1}) (tai (x_{k+1}, x_k), jos $x_k > x_{k+1}$) keskimääräisen muutosnopeuden tulee olla itseisarvoltaan alle yhden. Jos pätee $\left|g'(c)\right| < 1$ eli hetkellinen nopeus kohdassa c on alle yhden, niin pisteen c ympäristöstä on mahdollista löytää väli, jolla keskinopeus on alle yhden.

5.4 Jacobin menetelmä lineaarisille yhtälöryhmille

Lineaaristen yhtälöiden ryhmien ratkaisut jakautuvat kolmeen kategoriaan: tyyppiin: yksikäsitteinen ratkaisu, monikäsitteinen ratkaisu tai ei ratkaisua. Olipa yhtälöryhmän ratkaisu mitä tahansa näistä kolmesta tyypistä, se saadaan aina selvitettyä suoraviivaisesti Gaussin algoritmilla. Tästä johtuen voisi ajatella, ettei lineaaristen yhtälöryhmien ratkaisemiseen tarvittaisi sen kummempaa numeerista teoriaa, vaan laitettaisiin vain tietokone selvittämään ratkaisu Gaussin algoritmia käyttäen. Toisaalta lineaaristen yhtälöryhmien ratkaiseminen on havaittu työlääksi ja työmäärän kasvavan *kuutiollisesti* yhtälöryhmän koon kasvaessa. Tämä on se, mikä aiheuttaa numeeristen ratkaisumenetelmien tarpeen. Riittävän suurilla matriiseilla laskentateho loppuu väistämättä kesken. Toinen syy on se, että pyöristysvirheet voivat vaikuttaa merkittävästi lopputulokseen. Tämä aiheuttaa tarpeen kehittää kevyempi ja tarkempia menetelmiä lineaaristen yhtälöryhmien ratkaisemiseen.

Numeerisella menetelmällä löydetään kerrallaan vain yksi ratkaisu yhtälölle tai yhtälöryhmälle. Niillä ei täten saada suoran lineaarisen yhtälöryhmän monikäsitteistä ratkaisua, joka sisältää vapaita parametreja, vaan menetelmän lopputuloksena on vain kokoelma ratkaisua arvioivia desimaalilukuja. Tästä johtuen tällä kurssilla lineaaristen yhtälöryhmien numeerinen ratkaiseminen keskittyy vain yhtälöryhmiin, joilla on yksikäsitteinen ratkaisu. Tämä tarkoittaa käytännössä $n \times n$-yhtälöryhmiä, sillä matalan kerroinmatriisin tapauksessa, ratkaisu ei voi koskaan olla yksikäsitteinen (liian vähän yhtälöitä) ja korkean kerroinmatriisin tapauksessa yksikäsitteinen ratkaisu on varsin harvinainen (liikaa yhtälöitä). Yhtälöryhmän kerroinmatriisin voi siis tässä luvussa olettaa neliömatriisiksi, ellei toisin mainita.

5.4.1 Suorat ja iteratiiviset menetelmät

Newtonin menetelmässä ei saada kerralla hyvää arviota yhtälön ratkaisulle, vaan sen sijaan saadaan jono arvioita, jotka (tietyin ehdoin) lähestyvät tarkkaa ratkaisua. Sen sijaan kun Gaussin algoritmilla ratkaistaan numeerisesti lineaarinen yhtälöryhmä, ratkaisulle saadaan vain yksi arvio (joka voi poikkeustapauksessa olla tarkkakin). Jälkimmäisessä ei siis ole kyse iteratiivisesta prosessista, ja se on esimerkki *suorasta menetelmästä*, kun taas Newtonin menetelmä on esimerkki *iteratiivisesta menetelmästä*. Suora menetelmä on siis ei-iteratiivinen menetelmä, jolla ratkaisu saadaan teoriassa tarkasti mutta jonka soveltaminen johtaa käytännössä vain arvioon johtuen esimerkiksi pyöristysvirheestä ja reaalilukujen rajallisesta esitystarkkuudesta tietokoneissa.

Lineaaristen yhtälöryhmien ratkaisemiseksi on sekä suoria että iteratiivisia menetelmiä. Tällä kurssille keskitytään iteratiivisiin menetelmiin. Myös suoria menetelmiä käsitellään hieman, jotta asiasta saa paremman yleiskäsityksen, mutta merkittävän suoran menetelmän, LU-hajotelman,

tarkempi käsittely tapahtuu muilla kursseilla. Lineaarisia yhtälöryhmiä voidaan ratkaista Gaussin algoritmin ja sen muunnelmien lisäksi myös ainakin Gaussin matriisia ja Cramerin sääntöä käyttäen. Kaikki nämä ovat suoria menetelmiä, ja vaikka niillä saadaan teoriassa aina tarkka ratkaisu, niin käytännössä liukuluvuilla laskettaessa ratkaisusta tulee vain arvio.

5.4.2 Jacobin menetelmä

Yritetään ratkaista yhtälöryhmä

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

kiintopistemenetelmää käyttäen. Halutaan siis kirjoittaa yhtälöryhmä muotoon $\mathbf{x} = \mathbf{g}(\mathbf{x})$. Tähän on äärettömästi erilaisia vaihtoehtoja, mutta tehdään tämä myöhemmin selviävistä syistä johtuen niin, että ratkaistaan kultakin riviltä diagonaalia vastaava muuttuja:

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} 4x_1 &= 8 - 2x_2 - x_3 \\ 5x_2 &= 12 - x_1 - 3x_3 \\ 3x_3 &= 8 - x_1 + x_2 \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} x_1 &= \frac{8}{4} - \frac{2}{4}x_2 - \frac{1}{4}x_3 \\ x_2 &= \frac{12}{5} - \frac{1}{5}x_1 - \frac{3}{5}x_3 \\ x_3 &= \frac{8}{3} - \frac{1}{3}x_1 - \frac{1}{3}x_2. \end{aligned}$$

Kiintopistemenetelmän iteraatiokaavaksi saatiin siis tällä valinnalla

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 2 \\ \frac{12}{5} \\ \frac{8}{3} \end{bmatrix} + \begin{bmatrix} 0 & \frac{1}{2} & -\frac{1}{4} \\ \frac{1}{5} & 0 & -\frac{3}{5} \\ \frac{1}{3} & -\frac{1}{3} & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k.$$

Kun kaavaa kokeillaan käyttää, havaitaan, että iteraatit suppenevat alkuarvauksesta riippumatta kohti oikeaa ratkaisua $\mathbf{x} = \begin{bmatrix} 1 & 1 & 2 \end{bmatrix}^\mathsf{T}$ alkuarvauksesta riippumatta. Esimerkiksi tapauksessa $\mathbf{x}_0 = \begin{bmatrix} 0 & 0 & 0 \end{bmatrix}^\mathsf{T}$ pätee

$$\mathbf{x}_1 \approx \begin{bmatrix} 2.0000 \\ 2.4000 \\ 2.6667 \end{bmatrix}, \quad \mathbf{x}_2 \approx \begin{bmatrix} 0.1333 \\ 0.4000 \\ 1.2000 \end{bmatrix}, \quad \ldots, \quad \mathbf{x}_{35} \approx \begin{bmatrix} 1.0000 \\ 1.0000 \\ 2.0000 \end{bmatrix}.$$

Suppenemisehto Kun edellä käsitelty yhtälöryhmä kirjoitetaan muotoon $\mathbf{x} = \mathbf{g}(\mathbf{x})$ eri tavalla kuin edellä, se ei välttämättä suppenekaan. Esimerkiksi jos käytetään yksinkertaisinta valintaa

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

eli yhtäpitävästi

$$\begin{aligned} x_3 &= 8 - 4x_1 - 2x_2 \\ x_1 &= 12 - 5x_2 - 3x_3 \\ x_2 &= 8 - x_1 - 3x_3 \end{aligned}$$

eli yhtäpitävästi

$$\begin{aligned} x_1 &= 12 - 5x_2 - 3x_3 \\ x_2 &= 8 - x_1 - 3x_3 \\ x_3 &= 8 - 4x_1 - 2x_2 \end{aligned}$$

mikä antaa iteraatiokaavan

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 12 \\ 8 \\ 8 \end{bmatrix} + \begin{bmatrix} 0 & -5 & -3 \\ -1 & 0 & -3 \\ -4 & -2 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k ,$$

niin alkuarvauksen $\mathbf{x}_0 = [0\,0\,0]^\mathsf{T}$ tapauksessa iteraatit hajaantuvat:

$$\mathbf{x}_1 = \begin{bmatrix} 12 \\ 8 \\ 8 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} -52 \\ -28 \\ -56 \end{bmatrix}, \quad \ldots, \quad \mathbf{x}_3 = \begin{bmatrix} 320 \\ 228 \\ 272 \end{bmatrix}.$$

äin käy kyseisen iteraatiokaavan kanssa jokaisella alkuarvauksella. Toisaalta edellisen yhtälöryhmän kanssa toimivaksi havaittu diagonaalialkioita vastaavien muuttujien suhteen ratkaiseminenkaan ei toimi aina. Esimerkiksi yhtälöryhmälle

$$\begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

näin saatava iteraatiokaava

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_{k+1} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 & 1 \\ 3 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_k$$

hajaantuu jokaisella alkuarvauksella $\mathbf{x}_0$.

Edelliset havainnot herättävät kysymyksen, missä tapauksissa iteraatio suppenee. Jos kullakin rivillä diagonaalialkio on itseisarvoltaan suurempi kuin muiden saman rivin kertoimien itseisarvojen summa, niin diagonaalialkioiden suhteen ratkaistu iteraatiokaava suppenee. Tällaista matriisia kutsutaan *diagonaalisesti dominoivaksi*.

Määritelmä 5.14 (Diagonaalisesti dominoiva matriisi)**.** $n \times n$-matriisia $\mathbf{A}$ kutsutaan *diagonaalisesti dominoivaksi*, jos sen alkiot toteuttavat

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}|$$

jokaiselle $i = 1, 2, \ldots, n$.

Lause 5.15. *Jos $n \times n$-matriisi $\mathbf{A}$ on diagonaalisesti dominoiva ja $\mathbf{x}_{k+1} = \mathbf{g}(\mathbf{x})$ on kiintopistemenetelmällä diagonaalialkioiden suhteen ratkaistava iteraatiokaava, niin iteraatio suppenee yhtälöryhmän ratkaisuun kaikilla alkuarvauksilla $\mathbf{x}_0$.*

Todistus. Sivuutetaan. □

Edellinen lause ei siis kerro kaikkia mahdollisia tapauksia, joissa iteraatio voi supeta, vaan ainoastaan riittävän ehdon tälle. Voi siis olla muuntyyppisiäkin yhtälöryhmiä, jotka suppenevat joko kaikilla tai tietyillä alkuarvauksilla.

Huomaa, että vaikka yhtälöryhmän kerroinmatriisi ei ole suoraan diagonaalisesti dominoiva, se voidaan joissain tapauksissa muuttaa sellaiseksi rivejä vaihtamalla. Esimerkiksi edellä tarkastellun yhtälöryhmän

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

kerroinmatriisi on diagonaalisesti dominoiva mutta ei enää, jos yhtälöryhmän rivit vaihdetaan johonkin muuhun kuudesta mahdollisesta järjestyksestä. Myös yhtälöryhmän sarakkeiden järjestystä voitaisiin yrittää, kunhan vain muistetaan tehdä vastaavat muuttujien järjestyksen vaihdot, mutta tästä ei ole hyötyä, jos asia ei onnistunut rivejä muuttamalla. Perustele asia itsellesi vaikka seuraavan yhtälöryhmän avulla:

$$\begin{aligned} x_1 + 2x_2 + 4x_3 &= 8 \\ 2x_1 + 5x_2 + 2x_3 &= 12 \\ 3x_1 + 2x_2 + 7x_3 &= 8 \end{aligned}$$

Edellinen lause ei voi päteä tapauksessa, jossa kerroinmatriisi ei ole kääntyvä, koska tällöin yhtälöryhmällä ei ole yksikäsitteistä ratkaisua. Voidaankin osoittaa, että matriisin diagonaalisesta dominoivuudesta seuraa, että matriisi on kääntyvä. Tämä todistus sekä edellisen lauseen todistus ohitetaan.

Iteraatiokaava Johdetaan seuraavaksi Jacobin menetelmän iteraatiokaava yleisessä tapauksessa. Tämän avulla kutakin yhtälöryhmää vastaava iteraatiokaava voidaan kirjoittaa suoraan yhtälöryhmän kerroinmatriisista $\mathbf{A}$ ja vakiovektorista $\mathbf{b}$ saatavien tietojen avulla.

Yritetään ratkaista yhtälöryhmä $\mathbf{Ax} = \mathbf{b}$, jossa $\mathbf{A}$ on diagonaalisesti dominoiva, diagonaalia vastaavien muuttujien suhteen. Näihin päästään käsiksi matriisimuodossa, kun pilkotaan kerroinmatriisi alakolmiomatriisin, diagonaalimatriisin ja yläkolmiomatriisin summaksi:

$$\begin{aligned} \mathbf{Ax} &= \mathbf{b} \\ (\mathbf{L} + \mathbf{D} + \mathbf{U})\mathbf{x} &= \mathbf{b} \\ \mathbf{Lx} + \mathbf{Dx} + \mathbf{Ux} &= \mathbf{b} \\ \mathbf{Dx} &= \mathbf{b} - \mathbf{Lx} - \mathbf{Ux} \\ \mathbf{x} &= \mathbf{D}^{-1}\mathbf{b} - \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}. \end{aligned}$$

Määritelmä 5.16 (Jacobin menetelmä)**.** *Jacobin menetelmän* iteraatiokaava on muotoa

$$\mathbf{x}_{k+1} = \mathbf{Bx}_k + \mathbf{c},$$

missä $\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L}+\mathbf{U})$ ja $\mathbf{c} = \mathbf{D}^{-1}\mathbf{b}$.

Nopeasti katsottuna voisi näyttää siltä, että tällainen iteratiivinen menetelmä on yhtälöryhmän ratkaisemisen kannalta täysin turha, koska siinä joudutaan laskemaan $n \times n$-matriisn kerroinmatriisi, kun $n \times n$ käänteismatriisilla $\mathbf{A}^{-1}$ saataisiin suoraan ratkaisu. $\mathbf{D}$ on kuitenkin diagonaalimatriisi, joten sen käänteismatriisi saadaan suoraan ottamalla käänteisluvut diagonaalialkiosta, mikä on laskennallisesti varsin kevyt laskutoimitus.

Ratkaisualgoritmin koodissa matriisi $\mathbf{B}$ ja vektori $\mathbf{c}$ kannattaa laskea ennen silmukkaa turhan työn vähentämiseksi.

Suppenemisehdon havainnollistus Havainnollistetaan, miksi diagonaalisesti dominoiva kerroinmatriisi riittää takaamaan iteraation suppenemisen. Riittää siis onnistua näyttämään, että tällaisen yhtälöryhmän tapauksessa $\mathbf{x}_n$ suppenee.

Aloitetaan kirjoittamalla järjestyksessä iteraattien lausekkeita, jos vaikka saataisiin pääteltyä iteraatille $\mathbf{x}_n$ indeksistä n riippuva lauseke, koska tällöin voitaisiin katsoa, mitä tapauksessa $n \to \infty$ tapahtuu. Iteraatiokaavan $\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{c}$ nojalla pätee

$$\begin{aligned}
\mathbf{x}_1 &= \mathbf{B}\mathbf{x}_0 + \mathbf{c} \\
\mathbf{x}_2 &= \mathbf{B}\mathbf{x}_1 + \mathbf{c} = \mathbf{B}(\mathbf{B}\mathbf{x}_0 + \mathbf{c}) + \mathbf{c} = \mathbf{B}^2\mathbf{x}_0 + \mathbf{B}\mathbf{c} + \mathbf{c} \\
\mathbf{x}_3 &= \mathbf{B}\mathbf{x}_2 + \mathbf{c} = \mathbf{B}(\mathbf{B}^2\mathbf{x}_0 + \mathbf{B}\mathbf{c} + \mathbf{c}) + \mathbf{c} = \mathbf{B}^3\mathbf{x}_0 + \mathbf{B}^2\mathbf{c} + \mathbf{B}\mathbf{c} + \mathbf{c}.
\end{aligned}$$

Tapauksessa n pätee siis

$$\mathbf{x}_n = (\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B}^{n-1})\mathbf{c} + \mathbf{B}^n\mathbf{x}_0.$$

Havaitaan, että vektorin $\mathbf{c}$ kertoimeksi muodostuu geometristä summaa vastaava lauseke. Reaalilukujen tapauksessa pätee

$$1 + b + b^2 + \cdots + b^{n-1} = \frac{1-b^n}{1-b}$$

(Kerro yhtälö jakajalla, niin näet miksi). Matriiseille pätee vastaavasti

$$\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B} + \mathbf{B}^{-1} = (\mathbf{I} - \mathbf{B})^{-1}(\mathbf{I} - \mathbf{B}^n),$$

missä käänteismatriisi voidaan kirjoittaa kummalle puolella vain, sillä identiteettimatriisista johtuen pätee poikkeuksellisesti

$$(\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B} + \mathbf{B}^{-1})(\mathbf{I} - \mathbf{B}) = (\mathbf{I} - \mathbf{B})(\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B} + \mathbf{B}^{-1}).$$

Näin ollen

$$\mathbf{x}_n = (\mathbf{I} - \mathbf{B})^{-1}(\mathbf{I} - \mathbf{B}^n)\mathbf{c} + \mathbf{B}^n\mathbf{x}_0.$$

Reaalilukujen tapauksessa pätee tunnetusti $b^n \to 0$, kun $n \to \infty$, jos $|b| < 1$ (Mitä tapahtuu tapauksissa $|b| > 1$, $b = 1$ ja $b = -1$?). Matriiseille pätee vastaava tulos, mutta tänä vuonna matriisinormien käsittely jää väliin tällä kurssilla. Voidaan osoittaa, että näin käy aina iteraatiokaavan mukaiselle matriisille $\mathbf{B}$. Esimerkiksi edellä käsitellyssä tapauksessa

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 2 \\ \frac{12}{5} \\ \frac{8}{3} \end{bmatrix} + \begin{bmatrix} 0 & \frac{2}{4} & -\frac{1}{4} \\ \frac{1}{5} & 0 & -\frac{3}{5} \\ \frac{1}{3} & -\frac{1}{3} & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k,$$

missä kerroinmatriisi on diagonaalisesti dominoiva, meillä on

$$\mathbf{B} = \begin{bmatrix} 0 & \frac{2}{4} & -\frac{1}{4} \\ \frac{1}{5} & 0 & -\frac{3}{5} \\ \frac{1}{3} & -\frac{1}{3} & 0 \end{bmatrix}, \quad \mathbf{B}^2 = \begin{bmatrix} \frac{1}{60} & \frac{1}{12} & -\frac{3}{10} \\ -\frac{1}{5} & \frac{3}{10} & -\frac{1}{20} \\ -\frac{1}{15} & \frac{1}{6} & \frac{7}{60} \end{bmatrix} \quad \text{ja} \quad \mathbf{B}^3 = \begin{bmatrix} -\frac{1}{12} & \frac{13}{120} & -\frac{13}{240} \\ -\frac{13}{300} & -\frac{1}{12} & -\frac{13}{100} \\ \frac{13}{180} & -\frac{13}{180} & -\frac{1}{12} \end{bmatrix}.$$

Tämä havainnollistaa sitä, että diagonaalinen dominoivuus takaa matriisin $\mathbf{B}$ alkioista riittävän pienet, jotta sen alkiot alkavat pienetä ja lähestyä nollaa potenssien korotuksissa. Sen sijaan edellä käsitellyssä tapauksessa

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 12 \\ 8 \\ 8 \end{bmatrix} + \begin{bmatrix} 0 & -5 & -3 \\ -1 & 0 & -3 \\ -4 & -2 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k,$$

jossa kerroinmatriisi ei ollut diagonaalisesti dominoiva, päteekin

$$\mathbf{B} = \begin{bmatrix} 0 & -5 & -3 \\ -1 & 0 & -3 \\ -4 & -2 & 0 \end{bmatrix}, \quad \mathbf{B}^2 = \begin{bmatrix} 17 & 6 & 15 \\ 12 & 11 & 3 \\ 2 & 20 & 18 \end{bmatrix} \quad \text{ja} \quad \mathbf{B}^3 = \begin{bmatrix} -66 & -115 & -69 \\ -23 & -66 & -69 \\ -92 & -46 & -66 \end{bmatrix},$$

eli $\mathbf{B}$ räjähtää käsiin potenssiin korotuksissa.

Diagonaalisesti dominoivan kerroinmatriisin tapauksessa pätee siis

$$\mathbf{x}_n = (\mathbf{I}-\mathbf{B})^{-1}(\mathbf{I}-\mathbf{B}^n)\mathbf{c} + \mathbf{B}^n\mathbf{x}_0 \xrightarrow{n\to\infty} (\mathbf{I}-\mathbf{B})^{-1}\mathbf{c},$$

eli iteraatio suppenee kohti arvoa $(\mathbf{I}-\mathbf{B})^{-1}\mathbf{c}$. Samalla havaitaan myös, ettei alkuarvaus $\mathbf{x}_0$ vaikuta siihen, suppeneeko iteraatio vai ei.

Voisi tulla mieleen, miksei ratkaisua lasketa suoraan lausekkeella $(\mathbf{I}-\mathbf{B})^{-1}\mathbf{c}$. Samasta syystä kuin miksi ratkaisua ei kannata laskea lausekkeella $\mathbf{A}^{-1}\mathbf{b}$, eli koska kääänteismatriisin laskeminen on työlästä.

6 Differentiaaliyhtälöt

6.1 Eulerin menetelmä

6.2 Runge–Kutta-menetelmät

7 Optimointi

7.1 Optimoinnin peruskäsitteitä

7.2 Gradienttimenetelmä

7.3 Automaattinen derivointi