Numeeriset menetelmät

Toni Karvonen
toni.karvonen@lut.fi

Lappeenrannan–Lahden teknillinen yliopisto LUT

10. huhtikuuta 2026

Sisällys

1 Liukuluvut **1**
1.1 Kantalukujärjestelmät . . . 1
1.2 Liukuluvut . . . 2
1.3 IEEE 754 -liukulukustandardi . . . 2
1.4 Pyöristys ja tarkkuus . . . 5
1.5 Numeerinen vakaus . . . 7

2 Virhe **8**
2.1 Pyöristys- ja katkaisuvirhe . . . 8
2.2 Approksimaation tarkkuus . . . 9
2.3 Absoluuttinen ja suhteellinen virhe . . . 9
2.4 Iso-O-notaatio . . . 10
2.5 Iso-O-notaation ominaisuuksia . . . 12

3 Numeeristen menetelmien rakentaminen **15**
3.1 Taylorin polynomi . . . 15
3.2 Linearisointi . . . 17
3.3 Taulukko-ohjelmointi . . . 19

4 Numeerinen integrointi **21**
4.1 Keskipistesääntö . . . 21
4.2 Puolisuunnikassääntö . . . 26
4.3 Simpsonin sääntö . . . 28

5 Yhtälöryhmien ratkaiseminen **32**
5.1 Newtonin menetelmä . . . 33
5.2 Newtonin menetelmä yhtälöryhmille . . . 36
5.3 Kiintopistemenetelmä . . . 43
5.4 Jacobin menetelmä lineaarisille yhtälöryhmille . . . 49

6 Differentiaaliyhtälöt **55**
6.1 Eulerin menetelmä . . . 55
6.2 Keskipistemenetelmä . . . 61
6.3 Rungen–Kuttan menetelmät . . . 65
6.4 Numeerisiä ratkaisuja differentiaaliyhtälöryhmille . . . 68
6.5 Implisiittiset menetelmät . . . 68

7 Optimointi **70**
7.1 Neuroverkkojen kouluttaminen 70
7.2 Gradienttimenetelmä yhden muuttujan funktioille 72
7.3 Gradienttimenetelmä useamman muuttujan funktioille 76
7.4 Funktioiden yhdistäminen ja ketjusääntö 82
7.5 Automaattinen derivointi 85

1 Liukuluvut

Tämä osio käsittelee tapoja esittää reaalilukuja tietokoneessa. Koska reaalilukuja on ääretömän paljon, ei niitä kaikkia ole mahdollista esittää ja on välttämätöntä tehdä kompromisseja.

1.1 Kantalukujärjestelmät

Tutussa *kymmenjärjestelmässä* luvut esitetään kymmenen potenssien avulla. Esimerkiksi luku 1453,529 voidaan kirjoittaa muodossa

$$1453{,}529 = 1 \cdot 10^3 + 4 \cdot 10^2 + 5 \cdot 10^1 + 3 \cdot 10^0 + 5 \cdot 10^{-1} + 2 \cdot 10^{-2} + 9 \cdot 10^{-3}.$$

Tällaisessa *paikkajärjestelmässä* numeron vaikutus luvun arvoon on sen arvon tulo valitun *kantaluvun* (kymmenjärjestelmässä kanta on 10) potenssin kanssa. Numeron sijainti määrää kantaluvun eksponentin. Sijainti lasketaan *desimaalierottimesta* siten, että vasemmalla puolella potenssit ovat epänegatiivisia ja oikealla puolella negatiivisia. Koska 5 on toinen numero erottimesta vasemmalle luvussa 1453,529, sen eksponentiksi tulee 1 (sillä ensimmäinen potenssi desimaalierottimen vasemmalla puolella on 0). Täten numeron 5 vaikutus tämän luvun arvoon on $5 \cdot 10^1 = 50$. Vastaavasti koska 9 on kolmas numero desimaalierottimen oikealla puolella, sen eksponentti on -3 ja panos $9 \cdot 10^{-3} = 0{,}009$.

Määritelmä 1.1 (Kantalukujärjestelmä)**.** Olkoon $b \geq 2$ kokonaisluku, jota kutsutaan *kantaluvuksi*. Kannassa b luvut kirjoitetaan muodossa

$$(a_n a_{n-1} \cdots a_0{,}c_1 c_2 \cdots)_b = a_n \cdot b^n + a_{n-1} \cdot b^{n-1} + \cdots + a_0 \cdot b^0 + c_1 \cdot b^{-1} + c_2 \cdot b^{-2} + \cdots,$$

missä *numerot* $a_0, \ldots, a_n$ ja $c_1, c_2, \ldots$ ovat kokonaislukuja välillä lukujen 0 ja $b-1$ välillä.

Alaindeksiä b ei yleensä käytetä kymmenjärjestelmässä (eli kun $b = 10$) muutoin kuin selvyyden vuoksi.

Esimerkki 1.2. Oktaaliluvun (eli $b = 8$) $(35{,}07)_8$ muuntaminen kymmenjärjestelmään tapahtuu seuraavasti:

$$(35{,}07)_8 = 3 \cdot 8^1 + 5 \cdot 8^0 + 0 \cdot 8^{-1} + 7 \cdot 8^{-2} = 3 \cdot 8 + 5 + \frac{0}{8} + \frac{7}{8^2} = 29{,}109375.$$

Esimerkki 1.3. Heksadesimaalijärjestelmässä (eli kantaluku $b = 16$) kirjaimia A–F käytetään numeroiden 10–15 esittämiseen. Luvun $(\mathrm{AE{,}1B})_{16}$ muuntaminen kymmenjärjestelmään tapahtuu seuraavasti:

$$\begin{aligned}(\mathrm{AE{,}1B})_{16} &= 10 \cdot 16^1 + 14 \cdot 16^0 + 1 \cdot 16^{-1} + 11 \cdot 16^{-2} \\ &= 10 \cdot 16 + 14 + \frac{1}{16} + \frac{11}{256} \\ &= 174{,}10546875.\end{aligned}$$

Esimerkki 1.4. Muuntaaksemme luvun $(220{,}1)_3$ kymmenjärjestelmään kirjoitamme

$$(220{,}1)_3 = 2 \cdot 3^2 + 2 \cdot 3^1 + 0 \cdot 3^0 + 1 \cdot 3^{-1} = 2 \cdot 9 + 2 \cdot 3 + \frac{1}{3} = 24{,}333\ldots$$

Huomaa, kantalukuesitys voi olla päättyvä yhdessä kannassa $[(220,1)_3]$ mutta päättymätön toisessa $(24{,}333\ldots)$.

Esimerkki 1.5. Kymmenjärjestelmän luku 33,25 voidaan muuntaa binäärijärjestelmään (eli kantaluku $b = 2$) seuraavasti:

$$\begin{aligned}(33{,}25)_{10} = 32 + 1 + \frac{1}{4} &= 1\cdot 2^5 + 0\cdot 2^4 + 0\cdot 2^3 + 0\cdot 2^2 + 0\cdot 2^1 + 1\cdot 2^0 + 0\cdot 2^{-1} + 1\cdot 2^{-2} \\ &= (100001{,}01)_2.\end{aligned}$$

Binäärijärjestelmä. Binäärijärjestelmän numerot (eli 0 ja 1) ovat binäärinumeroita eli *bittejä*. Esimerkiksi binääriluvussa $(110{,}1)_2 = 6{,}5$ on neljä bittiä. Suurin luku, joka voidaan esittää n bitillä, on

$$(1\underbrace{0\cdots 00}_{n \text{ kertaa}})_2 - (1)_2 = (\underbrace{11\cdots 11}_{n \text{ kertaa}})_2 = 1\cdot 2^{n-1} + 1\cdot 2^{n-2} + \cdots + 1\cdot 2^1 + 1\cdot 2^0 = 2^n - 1. \tag{1.1}$$

1.2 Liukuluvut

Vaikka kaikki reaaliluvut pystyykin esittämään missä tahansa kannassa (esitys voi tosin olla päättymätön), käytännössä tämä on mahdotonta, sillä tietokoneiden muisti on rajallista. Kun lukuja toteutetaan tietokoneessa, on valittava, mitkä luvut esitetään ja miten. Tähän käytetään liukulukuesitystä.

Määritelmä 1.6 (Liukuluku)**.** *Liukuluku* $a \in \mathbb{R}$ kannassa b on muotoa

$$a = s\cdot c\cdot b^e,$$

missä $s \in \{-1, 1\}$ on luvun *etumerkki*, $c \in \mathbb{R}_{\geq 0}$ *mantissa* ja $e \in \mathbb{Z}$ *eksponentti*.

Liukulukuesitys ei ole yksikäsitteinen. Esimerkiksi 123,45 voidaan kirjoittaa

$$12345\cdot 10^{-2} \quad \text{tai} \quad 1234{,}5\cdot 10^{-1}$$

tai äärettömän monella muulla tavalla kymmenkantaisena (eli $b = 10$) liukulukuna. Jotta liukulukuja voidaan esittää tietokoneessa, on valittava äärellinen määrä mahdollisia mantissan ja eksponentin arvoja. Nämä valinnat määräävät syntyvän liukulukumuodon tarkkuuden ja muistinkulutuksen.

1.3 IEEE 754 -liukulukustandardi

IEEE-standardi liukulukulaskennalle (IEEE 754) määrittelee joukon liukulukumuotoja, joita käytetään käytännössä kaikessa laskennassa. Binääriset IEEE 754 -liukuluvut ovat muotoa

$$a = s\cdot(1+f)\cdot 2^{e-e_{\text{bias}}}, \tag{1.2}$$

missä e_{bias}, *eksponentin bias*, on positiivinen kokonaisluku ja $f \in (0,1)$ määrittää mantissan (kutsumme tätä lukua *mantissan murto-osaksi*). Sekä $f \in (0,1)$ että $e \in \mathbb{Z}_{\geq 0}$ tallennetaan binäärilukuina käyttäen valittua määrää bittejä. Toisin sanoen

$$f = (0{,}\bar{b}_1\bar{b}_2\cdots\bar{b}_p)_2 \quad \text{ja} \quad e = (\hat{b}_1\hat{b}_2\cdots\hat{b}_q)_2$$

joillekin positiivisille kokonaisluvuille p ja q sekä biteille $\bar{b}_i, \hat{b}_j \in \{0,1\}$. Etumerkki ilmoitetaan bitillä b_s muodossa $s = (-1)^{b_s}$, jolloin

$$b_s = 0 \implies s = 1 \qquad \text{ja} \qquad b_s = 1 \implies s = -1.$$

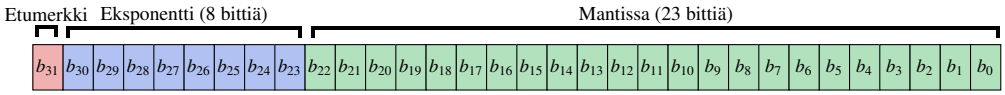

Kuva 1.1: 32-bittisten IEEE 754 -liukulukujen bittijako. Katso taulukko 1.1.

Tässä muodossa liukuluvun esittämiseen käytetään $n = p+q+1$ bittiä (p bittiä mantissalle, q eksponentille ja yksi etumerkille), jotka järjestetään seuraavasti:

$$(b_s\hat{b}_q\hat{b}_{q-1}\cdots\hat{b}_1\bar{b}_p\bar{b}_{p-1}\cdots\bar{b}_1)_2 = (b_{p+q}b_{p+q-1}\cdots b_0)_2. \tag{1.3}$$

Kuva 1.1 havainnollistaa bittijakoa. IEEE 754 -esityksessä käytetään arvoa $e_{\text{bias}} = 2^{q-1}-1$ kaavan (1.2) kokonaisluvulle e_{bias} kaavassa (1.2). Tämä arvo määrää luvun 2 *varsinaisen eksponentin* $e - e_{\text{bias}} = e - 2^{q-1}$. Tästä seuraa, että varsinainen eksponentti vaihtelee [ks. (1.1)]

$$\text{luvusta } e_{\min} = 0 - e_{\text{bias}} = -2^{q-1}+1 \text{ lukuun } e_{\max} = 2^q - 1 - e_{\text{bias}} = 2^{q-1}(2-1) = 2^{q-1}. \tag{1.4}$$

Esimerkki 1.7. Tarkastellaan IEEE 754 -muotoisia liukulukuja, joissa mantissalle on varattu $p = 3$ ja eksponentille $q = 2$ bittiä. Bittien kokonaismäärä on siis $n = p+q+1 = 6$. Tässä esitystavassa binääriluku $(101110)_2$ esittää muodon (1.2) mukaista liukulukua, jossa $s = (-1)^1 = -1$, $e = (01)_2 = 1$ ja $f = (0{,}110)_2 = 0{,}75$. Koska $e_{\text{bias}} = 2^{q-1}-1 = 1$, $(101110)_2$ esittää kaavan (1.2) nojalla kymmenjärjestelmän luvun

$$s\cdot(1+f)\cdot 2^{e-e_{\text{bias}}} = (-1)\cdot(1+0{,}75)\cdot 2^{1-1} = -1{,}75.$$

IEEE 754 -standardin erikoistapaukset. Eksponenteilla $e = (0\cdots0)_2$ ja $e = (1\cdots1)_2$ on erityistulkinnat:

- Jos eksponentti on nolla, eli $e = (0\cdots0)_2$:
  - Jos *mantissan murto-osa on nolla*, eli $f = (0.0\cdots0)_2$, luku tulkitaan nollaksi. Etumerkkibitti määrää, onko nolla "positiivinen" vai "negatiivinen", mikä ei vaikuta useimpiin laskutoimituksiin. Toisin sanoen,

    $$\text{“positiivinen” nolla} = (10\cdots0)_2 \quad \text{ja} \quad \text{“negatiivinen” nolla} = (00\cdots0)_2.$$

  - Jos *mantissan murto-osa ei ole nolla*, liukulukua kutsutaan *alinormaaliksi* (engl. *subnormal*) ja se esittää kymmenjärjestelmän luvun

    $$a_{\text{subnormal}} = s\cdot f\cdot 2^{-e_{\text{bias}}+1}. \tag{1.5}$$

    Tämä poikkeaa kaavan (1.2) antamasta *normaalista* luvusta siten, että $1+f \in (1,2)$ korvautuu termillä $f \in (0,1)$. Alinormaaleilla luvuilla voidaan esittää pienempiä lukuja kuin pelkillä normaaleilla luvuilla olisi mahdollista.
- Jos eksponentti on suurin mahdollinen, eli $e = (1\cdots1)_2$:
  - Jos *mantissan murto-osa on nolla*, eli $f = (0.0\cdots0)_2$, luku tulkitaan etumerkkibitin mukaan positiiviseksi äärettömäksi (∞) tai negatiiviseksi äärettömäksi ($-\infty$).
  - Jos *murto-osa ei ole nolla*, luku tulkitaan *epäluvuksi* (NaN), eli arvo on määrittelemätön. Tämä voi tapahtua esimerkiksi laskettaessa $0/0$.

IEEE 754 -binäärimuodot. Taulukko 1.1 sisältää kolmen yleisimmän IEEE 754 -standardin binäärisen liukulukumuodon määritykset ja keskeiset ominaisuudet. Näihin viitataan tyypillisesti nimillä *puolitarkkuus* (engl. *half-precision*; 16 bittiä), *perustarkkuus* (engl. *float* tai *single-precision*; 32 bittiä) ja *kaksoistarkkuus* (engl. *double* tai *double-precision*; 64 bittiä).

Taulukko 1.1: IEEE 754 -standardin puolitarkkuus- (half), yksittäistarkkuus- (float) ja kaksoistarkkuuslukujen (double) keskeiset ominaisuudet. Huomaa, että jokaisessa muoto käyttää eksponentti- ja mantissabittien lisäksi yhden bitin etumerkin esittämiseen. *Kone-epsilon* kuvaa liukulukujärjestelmän tarkkuutta. Se on luvun 1 ja seuraavan sitä suuremman liukuluvun erotusta. Voidaan näyttää, että $\varepsilon = 2^{-p}$, missä p on mantissabittien lukumäärä. *Mantissan bittien määrä määrittää tarkkuuden ja eksponentin bittien määrä määrittää, kuinka pieniä ja suuria lukuja on mahdollista esittää.*

Ominaisuus	**Half (16 bittiä)**	**Float (32 bittiä)**	**Double (64 bittiä)**
Bittejä yhteensä	16	32	64
Bittejä eksponentissa (q)	5	8	11
Bittejä mantissassa (p)	10	23	52
Eksponentin bias (e_{bias})	15	127	1023
Pienin pos. normaali luku	2^{-14}	2^{-126}	2^{-1022}
Pienin pos. alinormaali luku	2^{-24}	2^{-149}	2^{-1074}
Suurin äärellinen luku ($\approx$)	$6{,}55 \times 10^4$	$3{,}40 \times 10^{38}$	$1{,}80 \times 10^{308}$
Kone-epsilon (ε)	2^{-10}	2^{-23}	2^{-52}

Esimerkki 1.8. Etsitään kymmenjärjestelmän luvun $a = -3{,}75$ perustarkkuusesitys (eli 32-bittinen esitys). Koska etumerkki $s = (-1)^{b_s}$, etumerkkibitti on yksi, eli $b_s = 1$. Kaavan (1.4) mukaan eksponentin bias on $e_{\text{bias}} = 2^{q-1} - 1 = 2^7 - 1 = 127$. Koska $1 + f \in (1,2)$ ja $(1+f) \cdot 2^1 \in (2,4)$, varsinaisen eksponentin täytyy olla 1, eli $1 = e - e_{\text{bias}} = e - 127$. Tästä saadaan $e = 128 = 2^7 = (10\cdots0)_2$, missä nollia on seitsemän. Yhtälöstä $3{,}75 = (1+f) \cdot 2$ ratkaistaan $f = \frac{1}{2} \cdot 3{,}75 - 1 = 0{,}875 = (0,111)_2$. Täten luvun $-3{,}75$ perustarkkuusesitys 32 bitillä on

$$11000000011100000000000000000000,$$

missä käytämme samoja värejä kuin kuvassa 1.1: etumerkki, eksponentti ja mantissan murto-osa, ja olemme lisänneet mantissan murto-osaan nollia varmistaaksemme, että esityksessä on 32 bittiä.

Esimerkki 1.9. Edetään toiseen suuntaan ja selvitetään, mitä kymmenjärjestelmän lukua a vastaa 32-bittinen perustarkkuusesitys

$$00001010001100000000000000000000.$$

Etumerkkibitti (sign) on nolla ($b_s = 0$), joten etumerkki on positiivinen, sillä $s = (-1)^{b_s} = (-1)^0 = 1$. Eksponentti on $e = (00010100)_2 = 2^4 + 2^2 = 20$. Mantissan murto-osa on $f = (0.01100000000000000000000)_2 = 2^{-2} + 2^{-3} = 0{,}375$. Siispä

$$a = s \cdot (1+f) \cdot 2^{e - e_{\text{bias}}} = 1 \cdot (1 + 0{,}375) \cdot 2^{20-127} = 1{,}375 \cdot 2^{-107} \approx 8{,}47 \times 10^{-33}.$$

Esimerkki 1.10. Johdetaan joitakin taulukossa 1.1 lueteltuja ominaisuuksia perustarkkuusluvuille (32 bittiä). Kaavan (1.4) mukaan eksponentin bias on $e_{\text{bias}} = 2^{q-1} - 1 = 2^7 - 1 = 127$. Pienin mahdollinen positiivinen normaali luku on pienin positiivinen liukuluku, joka on esitettävissä muodossa (1.2). Täten meidän on määritettävä (a) mahdollisimman pieni mantissan murto-osa ja (b) mahdollisimman piene *positiivinen* eksponentti (luku on alinormaali,

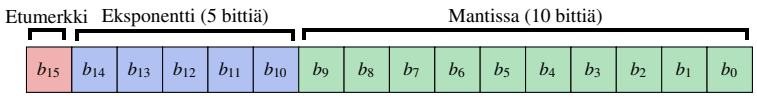

Kuva 1.2: 16-bittisten IEEE 754 -liukulukujen bittijako. Katso taulukko 1.1.

jos eksponentti on nolla). Täten

$$f = (0.\underbrace{0\cdots0}_{\text{23 kertaa}})_2 = 0 \quad \text{ja} \quad e = (\underbrace{0\cdots0}_{\text{7 kertaa}}1)_2 = 1.$$

Siispä pienin positiivinen *normaali* perustarkkuusluku on

$$a = 1\cdot(1+f)\cdot 2^{e-e_{\text{bias}}} = 1\cdot(1+0)\cdot 2^{1-127} = 2^{-126} \approx 1,18\times 10^{-38}.$$

Pienimmän positiivisen *alinormaalin* luvun saamme asettamalla eksponentin nollaksi, valitsemalla pienimmän positiivisen mantissan murto-osan $f = (0.0\cdots01)_2 = 2^{-23}$ ja käyttämällä alinormaalin luvun määrittävää kaavaa (1.5). Näin saamme

$$a = 1\cdot f\cdot 2^{-127+1} = 2^{-23}\cdot 2^{-126} = 2^{-149} \approx 1{,}40\times 10^{-45}.$$

Suurimmalla äärellisellä perustarkkuusluvulla on mahdollisimman suuri mantissan murto-osa ja eksponentti, joka on yhtä pienempi kuin suurin mahdollinen (koska suurin eksponentti tulkitaan äärettömyydeksi tai epäluvuksi). Siispä

$$f = (0.\underbrace{1\cdots1}_{\text{23 kertaa}})_2 = \sum_{k=1}^{23} 2^{-k} = 1-2^{-23} \quad \text{ja} \quad e = (\underbrace{1\cdots1}_{\text{7 kertaa}}0)_2 = \sum_{k=1}^{7} 2^{k} = 254.$$

Näin saadaan suurimmaksi äärelliseksi perustarkkuusluvuksi

$$a = 1\cdot(1+f)\cdot 2^{e-e_{\text{bias}}} = (2-2^{-23})\cdot 2^{127} \approx 3{,}40\times 10^{38}.$$

Liukuluvut Pythonissa. Pythonissa liukuluvun 32-bittisen esityksen voi tulostaa seuraavasti:

```
import numpy as np
a = -3.75
res = np.binary_repr(np.float32(a).view(np.int32), width=32)
print(res)
```

Näiden koodirivien suorittaminen tulostaa `11000000011100000000000000000000`, mikä on täsmälleen esimerkissä 1.8 laskemamme esitys. Huomaa kuitenkin, että Pythonissa termillä “float” viitataan kaksoistarkkuuden, eli 64 bitin liukulukuihin.

1.4 Pyöristys ja tarkkuus

Liukulukulaskennalla on *äärellinen tarkkuus*. Toisin sanoen kaikkia reaalilukuja ei voida esittää täsmälleen ja laskutoimitusten tulokset voivat poiketa *täsmällisen laskennan* tuloksista. Esimerkiksi tuttu kymmenjärjestelmän luku 0,1 ei ole esitettävissä täsmällisesti äärellisen monella bitillä, sillä sen binääriesitys on päättymätön:

$$(0{,}1)_{10} = (0{,}00011001100110011\ldots)_2.$$

Tästä seuraa, että tällaisia lukuja ei voida esittää täsmällisesti binäärisinä liukulukuina, vaan ne pyöristetään esitettävissä olevaan liukulukuun IEEE 754 -standardin määrittelemien pyöristys-

sääntöjen mukaisesti. Tähän törmää usein yksinkertaisissakin laskuissa. Esimerkiksi Pythonissa yksinkertainen kertolasku, jonka täsmällinen arvo on 653082380,34, ei tuotakaan täsmällistä arvoa:

```
>>> print(27869.01 * 23434)
653082380.3399999
```

Sama ilmiö havaitaan tulostettaessa 50 desimaalia esimerkiksi luvulle $a = 0{,}1$:

```
>>> a = 0.1
>>> print(f"{a:.{50}f}")
0.10000000000000000555111512312578270211815834045410
```

Tarkkuus. Liukulukujen *tarkkuus riippuu niiden kokoluokasta*. Tämä on sekä etu (liukuluvuilla voidaan esittää hyvin erikokoisia lukuja) että haitta (pyöristysvirheitä tulee väistämättä, kun operoidaan suurilla luvuilla). Esimerkiksi kaksoistarkkuusluvuilla (64 bittiä) voidaan esittää luvut välillä 1 ja 2 tarkkuudella 2^{-52}, eli kaikki luvut välillä $[1,2]$ pyöristyvät luvun 2^{-52} monikertoihin. Tarkkuus heikkenee lukujen kasvaessa: se on 2^{-51} lukujen välillä 2 ja 4 ja lopulta 2^{971} lukujen välillä 2^{1023} ja 2^{1024}. Tämän näkee havaitsee Pythonissa, joka käyttää oletuksena kaksoistarkkuuslukuja. Seuraavat laskutoimitukset palauttavat positiiviset arvot kuten niiden kuuluukin:

```
>>> b = 1.0
>>> a = 1.0 + 2.0**(-52)
>>> print(a - b)
2.220446049250313e-16
>>> b = 2.0**1023
>>> a = 2.0**1023 + 2.0**971
>>> print(a - b)
1.99584030953472e+292
```

Huomaa, että jälkimmäisessä laskussa on olennaista kirjoittaa “`2.0`” eikä “2”, jotta Python tulkitsee annetut luvut liukuluvuiksi, ei kokonaisluvuiksi (joita se käsittelee eri tavoin). Jos kuitenkin teemme luvusta a hieman pienemmän, se pyöristyykin luvuksi b ja erotuksesta tulee nolla, mitä ei tapahtuisi täsmällisessä laskennassa:

```
>>> b = 1.0
>>> a = 1.0 + 0.5*2.0**(-52)
>>> print(a - b)
0.0
>>> b = 2.0**1023
>>> a = 2.0**1023 + 0.5*2.0**971
>>> print(a - b)
0.0
```

Alivuoto ja ylivuoto. Samankaltaisia ilmiöitä esiintyy laskettaessa luvuilla, jotka ovat pienempiä kuin *alivuototaso* (pienimmät positiiviset alinormaalit luvut taulukossa 1.1), jolloin laskutoimituksen tulos pyöristyy nollaan, tai suurempia kuin *ylivuototaso* (suurimmat äärelliset luvut taulukossa 1.1), jolloin tulos pyöristyy äärettömyyteen tai aiheuttaa virheen. 64-bittisillä kaksoistarkkuusluvuilla ali- ja ylivuototasot ovat 2^{-1074} ja noin $1{,}80 \times 10^{308}$.

1.5 Numeerinen vakaus

Liukulukujen luontaiset rajoitteet on otettava huomioon numeerisia algoritmeja suunniteltaessa. Algoritmin tai numeerisen menetelmän *numeerinen vakaus* (tai *stabiilisuus*) tarkoittaa sen kykyä "sietää" numeerisia virheitä. Erityistä varovaisuutta tulee noudattaa vähennettäessä toisiaan lähellä olevia liukulukuja. Mikäli mahdollista, tätä tulee välttää.

Esimerkki 1.11. Lauseke $\sqrt{1+x}-\sqrt{x}>0$ on altis numeerisille kumoutumisille, kun x on suuri, koska tällöin sekä $\sqrt{1+x}$ että $\sqrt{x}$ ovat suuria ja hyvin lähellä toisiaan mutta kaukana lähimmistä esitettävissä olevista liukuluvuista (ks. osio 1.4). Esimerkiksi sijoitus $x=2^{60}$ lausekkeeseen $\sqrt{1+x}-\sqrt{x}$ tuottaa arvon nolla Pythonin käyttämässä 64-bittisessä kaksoistarkkuuslaskennassa. Sen sijaan yhtäpitävä muoto

$$\sqrt{1+x}-\sqrt{x}=\frac{(\sqrt{1+x}-\sqrt{x})(\sqrt{1+x}+\sqrt{x})}{\sqrt{1+x}+\sqrt{x}}=\frac{1}{\sqrt{1+x}+\sqrt{x}},$$

joka käyttää identiteettiä $(a-b)(a+b)=a^2-b^2$, tuottaa positiivisen arvon jopa sijoitukselle $x=2^{1023}$.

Esimerkki 1.12. Samanlainen ilmiö voi esiintyä laskettaessa a^2-b^2, kun a ja b ovat suuria. Laskua voidaan vakauttaa käyttämällä yhtälöä $(a-b)(a+b)=a^2-b^2$. Vaikka tämä uusi muoto sisältääkin vähennyslaskun $a-b$, vähennettävät luvut ovat pienempiä kuin alkuperäisessä lausekkesssa a^2-b^2 kun $a,b>1$. Pyöristysvirhettäkin tulee näin vähemmän.

Seuraava koodinpätkä Pythonia havainnollistaa esimerkkiä 1.12:

```
>>> a = 2.0**50
>>> b = a - 1.0
>>> print(a**2 - b**2)
2251799813685248.0
>>> print((a - b)*(a + b))
2251799813685247.0
```

Kun $a=2^{50}$ ja $b=2^{50}-1$, lausekkeen a^2-b^2 täsmällinen arvo on 2251799813685247, jonka saimme liukuluvuilla käyttäen numeerisesti vakaampaa muotoa $(a-b)(a+b)$.

2 Virhe

Tämä osio käsittelee numeeristen virheiden luonnetta ja esitystapoja laskennassa.

2.1 Pyöristys- ja katkaisuvirhe

Numeeriset virheet johtuvat sekä äärellistarkkuisen liukulukulaskennan luontaisesta epätarkkuudesta että matemaattisten approksimaatioiden käytöstä.

Määritelmä 2.1 (Pyöristysvirhe)**.** *Pyöristysvirhe* on virhe, joka aiheutuu äärellistarkkuisen laskennane (esim. liukulukulaskennan) käytöstä.

Esimerkki 2.2. Osioissa 1.4 ja 1.5 käsitellyt pyöristys- ja tarkkuusongelmat ovat esimerkkejä pyöristysvirheistä.

Määritelmä 2.3 (Katkaisuvirhe)**.** *Katkaisuvirhe* on virhe, joka aiheutuu matemaattisen prosessin numeerisesta approksimaatiosta.

Esimerkki 2.4. Eksponenttivakion $e \approx 2.718$ sarjaesityksen

$$e = \sum_{k=0}^{\infty} \frac{1}{k!},$$

pitäisi olla tuttu matematiikan peruskursseilta. Tässä esityksessä $n! = 1 \cdot 2 \cdots (n-1) \cdot n$ on kokonaisluvun n kertoma, jolle on määritelty $0! = 1$. Vakion e approksimoimiseksi voidaan tämä sarja katkaista termin n kohdalla (tässä $n \in \{0,1,2,3\}$):

$$\begin{aligned}
e \approx e_0 &= \sum_{k=0}^{0} \frac{1}{k!} = \frac{1}{0!} = \frac{1}{1} = 1, \\
e \approx e_1 &= \sum_{k=0}^{1} \frac{1}{k!} = \frac{1}{0!} + \frac{1}{1!} = \frac{1}{1} + \frac{1}{1} = 2, \\
e \approx e_2 &= \sum_{k=0}^{2} \frac{1}{k!} = \frac{1}{0!} + \frac{1}{1!} + \frac{1}{2!} = \frac{1}{1} + \frac{1}{1} + \frac{1}{2} = 2,5, \\
e \approx e_3 &= \sum_{k=0}^{3} \frac{1}{k!} = \frac{1}{0!} + \frac{1}{1!} + \frac{1}{2!} + \frac{1}{3!} = \frac{1}{1} + \frac{1}{1} + \frac{1}{2} + \frac{1}{2 \cdot 3} = 2,666\ldots
\end{aligned}$$

Jokainen erotuksista $e - e_n$ ($n \in \{0,1,2,3\}$) on katkaisuvirhe.

Katkaisuvirheellä ei kuitenkaan viitata ainoastaan ilmiselvään katkaisuun kuten esimerkissä 2.4, vaan yleensäkin numeerisiin approksimaatioihin.

Esimerkki 2.5. Palautetaan mieleen analyysistä, että funktion $f\colon \mathbb{R} \to \mathbb{R}$ derivaatta pisteessä $x_0 \in \mathbb{R}$ määritellään erotusosamäärän $[f(x_0+h) - f(x_0)]/h$ raja-arvona

$$f'(x_0) = \lim_{h \to 0} \frac{f(x_0+h) - f(x_0)}{h}.$$

Derivaattaa voi siis approksimoida laskemalla erotusosamäärän arvon jollakin pienellä luvulla h. Esimerkiksi funktion $f(x) = x^2$ derivaatta kohdassa $x_0 = 1$ voidaan approksimoida

seuraavasti käyttäen lukua $h = 1/10$:

$$f'(x_0) \approx \frac{f(x_0+h) - f(x_0)}{h} = \frac{(1+1/10)^2 - 1^2}{1/10} = \frac{21}{10}.$$

Koska $f'(x) = 2x$, todellinen derivaatta on $f'(x_0) = f'(1) = 2$. Virhe

$$f'(x_0) - \frac{21}{10} = 2 - \frac{21}{10} = -\frac{1}{10}$$

on katkaisuvirhe, vaikka mitään sarjaa ei katkaistakaan. Kuitenkin tässäkin tapauksessa voidaan erotusosamäärään perustuvaa approksimaatiota pitää eräänlaisena katkaisuna, sillä sitä käyttäen "katkaistaan raja-arvoprosessi $h \to 0$" valitsemalla jokin pieni h raja-arvon itsensä käyttämisen sijaan.

2.2 Approksimaation tarkkuus

Määritelmä 2.6 (Approksimaation tarkkuus)**.** Olkoon $\tilde{x}$ approksimaatio luvulle x. Tällöin $\tilde{x}$ approksimoi lukua x *d:n desimaalin tarkkuudella*, jos

$$|x - \tilde{x}| < \frac{1}{2}10^{-d}.$$

Jos haluamme, että $\tilde{x}$ approksimoi lukua x kokonaislukujen tarkkuudella (eli nollan desimaalin tarkkuudella), täytyy päteä $|x - \tilde{x} < |0{,}5$. Tämä tarkoittaa, että lukujen x ja $\tilde{x}$ välinen etäisyys on nolla lähimpään kokonaislukuun pyöristettäessä. Tämä ei kuitenkaan tarkoita sitä, että molemmat luvut pyöristyvät samaan kokonaislukuun. Esimerkiksi jos $x = 0{,}51$ ja $\tilde{x} = 0{,}49$, niin $|0{,}51 - 0{,}49| = 0{,}02 < 0{,}5$, mutta $x \approx 1$ ja $\tilde{x} \approx 0$. Huomaa myös, että jos $\tilde{x}$ approksimoi lukua xd:n desimaalin tarkkuudella, se approksimoi sitä myös $(d-1)$:n desimaalin tarkkuudella ja niin edelleen. Olennaista on toki suurin mahdollinen desimaalitarkkuus, eli suurin d.

Esimerkki 2.7. Luku 3,14 approksimoi piitä (π) kahden desimaalin tarkkuudella, sillä

$$|\pi - 3{,}14| = 0{,}00159\ldots = 0{,}159\ldots \cdot 10^{-2} < 0{,}5 \cdot 10^{-2}.$$

Luku 3,14 approksimoi piitä myös yhden desimaalin tarkkuudella, sillä

$$|\pi - 3{,}14| = 0{,}00159\ldots = 0{,}0159\ldots \cdot 10^{-1} < 0{,}5 \cdot 10^{-1}.$$

Luku 3,14 *ei* kuitenkaan approksimoi piitä kolmen desimaalin tarkkuudella, sillä

$$|\pi - 3{,}14| = 0{,}00159\ldots = 1{,}59\ldots \cdot 10^{-3} > 0{,}5 \cdot 10^{-3}.$$

2.3 Absoluuttinen ja suhteellinen virhe

Virhe voidaan mitata joko absoluuttisena tai suhteellisena.

Määritelmä 2.8 (Absoluuttinen ja suhteellinen virhe)**.** Olkoon $\tilde{x}$ luvun x approksimaatio. Tällöin

$$\textit{absoluuttinen virhe} = |x - \tilde{x}| \quad \text{ja} \quad \textit{suhteellinen virhe} = \left|\frac{x - \tilde{x}}{x}\right|.$$

Absoluuttinen virhe on luvun x ja sen approksimaation $\tilde{x}$ erotuksen itseisarvo. Suhteellinen virhe mittaa virhettä *suhteessa luvun x suuruuteen*. Huomaa, että suhteellista virhettä laskettaessa

jaetaan approksimoitavan luvun (eli x) itseisarvolla, ei approksimaation (eli $\tilde{x}$) itseisarvolla. Suhteellinen virhe ilmaistaan usein prosentteina.

Esimerkki 2.9. Jos lukua $x = \pi$ approksimoidaan kahden desimaalin tarkkuudella kuten esimerkissä 2.7 (vaikkapa $\tilde{x} = 3,14$), niin approksimaation absoluuttinen virhe on

$$|\pi - 3{,}14| = 0{,}00159\ldots$$

ja suhteellinen virhe

$$\left|\frac{\pi - 3.14}{\pi}\right| = 0.000507\ldots = 0.0507\ldots\,\%.$$

Suhteellinen virhe on usein näistä virheistä hyödyllisempi.

Esimerkki 2.10. Osiossa 1.4 havaitsimme, että Pythonin 64-bittisessä kaksoistarkkuuslaskennassa luku

$$x = 2^{1023} + 0{,}5 \cdot 2^{971} \quad \text{pyöristyy lukuun} \quad \tilde{x} = 2^{1023}.$$

Täten absoluuttinen pyöristysvirhe on

$$|x - \tilde{x}| = |2^{1023} + 0{,}5 \cdot 2^{971} - 2^{1023}| = 0{,}5 \cdot 2^{971} \approx 9{,}9792 \cdot 10^{291}.$$

Tämä verrattain suuri virhe on kuitenkin hyvin pieni suhteessa luvun x kokoon, sillä suhteellinen pyöristysvirhe on mitättömän pieni:

$$\left|\frac{x - \tilde{x}}{x}\right| = \left|\frac{2^{1023} + 0.5 \cdot 2^{971} - 2^{1023}}{2^{1023} + 0.5 \cdot 2^{971}}\right| \approx 1.11 \cdot 10^{-16} = 1.11 \cdot 10^{-14}\,\%.$$

2.4 Iso-O-notaatio

Kätevää iso-O-notaatiota käytetään approksimaatioiden asymptoottisen, eli raja-arvokäyttäytymisen, ilmaisemiseen.

Määritelmä 2.11 (Iso-O-notaatio funktioille)**.** Olkoon $x_0 \in (a,b)$ ja olkoot $f, g\colon (a,b) \to \mathbb{R}$ funktioita. Kirjoitamme

$$f(x) = O(g(x)) \quad \text{kun} \quad x \to x_0,$$

jos on olemassa $C \geq 0$ ja $\delta > 0$ siten, että $|f(x)| \leq Cg(x)$ kaikilla $x \in (x_0 - \delta, x_0 + \delta)$.

Palautetaan mieliin, että jono $(a_n)_{n=1}^{\infty} = (a_1, a_2, \ldots)$ on reaalilukujen järjestetty kokoelma.

Määritelmä 2.12 (Iso-O-notaatio jonoille)**.** Olkoot $(a_n)_{n=1}^{\infty}$ ja $(b_n)_{n=1}^{\infty}$ kaksi jonoa. Kirjoitamme

$$a_n = O(b_n) \quad \text{kun} \quad n \to \infty,$$

jos on olemassa $C \geq 0$ siten, että $|a_n| \leq Cb_n$ kaikilla $n \geq 1$.

Merkintä $O(g(x))$ luetaan esimerkiksi "suuruusluokkaa $g(x)$", "iso oo $g(x)$" tai "oo $g(x)$". Raja-arvo (joko $x \to x_0$ tai $n \to \infty$) jätetään usein merkitsemättä, mikäli se selviää asiayhteydestä.

Tällä kurssilla käytämme iso-O-notaatiota kuvaamaan numeerisen approksimaation käyttäytymistä. Notaatio on kuitenkin hyvin monipuolinen ja sitä käytetään myös algoritmien aika- ja tilavaativuuden kuvaamiseen.[1] Jos $g(x) \to 0$ kun $x \to x_0$ (tai $b_n \to 0$ kun $n \to \infty$), väite $f(x) = O(g(x))$ kertoo, kuinka nopeasti $f(x)$ lähestyy nollaa, kun $x \to x_0$. Tarkemmin sanottuna tämä tarkoittaa, että $f(x)$ lähestyy nollaa *vähintään* yhtä nopeasti kuin $g(x)$. Tällaisessa tilanteessa pyritään löytämään g, joka lähestyy nollaa mahdollisimman nopeasti siten, että $f(x) = O(g(x))$ on totta.

Esimerkki 2.13. Määritetään funktion $f(x) = x^2 + x^3$ suuruusluokka, kun $x \to 0$ (eli $x_0 = 0$). Määritelmän 2.11 mukaan meidän tulee löytää funktio g ja vakiot $C \geq 0$ ja $\delta > 0$ siten, että $|f(x)| \leq Cg(x)$ kaikille $x \in (-\delta, \delta)$. Valitaan $\delta = 1$ (mikä tahansa muukin $\delta \leq 1$ toimisi). Tällöin kaikilla $x \in (-1, 1)$ pätee

$$|f(x)| = x^2 + |x|^3 \leq x^2 + |x|^2 = 2x^2,$$

missä käytimme epäyhtälöä $|a|^n \leq |a|^m$, joka pätee kaikilla $|a| \leq 1$ ja $n \geq m$. Voimme siis valita $C = 2$ ja $g(x) = x^2$, mikä tarkoittaa, että $f(x)$ on suuruusluokkaa x^2 [$f(x) = O(x^2)$], kun $x \to 0$. Huomaa kuitenkin, että myös

$$|f(x)| = x^2 + |x|^3 \leq x^2 + |x|^2 \leq |x| + |x| = 2|x|,$$

joten olisimme voineet valita $g(x) = |x|$, jolloin $f(x) = O(|x|)$.

Esimerkissä 2.13 valinta $g(x) = x^2$ on parempi kuin $g(x) = |x|$, koska se kuvaa paremmin funktion f käyttäytymistä pisteen $x_0 = 0$ ympäristössä. Nimittäin, kun $x \to 0$,

$$f(x) = O(x^2) \quad \text{ja} \quad f(x) = O(|x|)$$

mutta

$$x^2 = O(|x|) \quad \text{ja} \quad |x| \neq O(x^2),$$

missä $|x| \neq O(x^2)$ tarkoittaa, että $|x|$ ei ole suuruusluokkaa x^2 kun $x \to 0$. Sanallisesti ilmaistuna nämä neljä iso-O-väitettä ovat

$f(x)$ lähestyy nollaa vähintään yhtä nopeasti kuin x^2
ja $f(x)$ lähestyy nollaa vähintään yhtä nopeasti kuin $|x|$

mutta

x^2 lähestyy nollaa vähintään yhtä nopeasti kuin $|x|$
ja $|x|$ lähestyy nollaa *hitaammin* kuin x^2.

Kuva 2.1 havainnollistaa iso-O-notaatiota polynomeille pisteen $x_0 = 0$ läheisyydessä.

Huomautus 2.14. Notaation $f(x) = O(g(x))$ kanssa on syytä olla tarkkana. Koska yhtäsuuruus ("=") on muualla matematiikassa vaihdannainen (eli $a = b$ on sama kuin $b = a$), $f(x) = O(g(x))$ antaa ymmärtää, että voitaisiin kirjoittaa $O(g(x)) = f(x)$, mitä on kuitenkin vaikea tulkita mielekkäästi. Täsmällisesti ilmaistuna $f(x) = O(g(x))$ kun $x \to x_0$ tarkoittaa, että *f kuuluu niiden funktioiden joukkoon, jotka ovat ylhäältä rajoitettuja jonkin vakion ja funktion g tulolla pisteen x_0 ympäristössä.* Merkintä on siis tulkittava vain kätevänä lyhennyksenä.

[1] *Data Structures and Algorithms* (BM40A1500).

Toisinaan käytetään merkintätapaa

$$f(x) = g(x) + O(r(x)) \quad \text{kun} \quad x \to x_0.$$

Tällä tarkoitetaan sitä, että funktion f on summa funktiosta g ja sellaisesta funktiosta, joka on suuruusluokkaa $r(x)$ kun $x \to x_0$. Esimerkiksi käyköön funktio $f(x) = 3 + x^2 + x^3$, jonka voimme tätä merkintätapaa käyttäen kirjoittaa muodossa

$$f(x) = 3 + O(x^2) \quad \text{kun} \quad x \to 0,$$

sillä esimerkissä 2.13 päättelimme, että $x^2 + x^3 = O(x^2)$ kun $x \to 0$.

2.5 Iso-O-notaation ominaisuuksia

Seuraava lause osoittaa, että iso-O-notaatio on *transitiivinen*. Käytännössä lauseessa ei ole kyse muusta kuin siitä perustuloksesta, että $a \le c$ jos $a \le b$ ja $b \le c$.

Lause 2.15. *Jos $f(x) = O(g_1(x))$ ja $g_1(x) = O(g_2(x))$ kun $x \to x_0$, niin*

$$f(x) = O(g_2(x)) \quad \textit{kun} \quad x \to x_0.$$

Todistus. Määritelmän 2.11 nojalla on olemassa $C_1, C_2 \ge 0$ ja $\delta_1, \delta_2 > 0$ siten, että

$$|f(x)| \le C_1 g_1(x) \quad \text{kaikilla} \quad x \in (x_0 - \delta_1, x_0 + \delta_1)$$

ja

$$|g_1(x)| \le C_2 g_2(x) \quad \text{kaikilla} \quad x \in (x_0 - \delta_2, x_0 + \delta_2).$$

Nämä kaksi epäyhtälöä pätevät samanaikaisesti, kun $x \in (x_0 - \delta, x_0 + \delta)$, missä $\delta = \min\{\delta_1, \delta_2\}$. Täten kaikilla $x \in (x_0 - \delta, x_0 + \delta)$ pätee

$$|f(x)| \le C_1 g_1(x) \le C_1 |g_1(x)| \le C_1 \cdot C_2 g_2(x),$$

joten voimme asettaa $g = g_2$, $C = C_1 \cdot C_2$ ja $\delta = \min\{\delta_1, \delta_2\}$ määritelmässä 2.11. □

Seuraava lause osoittaa, ettei määritelmän 2.11 vakio C vaikuta suuruusluokkaan.

Lause 2.16. *Jos $f(x) = O(g_1(x))$ kun $x \to x_0$ ja $g_1(x) = C_{12} g_2(x)$ jollakin $C_{12} \ge 0$, niin $f(x) = O(g_2(x))$ kun $x \to x_0$.*

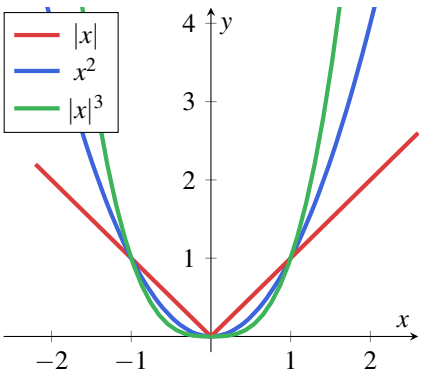

Kuva 2.1: Funktiot $|x|$, x^2 ja $|x|^3$ pisteen $x_0 = 0$ läheisyydessä. Koska $|x|$ on x^2:n yläpuolella kun $x \in (-1, 1)$ ja x^2 on $|x|^3$:n yläpuolella, kuva havainnollistaa, että $x^2 = O(|x|)$ ja $|x|^3 = O(x^2)$, kun $x \to 0$. *Huomaa, että kuvaajien järjestys muuttuu, kun* $|x| > 1$. Jos tarkasteltaisiin pistettä x_0, jolle $|x_0| > 1$ (esim. $x_0 = 2$), iso-O-suhteet pitäisi kääntää: $|x| = O(x^2)$ ja $x^2 = O(|x|^3)$, kun $x \to 2$. Huomaa, että käytämme itseisarvoja $|x|$ ja $|x|^3$, sillä x ja x^3 ovat negatiivisia kun $x < 0$, mutta $f(x) = O(g(x))$ on väite ylärajasta itseisarvolle $|f(x)| \ge 0$, ei funktiolle $f(x)$.

Todistus. Määritelmän 2.11 nojalla on olemassa $C_1 \geq 0$ ja $\delta > 0$ siten, että $|f(x)| \leq C_1 g_1(x)$ kaikilla $x \in (x_0 - \delta, x_0 + \delta)$. Oletuksesta $g_1(x) = C_{12} g_2(x)$ seuraa, että kaikilla $x \in (x_0 - \delta, x_0 + \delta)$ pätee

$$|f(x)| \leq C_1 g_1(x) = C_1 \cdot C_{12} g_2(x),$$

joten voimme valita $C = C_1 \cdot C_{12}$ ja $g = g_2$ määritelmässä 2.11. □

Lauseilla 2.15 ja 2.16 on luonnolliset vastineet jonoille (Määritelmä 2.12). Seuraava esimerkki havainnollistaa varsin tyypillistä iso-O-notaation käyttöä numeerisessa approksimaatiossa, jossa ollaan yleensä kiinnostuneita virheen käyttäytymisestä jonkin *diskretointiparametrin* h lähestyessä nollaa.

Esimerkki 2.17. Esimerkissä 2.5 approksimoimme funktion $f(x) = x^2$ derivaattaa kohdassa $x_0 = 1$ käyttäen erotusosamäärää

$$q(h) = \frac{f(x_0 + h) - f(x_0)}{h}.$$

Lasketaan nyt tämän approksimaation absoluuttisen virheen suuruusluokka kun $h \to 0$. Koska $f'(x) = 2x$ ja $x_0 = 1$, absoluuttinen virhe $\varepsilon(h)$ on

$$\begin{aligned}\varepsilon(h) = |f'(x_0) - q(h)| = \left| f'(x_0) - \frac{f(x_0 + h) - f(x_0)}{h} \right| &= \left| 2 - \frac{(1+h)^2 - 1}{h} \right| \\ &= \left| 2 - \frac{2h + h^2}{h} \right| \\ &= |2 - (2 + h)| \\ &= |h|,\end{aligned}$$

missä käytimme identiteettiä $(a+b)^2 = a^2 + 2ab + b^2$. Täten $\varepsilon(h) = O(|h|)$, mikä tarkoittaa sitä, että erotusosamäärän avulla muodostetun approksimaation $f'(x_0) \approx q(h)$ virhe on suuruusluokaltaan *lineaarinen* kun $h \to 0$. Huomaa, että suhteellinen virhe $\rho(h)$ on samaa suuruusluokkaa, sillä

$$\rho(h) = \left| \frac{f'(x_0) - q(h)}{f'(x_0)} \right| = \frac{1}{|f'(x_0)|} \varepsilon(h),$$

missä $1/|f'(x_0)| = 1/2 > 0$. Lauseesta 2.16 seuraa nyt, että $\rho(h) = O(|h|)$.

Keskitymme pääosin virheisiin $\varepsilon(h)$, joilla on *polynominen suuruusluokka* kun $h \to 0$. Jos funktio on polynomi, pienimmän asteluvun termin kerroin määrää suuruusluokan.

Lause 2.18. *Jos* $\varepsilon(h) = a_n h^n + a_{n+1} h^{n+1} + \cdots + a_{n+m} h^{n+m}$, *missä* $n, m \in \mathbb{N} \cup \{0\}$ *ja* $a_n, \ldots, a_{n+m} \in \mathbb{R}$, *niin*

$$\varepsilon(h) = O(|h|^n) \quad \textit{kun} \quad h \to 0.$$

Todistus. Huomaa, että $x_0 = 0$. Valitaan $\delta = 1$. Kun $h \in (x_0 - \delta, x_0 + \delta) = (-1, 1)$,

$$|\varepsilon(h)| = |a_n h^n + a_{n+1} h^{n+1} + \cdots + a_{n+m} h^{n+m}| \leq |a_n||h|^n + \cdots + |a_{n+m}||h|^{n+m},$$

missä käytimme kolmioepäyhtälöä $|a + b| \leq |a| + |b|$. Koska $|h|^{n+m} \leq |h|^n$ kun $h \in (-1, 1)$, saamme epäyhtälön

$$|\varepsilon(h)| \leq (|a_n| + \cdots + |a_{n+m}|)|h|^n,$$

missä vakio $C = |a_n| + \cdots + |a_{n+m}|$ on epänegatiivinen (eli ≥ 0). Määritelmästä 2.11 seuraa nyt, että $\varepsilon(h) = O(|h|^n)$. □

Emme ole vielä käsitelleet määritelmää 2.12, eli iso-O-notaatiota jonoille. Tällä kurssilla käytämme tätä notaatiota kuvaamaan numeeristen menetelmien virhettä kun n, *diskretisointipisteiden* tai *aika-askelten* lukumäärä, kasvaa.

Esimerkki 2.19. Palataan esimerkkiin 2.4, jossa approksimoimme eksponenttivakiota $e \approx 2.718$ katkaistulla sarjakehitelmällä $e = \sum_{k=0}^{\infty} 1/k!$ n:

$$e \approx e_n = \sum_{k=0}^{n} \frac{1}{k!}.$$

Määritetään tämän approksimaation suuruusluokka (eli virheen $\varepsilon_n = |e - e_n|$ suuruusluokka), kun $n \to \infty$. Saamme

$$\varepsilon_n = |e - e_n| = \left| \sum_{k=0}^{\infty} \frac{1}{k!} - \sum_{k=0}^{n} \frac{1}{k!} \right| = \left| \sum_{k=n+1}^{\infty} \frac{1}{k!} \right| = \sum_{k=n+1}^{\infty} \frac{1}{k!}. \tag{2.1}$$

Mille tahansa $m \geq 1$ voimme kirjoittaa

$$(n+m)! = 1 \cdot 2 \cdots (n+1) \cdot (n+2) \cdots (n+m) = (n+1)! \cdot (n+2) \cdots (n+m), \tag{2.2}$$

missä tulo $(n+2) \cdots (n+m)$ tulkitaan ykköseksi, jos $m = 1$. Sijoittamalla yhtälön (2.2) yhtälöön (2.1) saamme

$$\varepsilon_n = \sum_{k=n+1}^{\infty} \frac{1}{k!} = \sum_{m=1}^{\infty} \frac{1}{(n+m)!} = \frac{1}{(n+1)!} \left(1 + \sum_{m=2}^{\infty} \frac{1}{(n+2) \cdots (n+m)} \right).$$

Viimeinen sarja suppenee (ohitamme todistuksen), mistä seuraa, että voimme valita

$$a_n = \varepsilon_n, \quad b_n = \frac{1}{(n+1)!} \quad \text{ja} \quad C = 1 + \sum_{m=2}^{\infty} \frac{1}{(n+2) \cdots (n+m)}$$

määritelmässä 2.12. Täten

$$\varepsilon_n = |e - e_n| = O\left(\frac{1}{(n+1)!} \right).$$

3 Numeeristen menetelmien rakentaminen

Tämä osio käsittelee numeeristen menetelmien rakentamisen ja implementoinni peruskäsitteistöä ja -työkaluja.

3.1 Taylorin polynomi

Monet numeeriset menetelmät hyödyntävät sileän (eli riittävän monta kertaa derivoituvan) funktion Taylorin polynomeja.

Määritelmä 3.1 (Taylorin polynomit)**.** Olkoon $f\colon (a,b) \to \mathbb{R}$ funktio, joka on n kertaa derivoituva pisteessä $x_0 \in (a,b)$. Funktion f *kertaluvun n Taylorin polynomi* pisteessä x_0 on

$$P_n(x) = f(x_0) + f'(x_0)(x-x_0) + \frac{f''(x_0)}{2!}(x-x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}(x-x_0)^n. \tag{3.1}$$

Palautetaan mieliin, että $f^{(n)}(x)$ tarkoittaa funktion f kertaluvun n derivaattaa pisteessä x, eli

$$f^{(n)}(x) = \frac{\mathrm{d}^n}{\mathrm{d}x^n} f(x).$$

Lisäksi nollas derivaatta on funktio itse: $f^{(0)}(x) = f(x)$. Taylorin polynomit voidaan siis kirjoittaa käyttäen summamerkintää:

$$P_n(x) = \sum_{k=0}^{n} \frac{f^{(k)}(x_0)}{k!}(x-x_0)^k.$$

Esimerkki 3.2. Muodostetaan kertalukujen $n \in \{1,3,5\}$ Taylorin polynomit funktiolle $f(x) = \sin(x)$ pisteessä $x_0 = 0$. Tarvitsemme tätä varten funktion f derivaattojen arvot viidenteen kertalukuun saakka pisteessä $x_0 = 0$. Muistamalla, että funktion $\sin(x)$ derivaatta

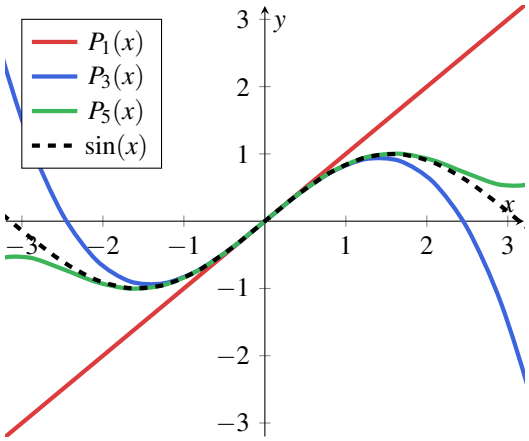

Kuva 3.1: Funktio $f(x) = \sin(x)$ sekä sen Taylorin polynomit P_1, P_3 ja P_5, joiden kertaluvut ovat $n \in \{1,3,5\}$. Taylorin polynomit määritellään yhtälössä (3.1) ja lasketaan sinifunktiolle esimerkissä 3.2. Kuvasta havaitsemme, että Taylorin polynomin kertaluvun kasvattaminen parantaa approksimaation $f(x) \approx P_n(x)$ tarkkuutta. Polynomi P_1 on kelvollinen approksimaatio kun $|x| < 1$, kun taas P_5 toimii hyvin kun $|x| < 2.5$.

on $\cos(x)$ ja funktion $\cos(x)$ derivaatta on $-\sin(x)$, saamme

$$\begin{aligned}
f^{(0)}(x) &= f(x) = \sin(x) &&\Longrightarrow && f^{(0)}(0) = 0,\\
f'(x) &= \cos(x) &&\Longrightarrow && f'(0) = 1,\\
f''(x) &= -\sin(x) &&\Longrightarrow && f''(0) = 0,\\
f^{(3)}(x) &= -\cos(x) &&\Longrightarrow && f^{(3)}(0) = -1,\\
f^{(4)}(x) &= \sin(x) &&\Longrightarrow && f^{(4)}(0) = 0,\\
f^{(5)}(x) &= \cos(x) &&\Longrightarrow && f^{(5)}(0) = 1.
\end{aligned}$$

Sijoittamalla nämä arvot kaavaan (3.1) saamme Taylorin polynomit

$$\begin{aligned}
P_1(x) &= f(x_0) + f'(x_0)(x - x_0) = f(0) + f'(0)x = x,\\
P_3(x) &= f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + \frac{f^{(3)}(0)}{3!}x^3 = x - \frac{1}{6}x^3,\\
P_5(x) &= f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + \frac{f^{(3)}(0)}{3!}x^3 + \frac{f^{(4)}(0)}{4!}x^4 + \frac{f^{(5}(0)}{5!}x^5\\
&= x - \frac{1}{6}x^3 + \frac{1}{120}x^5.
\end{aligned}$$

Näet nämä polynomit kuvassa 3.1.

Esimerkki 3.2 ja kuva 3.1 viittaavat siihen, että Taylorin polynomin kertaluvun tuottaa paremman approksimaation funktiolle f. Matemaattisesta analyysistä tuttu Taylorin lause selittää tämän havainnon.

Lause 3.3 (Taylorin lause)**.** *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja $n+1$ kertaa derivoituva välillä (a,b). Olkoon $x_0 \in (a,b)$. Tällöin jokaisella $x \in [a,b]$ pätee*

$$f(x) - P_n(x) = R_{n+1}(x),$$

missä jäännöstermi R_{n+1} *on*

$$R_{n+1}(x) = \frac{f^{(n+1)}(c_x)}{(n+1)!}(x - x_0)^{n+1}$$

jollakin pisteellä c_x, joka on pisteiden x_0 ja x välillä.

Luvun c_x arvo Taylorin lauseessa riippuu pisteestä x ja kertaluvusta n. Iso-O-notaatiotalla (osio 2.4) voimme kirjoittaa Taylorin lauseen yksinkertaisemmin, mikäli funktion f kertaluvun $(n+1)$ derivaatta on rajoitettu.

Korollaari 3.4. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja $n+1$ kertaa derivoituva välillä (a,b). Olkoon $x_0 \in (a,b)$. Jos on olemassa vakio $L \geq 0$, jolla $|f^{(n+1)}(x)| \leq L$ kaikilla $x \in (a,b)$, niin*

$$R_{n+1}(x) \leq \frac{L}{(n+1)!}|x - x_0|^{n+1} = O(|x - x_0|^{n+1}) \quad \text{as} \quad x \to x_0. \tag{3.2}$$

Todistus. Taylorin lause ja oletus $|f^{(n+1)}(x)| \leq L$ kaikilla $x \in (a,b)$ antavat

$$|R_{n+1}(x)| = \left|\frac{f^{(n+1)}(c_x)}{(n+1)!}(x - x_0)^{n+1}\right| = \frac{|f^{(n+1)}(c_x)|}{(n+1)!}|x - x_0|^{n+1} \leq \frac{L}{(n+1)!}|x - x_0|^{n+1}$$

kaikilla $x \in (a,b)$. Koska $x_0 \in (a,b)$, on olemassa $\delta > 0$ siten, että $(x_0 - \delta, x + \delta) \subset (a,b)$, jolloin yllä oleva epäyhtälö pätee kaikilla $x \in (x_0 - \delta, x + \delta)$. Täten voimme valita $f(x) = R_{n+1}(x)$, $g(x) = |x - x_0|^{n+1}$ ja $C = L/(n+1)!$ määritelmässä 2.11. Tämä todistaa väitteen (3.2). □

Valitsemalla $x = x_0 + h$ (jolloin $x - x_0 = h$) voidaan (3.2) kirjoittaa muotoon

$$R_{n+1}(x_0 + h) = O(|h|^{n+1}) \quad \text{kun} \quad h \to 0,$$

mikä korostaa jäännöstermin pienenmistä tarkasteltaessa pisteen x_0 läheisyydessä olevia pisteitä (eli tapausta $h \to 0$).

Esimerkki 3.5. On tärkeää ymmärtää, että jäännöstermi R_{n+1} on pieni vain pisteen x_0 läheisyydessä. Tarkastellaan esimerkiksi kertaluvun $n = 2$ Taylorin polynomia pisteessä $x_0 = 1$ funktiolle $f(x) = x^4 + 2x^2$. Koska f on määritelty koko reaaliakselilla $\mathbb{R}$, voimme valita minkä tahansa välin, joka sisältää x_0:n, ja käyttää sitä korollaarissa 3.4. Valitaan $[a,b] = [0,2]$. Tällöin (koska $n + 1 = 3$)

$$|f^{(3)}(x)| = \left| \frac{\mathrm{d}^2}{\mathrm{d}x^2}(4x^3 + 4x) \right| = \left| \frac{\mathrm{d}}{\mathrm{d}x}(12x^2 + 4) \right| = |24x| \leq 48 \quad \text{kaikilla} \quad x \in [0,2].$$

Siksi voimme soveltaa korollaaria 3.4 arvoilla $n = 2$, $x_0 = 1$ ja $L = 48$ ja päätellä, että

$$f(x) - P_2(x) = R_3(x) = O(|x - 1|^3) \quad \text{kun} \quad x \to 1,$$

mistä seuraa, että kertaluvun kaksi Taylorin polynomin P_2 virhe on suuruusluokaltaan *kuutiollinen* kun $x \to x_0 = 1$. Tilanne muuttuu kuitenkin täysin, kun liikutaan poispäin pisteestä $x_0 = 1$. Koska $n = 2$, nähdään Taylorin polynomin määritelmästä (3.1), että P_2 on *toisen* asteen polynomi, eli $P_2(x) = \alpha x^2 + \beta x + \gamma$ joillakin $\alpha, \beta, \gamma \in \mathbb{R}$. Koska $f(x) = x^4 + 2x^2$, tästä seuraa, että

$$f(x) - P_2(x) = x^4 + (2 - \alpha)x^2 - \beta x - \gamma,$$

joka on *neljännen* asteen polynomi, korkeimman asteen termin kerroin on positiivinen (eli asteen 4 termin kerroin on 1). Tästä seuraa, että

$$f(x) - P_2(x) \to \infty \quad \text{kun} \quad x \to \infty \text{ tai } x \to -\infty.$$

Näin ollen virheestä voidaan tehdä mielivaltaisen suuri valitsemalla x, joka on riittävän kaukana pisteestä $x_0 = 1$.

3.2 Linearisointi

Taylorin polynomi (Määritelmä 3.1) tapauksessa $n = 1$ on eräs tärkeimmistä työkaluista numeeristen menetelmien kehityksessä.

Määritelmä 3.6 (Lineaarinen approksimaatio)**.** Olkoon $f\colon (a,b) \to \mathbb{R}$ derivoituva pisteessä $x_0 \in (a,b)$. Funktion f *lineaarinen approksimaatio* pisteessä x_0 on lineaarinen polynomi

$$L(x) = P_1(x) = f(x_0) + f'(x_0)(x - x_0). \tag{3.3}$$

Lineaarisen approksimaation L laskemista ja käyttämistä funktion f approksimointiin kutsutaan *linearisoinniksi*.

Lineaarinen approksimaatio on korkeamman kertaluvun Taylorin polynomeja helpompi laskea ja käyttää, sillä sen laskemiseen tarvitaan ainoastaan $f(x_0)$ ja $f'(x_0)$. Sovelluksissa korkeamman

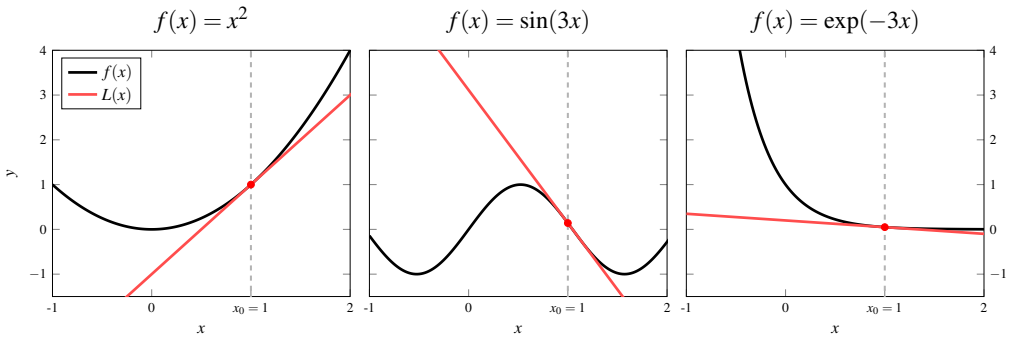

Kuva 3.2: Lineaariset approksimaatiot (punainen) kolmelle funktiolle $f(x) = x^2$, $f(x) = \sin(3x)$ ja $f(x) = \exp(-3x)$ pisteessä $x_0 = 1$. Havaitaan, että lineaariset approksimaatiot ovat *tangenttisuoria* pisteessä $x_0 = 1$. Toisin sanoen lineaarinen approksimaatio on suora, jonka kulmakerroin on funktion f derivaatta pisteessä x_0.

kertaluvun derivaattojen laskeminen on usein hankalaa tai jopa mahdotonta. Lisäksi linearisointi yleistyy helposti useamman muuttujan funktioihin $f\colon \mathbb{R}^d \to \mathbb{R}$ *gradientin* avulla ja tuottaa numeerisia menetelmiä, joiden implementointi on suoraviivaista ja joiden toimintaa on helppo ymmärtää.

Esimerkki 3.7. Muodostetaan lineaariset approksimaatiot funktioille

$$f_1(x) = -x^2, \quad f_2(x) = \sin(\tfrac{\pi}{2}x) \quad \text{ja} \quad f_3(x) = e^x - x^2$$

pisteessä $x_0 = 1$. Funktiolle f_1 saadaan

$$f_1(1) = -1 \text{ ja } f_1'(1) = -2 \quad \Longrightarrow \quad L(x) = f(1) + f'(1)(x-1) = -2x+1.$$

Funktiolle f_2 saadaan [muista trigonometriasta $\sin(\frac{\pi}{2}) = 1$]

$$f_2(1) = 1 \text{ ja } f_2'(1) = 0 \quad \Longrightarrow \quad L(x) = f(1) + f'(1)(x-1) = 1.$$

Funktiolle f_3 saadaan

$$f_3(1) = e-1 \text{ ja } f_3'(1) = e-2 \quad \Longrightarrow \quad L(x) = f(1) + f'(1)(x-1) = (e-2)x+1.$$

Kuva 3.2 näyttää lineaariset approksimaatiot pisteessä $x_0 = 1$ kolmelle samankaltaiselle funktiolle.

Esimerkki 3.7 ja kuva 3.2 osoittavat, että linearisointi vastaa sellaisen suoran piirtämistä, joka (a) kulkee pisteen $(x_0, f(x_0))$ kautta ja (b) jonka kulmakerroin on $f'(x_0)$.

Lause 3.8. *Lineaarinen approksimaatio on ainoa suora, joka kulkee pisteen $(x_0, f(x_0))$ kautta ja jonka kulmakerroin on $f'(x_0)$.*

Todistus. Jokaisen suoran voi esittää yhtälöllä $y = \alpha x + \beta$ joillakin $\alpha, \beta \in \mathbb{R}$, missä α on suoran kulmakerroin. Se, että suora kulkee pisteen $(x_0, f(x_0))$ kautta, tarkoittaa että $f(x_0) = \alpha x_0 + \beta$. Se, että suoran kulmakerroin on $f'(x_0)$, tarkoittaa että $\alpha = f'(x_0)$. Siispä

$$f(x_0) = \alpha x_0 + \beta = f'(x_0)x_0 + \beta \quad \Longrightarrow \quad \beta = f(x_0) - f'(x_0)x_0.$$

Täten kaikilla väitteen suorilla on $\alpha = f'(x_0)$ ja $\beta = f(x_0) - f'(x_0)x_0$. Toisin sanoen on täsmälleen yksi suora, joka kulkee pisteen $(x_0, f(x_0))$ kautta ja jonka kulmakerroin on $f'(x_0)$. Tämän suoran yhtälö on

$$y = \alpha x + \beta = f'(x_0)x + f(x_0) - f'(x_0)x_0 = f(x_0) + f'(x_0)(x - x_0),$$

joka on täsmälleen kaavan (3.3) lineaarinen approksimaatio. □

Kuvasta 3.2 näemme, että linearisointi antaa hyvän approksimaation kun x on lähellä pistettä x_0, mutta approksimaation tarkkuus voi heikentyä nopeasti, kun liikutaan kauemmas tästä pisteestä. Seuraavan tuloksen mukaan lineaarisen approksimaation virhe on *neliöllistä* kertaluokkaa kun $x \to x_0$, jos f on kahdesti derivoituva.

Lause 3.9. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja kahdesti derivoituva välillä (a,b). Olkoon $x_0 \in (a,b)$. Jos on olemassa vakio $L \geq 0$, jolla $|f''(x)| \leq L$ kaikilla $x \in (a,b)$, niin*

$$f(x) - L(x) = O(|x - x_0|^2) \quad \textit{kun} \quad x \to x_0.$$

Todistus. Koska $L(x) = P_1(x)$, väite seuraa asettamalla $n = 1$ korollaarissa 3.4. □

3.3 Taulukko-ohjelmointi

Taulukko-ohjelmointi, eli *vektorisointi*, tarkoittaa ohjelmointityyliä, jossa matemaattisia operaatioita sovelletaan kerralla kaikkiin taulokon arvoihin (vektoriin) sen sijaan, että niitä sovellettaisiin jokaiseen arvoon erikseen (eli silmukalla). Taulukko-ohjelmoinnilla toteutetut algoritmit vat yleensä *helppolukuisempia* kuin vastaavat silmukoin toteutetut algoritmit. Monissa korkean abstraktion kielissä, kuten Pythonissa ja MATLABissa, taulukko-ohjelmointi on myös *huomattavasti nopeampaa* kuin silmukat ja sitä kannattaa hyödyntää aina. Oletetaan, että haluamme korottaa neliöön (eli laskea x^2) kymmenen miljoonaa lukua x välillä nollasta yhteen käyttäen Pythonia. Taulukko-ohjelmointiin käytämme Pythonin `numpy`-kirjastoa.

```
>>> import numpy as np
>>> import time
>>> # an array of ten million numbers between 0 and 1
>>> a = np.linspace(start=0, stop=1, num=int(1e7))
>>> # use loop to square each number
>>> start1 = time.perf_counter()
>>> b1 = [x**2 for x in a]
>>> end1 = time.perf_counter()
>>> # square each number using array programming
>>> start2 = time.perf_counter()
>>> b2 = a**2
>>> end2 = time.perf_counter()
>>> # print elapsed times
>>> print(end1 - start1)
0.5299568176269531
>>> print(end2 - start2)
0.007016181945800781
```

Vaikka kulunut aika riippuu tietokoneesta ja ajokerrasta, taulukko-ohjelmointi on aina nopeampaa.

Esimerkki 3.10. Monte Carlo -integrointi on yksinkertainen menetelmä funktion integraalin approksimoimiseen. Oletetaan, että haluamme approksimoida jonkin funktion $f\colon [0,1] \to \mathbb{R}$ integraalia $\int_0^1 f(x)\,\mathrm{d}x$. Monte Carlo -integroinnissa arvotaan n lukua $x_1, \ldots, x_n$ tasaisesti välillä $[0,1]$ ja approksimoidaan integraalia funktion näiden pisteiden avulla laskettulla

keskiarvolla:

$$\int_0^1 f(x)\,\mathrm{d}x \approx \frac{1}{n}\sum_{i=1}^{n} f(x_i). \tag{3.4}$$

Taulukko-ohjelmointia tukevissa ohjelmointikielissä Monte Carlo -approksimaation (3.4) laskeminen onnistuu ilman yhtäkään silmukkaa.

Pythonissa approksimaatio ($n = 200$) funktion $f(x) = x^{3.4} + \sin(x)$ integraalille voidaan laskea esimerkiksi näin:

```
>>> import numpy as np
>>> rng = np.random.default_rng()
>>> # draw n = 200 random numbers on [0, 1]
>>> n = 200
>>> samples = rng.random(size=n)
>>> # evaluate f at these point and compute average
>>> evals = np.power(samples, 3.4) + np.sin(samples)
>>> mc_approx = np.sum(evals) / n
>>> print(mc_approx)
0.692222065735476
```

Lopputulos vaihtelee ajokerrasta toiseen, koska 200 pistettä x_i arvotaan satunnaisesti. MATLABissa tämän voi tehdä seuraavasti:

```
>>> # draw n = 200 random numbers on [0, 1]
>>> n = 200;
>>> samples = rand(n, 1);
>>> # evaluate f at these point and compute average
>>> evals = samples.^(3.4) + sin(samples);
>>> mc_approx = sum(evals) / n
mc_approx =

   0.6686
```

Tässä käytimme MATLABin pistepotenssia (eli alkioittaista potenssi), joka laskee potenssin $x^{3.4}$ jokaiselle satunnaisluvulle x.

4 Numeerinen integrointi

Palautetaan mieleen, että funktion f *integraalifunktio* (tai *määräämätön integraali* tai *antiderivaatta*) on funktio F, jolla

$$F'(x) = f(x).$$

Olkoon $a < b$. Funktion f *määrätty integraali* pisteestä a pisteeseen b kuvaa funktion f kuvaajan ja x-akselin välistä pinta-alaa. Määrätty integraali voidaan ilmaista antiderivaatan avulla muodossa

$$\int_a^b f(x)\,\mathrm{d}x = F(b) - F(a)$$

analyysin peruslauseen nojalla. Derivointi on helppoa. Esimerkiksi ketjusäännön ja eksponenttifunktioiden, polynomien sekä trigonometristen funktioiden derivointisääntöjen avulla funktion $f(x) = \exp(-x^2 + \sin(x))$ derivointi ei tuota vaikeuksia. Sen sijaan integrointi on yleensä vaikeaa tai suorastaan mahdotonta. Funktion $f(x) = \exp(-x^2 + \sin(x))$ integraalifunktiota ei ole mahdollista ilmaista suljetussa muodossa tuttujen alkeisfunktioiden[2] avulla. Tämän vuoksi numeeriset menetelmät ovat välttämättömiä useimpien määrättyjen integraalien laskemiseksi. Integraalifunktion laskemiseen täytyy käyttää *symbolista laskentaa*, jota ei käsitellä tällä kurssilla. Huomaa, että funktiolla, jonka integraalifunktio ei ole esitettävissä alkeisfunktioiden avulla, voi silti olla yksinkertainen määrätty integraali. Esimerkiksi käy hyvin vaikkapa

$$\int_{-\infty}^{\infty} \exp(-x^2)\,\mathrm{d}x = \sqrt{\pi}.$$

On hyödyllistä ajatella määrättyjä integraaleja pinta-aloina ja *numeerisen integroinnin* menetelmiä pinta-aloja arvioivina menetelminä. Tällaisia menetelmiä kutsutaan kvadratuurisäännöiksi (tai yksinkertaisesti säännöiksi). Terminologia juontaa latinan sanasta *quadratus*, joka tarkoittaa neliötä (tämä on erityisen osuvaa keskipistesäännöstä puhuttaessa, ks. osio 4.1).

Määritelmä 4.1 (Kvadratuurisääntö)**.** Olkoon $n \in \mathbb{N}$. *Kvadratuurisääntö* on integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{i=1}^{n} w_i f(t_i), \tag{4.1}$$

missä $w_1, \ldots, w_n \in \mathbb{R}$ ovat *painoja* ja $t_1, \ldots, t_n \in [a,b]$ ja *solmupisteitä*.

Painojen ja solmupisteiden valinta määrää, kuinka hyvä kvadratuurisääntö on. Tässä luvussa käsitellään kolmea kvadratuurisääntöä: keskipistesääntöä, puolisuunnikassääntöä ja Simpsonin sääntöä.

4.1 Keskipistesääntö

Olkoot $x_i = a + (b-a)i/n$, missä $i \in \{0, 1, \ldots, n\}$, tasavälisiä pisteitä välillä $[a,b]$. Muistetaan integraalilaskennan kurssilta, että riittävän säännöllisen (eli Riemann-integroituvan) funktion integraali saadaan Riemannin summan raja-arvona:

$$\int_a^b f(x)\,\mathrm{d}x = \lim_{n\to\infty} \sum_{i=1}^{n} (x_i - x_{i-1}) f(t_i) = \lim_{n\to\infty} \frac{b-a}{n} \sum_{i=1}^{n} f(t_i), \tag{4.2}$$

missä $t_i \in [x_{i-1}, x_i]$. Jokainen summan termi on sellaisen *suorakulmion pinta-ala*, jonka kannan leveys on $(x_i - x_{i-1}) = (b-a)/n$ ja korkeus $f(t_i)$. Suorakulmioiden korkeudet voidaan laskea

[2] Funktiota pidetään tyypillisesti *alkeisfunktiona*, jos se koostuu äärellisen monesta vakiosta, polynomista, funktioista exp, log, trigonometrisistä ja hyperbolisista funktioista (sin, cos, tan, sinh, cosh, tanh ja niin edelleen) sekä trigonometristen ja hyperbolisten funktioiden käänteisfunktioista.

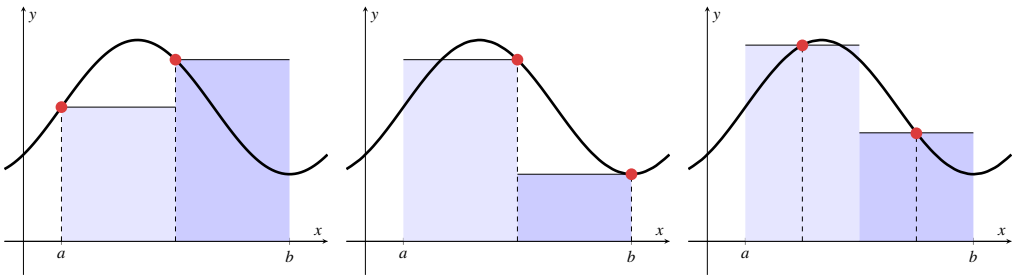

Kuva 4.1: Määrätyn integraalin $\int_a^b f(x)\,\mathrm{d}x$ approksimaatiot kahdella suorakulmiolla, joiden korkeudet lasketaan kunkin osavälin alkupisteessä (*vasemmalla*), päätepisteessä (*keskellä*) ja keskipisteessä (*oikealla*). Määritelmän 4.2 keskipistesääntö vastaa oikeanpuoleista kuvaa.

käyttäen funktion arvoa missä tahansa osavälin $[x_{i-1}, x_i]$ pisteessä. Yksinkertaisin lähestymistapa olisi laskea korkeus välin päätepisteessä, mikä tarkoittaa termin $f(t_i)$ korvaamista termillä $f(x_{i-1})$ tai $f(x_i)$ yhtälössä (4.2). Näitä kolmea vaihtoehtoa havainnollistetaan kuvassa 4.1. Korvaamalla termit $f(t_i)$ termeillä $f(\frac{1}{2}(x_i + x_{i-1}))$, missä $\frac{1}{2}(x_i + x_{i-1})$ on osavälin $[x_{i-1}, x_i]$ *keskipiste*, ja raja-arvo yhtälössä (4.2) äärellisellä luvun n arvolla saadaan keskipistesääntö, joka on käsitteellisesti samankaltainen kuin esimerkin 2.5 erotusosamääräapproksimaatio siinä mielessä, että approksimaatio muodostetaan ”katkaisemalla raja-arvoprosessi”.

Määritelmä 4.2 (Keskipistesääntö)**.** Olkoot $x_i = a + (b-a)i/n$, missä $i \in \{0, 1, \ldots, n\}$. *Keskipistesääntö* (eli *suorakulmiosääntö*) on integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{n} \sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) = h \sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right), \tag{4.3}$$

missä $h = x_{i-1} - x_i = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Vertaamalla yhtälöä (4.3) yhtälöön (4.1) nähdään, että keskipistesääntö on kvadratuurisääntö solmupisteillä $t_i = \frac{1}{2}(x_i + x_{i-1})$ ja yhtäsuuruisilla painoilla $w_i = (b-a)/n$. Kuva 4.2 havainnollistaa kahden osavälin (eli $n = 2$) keskipistesääntöä.

Huomautus 4.3. Olisimme voineet käyttää epätasavälisiä pisteitä $a = x_0 < x_1 < \cdots < x_{n-1} < x_n = b$ keskipistesäännön muodostamiseen. Tuloksena oleva sääntö on

$$\int_a^b f(x)\,\mathrm{d}x \approx \sum_{i=1}^{n} (x_i - x_{i-1}) f\left(\frac{x_i + x_{i-1}}{2}\right).$$

Kaikki tässä osiossa määritellyt kvadratuurisäännöt voidaan muodostaa epätasavälisin pistein. Yksinkertaisuuden vuoksi käytämme kuitenkin aina tasavälisiä pisteitä.

Esimerkki 4.4. Käytetään keskipistesääntöä neljällä osavälillä (eli $n = 4$) integraalin $\int_0^4 x^3\,\mathrm{d}x = 4^4/4 = 64$ approksimoimiseen. Yhtälön (4.3) oikean puolen laskemiseksi tarvitaan (a) osavälien pituus $h = (b-a)/n$ ja (b) keskipisteet $\frac{1}{2}(x_i + x_{i-1})$. Koska $n = 4$, $b = 4$ ja $a = 0$, saadaan

$$\frac{b-a}{n} = \frac{4-0}{4} = 1 \tag{4.4}$$

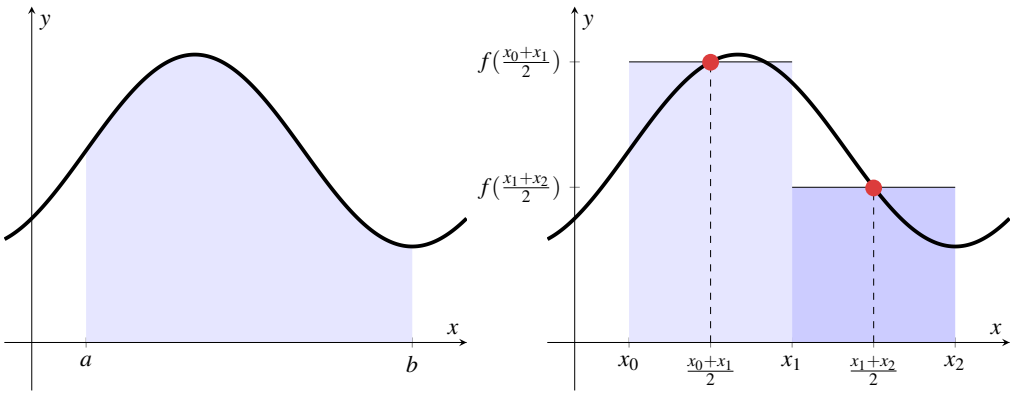

Kuva 4.2: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio kahden (eli $n = 2$) osavälin keskipistesäännöllä.

ja

$$x_i = a + \frac{(b-a)i}{n} = 0 + \frac{(4-0)i}{4} = i.$$

Täten keskipisteet ovat

$$\frac{x_i + x_{i-1}}{2} = \frac{i + (i-1)}{2} = i - \frac{1}{2}. \tag{4.5}$$

Sijoittamalla (4.4) ja (4.5) yhtälöön (4.3) saadaan

$$\begin{aligned}\int_0^4 x^3\,\mathrm{d}x \approx 1 \cdot \sum_{i=1}^{4} f\left(i - \frac{1}{2}\right) &= 1 \cdot f\left(\frac{1}{2}\right) + 1 \cdot f\left(\frac{3}{2}\right) + 1 \cdot f\left(\frac{5}{2}\right) + 1 \cdot f\left(\frac{7}{2}\right) \\ &= \left(\frac{1}{2}\right)^3 + \left(\frac{3}{2}\right)^3 + \left(\frac{5}{2}\right)^3 + \left(\frac{7}{2}\right)^3 \\ &= 62.\end{aligned}$$

Täten keskipistesäännön suhteellinen virhe (muista määritelmä 2.8) on

$$\left|\frac{\int_0^4 x^3\,\mathrm{d}x - 62}{\int_0^4 x^3\,\mathrm{d}x}\right| = \left|\frac{64-62}{64}\right| = \frac{1}{32} = 3{,}125\ \%.$$

Kvadratuurisäännön sanotaan olevan *tarkka* funktiolle f, jos sääntö antaa integraalin todellisen arvon.

Lause 4.5. *Keskipistesääntö on tarkka jokaiselle polynomille, jonka aste on enintään yksi.*

Todistus. Jokainen polynomi, jonka aste on enintään yksi, on muotoa $f(x) = \alpha + \beta x$ joillakin vakioilla $\alpha, \beta \in \mathbb{R}$. Haluamme osoittaa, että

$$\int_a^b f(x)\,\mathrm{d}x = \frac{b-a}{n} \sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right)$$

tällaiselle funktiolle f. Integraali on

$$\int_a^b f(x)\,\mathrm{d}x = \int_a^b (\alpha + \beta x)\,\mathrm{d}x = (b-a)\alpha + \frac{(b^2 - a^2)\beta}{2}. \tag{4.6}$$

Koska $x_i = a + (b-a)i/n$, keskipisteet ovat

$$\frac{x_i + x_{i-1}}{2} = a + \frac{(b-a)i/n + (b-a)(i-1)/n}{2} = a + \frac{(b-a)i}{n} - \frac{b-a}{2n}.$$

Täten keskipistesääntö on

$$\begin{aligned}
\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) &= \frac{b-a}{n}\left(\alpha n + \beta \sum_{i=1}^{n}\left[a + \frac{(b-a)i}{n} - \frac{b-a}{2n}\right]\right) \\
&= (b-a)\alpha + \frac{b-a}{n}\beta\left(na - \frac{b-a}{2} + \frac{b-a}{n}\sum_{i=1}^{n} i\right) \\
&= (b-a)\alpha + (b-a)a\beta - \frac{(b-a)^2\beta}{2n} + \frac{(b-a)^2\beta}{n^2}\sum_{i=1}^{n} i.
\end{aligned}$$

Muistamalla aritmeettisen summan kaava $\sum_{i=1}^{n} i = n(n+1)/2$ saadaan

$$\begin{aligned}
\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) &= (b-a)\alpha + \frac{(b-a)a\beta}{n} - \frac{(b-a)^2\beta}{2n} + \frac{(b-a)^2\beta}{n^2}\cdot\frac{n(n+1)}{2} \\
&= (b-a)\alpha + (b-a)a\beta - \frac{(b-a)^2\beta}{2n} + (n+1)\frac{(b-a)^2\beta}{2n} \\
&= (b-a)\alpha + (b-a)a\beta + \frac{(b-a)^2\beta}{2} \\
&= (b-a)\alpha + (b-a)a\beta + \frac{(b^2 - 2ab + a^2)\beta}{2} \\
&= (b-a)\alpha + \frac{(2(b-a)a + b^2 - 2ab + a^2)\beta}{2} \\
&= (b-a)\alpha + \frac{(b^2 - a^2)\beta}{2}.
\end{aligned}$$

Tämä on yhtä suuri kuin (4.6). Täten keskipistesääntö on tarkka kaikille funktioille, jotka ovat muotoa $f(x) = \alpha + \beta x$. □

Keskipistesääntö *ei* ole tarkka kaikille toisen asteen polynomeille. Tämän osoittamiseksi riittää löytää yksi toisen asteen polynomi, jolle (4.3) ei ole yhtäsuuruus. Valitaan $f(x) = x^2$ ja tarkastellaan yksinkertaisuuden vuoksi tapausta $a = 0$. Tällöin

$$\int_a^b f(x)\,\mathrm{d}x = \int_0^b x^2\,\mathrm{d}x = \frac{b^3}{3} \tag{4.7}$$

ja (kuten lauseen 4.5 todistuksessa)

$$\begin{aligned}
\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i + x_{i-1}}{2}\right) = \frac{b-a}{n}\sum_{i=1}^{n}\left(a + \frac{(b-a)i}{n} - \frac{b-a}{2n}\right)^2 &= \frac{b}{n}\sum_{i=1}^{n}\left(\frac{bi}{n} - \frac{b}{2n}\right)^2 \\
&= \frac{b^3}{n^3}\sum_{i=1}^{n}\left(i - \frac{1}{2}\right)^2 \\
&= \frac{b^3}{n^3}\sum_{i=1}^{n}\left(i^2 - i + \frac{1}{4}\right).
\end{aligned}$$

Palautetaan mieliin summakaavat

$$\sum_{i=1}^{n} i = \frac{n(n+1)}{2} \quad \text{and} \quad \sum_{i=1}^{n} i^2 = \frac{n(n+1)(2n+1)}{6},$$

joilla saadaan

$$\begin{aligned}\frac{b^3}{n^3}\sum_{i=1}^{n}\left(i^2-i+\frac{1}{4}\right) &= \frac{b^3}{n^3}\left(\frac{n(n+1)(2n+1)}{6}-\frac{n(n+1)}{2}+\frac{n}{4}\right)\\ &= \frac{b^3}{n^3}\cdot\frac{n}{12}[2n(n+1)(2n+1)-6n(n+1)+3n]\\ &= \frac{b^3(4n^3+6n^2+2n-6n^2-6n+3n)}{12n^2}\\ &= \frac{b^3(4n^2-1)}{12n^2}.\end{aligned}$$

Täten

$$\frac{b-a}{n}\sum_{i=1}^{n} f\left(\frac{x_i+x_{i-1}}{2}\right) = \frac{b^3}{3}\left(1-\frac{1}{4n^2}\right),$$

mikä ei ole yhtä suuri kuin yhtälössä (4.7) annettu todellinen integraali millään $n \in \mathbb{N}$, koska $1-1/(4n^2) \neq 1$.

Lause 4.6. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja kahdesti derivoituva välillä (a,b). Jos on olemassa vakio $L \geq 0$ siten, että $|f''(x)| \leq L$ kaikilla $x \in (a,b)$, niin keskipistesäännön virheelle pätee*

$$\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^{n} h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right| \leq \frac{(b-a)^3L}{24n^2} = \frac{(b-a)L}{24}h^2,$$

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1},x_i]$ pituus.

Todistus. Jakamalla integrointiväli n osaväliin voimme kirjoittaa keskipistesäännön virheen muodossa

$$\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^{n} h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right) = \sum_{i=1}^{n}\left(\int_{x_{i-1}}^{x_i} f(x)\,\mathrm{d}x - h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right). \tag{4.8}$$

Olkoon $t_i = \frac{1}{2}(x_i+x_{i-1})$ osavälin $[x_{i-1},x_i]$ keskipiste. Tällöin

$$\begin{aligned}\int_{x_{i-1}}^{x_i}[f(t_i)+f'(t_i)(x-t_i)]\,\mathrm{d}x &= f(t_i)(x_i-x_{i-1}) + \frac{f'(t_i)}{2}(x_i^2-x_{i-1}^2) - f'(t_i)t_i(x_i-x_{i-1})\\ &= (x_i-x_{i-1})\left[f(t_i)+\frac{f'(t_i)}{2}(x_i+x_{i-1}) - f'(t_i)t_i\right]\\ &= (x_i-x_{i-1})[f(t_i)-f'(t_i)t_i+f'(t_i)t_i]\\ &= (x_i-x_{i-1})f(t_i)\\ &= h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right).\end{aligned}$$

Täten (4.8) saa muodon

$$\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^{n} h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right) = \sum_{i=1}^{n}\int_{x_{i-1}}^{x_i}[f(x)-f(t_i)-f'(t_i)(x-t_i)]\,\mathrm{d}x.$$

Huomataan, että $f(x)-f(t_i)-f'(t_i)(x-t_i) = f(x)-P_{1,t_i}(x) = R_{2,t_i}(x)$, missä P_{1,t_i} ja R_{2,t_i} ovat (osio 3.1) ensimmäisen asteen Taylorin polynomi ja sen jäännöstermi, kun $x_0 = t_i$. Taylorin

lauseesta (lause 3.3) ja korollaarista 3.4, kun $n+1=2$, seuraa sitten, että

$$\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^n h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = \left|\sum_{i=1}^n \int_{x_{i-1}}^{x_i} R_{2,t_i}(x)\,\mathrm{d}x\right| \le \sum_{i=1}^n \int_{x_{i-1}}^{x_i} \frac{L}{2!}(x-t_i)^2\,\mathrm{d}x$$
$$= \frac{L}{2}\sum_{i=1}^n \int_{-h/2}^{h/2} y^2\,\mathrm{d}y,$$

missä viimeisessä yhtälössä käytettiin muuttujanvaihtoa $y = x - t_i$ ja sitä, että t_i on välin $[x_{i-1}, x_i]$ keskipiste. Täten

$$\begin{aligned}\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^n h\cdot f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = \frac{L}{2}\sum_{i=1}^n \int_{-h/2}^{h/2} y^2\,\mathrm{d}y &= \frac{L}{2}\sum_{i=1}^n \frac{1}{3}\cdot[(h/2)^3-(-h/2)^3] \\ &= \frac{L}{24}\sum_{i=1}^n h^3 \\ &= \frac{L}{24}nh^3 \\ &= \frac{L}{24}n\left(\frac{b-a}{n}\right)^3 \\ &= \frac{(b-a)^3L}{24n^2}.\end{aligned}$$

□

Käyttäen iso-O-notaatiota osiosta 2.4 voimme kirjoittaa lauseen 4.6 muodossa

$$\left|\int_a^b f(x)\,\mathrm{d}x - \frac{b-a}{n}\sum_{i=1}^n f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = O(n^{-2}) \quad \text{kun} \quad n\to\infty.$$

Tämä antaa tietoa integrointivirheen suuruusluokasta osavälien lukumäärän (n) kasvaessa. Vastaavasti voimme kirjoittaa

$$\left|\int_a^b f(x)\,\mathrm{d}x - h\sum_{i=1}^n f\left(\frac{x_i+x_{i-1}}{2}\right)\right| = O(h^2) \quad \text{as} \quad h\to 0,$$

mikä kuvaa virheen käyttäytymistä, kun osavälien pituus, $h=(b-a)/n$, lähestyy nollaa.

4.2 Puolisuunnikassääntö

Keskipistesääntö käytti suorakulmioita integraalin approksimoimiseen. Puolisuunnikassääntö käyttää *puolisuunnikkaita*, jotka ovat suorakulmioita yleisempiä. Suorakulmion molemmat sivuparit ovat yhdensuuntaiset, kun taas puolisuunnikkaalla on vähintään yksi yhdensuuntaisten sivujen pari. Suorakulmion, jonka kannan pituus on h ja korkeus a, pinta-ala on $a\cdot h$; puolisuunnikkaan, jonka kannan pituus on h ja korkeudet b_1 ja b_1, pinta-ala on $\frac{1}{2}(b_1+b_2)\cdot h$ (ks. kuva 4.3). Korvaamalla suorakulmiot, joiden korkeudet lasketaan funktion f arvoista osavälien keskipisteissä $\frac{1}{2}(x_i+x_{i-1})$, puolisuunnikkailla, joiden sivujen korkeudet ovat funktion f arvot osavälien päätepisteissä x_{i-1} ja x_i, saadaan puolisuunnikassääntö.

Määritelmä 4.7 (Puolisuunnikassääntö)**.** Olkoot $x_i = a+(b-a)i/n$, missä $i\in\{0,1,\dots,n\}$. *Puolisuunnikassääntö* integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{n}\sum_{i=1}^n \frac{f(x_i)+f(x_{i-1})}{2} = h\sum_{i=1}^n \frac{f(x_i)+f(x_{i-1})}{2}, \tag{4.9}$$

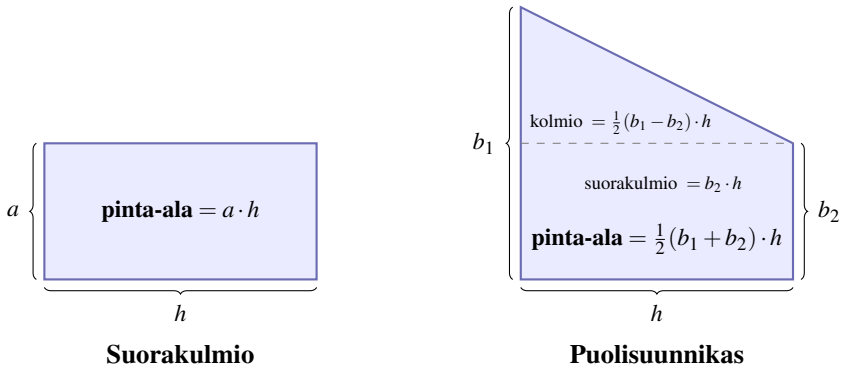

Kuva 4.3: Suorakulmion ja puolisuunnikkaan pinta-alat, kun puolisuunnikkaassa on kaksi suoraa kulmaa.

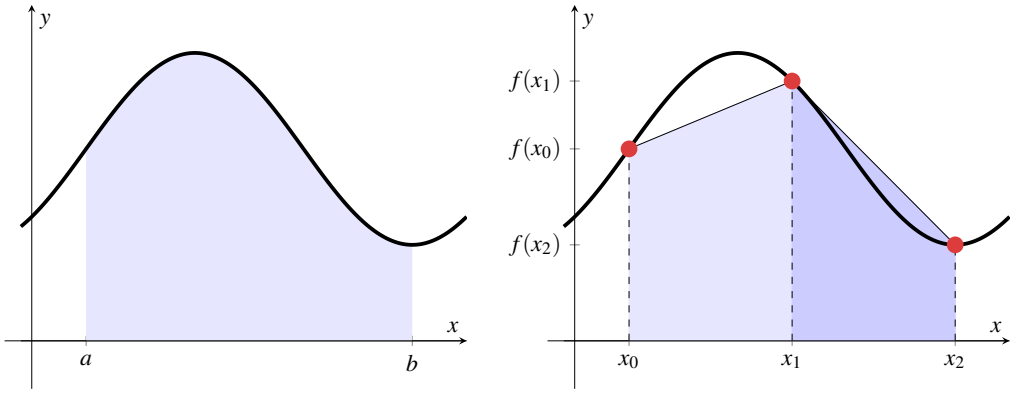

Kuva 4.4: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio kahden ($n = 2$) osavälin puolisuunnikassäännöllä.

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Huomaamalla, että $f(x_0)$ ja $f(x_n)$ esiintyvät kerran ja kaikki muut funktioiden arvot kahdesti yhtälössä (4.9), voimme kirjoittaa puolisuunnikassäännön muodossa

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{h}{2}[f(x_0) + 2f(x_1) + \cdots + 2f(x_{n-1}) + f(x_n)]. \tag{4.10}$$

Täten puolisuunnikassääntö on kvadratuurisääntö [muistetaan (4.1)] solmupisteillä $t_i = x_i$, missä $i \in \{0, \ldots, n\}$, ja painoilla $w_0 = w_n = \frac{1}{2}h$ sekä $w_1 = \cdots = w_{n-1} = h$. Kuva 4.4 havainnollistaa puolisuunnikassääntöä.

Esimerkki 4.8. Käytetään puolisuunnikassääntöä neljällä osavälillä (eli $n = 4$) integraalin $\int_0^4 x^3\,\mathrm{d}x = 4^4/4 = 64$ approksimoimiseen. Yhtälön (4.9) oikean puolen laskemiseksi tarvitaan (a) osavälien pituus $h = (b-a)/n$ ja (b) pisteet x_i. Koska $n = 4$, $b = 4$ ja $a = 0$, saadaan

$$h = \frac{b-a}{n} = \frac{4-0}{4} = 1 \tag{4.11}$$

ja

$$x_i = a + \frac{(b-a)i}{n} = 0 + \frac{(4-0)i}{4} = i. \tag{4.12}$$

Sijoittamalla (4.11) ja (4.12) yhtälöön (4.10) saadaan

$$\begin{aligned}\int_0^4 x^3 \,\mathrm{d}x &\approx \frac{h}{2}[f(x_0)+2f(x_1)+2f(x_2)+2f(x_3)+f(x_4)] \\ &= \frac{1}{2}[f(0)+2f(1)+2f(2)+2f(3)+f(4)] \\ &= \frac{1}{2}[0^3+2\cdot 1^3+2\cdot 2^3+2\cdot 3^3+4^3] \\ &= 68.\end{aligned}$$

Täten puolisuunnikassäännön suhteellinen virhe (muistetaan määritelmä 2.8) on

$$\left|\frac{\int_0^4 x^3\,\mathrm{d}x - 68}{\int_0^4 x^3\,\mathrm{d}x}\right| = \left|\frac{64-68}{64}\right| = \frac{1}{16} = 6{,}25\ \%.$$

Puolisuunnikassääntö käyttäytyy samalla tavalla kuin keskipistesääntö. Vertaa seuraavia lauseita lauseisiin 4.5 ja 4.6.

Lause 4.9. *Puolisuunnikassääntö on tarkka kaikille polynomeille, joiden aste on enintään yksi.*

Todistus. Samankaltainen kuin lauseen 4.5 todistus. Jätetään harjoitustehtäväksi. □

Lause 4.10. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja kahdesti derivoituva välillä (a,b). Jos on olemassa vakio $L \geq 0$ siten, että $|f''(x)| \leq L$ kaikilla $x \in (a,b)$, niin puolisuunnikassäännön virheelle pätee*

$$\left|\int_a^b f(x)\,\mathrm{d}x - \sum_{i=1}^n h\cdot\frac{f(x_i)+f(x_{i-1})}{2}\right| \leq \frac{(b-a)^3L}{12n^2} = \frac{(b-a)L}{12}h^2,$$

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1},x_i]$ pituus.

Todistus. Todistus jätetään pois; se on samankaltainen kuin lauseen 4.6 todistus. □

4.3 Simpsonin sääntö

Keskipistesääntö käyttää suorakulmioita ja puolisuunnikassääntö puolisuunnikkaita integraalin approksimoimiseen. Keskipistesääntö muodostetaan käyttäen yhtä funktion f arvoa kullakin osavälillä $[x_{i-1},x_i]$ (eli arvoa keskipisteessä), kun taas puolisuunnikassääntö käyttää kahta arvoa (arvot päätepisteissä). Simpsonin sääntö käyttää kolmea arvoa kullakin osavälillä, eli sekä päätepisteitä että keskipistettä. Kolme funktion f arvoa annetuissa pisteissä määrittää yksikäsitteisen toisen asteen polynomin (eli toisen asteen *interpolointifunktion*), jolla on sama arvo kuin funktiolla f näissä pisteissä ja jonka integraalia (eli polynomin kuvaajan alle jäävää pinta-alaa) voidaan käyttää funktion f integraalin approksimoimiseen.

Oletetaan, että meillä on vain yksi osaväli $[a,b]$. Keskipiste on $(a+b)/2$. Toisen asteen polynomi $\alpha+\beta x+\gamma x^2$, jolla on sama arvo kuin funktiolla f päätepisteissä a ja b sekä keskipisteessä $c = (a+b)/2$, toteuttaa kolme yhtälöä

$$\alpha + \beta c + \gamma c^2 = f(c),$$

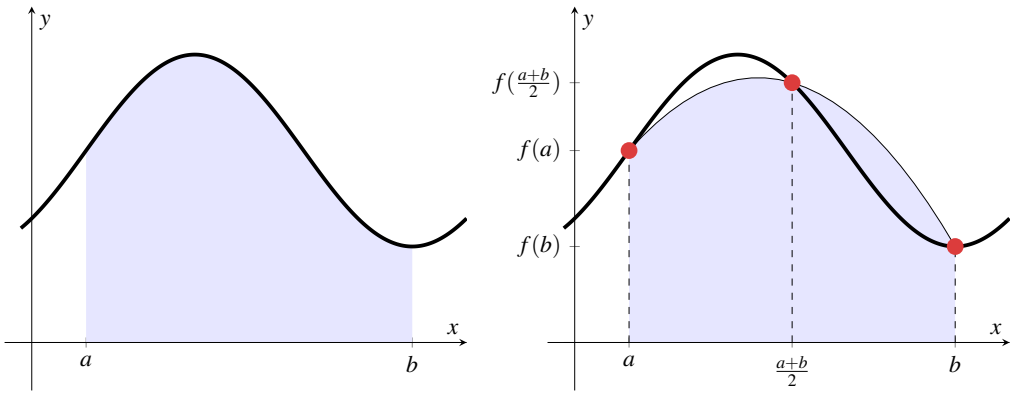

Kuva 4.5: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio Simpsonin säännöllä yhtälön (4.14) mukaisesti käyttäen kolmea pistettä.

$$\begin{aligned} \alpha + \beta a + \gamma a^2 &= f(a), \\ \alpha + \beta b + \gamma b^2 &= f(b). \end{aligned} \tag{4.13}$$

Koska meillä on kolme yhtälöä kolmelle tuntemattomalle (α, β ja γ), on suoraviivaista ratkaista (sivuutamme laskut) yksikäsitteiset kertoimet, joilla nämä kolme yhtälöä pätevät. Koska

$$\int_a^b (\alpha + \beta x + \gamma x^2)\,\mathrm{d}x = (b-a)\alpha + \frac{(b^2-a^2)\beta}{2} + \frac{(b^3-a^3)\gamma}{3}$$

kaikilla $\alpha, \beta, \gamma \in \mathbb{R}$, voimme approksimoida integraalia käyttäen juuri laskemiamme kertoimia:

$$\int_a^b f(x)\,\mathrm{d}x \approx (b-a)\alpha + \frac{(b^2-a^2)\beta}{2} + \frac{(b^3-a^3)\gamma}{3}.$$

Yhtälöt (4.13) ratkaiseville kertoimille oikea puoli sievenee huomattavasti, jolloin lopulta saadaan

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{b-a}{6}\left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right]. \tag{4.14}$$

Kuva 4.5 havainnollistaa tätä approksimaatiota. Useampaa kuin kolmea funktion f arvoa käyttävän approksimaation muodostamiseksi voimme yhdistää useita tämäntyyppisiä approksimaatioita. Olkoon n parillinen ja $x_i = a + hi$, missä $h = (b-a)/n$. Tällöin

$$\int_a^b f(x)\,\mathrm{d}x = \sum_{k=1}^{\frac{n}{2}} \int_{x_{2k-2}}^{x_{2k}} f(x)\,\mathrm{d}x \approx \sum_{k=1}^{\frac{n}{2}} \frac{x_{2k}-x_{2k-2}}{6}[f(x_{2k-2}) + 4f(x_{2k-1}) + f(x_{2k})],$$

missä sovelsimme yhtälöä (4.14) sijoituksilla $a = x_{2k-2}$ ja $b = x_{2k}$ kuhunkin integraaliin ja hyödynsimme tässä tapauksessa pätevää yhtälöä $\frac{1}{2}(a+b) = x_{2k-1}$ (eli *kahta* osaväliä vastaa *yksi* toisen asteen interpolointifunktio). Ryhmittelemällä parittomia ja parillisia indeksejä vastaavat termit saadaan Simpsonin sääntö.

Määritelmä 4.11 (Simpsonin sääntö)**.** Olkoon $n \in \mathbb{N}$ parillinen ja $x_i = a + (b-a)i/n$, missä $i \in \{0, 1, \ldots, n\}$. *Simpsonin sääntö* on integraaliapproksimaatio

$$\int_a^b f(x)\,\mathrm{d}x \approx \frac{h}{3}[f(x_0) + 4f(x_1) + 2f(x_2) + \cdots + 2f(x_{n-2}) + 4f(x_{n-1}) + f(x_n)], \tag{4.15}$$

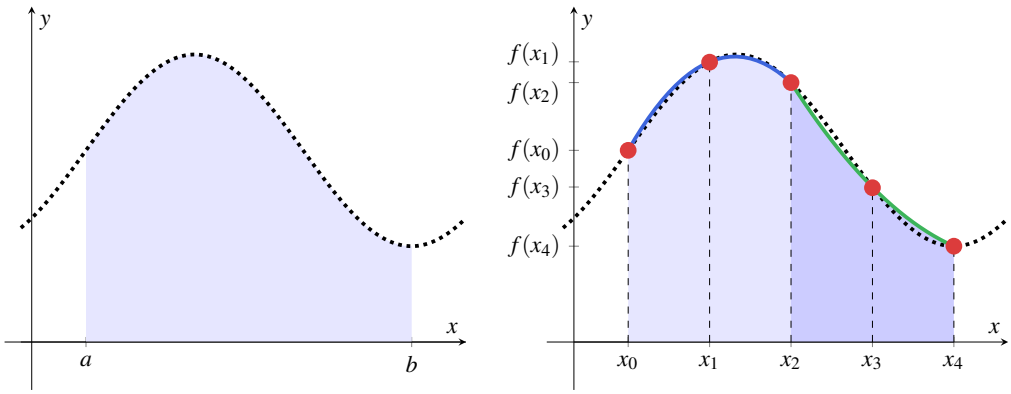

Kuva 4.6: *Vasemmalla*: Määrättyä integraalia $\int_a^b f(x)\,\mathrm{d}x$ vastaava pinta-ala. *Oikealla*: Sen approksimaatio Simpsonin säännöllä yhtälön (4.12) mukaisesti, kun $n = 4$. Huomaa, että kaksi toisen asteen polynomia on sovitettu osaväleille $[x_0, x_2]$ ja $[x_2, x_4]$.

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Summamerkinnällä voimme kirjoittaa Simpsonin säännön muodossa

$$\int_a^b f(x)\,\mathrm{d}x = \frac{h}{3}\left(f(x_0) + f(x_n) + 4\sum_{i=1}^{\frac{n}{2}} f(x_{2i-1}) + 2\sum_{i=1}^{\frac{n}{2}-1} f(x_{2i})\right).$$

Tästä nähdään, että välin $[a,b]$ päätepisteet saavat painot $\frac{1}{3}h$, parittomat pisteet (x_{2i-1}) painot $\frac{4}{3}h$ ja parilliset pisteet (x_{2i}) painot $\frac{2}{3}h$.

Esimerkki 4.12. Käytetään Simpsonin sääntöä arvolla $n = 4$ integraalin $\int_0^4 x^3\,\mathrm{d}x = 4^4/4 = 64$ approksimoimiseen. Yhtälön (4.9) oikean puolen laskemiseksi tarvitaan (a) osavälien pituus $h = (b-a)/n$ ja (b) pisteet x_i. Koska $n = 4$, $b = 4$ ja $a = 0$, saadaan

$$h = \frac{b-a}{n} = \frac{4-0}{4} = 1 \tag{4.16}$$

ja

$$x_i = a + \frac{(b-a)i}{n} = 0 + \frac{(4-0)i}{4} = i. \tag{4.17}$$

Sijoittamalla (4.16) ja (4.17) yhtälöön (4.12) saadaan

$$\begin{aligned}\int_0^4 x^3\,\mathrm{d}x &\approx \frac{h}{3}[f(x_0) + 4f(x_1) + 2f(x_2) + 4f(x_3) + \cdots + 4f(x_{n-1}) + f(x_n)] \\ &= \frac{1}{3}[f(0) + 4f(1) + 2f(2) + 4f(3) + f(1)] \\ &= \frac{1}{3}[0^3 + 4\cdot 1^3 + 2\cdot 2^3 + 4\cdot 3^3 + 4^3] \\ &= 64.\end{aligned}$$

Täten Simpsonin säännön suhteellinen virhe (muistetaan määritelmä 2.8) on

$$\left|\frac{\int_0^4 x^3\,\mathrm{d}x - 64}{\int_0^4 x^3\,\mathrm{d}x}\right| = \left|\frac{64-64}{64}\right| = 0 = 0\,\%.$$

Ei ole sattumaa, että Simpsonin sääntö oli tarkka esimerkissä (4.12).

Lause 4.13. *Simpsonin sääntö on tarkka kaikille polynomeille, joiden aste on enintään kolme.*

Todistus. Samankaltainen mutta monimutkaisempi kuin lauseen 4.5 todistus. □

Olkoon

$$E_n(f) = \left|\int_a^b f(x)\,\mathrm{d}x - \frac{h}{3}\left(f(x_0) + f(x_n) + 4\sum_{i=1}^{\frac{n}{2}} f(x_{2i-1}) + 2\sum_{i=1}^{\frac{n}{2}-1} f(x_{2i})\right)\right|$$

Simpsonin säännön absoluuttinen virhe.

Lause 4.14. *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva välillä $[a,b]$ ja neljästi derivoituva välillä (a,b). Jos on olemassa vakio $L \geq 0$ siten, että $|f^{(4)}(x)| \leq L$ kaikilla $x \in (a,b)$, niin Simpsonin säännön virheelle pätee*

$$E_n(f) \leq \frac{(b-a)^5 L}{180 n^4} = \frac{(b-a)L}{180} h^4,$$

missä $h = x_i - x_{i-1} = (b-a)/n$ on kunkin osavälin $[x_{i-1}, x_i]$ pituus.

Todistus. Sivuutetaan. □

Jos f on riittävän sileä (eli riittävän monta kertaa derivoituva), lauseet 4.6, 4.10 ja 4.14 osoittavat, että keskipiste- ja puolisuunnikassääntöjen virheet ovat suuruusluokka h^2, kun taas Simpsonin säännön virhe on suuruusluokkaa h^4. Täten Simpsonin sääntö voi olla tarkempi kuin keskipiste- tai puolisuunnikassääntö, jos f on riittävän sileä.

5 Yhtälöryhmien ratkaiseminen

Monet matematiikan opiskelussa vastaan tulevat ongelmat voidaan ratkaista suljetussa muodossa. Tämä saattaa antaa vaikutelman, että jokainen yhtälö voidaan ratkaista tarkasti. Päinvastoin: useimpia yhtälöitä ei voida ratkaista suljetussa muodossa käyttäen äärellistä määrää alkeisfunktioita. Näin on lähes aina, kun yhtälö sisältää useita erilaisia alkeisfunktioita. Esimerkiksi yhtälön

$$e^x = 2$$

ratkaisu on $x = \log 2 \approx 0.693$. Mutta yhtälön

$$e^x + x = 2$$

ratkaisu on $x = 2 - W(e^2) \approx 0.442$, missä W on *Lambertin W-funktio*, eli eräs erikoisfunktio. Yhtälön

$$e^x + x + \sin(x) = 2,$$

ratkaisu, joka on $x \approx 0.316$, ei ole ilmaistavissa minkään tunnetun alkeis- tai erikoisfunktion avulla. Yhtälöt, joita ei voida ratkaista suljetussa muodossa, täytyy ratkaista numeerisesti.

Jos f ja g ovat yhden reaalimuuttujan reaaliarvoisia funktioita, $x^* \in \mathbb{R}$ on yhtälön

$$f(x) = g(x)$$

ratkaisu, jos $f(x^*) = g(^*)$. Vastaavasti, jos $\mathbf{f}, \mathbf{g} \colon \mathbb{R}^m \to \mathbb{R}^n$, $\mathbf{x}^* \in \mathbb{R}^m$ on ratkaisu yhtälölle

$$\mathbf{f}(\mathbf{x}) = \mathbf{g}(\mathbf{x})$$

jos $\mathbf{f}(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*)$. Yhtälön ratkaisu *ratkaisee* yhtälön.

Esimerkki 5.1. Tarkastellaan yhtälöä $x^2 + 1 = 2$, joten $f(x) =^2 +1$ ja $g(x) = 2$. Reaaliluku $x = -1$ on yhtälön $x^2 + 1 = 2$ ratkaisu, koska

$$f(-1) = (-1)^2 + 1 = 1 + 1 = 2 = g(-1),$$

mutta $x = 2$ ei ole ratkaisu, koska

$$f(2) = 2^2 + 1 = 4 + 1 = 5 \neq 2 = g(2).$$

Graafisesti yhtälön ratkaisut vastaavat x-akselilla olevia pisteitä, joissa funktioiden f ja g kuvaajat leikkaavat. Esimerkiksi yhtälön $x^2 + 1 = 2$ ratkaisut ovat $x_0 = \pm 1$, koska näissä pisteissä funktioiden $f(x) = x^2 + 1$ ja $g(x) = 2$ kuvaajat ovat samalla korkeudella. Funktiot f ja g voidaan myös valita eri tavalla, sillä yhtälöt voidaan kirjoittaa useaan yhtäpitävään muotoon. Esimerkiksi yhtälö $x^2 + 1 = 2$ voidaan kirjoittaa muotoon $x^2 - 1 = 0$, jolloin $f(x) = x^2 - 1$ ja $g(x) = 0$. Tämä johtaa vastaavuuteen ratkaisujen ja nollakohtien välillä. $x^* \in \mathbb{R}$ on funktion $f \colon \mathbb{R} \to \mathbb{R}$ *nollakohta* (tai *juuri*), jos $f(x^*) = 0$. Graafisesti nollakohdat ovat ne x-akselilla olevat pisteet, joissa funktion f kuvaaja leikkaa x-akselin. Vastaavasti $\mathbf{x}^* \in \mathbb{R}^n$ on funktion $f \colon \mathbb{R}^m \to \mathbb{R}^n$ nollakohta, jos $\mathbf{f}(\mathbf{x}^*) = \mathbf{0}$.

Lause 5.2. *Olkoon $\mathbf{f}, \mathbf{g} \colon \mathbb{R}^n \to \mathbb{R}^m$. Piste $\mathbf{x}^* \in \mathbb{R}^n$ on ratkaisu yhtälölle $\mathbf{f}(\mathbf{x}) = \mathbf{g}(\mathbf{x})$ jos ja vain jos se on funktion $\mathbf{f} - \mathbf{g}$ nollakohta.*

Todistus. Oletetaan, että $\mathbf{x}^*$ ratkaisee yhtälön. Täten $\mathbf{f}(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*)$, mikä on yhtäpitävää yhtälön $\mathbf{f}(\mathbf{x}^*) - \mathbf{g}(\mathbf{x}^*) = \mathbf{0}$ kanssa. Tämä osoittaa, että $\mathbf{x}^*$ on funktion $\mathbf{f} - \mathbf{g}$ nollakohta. Kääntäen, jos $\mathbf{x}^*$ on funktion $\mathbf{f} - \mathbf{g}$ nollakohta, pätee $\mathbf{f}(\mathbf{x}^*) - \mathbf{g}(\mathbf{x}^*) = \mathbf{0}$. Tämä on yhtäpitävää yhtälön $\mathbf{f}(\mathbf{x}^*) = \mathbf{g}(\mathbf{x}^*)$ kanssa, joten $\mathbf{x}^*$ ratkaisee yhtälön. □

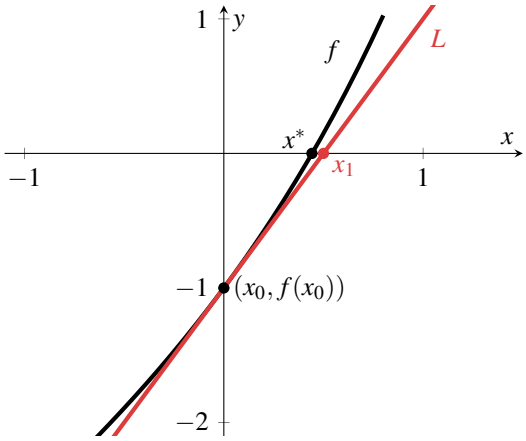

Kuva 5.1: *Newtonin menetelmän idea*: Lineaarisen approksimaation (eli tangentin) L_{x_0} nollakohta x_1 funktiolle $f(x) = e^x + x - 2$ toimii approksimaationa funktion nollakohdalle x^* edellyttäen, että kehityspiste (eli tangenttipiste) x_0 on lähellä todellista nollakohtaa.

Täten yhtälön ratkaiseminen vastaa alkuperäisen yhtälön puolten erotuksesta saadun funktion nollakohtien etsintää.

Funktiolla voi olla nolla, yksi tai useita nollakohtia. Vastaavasti yhtälöllä voi olla nolla, yksi tai useita ratkaisuja. Esimerkiksi esimerkin 5.1 yhtälöllä oli kaksi ratkaisua ($x_0 \pm 1$). Yhtälöllä $x^2 = 0$ on yksi ratkaisu ($x^* = 0$) ja yhtälöllä $x^2 + 1 = 0$ ei ole ratkaisuja[3] (koska x^2 on aina ei-negatiivinen). Matemaattisesta analyysista tuttua Bolzanon lausetta voidaan käyttää sen selvittämiseen, onko jatkuvalla funktiolla ainakin yksi ratkaisu.

Lause 5.3 (Bolzanon lause)**.** *Olkoon $f\colon [a,b] \to \mathbb{R}$ jatkuva. Jos $f(a)$ ja $f(b)$ ovat erimerkkisiä, niin $f(c) = 0$ jollekin $c \in [a,b]$.*

Jos $f(a)$ ja $f(b)$ ovat erimerkkisiä, niin joko (i) $f(a) < 0$ ja $f(b) > 0$ tai (ii) $f(a) > 0$ ja $f(b) < 0$. Nämä voidaan yhdistää yhdeksi ehdoksi $f(a)f(b) < 0$, koska positiivisen ja negatiivisen luvun tulo on negatiivinen. Huomaa, että välillä $[a,b]$ voi olla nollakohtia, vaikka ehto $f(a)f(b) < 0$ ei pätisi. Lisäksi $f(a)f(b) < 0$ takaa vain, että on *ainakin yksi nollakohta* (eli nollakohtia voi olla yksi tai useita).

5.1 Newtonin menetelmä

Muistetaan osiosta 3.2, että funktion f lineaarinen approksimaatio (tai ensimmäisen kertaluvun Taylorin polynomi) pisteessä x_0 on tangenttisuora

$$L_{x_0}(x) = f(x_0) + f'(x_0)(x - x_0). \tag{5.1}$$

Taylorin lauseen mukaan (ks. lause 3.3 ja korollaari 3.4) lineaarinen approksimaatio on hyvä approksimaatio funktiolle f arvoilla x, jotka ovat lähellä kehityspistettä x_0. Näin ollen, jos funktiolla f on nollakohta lähellä pistettä x_0, myös lineaarisella approksimaatiolla on nollakohta lähellä pistettä x_0, ja tätä nollakohtaa voidaan käyttää approksimoimaan funktion f nollakohtaa. Kuva 5.1 havainnollistaa tätä funktiolle $f(x) = e^x + x - 2$, kun $x_0 = 0$. Jos sen sijaan tangenttipiste x_0 *ei* ole lähellä funktion f nollakohtaa, tangentin nollakohta x_1 on usein silti lähempänä funktion nollakohtaa kuin x_0. Tästä seuraa, että jos tangentit muodostetaan iteratiivisesti edellisen tangentin nollakohdassa, saatavat nollakohdat x_1, x_2, x_3, … lähestyvät usein funktion f nollakohtaa. Kuva 5.2 havainnollistaa asiaa.

[3] Ellei oteta huomioon kompleksilukuja, jolloin ratkaisut ovat $x^* = \pm i$. Emme käytä kompleksilukuja tällä kurssilla.

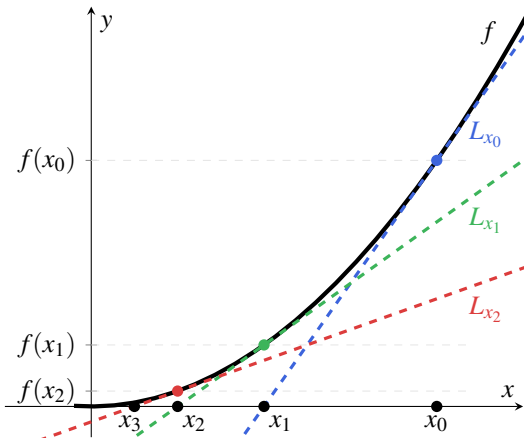

Kuva 5.2: Tangenttien nollakohdat x_k lähestyvät funktion nollakohtaa pisteessä $x = 0$.

Tangentin nollakohdat x_k toimivat yleisesti yhä tarkempina approksimaatioina funktion nollakohdalle kun k kasvaa. Näin saatavaa menetelmää kutsutaan Newtonin menetelmäksi. Johdetaan nyt iteraatiokaava, joka mahdollistaa seuraavan approksimaation x_{k+1} laskemisen edellisestä approksimaatiosta x_k. Pisteessä x_0 muodostetun lineaarisen approksimaation (5.1) nollakohta x_1 saadaan seuraavasti:

$$L_{x_0}(x_1) = 0 \quad \Longleftrightarrow \quad f(x_0) + f'(x_0)(x_1 - x_0) = 0 \quad \Longleftrightarrow \quad x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}.$$

Vastaavalla päättelyllä pisteessä x_1 muodostetun tangentin nollakohta x_2 saadaan kaavasta

$$x_2 = x_1 - \frac{f(x_1)}{f'(x_1)},$$

ja yleisemmin pisteessä x_k muodostetun tangentin nollakohta x_{k+1} saadaan kaavasta

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}. \tag{5.2}$$

Huomaa, että tämä kaava olettaa, että $f'(x_k) \neq 0$. Jos $f'(x_k) = 0$, lineaarinen approksimaatio $L_{x_k}(x) = f(x_k) + f'(x_k)(x - x_k) = f(x_k)$ vastaa vaakasuoraa viivaa, jolla ei ole nollakohtaa, mikä tarkoittaa, että iteraatiota ei voida jatkaa, koska ei ole seuraavaa nollakohtaa x_{k+1}, jonka kohdalle muodostaa lineaarinen approksimaatio. Kaavan (5.2) avulla voidaan laskea uusia approksimaatioita rekursiivisesti, kun x_0 on valittu. Pistettä x_0 kutsutaan alkuarvaukseksi. Mitä lähempänä alkuarvaus on funktion f nollakohtaa x^*, sitä luotettavammin Newtonin menetelmä toimii ja sitä nopeammin approksimaatiot suppenevat ratkaisuun.

Määritelmä 5.4 (Newtonin menetelmä)**.** Olkoon $f\colon \mathbb{R} \to \mathbb{R}$ derivoituva funktio ja $x_0 \in \mathbb{R}$ *alkuarvaus*. *Newtonin menetelmä* on jono approksimaatioita funktion f nollakohdalle, joka saadaan iteraatiolla

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \tag{5.3}$$

missä $k \geq 0$.

Esimerkki 5.5. Käytetään Newtonin menetelmää alkuarvauksella $x_0 = 4$ laskemaan approksimaatiot x_1 ja x_2 yhtälön $x^2 = 0$ nollakohdalle, joka on $x^* = 0$. Koska $f(x) = x^2$ ja $f'(x) = 2x$, Newtonin menetelmän iteraatiokaava (5.3) on

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_{k+1})} = x_k - \frac{x_k^2}{2x_k}. \tag{5.4}$$

Siten

$$\begin{aligned} x_0 &= 4, \\ x_1 &= x_0 - \frac{f(x_0)}{f'(x_0)} = 4 - \frac{4^2}{2 \cdot 4} = 2, \\ x_2 &= x_1 - \frac{f(x_1)}{f'(x_1)} = 2 - \frac{2^2}{2 \cdot 2} = 1. \end{aligned}$$

Tässä tapauksessa iteraatiokaava (5.4) yksinkertaistuu muotoon

$$x_{k+1} = x_k - \frac{x_k^2}{2x_k} = x_k - \frac{1}{2}x_k = \frac{1}{2}x_k,$$

joten

$$x_{k+1} = \frac{1}{2}x_k = \frac{1}{2} \cdot \frac{1}{2}x_{k-1} = \cdots = \frac{1}{2^{k+1}x_0}.$$

Toisin sanoen tässä tapauksessa jokainen x_k olisi voitu laskea suoraan arvosta x_0 ilman iteraatiota. *Näin käy käytännössä hyvin harvoin.*

Edellisessä esimerkissä kuvattu prosessi, jossa *samat vaiheet* toistetaan yhä uudelleen, kutsutaan *iteraatioksi*. Yhtä iteraatiovaihetta kutsutaan *iteraatioaskeleeksi*. Iteraatiolla laskettuja arvoja, kuten yllä olevaa lukua x_k, kutsutaan *iteraateiksi*. Siten Newtonin menetelmä perustuu iteraatioon, ja kaava (5.3) on Newtonin menetelmän kaava, rekursiivinen kaava tai *iteraatiokaava*.

Newtonin menetelmä ei aina toimi:

- Vaikka iteraatit suppenevat, ne eivät vältämättä suppene oikeaa nollakohtaa kohti.
- Geometrisesti on ilmeistä, että voi käydä niin, että iteraatit jäävät toistamaan kahta perättäistä arvoa. Näin on esimerkiksi funktion $f(x) = x^2 + x + 1$ tapauksessa, kun alkuarvaus tai jokin myöhempi iteraatti on 0 tai -1.
- Iteraatiokaava ei selvästi toimi, jos derivaatta joudutaan laskemaan sellaisessa kohdassa, jossa se menee nollaksi.
- Iteraatiokaava ei selvästi toimi, jos derivaatta joudutaan laskemaan sellaisessa kohdassa, jossa sitä ei ole olemassa, kuten funktiolla $f(x) = \left|x^2 - 1\right| - 1$ kohdissa $x = \pm 1$. Vähemmän selvästi ongelmia voi tulla myös tällaisten kohtien ympäristössä, kuten funktiolla $f(x) = \sqrt[3]{x}$ kohdan $x = 0$ ympäristössä.
- Joissakin tapauksissa iteraatit hajaantuvat, jos alkuarvaus on liian kaukana nollakohdasta, kuten funktion $f(x) = x/(x^2 + 1)$ tapauksessa,

Seuraava lause antaa riittävät ehdot Newtonin menetelmän toimimiselle.

Lause 5.6. *Olkoon $f(c) = 0$ ja $f'(c) \neq 0$. Oletetaan, että f on kahdesti jatkuvasti deri-*

voituva välillä $[c-a, c+a]$ jollekin $a > 0$. Tällöin Newtonin menetelmän iteraatiokaava suppenee lukuun c, jos alkuarvaus x_0 on riittävän lähellä lukua c.

Todistus. Sivuutetaan. □

Huomaa, ettei lause kata kaikkia funktioita, joille Newtonin menetelmä toimii. Esimerkiksi funktiolle $f(x) = x^2$ pätee $f'(x) = 0$, joten lauseen oletukset eivät ole voimassa, mutta edellä on nähty, että Newtonin menetelmä toimii kyseiselle funktiolle.

Lause ei anna luvun c arvoa tarkasti, mutta tieto siitä, että alkuarvauksen tulee olla riittävän lähellä, on silti hyödyllinen. Esimerkiksi funktio $f(x) = x/(x^2+1)$ toteuttaa lauseen oletukset, joten Newtonin menetelmä toimii sille varmasti, kunhan alkuarvaus valitaan sopivasti. Sen sijaan $f(x) = \sqrt[3]{x}$ ei ei toteuta lauseen oletuksia (Miksei?), joten Newtonin menetelmä ei välttämättä toimi, vaikka alkuarvaus valittaisiin kuinka lähelle nollakohtaa hyvänsä.

Jos Newtonin menetelmä ei toimi ensimmäisellä yrityksellä, niin ei ole syytä luovuttaa, vaan tulee kokeilla uutta alkuarvausta. Nollakohta voidaan myös selvittää ensin karkeasti vaikka puolitusmenetelmällä. Tästä syystä kehittyneemmissä algoritmeissa, kuten MATLABin `fzero`-funktiossa, sovelletaan useampaa menetelmää.

5.2 Newtonin menetelmä yhtälöryhmille

Newtonin menetelmä yhtälöryhmille on lähes identtinen yhden muuttujan tapauksen kanssa, kun se muotoillaan vektoriarvoisia funktioita käyttäen. Tätä varten tulee tutustua käsitteeseen nimeltä *Jacobin matriisi*, joka on gradientin yleistys vektoriarvoisille funktioille. Kerrataan ennen sen esittelyä myös muita tarpeellisia käsitteitä.

5.2.1 Epälineaariset yhtälöryhmät

Yhtälöryhmä on lineaarinen, jos se on muotoa

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \tag{5.5}$$
$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \tag{5.6}$$
$$\vdots \tag{5.7}$$
$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m, \tag{5.8}$$

missä a_{ij} ja b_i ovat vakioita ja x_j muuttujia. Muissa tapauksissa yhtälöryhmä on *epälineaarinen*. Yhtälöryhmä on siis epälineaarinen, jos siinä on yksikin termi, joka ei vakio tai muotoa vakio · muuttuja. Esimerkiksi yhtälöryhmä

$$\begin{aligned} 4xy + y &= 1 \\ x - 2y &= 3 \end{aligned}$$

on epälineaarinen termin $4xy$ vuoksi ja yhtälöryhmä

$$\begin{aligned} 4x + y &= 1 \\ x - 2\sin(y) &= 3 \end{aligned}$$

termin $-2\sin(y)$ vuoksi.

Lineaaariset yhtälöryhmät voidaan kirjoittaa muotoon $\mathbf{Ax} = \mathbf{b}$, missä $\mathbf{A}$ on vakiomatriisi, ja niillä on aina joko täsmälleen 1, 0 tai ääretön ratkaisua. Ne voidaan kaikki ratkaista Gaussin algoritmilla, ja niille on olemassa myös Gaussian algoritmia ja erityisesti Newtonin menetelmää tehokkaampia numeerisia ratkaisumenetelmiä.

Epälineaarisia yhtälöryhmiä ei voida kirjoittaa muotoon $\mathbf{Ax} = \mathbf{b}$, missä $\mathbf{A}$ on vakiomatriisi, ja niiden ratkaisujen lukumäärä voi olla muukin kuin 1, 0 tai ääretön. Niiden ratkaiseminen on merkittävästi vaikeampaa kuin lineaaristen yhtälöryhmien.

5.2.2 *Usean muuttujan funktion nollakohdat*

Yhden muuttujan funktion nollakohdat ovat niitä x-akselin pisteitä, joissa funktion kuvaaja, joka on usein jokin käyrä, leikkaa x-akselin. Nämä ovat usein erillisiä pisteitä ja niitä on usein äärellinen määrä.

Kahden muuttujan reaaliarvoisen funktion nollakohdat ovat niitä xy-tason pisteitä, joissa funktion kuvaaja, joka on usein jokin pinta, leikkaa xy-tason. Nämä muodostavat yleensä jonkin käyrän, ja tällöin näitä pisteitä on äärettömästi. Esimerkiksi funktion $f(x,y) = x^2 + y^2 - 1$ nollakohdille pätee

$$\begin{aligned} f(x,y) &= 0 \\ x^2 + y^2 - 1 &= 0 \\ x^2 + y^2 &= 1, \end{aligned}$$

joten ne muodostavat origokeskisen 1-säteisen ympyrän. Kahden muuttujan tapauksessa saatetaan puhua nollakohtien sijaan myös tasa-arvokäyristä $f(x,y) = 0$, jotka siis tarkoittavat niiden xy-tason pisteiden muodostamia käyriä, joissa funktion korkeus on nolla (Vertaa tasa-arvokäyriä karttojen korkeuskäyriin).

Kolmen muuttujan reaaliarvoisen funktion nollakohdat muodostavat yleensä pintoja. Esimerkiksi funktion $f(x,y) = x^2 + y^2 + z^2 - 1$ nollakohdat muodostavat origokeskisen 1-säteisen pallon $x^2 + y^2 + z^2 = 1$. Kolmen muuttujan tapauksessa saatetaan puhua nollakohtien sijaan myös tasa-arvopinnoista $f(x,y,z) = 0$.

5.2.3 *Tangenttitaso*

Kahden muuttujan funktioilla tangenttisuoraa vastaava käsite on tangenttitaso. Kahden muuttujan funktiolle f pisteeseen (x_0, y_0) muodostettu lineaarinen approksimaatio eli tangenttitaso eli 1. asteen Taylorin polynomi on muotoa

$$L(x,y) = f(x_0,y_0) + f_x(x_0,y_0)(x - x_0) + f_y(x_0,y_0)(y - y_0).$$

Kahden muuttujan funktion nollakohtia voidaan arvioida nollakohdan lähelle muodostetun tangenttitason nollakohdilla hieman vastaavasti kuin yhden muuttujan nollakohtia tangenttisuoran nollakohdilla. Erona on kuitenkin se, että vain osa tangenttitason nollakohdista, jotka siis muodostavat suoran, arvioivat hyvin osaa funktion nollakohdista. Oheisessa kuvassa on esitetty funktion $f(x,y) = 3 - x^2 - y^2$ sekä sille pisteeseen $(1,1)$ muodostetun tangenttitason $L(x,y) = 1 - 2(x-1) - 2(y-1)$ nollakohtia. Huomaa, että vain osa suoran pisteistä arvioi hyvin osaa funktion nollakohdista.

5.2.4 *Vektoriarvoiset funktiot*

Vektoriarvoiset funktiot ovat yhden tai useamman muuttujan funktioita, joiden arvot ovat vektoreita. Esimerkiksi

$$\mathbf{f}\colon \mathbb{R} \to \mathbb{R}^3, \quad \mathbf{f}(t) = \begin{bmatrix} t^2 \\ t^2 \\ 3 \end{bmatrix}$$

on yhden muuttujan vektoriarvoinen funktio, jonka arvot ovat kolmiulotteisia vektoreita. Tällainen funktio voisi esimerkiksi kuvata kappaleen (kolmiulotteista) paikkaa ajan t funktiona. Funktio

$$\mathbf{f}\colon \mathbb{R}^3 \to \mathbb{R}^3, \quad \mathbf{f}(x,y,z) = \begin{bmatrix} xz \\ y+1 \\ x - 2z + \sin(y) \end{bmatrix}$$

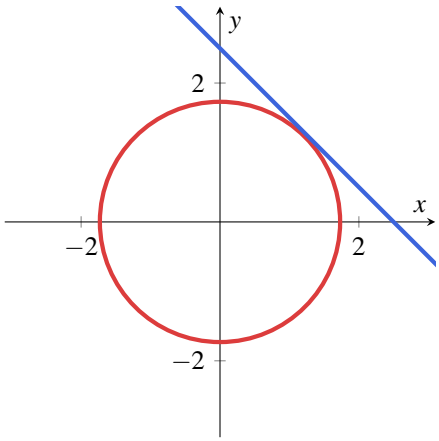

Kuva 5.3: Funktio $f(x,y) = 3 - x^2 - y^2$ sekä tangenttitaso $L(x,y) = 1 - 2(x-1) - 2(y-1)$ pisteessä $(1,1)$ ja sen nollakohdat.

puolestaan on kolmen muuttujan vektoriarvoinen funktio, jonka arvot ovat kolmiulotteisia vektoreita. Tällainen funktio voisi esimerkiksi esittää tuulen nopeusvektoria paikan (x,y,z) funktiona.

Yleisesti vektoriarvoiset funktiot ovat muotoa

$$\mathbf{f}\colon D \to \mathbb{R}^n,\ D \subset \mathbb{R}^m, \quad \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x}) \end{bmatrix},$$

ja funktioita f_i kutsutaan *komponenttifunktioiksi*. Voidaan myös merkitä $\mathbf{f}(x_1, x_2, \ldots, x_m)$, mutta vektorimerkintä muuttujille on selvästi lyhempi usean muuttujan tapauksessa.

Vektoriarvoisen funktion nollakohdilla tarkoitetaan niiden muuttujan arvojen, joille pätee $\mathbf{f}(\mathbf{x}) = \mathbf{0}$, muodostamaa joukkoa. Tästä seuraa, että yhtälöryhmän ratkaiseminen voidaan tulkita yhtäpitävästi myös vektoriarvoisen funktion nollakohtien ratkaisemiseksi. Esimerkiksi voidaan kirjoittaa

$$\begin{aligned} x^2 + y^2 &= 3 \\ (x-2)^2 + (y-1)^2 &= 2, \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} x^2 + y^2 - 3 &= 0 \\ (x-2)^2 + (y-1)^2 - 2 &= 0 \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} f(x,y) &= 0 \\ g(x,y) &= 0, \end{aligned}$$

ja määritellä funktio

$$\mathbf{f}(x,y) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix} = \begin{bmatrix} x^2 + y^2 - 3 \\ (x-2)^2 + (y-1)^2 - 2 \end{bmatrix},$$

jolloin alkuperäinen yhtälöpari voidaan tulkita yhtälöksi $\mathbf{f}(x,y) = \mathbf{0}$.

Kun Newtonin menetelmää yhtälöryhmille yleistettäessä ajatellaan, että ollaan ratkaisemassa vektoriarvoisen funktion nollakohtia, iteraatiokaava saadaan lähes identtiseen muotoon yhden muuttujan tapauksen kanssa. Tällöin x_k ja x_{k+1} korvautuvat vektoreilla $\mathbf{x}_k$ ja $\mathbf{x}_{k+1}$ ja reaaliarvoinen funktio f vektoriarvoisella funktiolla $\mathbf{f}$.

5.2.5 *Jacobin matriisi*

Reaaliarvoisen kahden muuttujan funktion $f\colon D \to \mathbb{R}$, $D \subset \mathbb{R}^2$, *gradientti* on funktio

$$\nabla f(x,y) = \begin{bmatrix} f_x(x,y) \\ f_y(x,y) \end{bmatrix},$$

joka on lyhyesti sanottuna eräänlainen derivaatan yleistys. Yleisesti usean muuttujan funktion $f\colon D \to \mathbb{R}$, $D \subset \mathbb{R}^n$, gradientti on funktio

$$\nabla f(\mathbf{x}) = \begin{bmatrix} f_{x_1}(\mathbf{x}) \\ f_{x_2}(\mathbf{x}) \\ \vdots \\ f_{x_n}(\mathbf{x}) \end{bmatrix}.$$

Kahden muuttujan vektoriarvoisen funktion

$$\mathbf{f}\colon D \to \mathbb{R}^2,\ D \subset \mathbb{R}^2, \quad \mathbf{f}(x,y) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix},$$

Jacobin matriisi on matriisiarvoinen funktio

$$\mathrm{J}_{\mathbf{f}}(x,y) = \begin{bmatrix} f_x(x,y) & f_y(x,y) \\ g_x(x,y) & g_y(x,y) \end{bmatrix}.$$

Esimerkiksi funktion

$$\mathbf{f}(x,y) = \begin{bmatrix} x^2 y \\ x + 2y^3 \end{bmatrix}$$

Jacobin matriisi on

$$\mathrm{J}_{\mathbf{f}}(x,y) = \begin{bmatrix} 2xy & x^2 \\ 1 & 6y^2 \end{bmatrix}.$$

Yleisesti usean muuttujan vektoriarvoisen funktion

$$\mathbf{f}\colon D \to \mathbb{R}^m,\ D \subset \mathbb{R}^n, \quad \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix},$$

Jacobin matriisi on matriisiarvoinen funktio

$$\mathrm{J}_{\mathbf{f}}(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}.$$

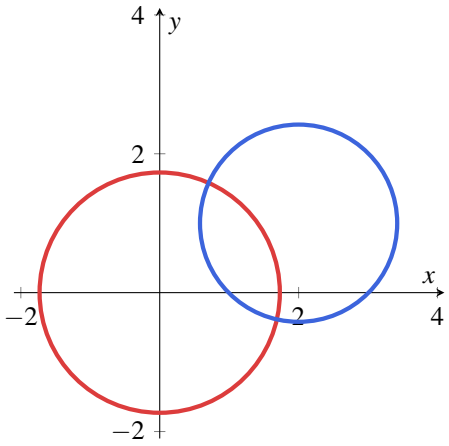

Kuva 5.4: Yhtälöt $x^2+y^2=3$ ja $(x-2)^2+(y-1)^2=2$ pätevät samanaikaisesti vain silloin, kun vastaavat käyrät leikkaavat toisensa.

Kun myöhemmin Newtonin menetelmä laajennetaan yhtälöryhmille, niin yhden muuttujan iteraatiokaavassa $x_{k+1}=x_k-f(x_k)/f'(x_k)$ esiintyvä derivaatalla $f'(x_k)$ jakaminen korvataan Jacobin matriisin käänteismatriisilla $\mathbf{J_f}(\mathbf{x})^{-1}$ kertomisella.

5.2.6 Newtonin menetelmän geometrinen idea yhtälöparille

Yhtälöparin ratkaisemissa on kyse tasokäyrien leikkuaspisteiden ratkaisemisesta. Esimerkiksi yhtälöparin

$$x^2+y^2=3 \tag{5.9}$$
$$(x-2)^2+(y-1)^2=2 \tag{5.10}$$

ratkaisut ovat oheisen kuvan käyrien leikkauspisteet. Jotta nähdään, miksi Newtonin menetelmää voidaan soveltaa myös yhtälöparien ratkaisemiseen, yhtälöparia joudutaan kuitenkin tarkastelemaan hieman eri näkökulmasta.

Edellinen yhtälöpari voidaan kirjoittaa muodossa

$$x^2+y^2-3=0$$
$$(x-2)^2+(y-1)^2-2=0,$$

missä yhtälöiden vasemmat puolet voidaan tulkita funktioiksi $f(x,y)=x^2+y^2-3$ ja $g(x,y)=(x-2)^2+(y-1)^2-2$. Näin tulkittuna yhtälöparissa

$$f(x,y)=0$$
$$g(x,y)=0$$

etsitään kahden muuttujan funktioiden f ja g yhteisiä nollakohtia.

Kahden muuttujan funktion nollakohtia voidaan arvioida nollakohdan lähelle pisteeseen (x_0,y_0) muodostetun tangenttitason nollakohdilla vastaavasti kuin yhden muuttujan nollakohtia tangenttisuoran nollakohdilla. Täten funtioiden f ja g yhteisiä nollakohtia voidaan arvioida funktioille muodostettujen tangenttitasojen nollakohtien muodostamien suorien leikkauspisteillä. Oheisessa kuvassa on esitetty funktioiden f ja g nollakohdat sekä niille pisteeseen $(x_0,y_0)=(1,1)$ muodostettujen tangenttitasojen nollakohdat. Suorien leikkauspiste (x_1,y_1) siis arvioi karkeasti yhtälöparin (5.9) ylempää nollakohtaa.

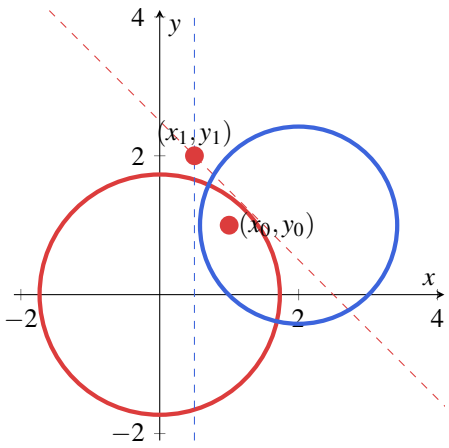

Kuva 5.5: Funktioiden $f(x,y) = x^2 + y^2 - 3$ ja $g(x,y) = (x-2)^2 + (y-1)^2 - 2$ tangenttitasojen nollakohtien muodostamien suorien leikkauspistettä voidaan käyttää funktioiden f ja g yhteisen nollakohdan approksimoimiseen.

Kun edellisen kuvan suorien leikkauspisteeseen (x_1, y_1) muodostetaan uudet tangenttitasot ja lasketaan niiden nollakohtien muodostamien leikkaussuorien leikkauspiste (x_2, y_2), saadaan parempi arvio yhtälöparin ratkaisulle. Tätä prosessia voidaan toistaa loputtomiin, ja usein leikkauspisteet (x_k, y_k) suppenevat kohti yhtälöparin erästä ratkaisua. Tämä on Newtonin menetelmän geometrinen idea kahden muuttujan yhtälöparille. Siirrytään seuraavaksi tarkastelemaan asiaa laskennallisesti.

5.2.7 Newtonin menetelmän kaava yhtälöryhmille

Johdetaan Newtonin menetelmän kaava kahden muuttujan yhtälöparin tapauksessa. Kaikki kahden muuttujan yhtälöparit voidaan kirjoittaa muotoon

$$\begin{aligned} f(x,y) &= 0 \\ g(x,y) &= 0. \end{aligned}$$

Arvioidaan yhtälöparin ratkaisua tangenttitasojen avulla edellisessä luvussa kuvatulla tavalla. Aloitetaan määrittämällä tangenttitasot pisteessä (x_0, y_0). Tangettitasojen yhtälöt ovat

$$L_f(x,y) = f(x_0,y_0) + f_x(x_0,y_0)(x-x_0) + f_y(x_0,y_0)(y-y_0)$$

ja

$$L_g(x,y) = g(x_0,y_0) + g_x(x_0,y_0)(x-x_0) + g_y(x_0,y_0)(y-y_0).$$

Niiden ja xy-tason leikkaussuorat puolestaan ovat $L_f(x,y) = 0$ ja $L_g(x,y) = 0$. Yhtälöparin ratkaisua voidaan arvioida näiden suorien leikkauspisteellä. Se voidaan ratkaista yhtälöparista

$$\begin{aligned} L_f(x,y) &= 0 \\ L_g(x,y) &= 0 \end{aligned}$$

joka on yhtäpitävästi

$$\begin{aligned} f(x_0,y_0) + f_x(x_0,y_0)(x-x_0) + f_y(x_0,y_0)(y-y_0) &= 0 \\ g(x_0,y_0) + g_x(x_0,y_0)(x-x_0) + g_y(x_0,y_0)(y-y_0) &= 0, \end{aligned}$$

josta saadaan

$$\begin{aligned} f_x(x_0,y_0)x + f_y(x_0,y_0)y &= f_x(x_0,y_0)x_0 + f_y(x_0,y_0)y_0 - f(x_0,y_0) \\ g_x(x_0,y_0)x + g_y(x_0,y_0)y &= g_x(x_0,y_0)x_0 + g_y(x_0,y_0)y_0 - g(x_0,y_0), \end{aligned}$$

kun muuttujat ja vakiot siirretään omille puolilleen. Näissä yhtälöissä x ja y ovat siis tuntemattomia ja kaikki muu kertoimet ja termit vakioita.

Yhtälöpari voitaisiin ratkaista suoraviivaisesti, mutta ennen kuin tehdään niin, kiinnitetään huomiota siihen, että yhtälöpari vaikuttaa jollakin tapaa erittäin säännönmukaiselta. Tämä säännönmukaisuus saadaan selkeämmin esille, kun kirjoitetaan yhtälö matriiseja käyttäen:

$$\begin{bmatrix} f_x(x_0,y_0) & f_y(x_0,y_0) \\ g_x(x_0,y_0) & g_y(x_0,y_0) \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} f_x(x_0,y_0) & f_y(x_0,y_0) \\ g_x(x_0,y_0) & g_y(x_0,y_0) \end{bmatrix} \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} - \begin{bmatrix} f(x_0,y_0) \\ g(x_0,y_0) \end{bmatrix}.$$

Tämä voidaan kirjoittaa vielä näppärämmin, kun siirrytään käyttämään merkintöjä

$$\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}, \quad \mathbf{x}_0 = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} \quad \text{ja} \quad \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix}.$$

Samalla havaitaan, että kerroinmatriisi on itse asiassa funktion $\mathbf{f}$ Jacobin matriisi eli että pätee

$$\begin{bmatrix} f_x(x_0,y_0) & f_y(x_0,y_0) \\ g_x(x_0,y_0) & g_y(x_0,y_0) \end{bmatrix} = \mathbf{J_f}(\mathbf{x}).$$

Näitä merkintöjä käyttäen matriisiyhtälö saadaan muotoon

$$\mathbf{J_f}(\mathbf{x}_0)\mathbf{x} = \mathbf{J_f}(\mathbf{x}_0)\mathbf{x}_0 - \mathbf{f}(\mathbf{x}_0),$$

ja olettaen Jacobin matriisi kääntyväksi yhtälöparin ratkaisuksi saadaan

$$\mathbf{x} = \mathbf{x}_0 - \mathbf{J_f}^{-1}(\mathbf{x}_0)\mathbf{f}(\mathbf{x}_0).$$

Alkuarvausta $\mathbf{x}_0$ seuraava iteraatti on siis $\mathbf{x}_1 = \mathbf{x}_0 - \mathbf{J_f}^{-1}(\mathbf{x}_0)\mathbf{f}(\mathbf{x}_0)$ ja seuraava $\mathbf{x}_2 = \mathbf{x}_1 - \mathbf{J_f}^{-1}(\mathbf{x}_1)\mathbf{f}(\mathbf{x}_1)$, ja niin edelleen. Yleisesti meillä on siis $\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{J_f}^{-1}(\mathbf{x}_k)\mathbf{f}(\mathbf{x}_k)$.

Edellinen päätttely yleistyy vastaavalla tavalla myös $n \times n$-yhtälöryhmille.

Määritelmä 5.7 (Newtonin menetelmä yhtälöryhmille)**.** Newtonin menetelmässä yhtälöryhmän $\mathbf{f}(\mathbf{x}) = \mathbf{0}$ likimääräisiä ratkaisuja lasketaan iteraatiolla

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{J_f}^{-1}(\mathbf{x}_k)\mathbf{f}(\mathbf{x}_k),$$

lähtien liikkeelle itse valittavasta arvosta $\mathbf{x}_0$, jota kutsutaan alkuarvaukseksi.

Huomaa, että Newtonin menetelmän kaava yhtälöryhmille on lähes identtinen yhden muuttujan tapauksen kanssa, nyt vain funktiot ja muuttujat ovat vektoreita ja derivaatan paikalla on Jacobin matriisi. Erityisesti tulee muistaa, että Jacobin matriisilla pitää kertoa *vasemmalta*.

Esimerkki 5.8. Käytetään Newtonin menetelmää yhtälöryhmän

$$\begin{aligned} x^2 + y^2 &= 3 \\ (x-2)^2 + (y-1)^2 &= 2 \end{aligned}$$

ratkaisun approksimaation $\mathbf{x}_1$ laskemiseen, kun alkuarvaus on $\mathbf{x}_0 = (1,1)$. Iteraatioon tarvittavat tiedot:

$$\mathbf{f}(x,y) = \begin{bmatrix} f(x,y) \\ g(x,y) \end{bmatrix} = \begin{bmatrix} x^2 + y^2 - 3 \\ (x-2)^2 + (y-1)^2 - 2 \end{bmatrix}.$$

$$\mathbf{J_f}(x,y) = \begin{bmatrix} 2x & 2y \\ 2(x-2) & 2(y-1) \end{bmatrix}$$

$$\mathbf{J_f}^{-1}(x,y) = \frac{1}{4x(y-1)-4y(x-2)} \begin{bmatrix} 2(y-1) & -2y \\ -2(x-2) & 2x \end{bmatrix}.$$

Ensimmäinen iteraatti:

$$\begin{aligned}
\mathbf{x}_1 &= \mathbf{x}_0 - \mathbf{J_f}^{-1}(\mathbf{x}_0)\mathbf{f}(\mathbf{x}_0) \\
&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{4(1-1)-4(1-2)} \begin{bmatrix} 2(1-1) & -2 \\ -2(1-2) & 2 \end{bmatrix} \begin{bmatrix} 1^2+1^2-3 \\ (1-2)^2+(1-1)^2-2 \end{bmatrix} \\
&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 0 & -2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ -1 \end{bmatrix} \\
&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 2 \\ -4 \end{bmatrix} \\
&= \begin{bmatrix} \frac{1}{2} \\ 2 \end{bmatrix}.
\end{aligned}$$

5.3 Kiintopistemenetelmä

Kiintopistemenetelmä on Newtonin menetelmän kaltainen numeerinen menetelmä yhtälön ratkaisemiseksi.

5.3.1 Kiintopiste

Yleensä muuttujan arvot eivät pysy kuvauksessa samana, vaan kuvautuvat joksikin eri arvoksi. Esimerkiksi funktio $f(x) = x^2$ kuvaa muuttujan arvon $x = 2$ funktion arvoksi $f(x) = 4$. Kyseisellä funktiolla on myös kaksi muuttujan arvoa, jotka eivät muutu kuvauksessa eli $x = 0$ ja $x = 1$. Ne ovat funktion f kiintopisteet.

Määritelmä 5.9 (Kiintopiste)**.** Funktion $f\colon D \to \mathbb{R}$, missä $D \subset \mathbb{R}$, kiintopisteet ovat pisteet $c \in D$, joille $f(c) = c$.

Funktiolla voi edellisen esimerkin tapaan olla useampikin kiintopiste, tai niitä ei välttämättä ole yhtään. Kiintopisteen geometrinen tulkinta on suoran $y = x$ ja funktion f kuvaajan leikkauspisteen x-koordinaatti (joka on toisaalta sama kuin kyseisen pisteen y-koordinaatti). Funktion kiintopisteet voidaan määrittää ratkaisemalla ne yhtälöstä $f(x) = x$. Kokeile funktion $f(x) = x^2$ tapauksessa.

5.3.2 Geometrinen idea

Kiintopistemenetelmä pohjautuu Newtonin menetelmän tapaan hyvin havainnolliseen geometriseen ideaan. Aloitetaan toteamalla vertailun vuoksi, että yhtälö $e^x = -x$ ratkaistaan graafisesti Newtonin menetelmällä seuraavilla vaiheilla, joita on havainnollistettu oheisessa kuvassa:

1. Yhtälö kirjoitetaan muotoon $e^x + x = 0$, eli siirretään kaikki termit samalle puolelle.
2. Piirretään funktion $f(x) = e^x + x$ kuvaaja, jolloin alkuperäisen yhtälön ratkaisut ovat funktion f nollakohdat.
3. Valitaan alkuarvaus x_0, joka on ensimmäinen arvio funktion f nollakohdalle.

4. Piirretään funktiolle f kohtaan x_0 tangentti.
5. Määritetään tangentin nollakohta x_1. Tästä tulee toinen arvio funktion f nollakohdalle.
6. Toistetaan tangenttisuorien piirtämistä vaiheiden 4 ja 5 mukaisesti korvaten aiempi iteraatti x_k uudemmalla x_{k+1}.
7. Tietyissä tapauksissa iteraatit suppenevat kohti funktion f nollakohtaa.

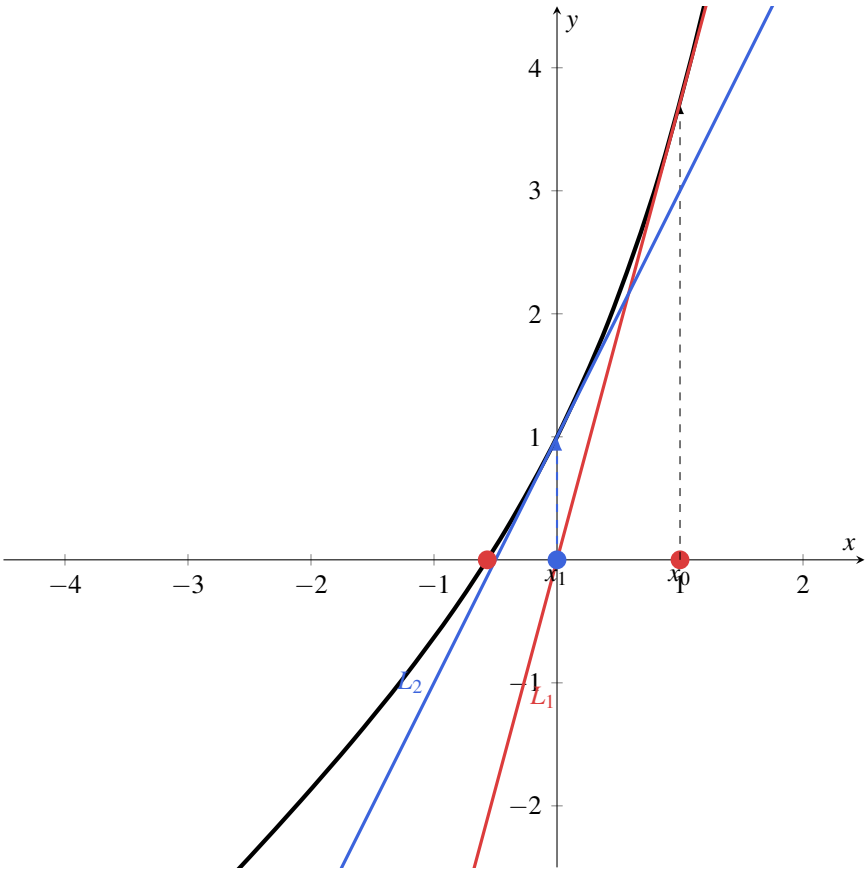

Yhtälö $e^x = -x$ ratkaistaan graafisesti kiintopistemenetelmällä seuraavilla vaiheilla, joita on havainnollistettu oheisessa kuvassa:

1. Yhtälö kirjoitetaan muotoon $x = -e^x$ eli muotoon, jossa toisella puolella on vain x. Tähän on erilaisia valintoja, mitä käsitellään lisää myöhemmin.
2. Piirretään suora $y = x$ ja funktion $g(x) = -e^x$ kuvaaja eli yhtälön molempien puolien kuvaat, jolloin alkuperäisen yhtälön ratkaisut ovat piirrettyjen käyrien leikkauspisteiden vaakakoordinaatit.
3. Valitaan alkuarvaus x_0, joka on ensimmäinen arvio yhtälön ratkaisulle.
4. Siirrytään kohdassa x_0 pystysuunnassa korkeudelle $g(x_0)$.
5. Siirrytään korkeudella $g(x_0)$ vaakasuunnassa suoralle $y = x$ eli pisteeseen $\Big(g(x_0), g(x_0)\Big)$. Pisteen x-koordinaatista tulee uusi arvio x_1 yhtälön ratkaisulle.
6. Toistetaan vaiheiden 4 ja 5 pysty- ja vaakasuuntaisia siirtymiä korvaten aiempi iteraatti x_k uudemmalla x_{k+1}.

7. Tietyissä tapauksissa iteraatit suppenevat kohti yhtälön ratkaisua.

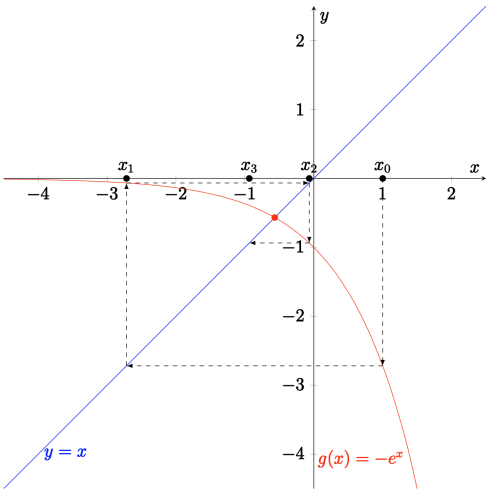

Edellä kiintopistemenetelmää käytettäessä yhtälö $e^x = -x$ olisi voitu ratkaista myös muotoon $x = \ln(-x)$, jolloin tarkasteltu funktio olisikin ollut $g(x) = \ln(-x)$. Tämä on esimerkki siitä, että funktio g ei ole yksikäsitteinen vaan voidaan itse asiassa valita äärettömän monella eri tavalla. Esimerkiksi edellä voidaan kirjoittaa

$$\begin{aligned} -x &= e^x \\ ax - x &= e^x + ax \\ x &= \frac{e^x + ax}{a-1} \end{aligned}$$

jolloin jokaista parametrin a arvoa vastaa eri funktio

$$g(x) = \frac{e^x + ax}{a-1}.$$

Edellä todettiin, että iteraatit suppenevat kohti ratkaisua *tietyissä tilanteissa*. Kiintopistemenetelmä ei siis aina toimi vastaavasti kuin Newtonin menetelmäkään ei aina toiminut. Yhtälön $-x = e^x$ ratkaiseminen valinnalla $g(x) = \ln(-x)$ epäonnistuu jo siksi, että joudutaan tarkastelemaan funktiota g kohdissa, joissa sitä ei ole määritelty (Piirrä kuva ja kokeile eri alkuarvauksia). Iteraatio voi kuitenkin myös epäonnistua, vaikka g olisi määritelty kaikkialla. Esimerkiksi jos yhtälöä

$$x - \frac{x}{2} = 0$$

yritetään ratkaista kirjoittamalla se ensin muotoon $x = 2x$, jolloin siis $g(x) = 2x$, iteraatit hajaantuvat oheisen kuvan mukaisesti.

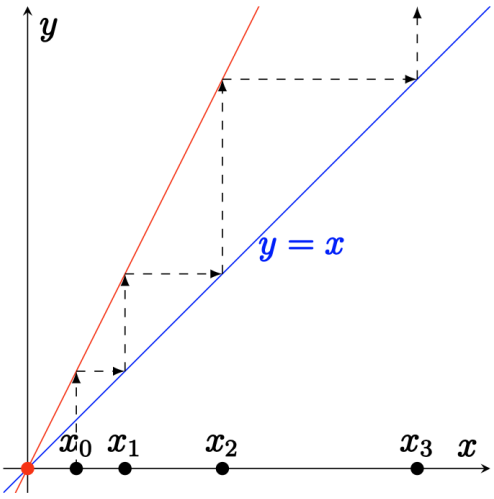

Jos sen sijaan samaa yhtälöä yritetään ratkaista kirjoittamalla se ensin muotoon $x = \frac{x}{2}$, jolloin siis $g(x) = \frac{x}{2}$, iteraatit suppenevatkin oheisen kuvan mukaisesti.

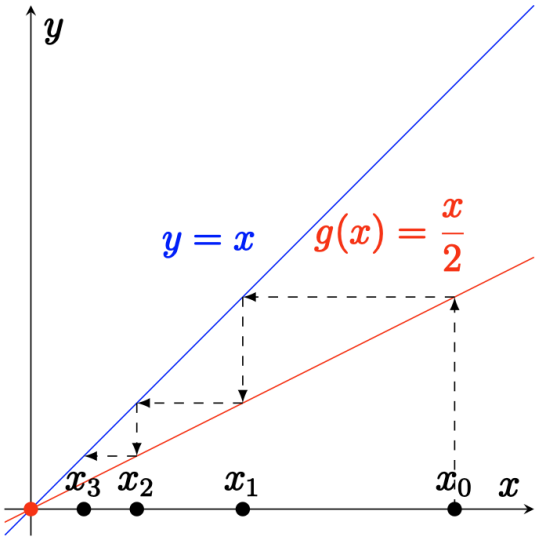

Ilmeinen ero edellä eri tavalla käyttäytyvien funktioiden g välillä on ainakin se, että ensimmäinen on jyrkempi kuin toinen. Vastaavia tarkasteluja toistamalla voi havaita, että juuri funktion g jyrkkyys näyttäisi olevan kriittinen tekijä suppenemisen kannalta. Kiintopistemenetelmä voi epäonnistua myös siksi, että iteraatit eivät suppene oikeaa arvoa kohti. Näin kuitenkin voi käydä vain, jos funktio g ei ole jatkuva.

Lause 5.10. *Olkoon g jatkuva funktio. Jos kiintopisteiteraation $x_{k+1} = g(x_k)$ iteraatit suppenevat, niin ne suppenevat kohti kiintopistettä.*

Todistus. Sivuutetaan. □

Vastaesimerkiksi siitä, miksi funktion g jatkuvuus on oleellinen, käy funktio

$$g(x) = \begin{cases} \frac{x}{2}, & x \neq 0 \\ -1, & x = 0 \end{cases}.$$

5.3.3 *Iteraatiokaava*

Johdetaan kiintopistemenetelmän iteraatiokaava. Tulee siis päätellä, miten x_{k+1} saadaan lasketuksi edellisen arvon x_k perusteella (tai useamman edellisen arvon kuten x_k ja x_{k-1} perusteella, jos tämä osoittautuu tarpeelliseksi). Vertailun vuoksi muistutettakoon, että Newtonin menetelmässä iteraatiokaava oli muotoa

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}.$$

Lähdetään tarkastelemaan ensimmäisiä iteraatioita edellä käsitellyn kuvan mukaisesti.

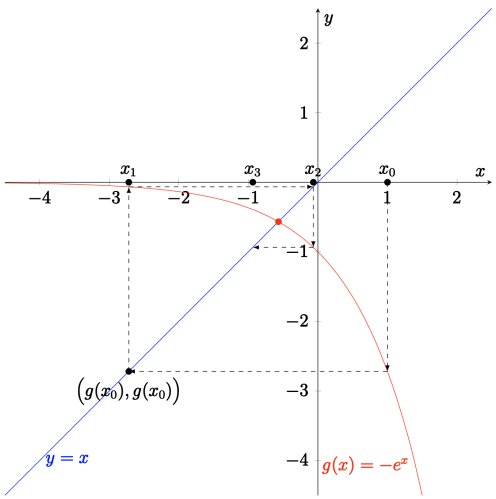

Alkuarvaus x_0 valitaan itse. Tämän jälkeen siirrytään korkeudelle $g(x_0)$, liikutaan suoralle $y = x$ pisteeseen $\big(g(x_0), g(x_0)\big)$ ja otetaan tämän pisteen vaakakoordinaatti uudeksi iteraatiksi x_1. Pätee siis $x_1 = g(x_0)$. Vastaavalla päättelyllä havaitaan, että pätee $x_2 = g(x_1)$, $x_3 = g(x_2)$ ja niin edelleen, eli yleisesti pätee $x_{k+1} = g(x_k)$.

Määritelmä 5.11 (Kiintopistemenetelmä)**.** *Kiintopistemenetelmässä* funktion $x - g(x)$ nollakohtaa approksimoidaan iteraatiokaavalla

$$x_{k+1} = g(x_k),$$

lähtien liikkeelle alkuarvauksesta x_0.

Otetaan yksinkertainen mutta havainnollinen esimerkki, jota on jo tarkasteltu edellä graafisesti.

Esimerkki 5.12. Ratkaistaan yhtälö

$$x - \frac{x}{2} = 0$$

kiintopistemenetelmällä. Ilmeinen valinta on kirjoittaa yhtälö muotoon $x = \frac{x}{2}$, jolloin iteraatiokaavaksi saadaan siis $x_{k+1} = \frac{x_k}{2}$, eli tällöin $g(x) = \frac{x}{2}$. Jos alkuarvaukseksi valitaan $x_0 = 4$, saadaan

$$\begin{aligned}
x_0 &= 4 \\
x_1 &= g(x_0) = g(4) = \frac{4}{2} = 2 \\
x_2 &= g(x_1) = g(2) = \frac{2}{2} = 1 \\
x_3 &= g(x_2) = g(1) = \frac{1}{2} \\
&\vdots
\end{aligned}$$

Saadaan siis lukujono, joka näyttäisi suppenevan kohti nollaa. Sijoittamalla tai ratkaisemalla voidaan tarkastaa, että tämä on oikea ratkaisu. Katso myös edellisen luvun kuva asiasta tai piirrä oma kuva.

Toinen ilmeinen valinta on kirjoittaa yhtälö muotoon $x = 2x$, jolloin iteraatiokaavaksi saadaan $x_{k+1} = 2x_k$. Tässä tapauksessa iteraatio hajaantuu jokaisella nollasta poikkeavalla alkuarvauksella. Esimerkiksi tapauksessa $x_0 = 4$ pätee:

$$\begin{aligned}
x_0 &= 4 \\
x_1 &= g(x_0) = g(4) = 2 \cdot 4 = 8 \\
x_2 &= g(x_1) = g(8) = 2 \cdot 8 = 16 \\
x_3 &= g(x_2) = g(16) = 2 \cdot 16 = 32 \\
&\vdots
\end{aligned}$$

Kiintopistemenetelmän nopea tarkastelu voidaan tehdä samalla tavoin kuin Newtonin menetelmässä, tallentamalla alkuarvaus muuttujaan `ans` ja toistuvasti suorittamalla komentoa `g(ans)`. Huolellisempi tarkastelu tehdään parhaiten silmukan avulla.

Newtonin menetelmä voidaan itse asiassa tulkita kiintopistemenetelmäksi, jossa

$$g(x) = x - \frac{f(x)}{f'(x)}.$$

Tämä mahdollistaa myös Newtonin menetelmän teorian käsittelemisen kiintopistemenetelmän teorian avulla, mitä ei toistaiseksi tehdä tällä kurssilla, sillä kiintopistemenetelmän teorian käsittely jäi tänä vuonna varsin suppeaksi.

5.3.4 Suppenemisesta

Edellä todettiin, että kiintopisteiteraatio näyttäisi suppenevan, kun funktion g kuvaaja nouse tai laskee riittävän loivasti. Seuraava tulos antaa tarkan ehdon.

Lause 5.13. *Olkoon c funktion g kiintopiste. Oletetaan, että g on derivoituva pisteessä c. Jos $\left|g'(c)\right| < 1$, kiintopisteiteraatio suppenee, kunhan x_0 valitaan riittävän läheltä kiintopistettä. Tässä tapauksessa kiintopistettä kutsutaan vetäväksi eli attraktiiviseksi. Toisaalta, jos $\left|g'(c)\right| > 1$, kiintopiste-iteraatio suppenee vain tapauksessa, jossa $x_n = c$. Tässä tapauksessa kiintopistettä kutsutaan hylkiväksi eli repulsiiviseksi.*

Todistus. Sivuutetaan. □

Lausetta ei todisteta, mutta havainnollistetaan iteraattien muutoksen ja derivaatan välistä yhteyttä hyvin karkeasti. Jotta iteraatio suppenisi, kuvissa nähtyjen vaakasuuntaisten siirtymien pitäisi pienetä. Tämä tarkoittaa, että tulisi päteä

$$\frac{|x_{k+2} - x_{k+1}|}{|x_{k+1} - x_k|} < K$$

jollakin $K \in (0,1)$ eli että seuraava vaakasuuntainen siirtymä on edellistä pienempi. Tämä ehto voidaan kirjoittaa myös muotoon

$$\left| \frac{g(x_{k+1}) - g(x_k)}{x_{k+1} - x_k} \right| < K,$$

mikä tarkoittaa, että välin (x_k, x_{k+1}) (tai (x_{k+1}, x_k), jos $x_k > x_{k+1}$) keskimääräisen muutosnopeuden tulee olla itseisarvoltaan alle yhden. Jos pätee $\left|g'(c)\right| < 1$ eli hetkellinen nopeus kohdassa c on alle yhden, niin pisteen c ympäristöstä on mahdollista löytää väli, jolla keskinopeus on alle yhden.

5.4 Jacobin menetelmä lineaarisille yhtälöryhmille

Lineaaristen yhtälöiden ryhmien ratkaisut jakautuvat kolmeen kategoriaan: tyyppiin: yksikäsitteinen ratkaisu, monikäsitteinen ratkaisu tai ei ratkaisua. Olipa yhtälöryhmän ratkaisu mitä tahansa näistä kolmesta tyypistä, se saadaan aina selvitettyä suoraviivaisesti Gaussin algoritmilla. Tästä johtuen voisi ajatella, ettei lineaaristen yhtälöryhmien ratkaisemiseen tarvittaisi sen kummempaa numeerista teoriaa, vaan laitettaisiin vain tietokone selvittämään ratkaisu Gaussin algoritmia käyttäen. Toisaalta lineaaristen yhtälöryhmien ratkaiseminen on havaittu työlääksi ja työmäärän kasvavan *kuutiollisesti* yhtälöryhmän koon kasvaessa. Tämä on se, mikä aiheuttaa numeeristen ratkaisumenetelmien tarpeen. Riittävän suurilla matriiseilla laskentateho loppuu väistämättä kesken. Toinen syy on se, että pyöristysvirheet voivat vaikuttaa merkittävästi lopputulokseen. Tämä aiheuttaa tarpeen kehittää kevyempi ja tarkempia menetelmiä lineaaristen yhtälöryhmien ratkaisemiseen.

Numeerisella menetelmällä löydetään kerrallaan vain yksi ratkaisu yhtälölle tai yhtälöryhmälle. Niillä ei täten saada suoran lineaarisen yhtälöryhmän monikäsitteistä ratkaisua, joka sisältää vapaita parametreja, vaan menetelmän lopputuloksena on vain kokoelma ratkaisua arvioivia desimaalilukuja. Tästä johtuen tällä kurssilla lineaaristen yhtälöryhmien numeerinen ratkaiseminen keskittyy vain yhtälöryhmiin, joilla on yksikäsitteinen ratkaisu. Tämä tarkoittaa käytännössä $n \times n$-yhtälöryhmiä, sillä matalan kerroinmatriisin tapauksessa, ratkaisu ei voi koskaan olla yksikäsitteinen (liian vähän yhtälöitä) ja korkean kerroinmatriisin tapauksessa yksikäsitteinen ratkaisu on varsin harvinainen (liikaa yhtälöitä). Yhtälöryhmän kerroinmatriisin voi siis tässä luvussa olettaa neliömatriisiksi, ellei toisin mainita.

5.4.1 Suorat ja iteratiiviset menetelmät

Newtonin menetelmässä ei saada kerralla hyvää arviota yhtälön ratkaisulle, vaan sen sijaan saadaan jono arvioita, jotka (tietyin ehdoin) lähestyvät tarkkaa ratkaisua. Sen sijaan kun Gaussin algoritmilla ratkaistaan numeerisesti lineaarinen yhtälöryhmä, ratkaisulle saadaan vain yksi arvio (joka voi poikkeustapauksessa olla tarkkakin). Jälkimmäisessä ei siis ole kyse iteratiivisesta prosessista, ja se on esimerkki *suorasta menetelmästä*, kun taas Newtonin menetelmä on esimerkki *iteratiivisesta menetelmästä*. Suora menetelmä on siis ei-iteratiivinen menetelmä, jolla ratkaisu saadaan teoriassa tarkasti mutta jonka soveltaminen johtaa käytännössä vain arvioon johtuen esimerkiksi pyöristysvirheestä ja reaalilukujen rajallisesta esitystarkkuudesta tietokoneissa.

Lineaaristen yhtälöryhmien ratkaisemiseksi on sekä suoria että iteratiivisia menetelmiä. Tällä kurssille keskitytään iteratiivisiin menetelmiin. Myös suoria menetelmiä käsitellään hieman, jotta asiasta saa paremman yleiskäsityksen, mutta merkittävän suoran menetelmän, LU-hajotelman,

tarkempi käsittely tapahtuu muilla kursseilla. Lineaarisia yhtälöryhmiä voidaan ratkaista Gaussin algoritmin ja sen muunnelmien lisäksi myös ainakin Gaussin matriisia ja Cramerin sääntöä käyttäen. Kaikki nämä ovat suoria menetelmiä, ja vaikka niillä saadaan teoriassa aina tarkka ratkaisu, niin käytännössä liukuluvuilla laskettaessa ratkaisusta tulee vain arvio.

5.4.2 Jacobin menetelmä

Yritetään ratkaista yhtälöryhmä

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

kiintopistemenetelmää käyttäen. Halutaan siis kirjoittaa yhtälöryhmä muotoon $\mathbf{x} = \mathbf{g}(\mathbf{x})$. Tähän on äärettömästi erilaisia vaihtoehtoja, mutta tehdään tämä myöhemmin selviävistä syistä johtuen niin, että ratkaistaan kultakin riviltä diagonaalia vastaava muuttuja:

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} 4x_1 &= 8 - 2x_2 - x_3 \\ 5x_2 &= 12 - x_1 - 3x_3 \\ 3x_3 &= 8 - x_1 + x_2 \end{aligned}$$

tai yhtäpitävästi

$$\begin{aligned} x_1 &= \frac{8}{4} - \frac{2}{4}x_2 - \frac{1}{4}x_3 \\ x_2 &= \frac{12}{5} - \frac{1}{5}x_1 - \frac{3}{5}x_3 \\ x_3 &= \frac{8}{3} - \frac{1}{3}x_1 - \frac{1}{3}x_2. \end{aligned}$$

Kiintopistemenetelmän iteraatiokaavaksi saatiin siis tällä valinnalla

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 2 \\ \frac{12}{5} \\ \frac{8}{3} \end{bmatrix} + \begin{bmatrix} 0 & \frac{1}{2} & -\frac{1}{4} \\ \frac{1}{5} & 0 & -\frac{3}{5} \\ \frac{1}{3} & -\frac{1}{3} & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k.$$

Kun kaavaa kokeillaan käyttää, havaitaan, että iteraatit suppenevat alkuarvauksesta riippumatta kohti oikeaa ratkaisua $\mathbf{x} = \begin{bmatrix} 1 & 1 & 2 \end{bmatrix}^\mathsf{T}$ alkuarvauksesta riippumatta. Esimerkiksi tapauksessa $\mathbf{x}_0 = \begin{bmatrix} 0 & 0 & 0 \end{bmatrix}^\mathsf{T}$ pätee

$$\mathbf{x}_1 \approx \begin{bmatrix} 2.0000 \\ 2.4000 \\ 2.6667 \end{bmatrix}, \quad \mathbf{x}_2 \approx \begin{bmatrix} 0.1333 \\ 0.4000 \\ 1.2000 \end{bmatrix}, \quad \ldots, \quad \mathbf{x}_{35} \approx \begin{bmatrix} 1.0000 \\ 1.0000 \\ 2.0000 \end{bmatrix}.$$

Suppenemisehto Kun edellä käsitelty yhtälöryhmä kirjoitetaan muotoon $\mathbf{x} = \mathbf{g}(\mathbf{x})$ eri tavalla kuin edellä, se ei välttämättä suppenekaan. Esimerkiksi jos käytetään yksinkertaisinta valintaa

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

eli yhtäpitävästi

$$\begin{aligned} x_3 &= 8 - 4x_1 - 2x_2 \\ x_1 &= 12 - 5x_2 - 3x_3 \\ x_2 &= 8 - x_1 - 3x_3 \end{aligned}$$

eli yhtäpitävästi

$$\begin{aligned} x_1 &= 12 - 5x_2 - 3x_3 \\ x_2 &= 8 - x_1 - 3x_3 \\ x_3 &= 8 - 4x_1 - 2x_2 \end{aligned}$$

mikä antaa iteraatiokaavan

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 12 \\ 8 \\ 8 \end{bmatrix} + \begin{bmatrix} 0 & -5 & -3 \\ -1 & 0 & -3 \\ -4 & -2 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k ,$$

niin alkuarvauksen $\mathbf{x}_0 = [0\,0\,0]^\intercal$ tapauksessa iteraatit hajaantuvat:

$$\mathbf{x}_1 = \begin{bmatrix} 12 \\ 8 \\ 8 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} -52 \\ -28 \\ -56 \end{bmatrix}, \quad \ldots, \quad \mathbf{x}_3 = \begin{bmatrix} 320 \\ 228 \\ 272 \end{bmatrix}.$$

äin käy kyseisen iteraatiokaavan kanssa jokaisella alkuarvauksella. Toisaalta edellisen yhtälöryhmän kanssa toimivaksi havaittu diagonaalialkioita vastaavien muuttujien suhteen ratkaiseminenkaan ei toimi aina. Esimerkiksi yhtälöryhmälle

$$\begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

näin saatava iteraatiokaava

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_{k+1} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 & 1 \\ 3 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_k$$

hajaantuu jokaisella alkuarvauksella $\mathbf{x}_0$.

Edelliset havainnot herättävät kysymyksen, missä tapauksissa iteraatio suppenee. Jos kullakin rivillä diagonaalialkio on itseisarvoltaan suurempi kuin muiden saman rivin kertoimien itseisarvojen summa, niin diagonaalialkioiden suhteen ratkaistu iteraatiokaava suppenee. Tällaista matriisia kutsutaan *diagonaalisesti dominoivaksi*.

Määritelmä 5.14 (Diagonaalisesti dominoiva matriisi)**.** $n \times n$-matriisia $\mathbf{A}$ kutsutaan *diagonaalisesti dominoivaksi*, jos sen alkiot toteuttavat

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}|$$

jokaiselle $i = 1, 2, \ldots, n$.

Lause 5.15. *Jos $n \times n$-matriisi $\mathbf{A}$ on diagonaalisesti dominoiva ja $\mathbf{x}_{k+1} = \mathbf{g}(\mathbf{x})$ on kiintopistemenetelmällä diagonaalialkioiden suhteen ratkaistava iteraatiokaava, niin iteraatio suppenee yhtälöryhmän ratkaisuun kaikilla alkuarvauksilla $\mathbf{x}_0$.*

Todistus. Sivuutetaan. □

Edellinen lause ei siis kerro kaikkia mahdollisia tapauksia, joissa iteraatio voi supeta, vaan ainoastaan riittävän ehdon tälle. Voi siis olla muuntyyppisiäkin yhtälöryhmiä, jotka suppenevat joko kaikilla tai tietyillä alkuarvauksilla.

Huomaa, että vaikka yhtälöryhmän kerroinmatriisi ei ole suoraan diagonaalisesti dominoiva, se voidaan joissain tapauksissa muuttaa sellaiseksi rivejä vaihtamalla. Esimerkiksi edellä tarkastellun yhtälöryhmän

$$\begin{aligned} 4x_1 + 2x_2 + x_3 &= 8 \\ x_1 + 5x_2 + 3x_3 &= 12 \\ x_1 + x_2 + 3x_3 &= 8 \end{aligned}$$

kerroinmatriisi on diagonaalisesti dominoiva mutta ei enää, jos yhtälöryhmän rivit vaihdetaan johonkin muuhun kuudesta mahdollisesta järjestyksestä. Myös yhtälöryhmän sarakkeiden järjestystä voitaisiin yrittää, kunhan vain muistetaan tehdä vastaavat muuttujien järjestyksen vaihdot, mutta tästä ei ole hyötyä, jos asia ei onnistunut rivejä muuttamalla. Perustele asia itsellesi vaikka seuraavan yhtälöryhmän avulla:

$$\begin{aligned} x_1 + 2x_2 + 4x_3 &= 8 \\ 2x_1 + 5x_2 + 2x_3 &= 12 \\ 3x_1 + 2x_2 + 7x_3 &= 8 \end{aligned}$$

Edellinen lause ei voi päteä tapauksessa, jossa kerroinmatriisi ei ole kääntyvä, koska tällöin yhtälöryhmällä ei ole yksikäsitteistä ratkaisua. Voidaankin osoittaa, että matriisin diagonaalisesta dominoivuudesta seuraa, että matriisi on kääntyvä. Tämä todistus sekä edellisen lauseen todistus ohitetaan.

Iteraatiokaava Johdetaan seuraavaksi Jacobin menetelmän iteraatiokaava yleisessä tapauksessa. Tämän avulla kutakin yhtälöryhmää vastaava iteraatiokaava voidaan kirjoittaa suoraan yhtälöryhmän kerroinmatriisista $\mathbf{A}$ ja vakiovektorista $\mathbf{b}$ saatavien tietojen avulla.

Yritetään ratkaista yhtälöryhmä $\mathbf{Ax} = \mathbf{b}$, jossa $\mathbf{A}$ on diagonaalisesti dominoiva, diagonaalia vastaavien muuttujien suhteen. Näihin päästään käsiksi matriisimuodossa, kun pilkotaan kerroinmatriisi alakolmiomatriisin, diagonaalimatriisin ja yläkolmiomatriisin summaksi:

$$\begin{aligned} \mathbf{Ax} &= \mathbf{b} \\ (\mathbf{L} + \mathbf{D} + \mathbf{U})\mathbf{x} &= \mathbf{b} \\ \mathbf{Lx} + \mathbf{Dx} + \mathbf{Ux} &= \mathbf{b} \\ \mathbf{Dx} &= \mathbf{b} - \mathbf{Lx} - \mathbf{Ux} \\ \mathbf{x} &= \mathbf{D}^{-1}\mathbf{b} - \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}. \end{aligned}$$

Määritelmä 5.16 (Jacobin menetelmä)**.** *Jacobin menetelmän* iteraatiokaava on muotoa

$$\mathbf{x}_{k+1} = \mathbf{Bx}_k + \mathbf{c},$$

missä $\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L}+\mathbf{U})$ ja $\mathbf{c} = \mathbf{D}^{-1}\mathbf{b}$.

Nopeasti katsottuna voisi näyttää siltä, että tällainen iteratiivinen menetelmä on yhtälöryhmän ratkaisemisen kannalta täysin turha, koska siinä joudutaan laskemaan $n \times n$-matriisn kerroinmatriisi, kun $n \times n$ käänteismatriisilla $\mathbf{A}^{-1}$ saataisiin suoraan ratkaisu. $\mathbf{D}$ on kuitenkin diagonaalimatriisi, joten sen käänteismatriisi saadaan suoraan ottamalla käänteisluvut diagonaalialkiosta, mikä on laskennallisesti varsin kevyt laskutoimitus.

Ratkaisualgoritmin koodissa matriisi $\mathbf{B}$ ja vektori $\mathbf{c}$ kannattaa laskea ennen silmukkaa turhan työn vähentämiseksi.

Suppenemisehdon havainnollistus Havainnollistetaan, miksi diagonaalisesti dominoiva kerroinmatriisi riittää takaamaan iteraation suppenemisen. Riittää siis onnistua näyttämään, että tällaisen yhtälöryhmän tapauksessa $\mathbf{x}_n$ suppenee.

Aloitetaan kirjoittamalla järjestyksessä iteraattien lausekkeita, jos vaikka saataisiin pääteltyä iteraatille $\mathbf{x}_n$ indeksistä n riippuva lauseke, koska tällöin voitaisiin katsoa, mitä tapauksessa $n \to \infty$ tapahtuu. Iteraatiokaavan $\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{c}$ nojalla pätee

$$\begin{aligned}
\mathbf{x}_1 &= \mathbf{B}\mathbf{x}_0 + \mathbf{c} \\
\mathbf{x}_2 &= \mathbf{B}\mathbf{x}_1 + \mathbf{c} = \mathbf{B}(\mathbf{B}\mathbf{x}_0 + \mathbf{c}) + \mathbf{c} = \mathbf{B}^2\mathbf{x}_0 + \mathbf{B}\mathbf{c} + \mathbf{c} \\
\mathbf{x}_3 &= \mathbf{B}\mathbf{x}_2 + \mathbf{c} = \mathbf{B}(\mathbf{B}^2\mathbf{x}_0 + \mathbf{B}\mathbf{c} + \mathbf{c}) + \mathbf{c} = \mathbf{B}^3\mathbf{x}_0 + \mathbf{B}^2\mathbf{c} + \mathbf{B}\mathbf{c} + \mathbf{c}.
\end{aligned}$$

Tapauksessa n pätee siis

$$\mathbf{x}_n = (\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B}^{n-1})\mathbf{c} + \mathbf{B}^n\mathbf{x}_0.$$

Havaitaan, että vektorin $\mathbf{c}$ kertoimeksi muodostuu geometristä summaa vastaava lauseke. Reaalilukujen tapauksessa pätee

$$1 + b + b^2 + \cdots + b^{n-1} = \frac{1-b^n}{1-b}$$

(Kerro yhtälö jakajalla, niin näet miksi). Matriiseille pätee vastaavasti

$$\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B} + \mathbf{B}^{-1} = (\mathbf{I} - \mathbf{B})^{-1}(\mathbf{I} - \mathbf{B}^n),$$

missä käänteismatriisi voidaan kirjoittaa kummalle puolella vain, sillä identiteettimatriisista johtuen pätee poikkeuksellisesti

$$(\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B} + \mathbf{B}^{-1})(\mathbf{I} - \mathbf{B}) = (\mathbf{I} - \mathbf{B})(\mathbf{I} + \mathbf{B} + \mathbf{B}^2 + \cdots + \mathbf{B} + \mathbf{B}^{-1}).$$

Näin ollen

$$\mathbf{x}_n = (\mathbf{I} - \mathbf{B})^{-1}(\mathbf{I} - \mathbf{B}^n)\mathbf{c} + \mathbf{B}^n\mathbf{x}_0.$$

Reaalilukujen tapauksessa pätee tunnetusti $b^n \to 0$, kun $n \to \infty$, jos $|b| < 1$ (Mitä tapahtuu tapauksissa $|b| > 1$, $b = 1$ ja $b = -1$?). Matriiseille pätee vastaava tulos, mutta tänä vuonna matriisinormien käsittely jää väliin tällä kurssilla. Voidaan osoittaa, että näin käy aina iteraatiokaavan mukaiselle matriisille $\mathbf{B}$. Esimerkiksi edellä käsitellyssä tapauksessa

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 2 \\ \frac{12}{5} \\ \frac{8}{3} \end{bmatrix} + \begin{bmatrix} 0 & \frac{2}{4} & -\frac{1}{4} \\ \frac{1}{5} & 0 & -\frac{3}{5} \\ \frac{1}{3} & -\frac{1}{3} & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k,$$

missä kerroinmatriisi on diagonaalisesti dominoiva, meillä on

$$\mathbf{B} = \begin{bmatrix} 0 & \frac{2}{4} & -\frac{1}{4} \\ \frac{1}{5} & 0 & -\frac{3}{5} \\ \frac{1}{3} & -\frac{1}{3} & 0 \end{bmatrix}, \quad \mathbf{B}^2 = \begin{bmatrix} \frac{1}{60} & \frac{1}{12} & -\frac{3}{10} \\ -\frac{1}{5} & \frac{3}{10} & -\frac{1}{20} \\ -\frac{1}{15} & \frac{1}{6} & \frac{7}{60} \end{bmatrix} \quad \text{ja} \quad \mathbf{B}^3 = \begin{bmatrix} -\frac{1}{12} & \frac{13}{120} & -\frac{13}{240} \\ -\frac{13}{300} & -\frac{1}{12} & -\frac{13}{100} \\ \frac{13}{180} & -\frac{13}{180} & -\frac{1}{12} \end{bmatrix}.$$

Tämä havainnollistaa sitä, että diagonaalinen dominoivuus takaa matriisin **B** alkioista riittävän pienet, jotta sen alkiot alkavat pienetä ja lähestyä nollaa potenssien korotuksissa. Sen sijaan edellä käsitellyssä tapauksessa

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_{k+1} = \begin{bmatrix} 12 \\ 8 \\ 8 \end{bmatrix} + \begin{bmatrix} 0 & -5 & -3 \\ -1 & 0 & -3 \\ -4 & -2 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}_k,$$

jossa kerroinmatriisi ei ollut diagonaalisesti dominoiva, päteekin

$$\mathbf{B} = \begin{bmatrix} 0 & -5 & -3 \\ -1 & 0 & -3 \\ -4 & -2 & 0 \end{bmatrix}, \quad \mathbf{B}^2 = \begin{bmatrix} 17 & 6 & 15 \\ 12 & 11 & 3 \\ 2 & 20 & 18 \end{bmatrix} \quad \text{ja} \quad \mathbf{B}^3 = \begin{bmatrix} -66 & -115 & -69 \\ -23 & -66 & -69 \\ -92 & -46 & -66 \end{bmatrix},$$

eli **B** räjähtää käsiin potenssiin korotuksissa.

Diagonaalisesti dominoivan kerroinmatriisin tapauksessa pätee siis

$$\mathbf{x}_n = (\mathbf{I}-\mathbf{B})^{-1}(\mathbf{I}-\mathbf{B}^n)\mathbf{c} + \mathbf{B}^n\mathbf{x}_0 \xrightarrow{n\to\infty} (\mathbf{I}-\mathbf{B})^{-1}\mathbf{c},$$

eli iteraatio suppenee kohti arvoa $(\mathbf{I}-\mathbf{B})^{-1}\mathbf{c}$. Samalla havaitaan myös, ettei alkuarvaus $\mathbf{x}_0$ vaikuta siihen, suppeneeko iteraatio vai ei.

Voisi tulla mieleen, miksei ratkaisua lasketa suoraan lausekkeella $(\mathbf{I}-\mathbf{B})^{-1}\mathbf{c}$. Samasta syystä kuin miksi ratkaisua ei kannata laskea lausekkeella $\mathbf{A}^{-1}\mathbf{b}$, eli koska kääänteismatriisin laskeminen on työlästä.

6 Differentiaaliyhtälöt

Differentiaaliyhtälöiden ratkaiseminen on yleensä erittäin vaikeaa. Vaikka ensimmäisen kertaluvun differentiaaliyhtälöille on olemassa monia erilaisia ratkaisumenetelmiä, useimpia niistä ei voida ratkaista analyyttisesti. Kaikki lineaariset ensimmäisen kertaluvun differentiaaliyhtälöt voidaan ratkaista analyyttisesti, kunhan ratkaisukaavassa tarvittavat integraalit voidaan laskea. Kuitenkin epälineaarisissa tapauksissa ratkaisu löydetään vain tietyissä erikoistapauksissa. Kun siirrymme korkeamman kertaluvun differentiaaliyhtälöihin ja differentiaaliyhtälöryhmiin, analyyttiset ratkaisut ovat saatavilla vielä harvemmin.

Kun tyypillistä yhtälöä, kuten $e^x = x + 1$, ei voida ratkaista analyyttisesti, se on ratkaistava numeerisesti, jolloin saadaan approksimaatio ratkaisulle. Yhtäläisesti: kun alkuarvotehtävää ei voida ratkaista analyyttisesti, se on ratkaistava numeerisesti. Koska ratkaisu ei ole yksittäinen luku vaan kokonainen funktio, alkuarvotehtävän ratkaisu ei ole yksittäinen approksimaatio vaan useita approksimaatioita tarkasteltavan välin yli. Oheinen kuva havainnollistaa tätä.

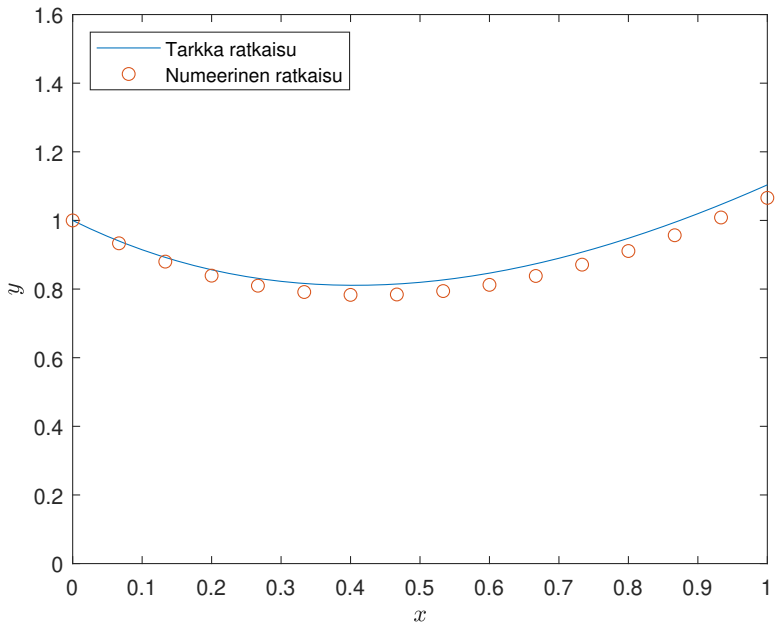

Tämä osio käsittelee muutamia numeerisia menetelmiä alkuarvotehtävien ratkaisemiseksi. Tavoitteena ei ole kattaa aihetta kokonaisvaltaisesti, vaan tutustua näiden menetelmien takana oleviin perusideoihin. Esimerkiksi syy siihen, miksi korkeamman kertaluvun differentiaaliyhtälöt on kirjoitettava yhtälöryhmiksi ODE-ratkaisijaa käytettäessä, tulee selväksi.

6.1 Eulerin menetelmä

Alkuarvotehtävää

$$y' = \sin(ty), \quad y(0) = 1,$$

ei voi ratkaista analyyttisesti. Hyväksymme hieman vaatimattomamman tavoitteen ja yritämme löytää karkean approksimaatiota ratkaisufunktion y arvolle kohdassa $t = 1$. Alkuehdosta tiedämme, että $y(0) = 1$. Tämän tiedon avulla voimme myös laskea funktion derivaatan arvon kyseisessä pisteessä:

$$y'(0) = \sin\Big(0 \cdot y(0)\Big) = \sin(0 \cdot 1) = 0.$$

Derivaatan perusteella voimme arvioida, kuinka funktio käyttäytyy pisteen $t = 0$ ympäristössä. Pisteessä $t = 0$ muodostettu lineaarinen approksimaatio on

$$L_0(t) = y(0) + y'(0)(t - 0) = 1 + 0(t - 0) = 1.$$

(Alaindeksi 0 on lisätty erottamaan tämä myöhemmin eri pisteissä muodostetuista lineaarisista approksimaatioista.) Pisteen $t = 0$ ympäristössä saadaan approksimaatio

$$y(1) \approx L_0(1) = 1.$$

Edellinen approksimaatio olisi tarkempi, jos lineaarinen approksimaatio tehtäisiin lähempänä pistettä $t = 1$. Ongelmana on, että emme tiedä funktion y ja sen derivaatan y' arvoja tällaisissa lähemmissä pisteissä. Voimme kuitenkin käyttää edellistä lineaarista approksimaatiota arvioon tähän tarkoitukseen. Esimerkiksi pisteessä $t = 0.5$ saamme

$$y(0.5) \approx L_0(0.5) = 1,$$

joten

$$y'(0.5) = \sin\Big(0.5 \cdot 1\Big) \approx 0.48.$$

Näiden arvojen avulla saadaan funktion y pisteessä $t = 0.5$ tehdyn lineaarisen approksimaation *arvio*

$$L_{0.5}(t) = y(0.5) + y'(0.5)(t - 0.5) \approx 1 + \sin(0.5)(t - 0.5) \approx 0.48t + 0.76.$$

Tällä voimme approksimoida funktioarvoa $y(1)$ seuraavasti:

$$y(1) \approx L_{0.5}(1) \approx 0.48 \cdot 1 + 0.76 = 1.24.$$

Tämä on parempi approksimaatio kuin edellinen, kuten oheisessa kuvassa havainnollistetaan. Huomaa, että kuvasta näkyy selvästi, että $0.48t + 0.76$ on vain arvio lineaariselle approksimaatiolle $L_{0.5}$. Todellisuudessa vastaavan suoran tulisi olla tangenttisuora pisteessä $t = 0.5$.

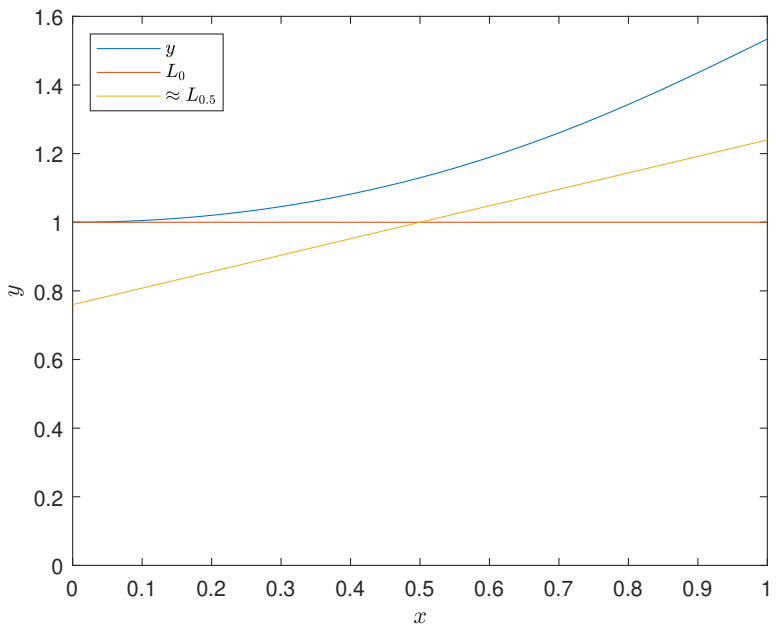

Yleistämisen vuoksi on selkeämpää esittää edellinen kuva seuraavassa muodossa.

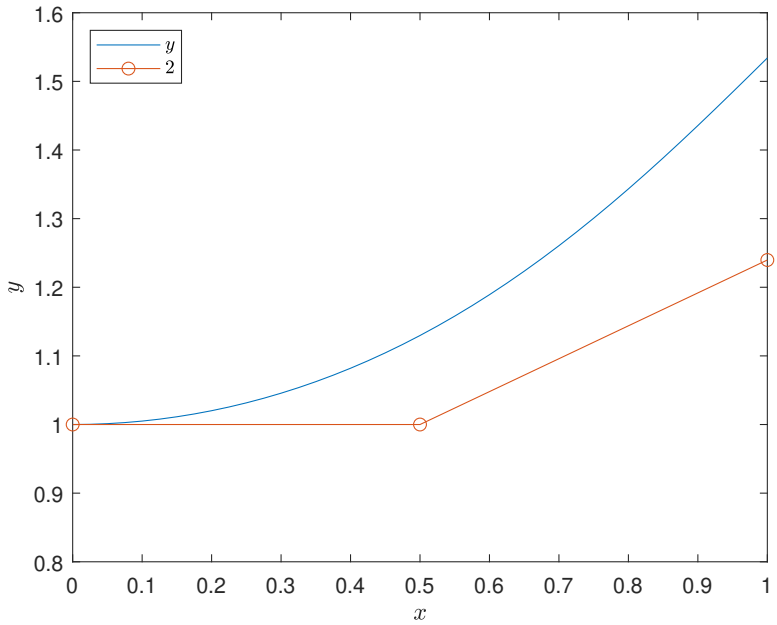

Tässä tapauksessa tangenttisuorat on piirretty vain väleille, joissa niitä käytetään funktion arvojen approksimaatioina.

Edellisiä kahta lineaarista approksimaatiota paremman arvion saa käyttämällä kolmea tai useampaa lineaarista approksimaatiota. Seuraava kuva havainnollistaa tätä 1, 2, 3, 4 ja 20 lineaarisella approksimaatiolla.

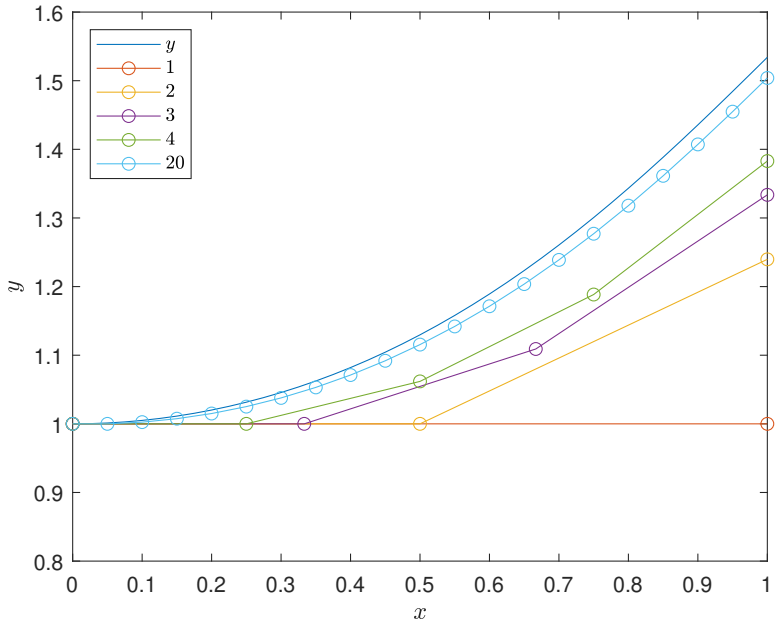

Kuvasta on selvää, että on löydetty menetelmä, jolla saadaan mielivaltaisen tarkka arvio arvolle $y(1)$ käyttämällä riittävän monta lineaarista approksimaatiota. On myös merkittävää,

että prosessissa saadaan arviot myös funktion y muille arvoille. Esimerkiksi neljän lineaarisen approksimaation tapauksessa saadaan arviot funktion arvoille pisteissä $y(0.25)$, $y(0.5)$ ja $y(0.75)$. Näitä arvioita voidaan pitää differentiaaliyhtälön *numeerisena ratkaisuna* välillä $[0,1]$. Täten on löydetty menetelmä ensimmäisen kertaluvun alkuarvotehtävien numeeriseen ratkaisemiseen.

Ennen kuin siirrymme yleisempään käsittelyyn, osoitamme, että edellisen esimerkin seuraavan arvion laskemisen edellisestä voidaan yksinkertaistaa melko suoraviivaiseksi prosessiksi. Tätä varten käytämme merkintää t_i pisteille, joissa lineaariset approksimaatiot muodostetaan, ja vastaaville funktion arvojen approksimaatioille käytetään merkitää y_1. Täten

$$y_0 = y(t_0), \quad y_1 \approx y(t_1), \quad y_2 \approx y(t_2), \quad \ldots, \quad y_n \approx y(t_n).$$

Tällä merkinnällä edellisen esimerkin suureet ovat $y_1 = y_0 + y'(t_0)(t_1 - t_0)$, $y_2 = y_1 + y'(t_1)(t_2 - t_1)$ ja yleisemmin

$$y_{i+1} = y_i + y'(t_i)(t_{i+1} - t_i).$$

Alkuehdosta voimme täten laskea arvion y_1, ja sen perusteella voimme edelleen laskea arvion y_2, ja niin edelleen.

Yllä esitetty numeerinen differentiaaliyhtälön ratkaisun menetelmä on esimerkki *askelmenetelmästä*. Näiden menetelmien idea on seuraava:

1. Siirtyminen alkuarvon pisteestä t_0 pisteeseen t_1.
2. Ratkaisufunktion arvon approksimaation laskeminen pisteessä t_1, eli $y_1 \approx y(t_1)$.
3. Siirtyminen seuraavaan pisteeseen ja approksimaation laskeminen tässä pisteessä.
4. Edellisen askeleen toistaminen, kunnes tarkasteltavan välin päätepisteen t_n arvo on laskettu.
5. Approksimaatiot $y_1, y_2, \ldots, y_n$ muodostavat numeerisen ratkaisun alkuarvotehtävälle.

Siirtymiä $t_i \to t_{i+1}$ kutsutaan *askeliksi*, ja erotuksia $t_{i+1} - t_i$ kutsutaan *askelpituuksiksi*. Tämän kurssin menetelmissä askelpituus on aina vakio, kuten edellisissä esimerkeissä, ja sitä merkitään h:lla. Askelpituuden ei ole pakko olla vakio; esimerkiksi voisi olla järkevää ottaa lyhyempiä askeleita, kun funktio kasvaa nopeasti, eli kun derivaatan itseisarvo on suuri. Tämä kuitenkin monimutkaistaa yleisen algoritmin muotoilua.

Jokainen arvio y_{i+1} lasketaan aiemmin laskettujen arvioiden perusteella. Uuden arvion saamiseen käytettyä kaavaa kutsutaan *rekursiokaavaksi*. Eri menetelmissä rekursiokaava on eri muodossa. Yllä käsitellyssä menetelmässä kaava on muotoa

Määritelmä 6.1 (Eulerin menetelmä)**.**

$$y_{i+1} = y_i + hf(t_i, y_i),$$

missä $f(t,y) = y'(t)$.

Tätä menetelmää kutsutaan *Eulerin menetelmäksi*. Eulerin menetelmässä seuraava arvio saadaan edellisestä käyttämällä lineaarista approksimaatiota, kuten oheisessa kuvassa havainnollistetaan.

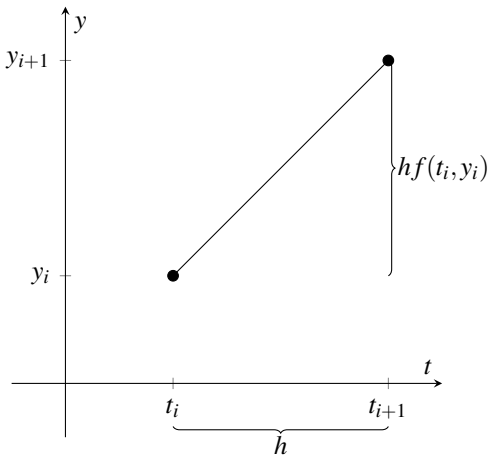

Esimerkki 6.2. Ratkaistaan alkuarvotehtävä

$$y' = xy, \quad y(0) = 1,$$

pisteessä $x = 1$ Eulerin menetelmällä ja (a) yhdellä (b) kahdella (c) sadalla askeleella. Kaikissa osissa funktio on $f(x,y) = xy$ ja väli on $[0,1]$.

(a) $n = 1$, joten askelpituus on

$$h = \frac{1-0}{1} = 1.$$

0. askel: $x_0 = 0$, $y_0 = 1$. **1. askel:**

$$x_1 = x_0 + h = 0 + 1 = 1,$$

$$y_1 = y_0 + hf(x_0, y_0) = 1 + 1 \cdot f(0,1) = 1 + 1 \cdot 0 \cdot 1 = 1.$$

Vertailun vuoksi on syytä mainita, että yhtälö voidaan ratkaista muuttujien erottelulla. Ratkaisu on $y(x) = e^{\frac{1}{2}x^2}$, joten $y(1) = e^{\frac{1}{2}} \approx 1.65$.

(b) $n = 2$, joten askelpituus on

$$h = \frac{1-0}{2} = \frac{1}{2}.$$

0. askel: $x_0 = 0$, $y_0 = 1$. **1. askel:**

$$x_1 = x_0 + h = 0 + \frac{1}{2} = \frac{1}{2},$$

$$y_1 = y_0 + hf(x_0, y_0) = 1 + \frac{1}{2} f(0,1) = 1 + \frac{1}{2} \cdot 0 \cdot 1 = 1.$$

2. askel:

$$x_2 = x_1 + h = \frac{1}{2} + \frac{1}{2} = 1,$$

$$y_2 = y_1 + hf(x_1, y_1) = 1 + \frac{1}{2} f(\tfrac{1}{2}, 1) = 1 + \frac{1}{2} \cdot \frac{1}{2} \cdot 1 = \frac{5}{4}.$$

(c) Tämän kaltaiset tehtävät tehdään tietokoneella. Vertailun mahdollistamiseksi piirretään kuva, joka sisältää kaikki tapaukset.

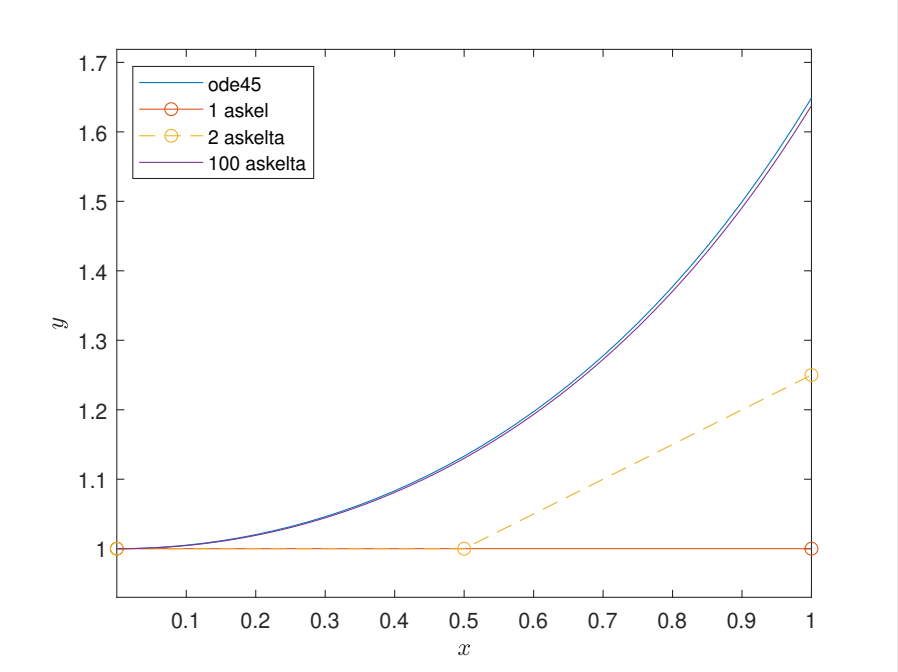

Seuraava lause antaa tietoa Eulerin menetelmän virheestä.

Lause 6.3. *Oletetaan, että y on jatkuva välillä $[t_0,t_n]$ ja kahdesti derivoituva välillä (t_0,t_n). Jos on olemassa vakiot $M,L \geq 0$ siten, että $|y''(x)| \leq M$ kaikille $x \in (t_0,t_n)$ ja f on L-Lipschitz toisen muuttujansa suhteen, eli $|f(t,y)-f(t,\tilde{t})| \leq L|y-\tilde{y}|$ kaikille $y,\tilde{y} \in \mathbb{R}$, niin Eulerin menetelmä askelpituudella $h = (t_n - t_0)/n$ toteuttaa epäyhtälön*

$$|y(t_n) - y_n| \leq \frac{Mh}{2L}(e^{L(t_n-t_0)} - 1).$$

Todistus. Eulerin menetelmän rekursiokaava on $y_{i+1} = y_i + hf(t_i,y_i)$, kun taas Taylorin lause sanoo, että

$$y(t_{i+1}) = y(t_i) + hf(t_i,y(t_i)) + \frac{h^2}{2}y''(c)$$

jollakin $c \in [t_i,t_{i+1}]$. Täten virhe ε_{i+1} toteuttaa epäyhtälön

$$\begin{aligned}
\varepsilon_{i+1} = |y(t_{i+1}) - y_{i+1}| &= \left| y(t_i) + hf(t_i,y(t_i)) + \frac{h^2}{2}y''(c) - y_i - hf(t_i,y_i) \right| \\
&= \left| \varepsilon_i + h[f(t_i,y(t_i)) - f(t_i,y_i)] + \frac{h^2}{2}y''(c) \right| \\
&\leq \varepsilon_i + h|f(t_i,y(t_i)) - f(t_i,y_i)| + \frac{M}{2}h^2 \\
&\leq \varepsilon_i + Lh|y_{t_i} - y_i| + \frac{M}{2}h^2 \\
&= (1+Lh)\varepsilon_i + \frac{M}{2}h^2
\end{aligned}$$

mille tahansa $i \leq n-1$, missä ensimmäinen epäyhtälö käytti funktion y toisen derivaatan rajoittuneisuutta ja toinen Lipschitz-oletusta. Iteroimalla tätä epäyhtälö saadaan

$$\begin{aligned}
\varepsilon_n &\leq (1+Lh)\varepsilon_{n-1} + \frac{M}{2}h^2 \\
&\leq (1+Lh)\left[(1+LH)\varepsilon_{n-2} + \frac{M}{2}h^2\right] + \frac{M}{2}h^2 \\
&= (1+Lh)^2\varepsilon_{n-2} + (1+Lh)\frac{M}{2}h^2 + \frac{M}{2}h^2 \\
&\vdots \\
&\leq (1+Lh)^n\varepsilon_0 + \frac{M}{2}h^2\sum_{i=0}^{n-1}(1+Lh)^i \\
&= \frac{M}{2}h^2\sum_{i=0}^{n-1}(1+Lh)^i
\end{aligned}$$

koska $\varepsilon_0 = |y(t_0) - y_0| = 0$. Geometrisen summan kaava $\sum_{i=0}^{n-1} r^i = (1-r^n)/(1-r)$ kun $r \neq 1$ antaa

$$\varepsilon_i \leq \frac{M}{2}h^2\sum_{i=0}^{n-1}(1+Lh)^k = \frac{M}{2}h^2 \cdot \frac{1-(1+Lh)^n}{1-(1+Lh)} = \frac{M}{2}h^2 \cdot \frac{(1+Lh)^n - 1}{Lh}.$$

Yhtälöstä $1+x \leq e^x$ (muista eksponenttifunktion Taylor-sarja) kaikille $x \geq 0$ saadaan

$$\varepsilon_n \leq \frac{M}{2}h^2 \cdot \frac{(1+Lh)^n - 1}{Lh} \leq \frac{M}{2}h^2 \cdot \frac{e^{Lhn} - 1}{Lh} = \frac{M}{2}h^2 \cdot \frac{e^{L(t_n - t_0)} - 1}{Lh} = \frac{Mh}{2L}(e^{L(t_n - t_0)} - 1)$$

koska $h = (t_n - t_0)/n$. □

6.2 Keskipistemenetelmä

Edellä Eulerin menetelmä esiteltiin käyttämällä tangenttisuoria. Se voidaan johtaa myös numeerisen integroinnin kautta. Seuraavaksi edetään tällä tavalla, sillä se antaa suoraviivaisen tavan johtaa muita numeerisia menetelmiä.

Määrätty integraali toteuttaa yhtälön

$$F(b) - F(a) = \int_a^b f(x)\,\mathrm{d}x.$$

Tämä yhtälö voidaan myös kirjoittaa muotoon

$$f(b) - f(a) = \int_a^b f'(x)\,\mathrm{d}x,$$

missä f vastaa edellisen yhtälön funktiota F. Tämän muotoilun perusteella kuvassa oleva väritetty alue

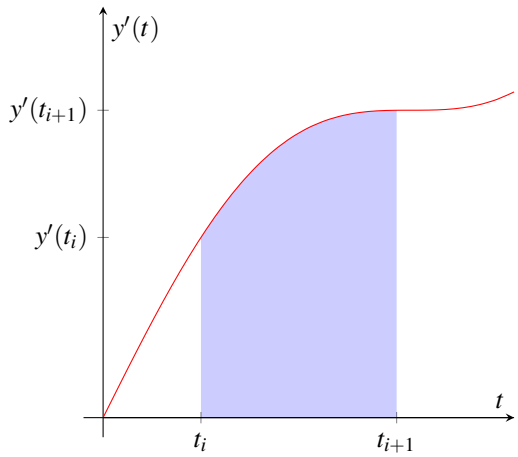

toteuttaa yhtälön

$$y(t_{i+1}) - y(t_i) = \int_{t_i}^{t_{i+1}} y'(t)\,\mathrm{d}t.$$

On olennaista huomata, että pystyakseli ei ole y kuten edellä tangenttisuoria käyttäessämme, vaan y'. Aluetta voidaan karkeasti approksimoida alla olevassa kuvassa näkyvällä suorakulmiolla.

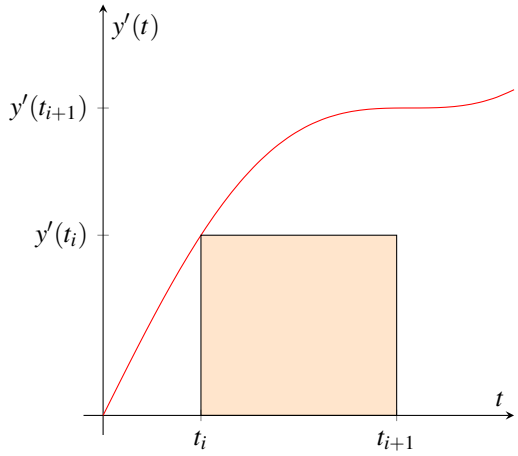

Tämän suorakulmion kannan pituus on $t_{i+1} - t_i = h$ ja sen korkeus on yhtä suuri kuin derivaatan arvo välin alkupisteessä, $y'(t_i)$. Täten

$$y(t_{i+1}) - y(t_i) \approx hy'(t_i).$$

Käyttämällä approksimaatioita $y(t_{i+1}) \approx y_{i+1}$ ja $y(t_i) \approx y_i$ vasemmalla puolella ja kirjoittamalla $y'(t_k) = f(t_i, y_i)$, saadaan

$$y_{i+1} - y_i \approx hf(t_i, y_i),$$

joka vastaa Eulerin menetelmän rekursiokaavaa. Termi $hf(t_i, y_i)$ voidaan täten tulkita suorakulmioksi, joka approksimoi integraalia $\int_{t_i}^{t_{i+1}} y'(t)\,\mathrm{d}t$ (Mikä oli sen tulkinta edellisessä luvussa?). Huomaa, että tässä tapauksessa arviota $f(t_i, y_i)$ käytetään suorakulmion korkeutena tarkan arvon $f\Big(t_i, y(t_i)\Big)$ sijaan, joten Eulerin menetelmässä käytettävä suorakulmio on vain approksimaatio edellisen kuvan suorakulmioille.

Yllä käytetty approksimaatio integraalille $\int_{t_i}^{t_{i+1}} y'(t)\,\mathrm{d}t$ on selvästi liian pieni, kuten kuvasta näkyy. Parempi approksimaatio voitaisiin saada esimerkiksi valitsemalla funktion arvo välin $[t_i, t_{i+1}]$ keskipisteessä, eli kohdassa $t_i + \frac{h}{2}$, suorakulmion korkeudeksi.

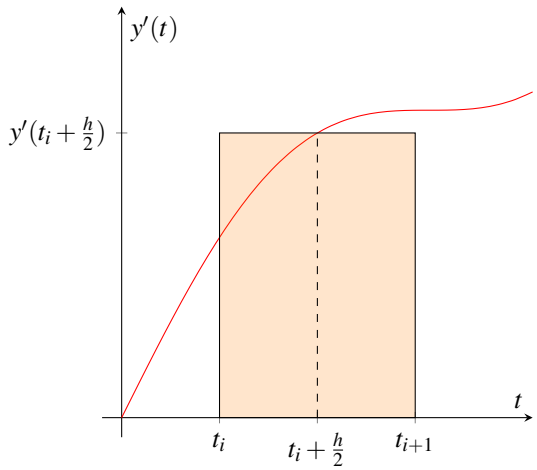

Silloin rekursiokaavaksi tulee

$$y_{i+1} = y_i + hf\left(t_i + \frac{h}{2}, y\left(t_i + \frac{h}{2}\right)\right).$$

Ongelmana on, että arvo $y(t_i + \frac{h}{2})$ on tuntematon. Mutta sitä voidaan approksimoida tangenttisuoraa käyttämällä kuten edellisessä luvussa. Tämä antaa approksimaation

$$y(t_i + \tfrac{h}{2}) \approx y(t_i) + \tfrac{h}{2} f(t_i, y_i),$$

jota oheinen kuva havainnollistaa. (Huomaa, että tässä kuvassa pystyakseli on y eikä y'.)

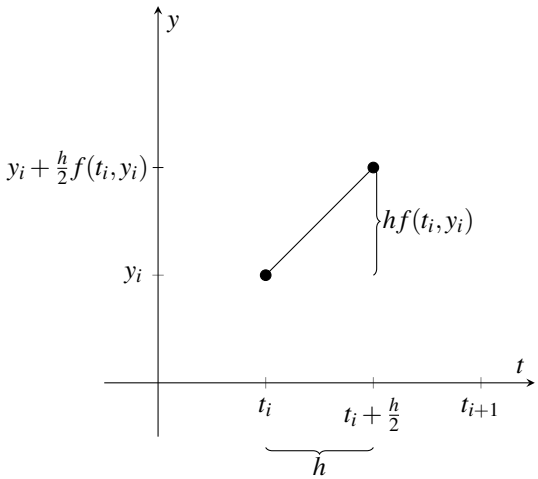

Tässä approksimaatiossa käytetty suorakulmio on, aivan kuin Eulerin menetelmässäkin, vain approksimaatio aiemmin piirretylle suorakulmiosta. Tämä antaa menetelmän, jonka rekursiokaava on

Määritelmä 6.4 (Keskipistemenetelmä)**.**

$$y_{i+1} = y_i + hf\left(t_i + \frac{h}{2}, y_i + \frac{h}{2} f(t_i, y_i)\right).$$

Tätä menetelmää kutsutaan *keskipistemenetelmäksi*.

Esimerkki 6.5. Ratkaistaan alkuarvotehtävä

$$y' = xy, \quad y(0) = 1,$$

pisteessä $x = 1$ keskipistemenetelmällä ja (a) yhdellä (b) kahdella askeleella. Molemmissa osissa $f(x,y) = xy$ ja tarkasteltava väli on $[0,1]$.

(a) $n = 1$, joten askelpituus on

$$h = \frac{1-0}{1} = 1.$$

0. askel: $x_0 = 0$, $y_0 = 1$. **1. askel:**

$$x_1 = x_0 + h = 0 + 1 = 1,$$

$$\begin{aligned}
y_1 &= y_0 + hf\left(x_0 + \frac{h}{2}, y_0 + \frac{h}{2}f(x_0,y_0)\right) \\
&= 1 + 1 \cdot f\left(0 + \frac{1}{2}, 1 + \frac{1}{2}f(0,1)\right) \\
&= 1 + f\left(\frac{1}{2}, 1 + \frac{1}{2} \cdot 0 \cdot 1\right) \\
&= 1 + f\left(\frac{1}{2}, 1\right) \\
&= 1 + \frac{1}{2} \cdot 1 \\
&= \frac{3}{2}.
\end{aligned}$$

(b) $n = 2$, joten askelpituus on

$$h = \frac{1-0}{2} = \frac{1}{2}.$$

0. askel: $x_0 = 0$, $y_0 = 1$. **1. askel:**

$$x_1 = x_0 + \frac{1}{2} = 0 + \frac{1}{2} = \frac{1}{2},$$

$$\begin{aligned}
y_1 &= y_0 + hf\left(x_0 + \frac{h}{2}, y_0 + \frac{h}{2}f(x_0,y_0)\right) \\
&= 1 + \frac{1}{2}f\left(0 + \frac{1}{4}, 1 + \frac{1}{4}f(0,1)\right) \\
&= 1 + \frac{1}{2}f\left(\frac{1}{4}, 1\right) \\
&= \frac{9}{8}.
\end{aligned}$$

2. askel:

$$x_2 = x_1 + h = \frac{1}{2} + \frac{1}{2} = 1,$$

$$
\begin{aligned}
y_2 &= y_1 + hf\left(x_1 + \frac{h}{2}, y_1 + \frac{h}{2} f(x_1, y_1)\right) \\
&= \frac{9}{8} + \frac{1}{2} f\left(\frac{1}{2} + \frac{1}{4}, \frac{9}{8} + \frac{1}{4} f(\tfrac{1}{2}, \tfrac{9}{8})\right) \\
&= \frac{9}{8} + \frac{1}{2} f(\tfrac{3}{4}, \tfrac{81}{64}) \\
&= \frac{9}{8} + \frac{1}{2} \cdot \frac{3}{4} \cdot \frac{81}{64} \\
&= \frac{819}{512}.
\end{aligned}
$$

6.3 Rungen–Kuttan menetelmät

Eulerin menetelmän ja keskipistemenetelmän kaavat saadaan approksimoimalla integraalia

$$y_{i+1} \approx y_i + \int_{t_i}^{t_{i+1}} y'(t)\,\mathrm{d}t$$

käyttämällä suorakulmiota. Integraalia voidaan approksimoida myös muilla tavoin. Erityisesti voisimme approksimoida integraalin käyttämällä *kahta* suorakulmiota. Oheinen kuva havainnollistaa tätä.

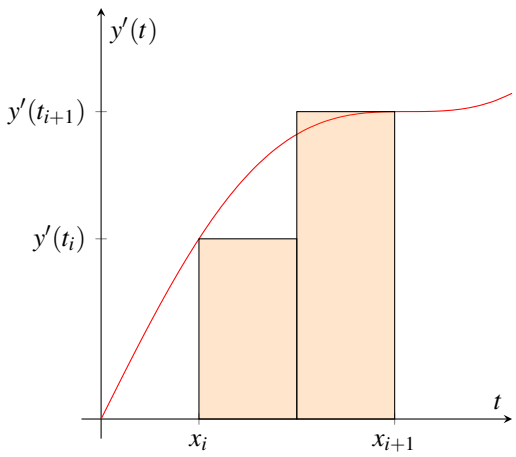

Tämä tulkinta mahdollistaa yleiset menetelmät, jotka perustuvat kahteen mielivaltaiseen suorakulmioon. Tällaisia menetelmiä kutsutaan *kaksivaiheisiksi Rungen–Kuttan menetelmiksi*, ja niiden rekursiokaavat ovat muotoa

Määritelmä 6.6 (Kaksivaiheinen Rungen–Kuttan menetelmä)**.**

$$y_{i+1} = y_i + h(b_1 k_1 + b_2 k_2), \quad b_1 + b_2 = 1,$$

missä

$$k_1 = f(t_i, y_i)$$

ja

$$k_2 = f(t_i + ch, y_i + ahk_1), \quad a, c \in (0, 1].$$

Kaavassa $b_1 h$ ja $b_2 h$ ovat suorakulmioiden leveydet, ja k_1 ja k_2 ovat niiden korkeudet. Korkeus k_1 lasketaan aina välin $[t_i, t_{i+1}]$ alkupisteessä, ja k_2 jossakin muussa välin pisteessä. Tapaus $b_1 = b_2 = \frac{1}{2}$, $c = a = 1$ vastaa menetelmää, jota kutsutaan *Heunin menetelmäksi*. Tapaus $b_1 = 0$,

$b_2 = 1$, $c = a = \frac{1}{2}$ vastaa keskipistemenetelmää, koska sen rekursiokaava voidaan myös kirjoittaa muotoon

$$y_{i+1} = y_i + hk_2,$$

$$\begin{aligned} k_1 &= f(t_i, y_i), \\ k_2 &= f\left(t_i + \frac{h}{2}, y_i + \frac{h}{2}k_1\right). \end{aligned}$$

Tässä ensimmäisen suorakulmion pinta-ala on $0 \cdot hk_1 = 0$. Eulerin menetelmä ei ole kaksivaiheinen Rungen–Kuttan menetelmä vaan yksivaiheinen menetelmä, koska se ei vaadi korkeutta k_2.

n-vaiheinen Rungen–Kuttan menetelmä approksimoi integraalia $\int_{t_i}^{t_{i+1}} y'(t)\,\mathrm{d}t$ käyttäen n suorakulmiota. Tässä tapauksessa rekursiokaava on muotoa

Määritelmä 6.7 (n-vaiheinen Rungen–Kuttan menetelmä)**.**

$$y_{i+1} = y_i + h\sum_{i=1}^{n} b_i k_i, \quad \sum_{i=1}^{n} b_i = 1,$$

$$\begin{aligned} k_1 &= f(t_i, y_i), \\ k_i &= f\left(t_i + c_i h, y_i + h\sum_{m=j}^{j-1} a_{jm} k_m\right), \quad j = 2, 3, \ldots, n. \end{aligned}$$

Ehkä tunnetuin Rungen–Kuttan menetelmä on *klassinen Rungen–Kuttan menetelmä* (RK4), jonka rekursiokaava on muotoa

Määritelmä 6.8 (Klassinen Rungen–Kuttan menetelmä — RK4)**.**

$$y_{i+1} = y_i + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4),$$

$$\begin{aligned} k_1 &= f(t_i, y_i), \\ k_2 &= f(t_i + \tfrac{h}{2}, y_i + \tfrac{h}{2}k_1), \\ k_3 &= f(t_i + \tfrac{h}{2}, y_i + \tfrac{h}{2}k_2), \\ k_4 &= f(t_i + h, y_i + hk_3). \end{aligned}$$

Tämä on nelivaiheinen menetelmä, ja käytetty neljän suorakulmion arvio vastaa itse asiassa Simpsonin menetelmää, missä arvioitavan alueen ylä- (tai ala-) raja approksimoidaan paraabelilla, joka kulkee pisteiden $\left(t_i, y(t_i)\right)$, $\left(t_i + \frac{h}{2}, y(t_i + \frac{h}{2})\right)$ ja $\left(t_{i+1}, y(t_{i+1})\right)$ kautta Tätä havainnollistetaan oheisessa kuvassa.

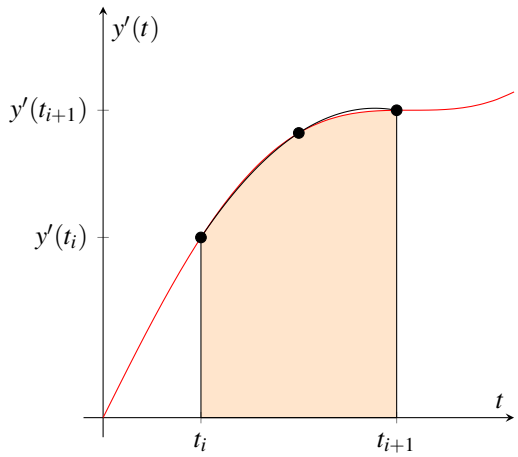

Edellinen kuva vastaa ihanteellista tilannetta, ja todellinen tilanne on sen arvio. Kahta erilaista arviota käytetään derivaatan arvolle välin keskipisteessä, $f\left(t_i + \frac{h}{2}, y(t_i + \frac{h}{2})\right)$: yhdessä $y(t_i + \frac{h}{2}) \approx y_i + \frac{h}{2}k_1$ ja toisessa $y(t_i + \frac{h}{2}) \approx y_i + \frac{h}{2}k_2$. Nämä ovat suorakulmiotulkinnassa kahden keskimmäisen suorakulmion korkeudet.

Esimerkki 6.9. Ratkaistaan alkuarvotehtävä

$$y' = xy, \quad y(0) = 1,$$

pisteessä $x = 1$ klassisella Rungen–Kuttan menetelmällä yhdellä askeleella. Funktio on $f(x,y) = xy$ ja tarkasteltava väli on $[0,1]$. $n = 1$, joten askelpituus on

$$h = \frac{1-0}{1} = 1.$$

0. askel $x_0 = 0$, $y_0 = 1$. **1. askel**

$$x_1 = x_0 + h = 0 + 1 = 1,$$

$$k_1 = f(x_0, y_0) = f(0,1) = 0 \cdot 1 = 0,$$

$$k_2 = f(x_0 + \tfrac{h}{2}, y_0 + \tfrac{h}{2}k_1) = f(0 + \tfrac{1}{2}, 1 + \tfrac{1}{2} \cdot 0) = \frac{1}{2} \cdot 1 = \frac{1}{2},$$

$$k_3 = f(x_0 + \tfrac{h}{2}, y_0 + \tfrac{h}{2}k_2) = f(0 + \tfrac{1}{2}, 1 + \tfrac{1}{2}\tfrac{1}{2}) = \frac{1}{2} \cdot \frac{5}{4} = \frac{5}{8}$$

$$k_4 = f(x_0 + h, y_0 + hk_3) = f(0 + 1, 1 + 1 \cdot \tfrac{5}{8}) = 1 \cdot \frac{13}{8} = \frac{13}{8},$$

$$y_1 = y_0 + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4) = 1 + \frac{1}{6}\left(0 + 2 \cdot \frac{1}{2} + 2 \cdot \frac{5}{8} + \frac{13}{8}\right) = \frac{79}{48}.$$

Tehdään yhteenveto eri menetelmillä tuotetuista ratkaisuista yhdellä askeleella:

$$\begin{aligned} y_{\text{exact}}(1) &\approx 1.649 \\ y_{\text{Euler}}(1) &\approx 1.000 \\ y_{\text{midpoint}}(1) &\approx 1.500 \\ y_{\text{RK4}}(1) &\approx 1.646. \end{aligned}$$

RK4 selvästi ylittää muut menetelmät, mutta se vaatii eniten laskemista.

6.4 Numeerisiä ratkaisuja differentiaaliyhtälöryhmille

Edellisiä menetelmiä voidaan soveltaa myös ensimmäisen kertaluvun differentiaaliyhtälöryhmiin. Havainnollistamme tätä esimerkillä Eulerin menetelmän tapauksessa.

Esimerkki 6.10. Ratkaistaan alkuarvotehtävä

$$\begin{matrix} y_1' = y_1 + y_2 \\ y_2' = y_1^2 \end{matrix}, \quad \begin{matrix} y_1(0) = -1 \\ y_2(0) = 2 \end{matrix},$$

pisteessä $t = 1$ Eulerin menetelmällä askelpituudella $h = 0.5$. Aletaan muuttamalla merkintöjä niin, että alaindekseillä on vain yksi merkitys laskelmissa:

$$\begin{matrix} y' = y + u \\ u' = y^2 \end{matrix}, \quad \begin{matrix} y(0) = -1 \\ u(0) = 2 \end{matrix}.$$

Merkitään $f(t,y,u) = y + u$ ja $g(t,y,u) = y^2$ **0. askel:** $t_0 = 0$, $y_0 = -1$, $u_0 = 2$. **1. askel:**

$$t_1 = t_0 + h = 0 + \frac{1}{2} = \frac{1}{2},$$

$$y_1 = y_0 + hf(t_0, y_0, u_0) = -1 + \frac{1}{2} \cdot f(0,-1,2) = -1 + \frac{1}{2} \cdot (-1+2) = -\frac{1}{2},$$

$$u_1 = u_0 + hg(t_0, y_0, u_0) = 2 + \frac{1}{2} \cdot g(0,-1,2) = 2 + \frac{1}{2}(-1)^2 = \frac{5}{2}.$$

2. askel:

$$t_2 = t_1 + h = \frac{1}{2} + \frac{1}{2} = 1,$$

$$y_2 = y_1 + hf(t_1, y_1, u_1) = -\frac{1}{2} + \frac{1}{2} f(\tfrac{1}{2}, -\tfrac{1}{2}, \tfrac{5}{2}) = -\frac{1}{2} + \frac{1}{2}\left(-\frac{1}{2} + \frac{5}{2}\right) = \frac{1}{2},$$

$$u_2 = u_1 + hg(t_1, y_1, u_1) = \frac{5}{2} + \frac{1}{2} g(\tfrac{1}{2}, -\tfrac{1}{2}, \tfrac{5}{2}) = \frac{5}{2} + \frac{1}{2}\left(-\frac{1}{2}\right)^2 = \frac{21}{8}.$$

Saadaan approksimaatio

$$\begin{matrix} y(1) \approx \frac{1}{2} \\ u(1) \approx \frac{21}{8} \end{matrix}.$$

6.5 Implisiittiset menetelmät

Eulerin menetelmässä $y_{k+1} = y_k + hf(t_k, y_k)$ integraalia $\int_{t_k}^{t_{k+1}} y'(t)\,\mathrm{d}t$ approksimoidaan suorakulmiolla, jonka korkeus $y'(t)$ lasketaan välin $[t_k, t_{k+1}]$ alkupisteessä, ja jonka leveys on $h = t_{k+1} - t_k$. Jos suorakulmion korkeus lasketaan sen sijaan välin päätepisteessä, kaavaksi saadaan

$$y_{k+1} = y_k + hf(t_{k+1}, y_{k+1}).$$

Esimerkiksi differentiaaliyhtälön $y'(x) = xy$ tapauksessa tämä johtaa yhtälöön

$$y_{k+1} = y_k + ht_{k+1} y_{k+1}.$$

Tässä yhtälössä vasemmalla puolella olevaa arvoa ei voida saada korvaamalla tunnetut arvot oikealle puolelle, kuten aiemmissa käsitellyissä menetelmissä. Voimme kuitenkin ratkaista y_{k+1}:n:

$$\begin{aligned} y_{k+1} &= y_k + ht_{k+1}y_{k+1} \\ y_{k+1} &= \frac{y_k}{1 - ht_{k+1}}. \end{aligned}$$

Tämä on esimerkki *implisiittisesta menetelmästä*, kun taas aiemmin käsiteltyjä menetelmiä kutsutaan *eksplisiittisiksi menetelmiksi*. Menetelmä on eksplisiittinen, jos sen kaava määrittelee arvon y_{k+1} eksplisiittisesti, eli suoraan, ja implisiittinen, jos sen kaava määrittelee arvon y_{k+1} implisiittisesti, eli epäsuorasti.

Implisiittisessä menetelmässä y_{k+1} on ratkaistava erikseen menetelmän kaavasta. Edellisessä esimerkissä se ratkaistiin melko suoraviivaisesti. Yleensä näin ei ole, ja esimerkiksi funktion $f(t,y) = e^y$ tapauksessa yhtälöä ei voitaisi ratkaista käsin. Tällaisissa tapauksissa yhtälö on ratkaistava numeerisesti esimerkiksi Newtonin menetelmällä.

7 Optimointi

Tässä kappaleessa käsittelemme *optimointia*, eli niiden pisteiden etsimistä, joissa funktion saa joko suurimman tai pienimmän arvonsa.[4] Keskitymme *gradienttimenetelmään*, jonka muunnelmiin suuri osa koneoppimesta perustuu.

7.1 Neuroverkkojen kouluttaminen

Aloitetaan motivoimalla optimoinnin tarpeellisuutta.

7.1.1 Lineaarinen regressio

Oletetaan, että meillä on havaintoja (tai vasteita) $y_1, \dots, y_n \in \mathbb{R}$ joissakin pisteissä (eli syötteissä) $x_1, \dots, x_n \in \mathbb{R}$. Pisteet ja niitä vastaavat havainnot muodostavat *opetusjoukon*. Pisteet voivat esimerkiksi kuvata mittalaitteiden sijainteja, mittausten ajankohtia (jolloin kyseessä on *aikasarja*) tai parametreja, joita käyttäen jokin koe suoritetaan. Näiden tietojen perusteella haluamme ennustaa havainnon pisteessä, joka ei sisälly opetusjoukkoon. Tätä varten voimme olettaa, että havainnot riippuvat lineaarisesti pisteistä:

$$y_i = a + bx_i + \varepsilon_i \quad \text{kun} \quad i \in \{1, \dots n\} \tag{7.1}$$

missä a ja b määräävät yhteyden pisteiden x_i ja havaintojen y_i välillä ja residuaali ε_i mallintaa mittausvirhettä tai muiden lähteiden kuin pisteiden x_i vaikutusta havaintoihin y_i. Tehtävämme on löytää "hyvät" tai "optimaaliset" arvot parametreille a ja b. Tätä kutsutaan *lineaariseksi regressioksi*. Eräs tapa on valita a ja b, joilla *residuaalien neliösumman*

$$L(a,b) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - a - bx_i)^2 \tag{7.2}$$

on niin pieni kuin mahdollista. Funktio L on esimerkki *tappiofunktiosta* (engl. *loss function* tai *cost function*). Tappiofunktio voidaan valita lähes mielivaltaisesti (voisimme esimerkiksi vaihtoehtoisesti yrittää minimoida summaa $\sum_{i=1}^{n} |\varepsilon_i|$), mutta yhtälön (7.2) *neliöllinen* tappiofunktio on matemaattisesti erittäin kätevä, sillä se johtaa *pienimmän neliösumman menetelmään*. Parametrien a ja b arvot a^* ja b^* parametreille, jotka minimoivat tappiofunktion $L(a,b)$, saadaan yhtälöstä (emme johda tätä yhtälöä)

$$\begin{bmatrix} a^* \\ b^* \end{bmatrix} = (\mathbf{X}^\intercal \mathbf{X})^{-1} \mathbf{X}^\intercal \mathbf{y}, \quad \text{missä} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \in \mathbb{R}^{n \times 2} \quad \text{ja} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \in \mathbb{R}^n. \tag{7.3}$$

Tämän minimointiongelman ratkaisu on *yksikäsitteinen* siinä mielessä, että $L(a^*, b^*) < L(a,b)$ jokaiselle parille $(a,b) \neq (a^*, b^*)$. Lineaarisen regression tuottamat *lineaariset sovitteet* $f(x) = a^* + bx^*$ on esitetty kuvassa 7.1 kahdelle varsin erilaiselle opetusjoukolle. Kuva osoittaa, että lineaarinen sovite voi olla varsin hyödyllinen, jos aineistossa todella esiintyy lineaarinen trendi, kuten opetusjoukossa 1. Vaikuttaa siis uskottavalta, että $f(x_0)$ olisi lähellä opetusjoukkoon sisältymätöntä pistettä x_0 vastaavaa havaintoa y_0. Sovite on kuitenkin hyödytön, jos opetusjoukossa ei ole havaittavaa lineaarista trendiä kuten aineistossa 2. Tämä johtuu siitä, että olettamamme yhteys (7.1) pisteiden x_i ja havaintojen y_i välillä ei ole erityisen ilmaisuvoimainen, sillä siinä on vain kaksi parametria, a ja b.

[4] Optimoinnin teoriaa ja käytäntöä käsitellään huomattavasti yksityiskohtaisemmin toisen vuoden kurssilla *Optimization* (BM20A8201).

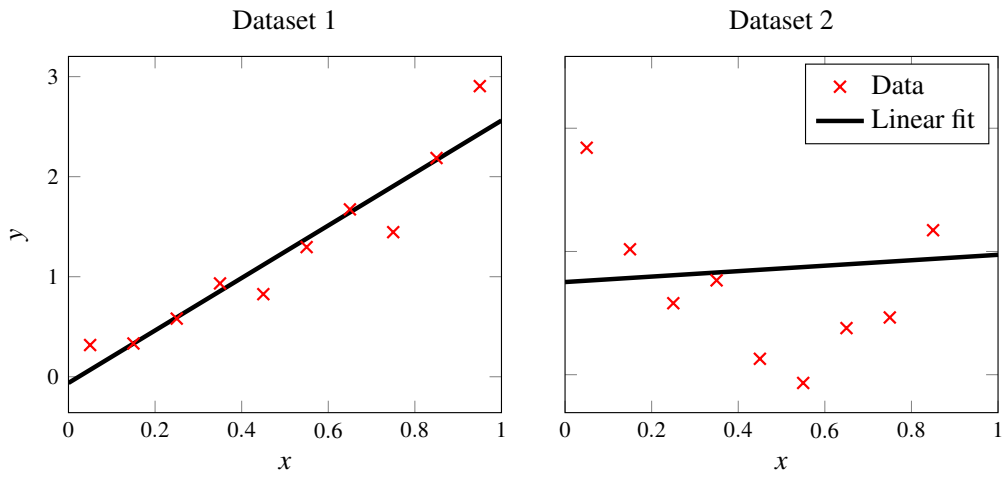

Kuva 7.1: Lineaariset sovitteet $f(x) = a^* + bx^*$ kahdelle eri opetusjoukolle. Tässä a^* ja b^* on laskettu yhtälöstä (7.3). Sovite on varsin hyvä ensimmäiselle opetusjoukolle, mutta täysin hyödytön toiselle.

7.1.2 Neuroverkot

Perimmiltään *neuroverkko* koostuu vain (i) joustavasta oletus kuten (7.1) syötteiden ja vasteiden väliselle yhteydelle, (ii) joidenkin parametrien valinnasta minimoimalla tappiofunktio ja (iii) sovitteesta, jota, jota käytetään ennustamaan vaste uusissa syötteissä. Tarkastellaan yksinkertaista kahden kerroksen verkkoa, joka perustuu *sigmoidiseen aktivaatiofunktioon*

$$\sigma(x) = \frac{1}{1+e^{-x}}. \tag{7.4}$$

Olkoot $w_1, w_2 \in \mathbb{R}$ *painoja* ja $b_1, b_2 \in \mathbb{R}$ *vakiotermejä* (engl. *biases*). Yhtälön (7.1) inspiroimana oletamme, että opetusvasteet $0 \leq y_i \leq 1$ liittyvät syötteisiin x_i yhtälön

$$y_i = \sigma(w_2\sigma(w_1x_i + b_1) + b_2) + \varepsilon_i \quad \text{kun} \quad i \in \{1, \ldots, n\}. \tag{7.5}$$

kautta. Määritellään

$$F(x \mid w_1, w_2, b_1, b_2) = \sigma(w_2\sigma(w_1x + b_1) + b_2), \tag{7.6}$$

jolloin (7.5) saa muodon $y_i = F(x_i \mid w_1, w_2, b_1, b_2) + \varepsilon_i$. Kuten lineaarisen regressiossa voimme määritellä neliöllisen tappiofunktion

$$L(w_1, w_2, b_1, b_2) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (y_i - F(x_i \mid w_1, w_2, b_1, b_2))^2 \tag{7.7}$$

ja valita painot w_1, w_2 ja vakiotermit b_1, b_2 minimoimalla tämän tappiofunktion. Vastassamme on kuitenkin ongelma. Toisin kuin pienimmän neliösumman menetelmässä, joka tarjoaa yksinkertaisen lausekkeen (7.3) tappiofunktion (7.2) minimoijille, vastaavaa kätevää kaavaa ei olekaan nyt olemassa. Sen sijaan meidän on kehitettävä ja käytettävä jotakin *optimointimenetelmää* tappiofunktion (7.7) minimoimiseksi. Koska todellisissa ongelmissa painoja ja vakiotermejä on tuhansia ja opetusjoukot ovat valtavia, on olennaista, että tämä optimointimenetelmä on nopea ajaa. Tässä osiossa opimme käyttämään *derivaattoja* ja *gradientteja* kuvaamaan funktion muutoksen suuntaa ja nopeutta sekä toteuttamaan *gradienttimenetelmän*, erään koneoppimisen tärkeimmistä työjuhdista. Kuvassa 7.2 esitetään kaksi gradienttimenetelmällä optimoitua neuroverkkoa.

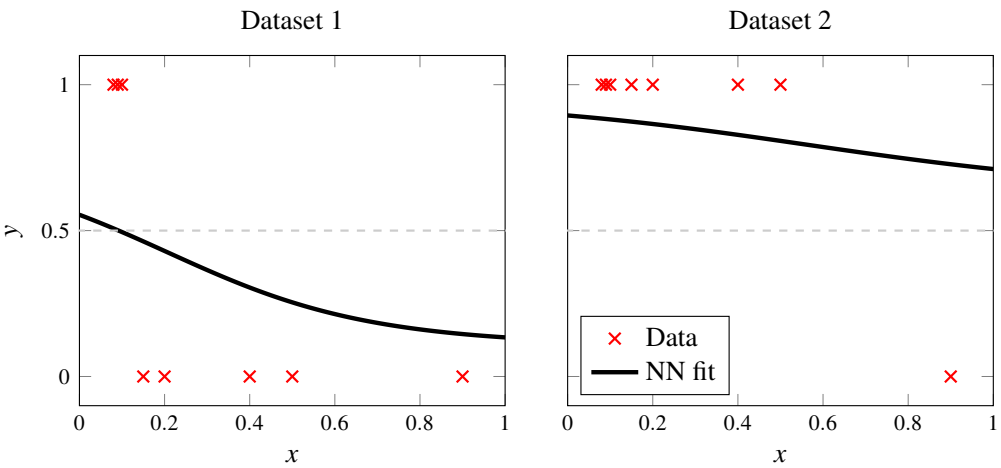

Kuva 7.2: Neuroverkkosovite $f(x) = F(x \mid w_1^*, w_2^*, b_1^*, b_2^*) = \sigma(w_2^* \sigma(w_1^* x + b_1^*) + b_2^*)$ kahdelle eri opetusjoukolla. Parametrit w_1^*, w_2^*, b_1^* ja b_2^* on laskettu gradienttimenetelmällä. Opetusjoukot koostuvat $n = 8$ *luokasta* $y \in \{0, 1\}$ (eli pisteet x, joille $y = 1$, kuuluvat kategoriaan A ja pisteet, joille $y = 0$, kategoriaan B). Neuroverkkosovitteen f laskemisen jälkeen voimme luokitella uuden pisteen esimerkiksi kategoriaan A kuuluvaksi, jos $f(x) > \frac{1}{2}$, ja kategoriaan B kuuluvaksi, jos $f(x) \leq \frac{1}{2}$. Harmaa katkoviiva on näin saatu *päätöspinta*. Tällainen luokittelu toimii aineistolle 1 (ainakin joten kuten), mutta ei aineistolle 2. Tämä on ymmärrettävää, sillä käyttämämme neuroverkko on äärimmäisen yksinkertainen. *Todellisuudessa σ esiintyy yhtälössä* (7.5) *huomattavasti useammin kuin kahdesti.*

7.2 Gradienttimenetelmä yhden muuttujan funktioille

Optimoinnin tavoitteena on löytää piste (tai pisteet) x^*, jossa tarkasteltava funktio f saavuttaa pienimmän tai suurimman arvonsa. Koneoppimisessa f on yleensä tappiofunktio, joka halutaan minimoida (osion 7.1 esimerkit). Keskitymme siis minimointiin. Huomaa, että minimoinnille johdettuja tuloksia ja menetelmiä voi soveltaa lähes sellaisinaan maksimointiin:

$$\text{funktion } f \text{ maksimointi} \quad \text{on sama asia kuin} \quad \text{funktion } -f \text{ minimointi.}$$

Määritelmä 7.1 (Minimit)**.** Olkoon $f\colon \mathbb{R} \to \mathbb{R}$ funktio. Piste $x^* \in \mathbb{R}$ on

- funktion f *globaali minimipiste*, jos $f(x^*) \leq f(x)$ kaikilla $x \in \mathbb{R}$;
- funktion f *paikallinen minimipiste*, jos on olemassa $\varepsilon > 0$ siten, että $f(x^*) \leq f(x)$ kaikilla pisteillä x välillä $[x^* - \varepsilon, x^* + \varepsilon]$, jonka pituus on 2ε ja keskipiste x^*.

Jos x^* on globaali minimipiste, lukua $f(x^*)$ kutsutaan *globaaliksi minimiksi*. Jos x^* on paikallinen minimipiste, lukua $f(x^*)$ kutsutaan *paikalliseksi minimiksi*.

Globaalit ja paikalliset maksimit määritellään vastaavasti korvaamalla määritelmissä epäyhtälö“$\leq$” epäyhtälöllä “$\geq$”. Minimejä ja maksimeja kutsutaan *ääriarvoiksi* ja minimi- ja maksimipisteitä *ääriarvopisteiksi*. Funktio saavuttaa pienimmän mahdollisen arvonsa globaalissa minimipisteessä. Paikallisessa minimipisteessä funktio saavuttaa arvon, joka on pienempi tai yhtä suuri kuin funktion arvot pisteissä “lähellä” minimipistettä. Paikallisen minimipisteen määritelmä sanoo yksinkertaisesti, että on olemassa *jokin* väli minimpisteen x^* ympärillä siten, että $f(x^*) \leq f(x)$ jokaisella kyseisen välin pisteellä x. Huomaa, että globaali minimipiste on myös paikallinen minimipiste. Kuvassa 7.3 on esitetty erään funktion ääriarvopisteet. Keskitymme paikalliseen

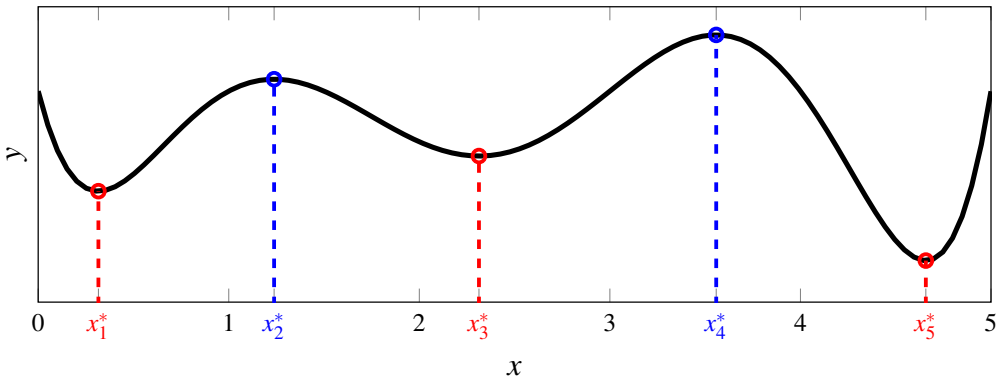

Kuva 7.3: Erään funktion paikalliset minimipisteet (punainen; x_1^*, x_3^* ja x_5^*) ja maksimipisteet (sininen; x_2^* ja x_4^*). Paikallinen minimipiste x_5^* on myös *globaali* minimipiste. Vaikka asiaa ei voikaan päätellä kuvasta, tällä funktiolla ei ole globaalia maksimipistettä, sillä se lähestyy ääretöntä kun $x \to -\infty$ ja $x \to \infty$.

optimointiin *globaalin optimoinnin* sijaan. Toisin sanoen olemme tyytyväisiä, jos kykenemme löytämään paikallisen minimipisteen. Globaalin minimipisteen löytäminen voi olla huomattavasti haastavampaa. Paikalliset ääriarvopisteet liittyvät läheisesti pisteisiin, joissa funktion derivaatta on nolla.

Määritelmä 7.2 (Kriittinen piste)**.** Piste $x^* \in \mathbb{R}$ on derivoituvan funktion f *kriittinen piste* (tai *stationaarinen piste*), jos $f'(x^*) = 0$.

Esimerkki 7.3. Tarkastellaan funktioita $f(x) = \cos(x)$ ja $g(x) = \frac{1}{3}x^3 - x$. Ensimmäisen funktion derivaatta on $f'(x) = -\sin(x)$. Perustrigonometrian perusteella tiedämme, että $\sin(x) = 0$ jos ja vain jos $x = \pi n$ jollakin kokonaisluvulla n (eli $n \in \mathbb{Z}$). Siten $f'(x) = 0$ jos ja vain jos $x = \pi n$ jollakin kokonaisluvulla n. Nämä ovat siis funktion $f(x) = \cos(x)$ kriittiset pisteet. Toisin sanoen kosinilla on ääretön määrä kriittisiä pisteitä. Funktiolle g pätee $g'(x) = x^2 - 1$, joten $g'(x) = 0$ jos ja vain jos $x = 1$ tai $x = -1$. Siten polynomilla $g(x) = \frac{1}{3}x^3 - x$ on kaksi kriittistä pistettä, $x^* = -1$ ja $x^* = 1$.

Lause 7.4 (Fermat'n lause)**.** *Jokainen derivoituvan funktion f paikallinen ääriarvopiste x^* on kriittinen piste, eli $f'(x^*) = 0$.*

Todistus. Oletetaan, että x^* on paikallinen ääriarvopiste. Oletetaan, että se on paikallinen minimipiste (todistus on täysin vastaava paikalliselle maksimipisteelle). Paikallisen minimipisteen määritelmän (määritelmä 7.1) nojalla on olemassa $\varepsilon > 0$ siten, että

$$f(x^*) \leq f(x) \quad \text{kaikilla} \quad x \in [x^* - \varepsilon, x^* + \varepsilon]. \tag{7.8}$$

Muistetaan, että derivaatta $f'(x^*)$ on määritelty erotusosamäärän raja-arvona

$$f'(x^*) = \lim_{h \to 0} \frac{f(x^* + h) - f(x^*)}{h}. \tag{7.9}$$

Jokaisella $h \in (0, \varepsilon)$ erotusosamäärä toteuttaa epäyhtälön

$$\frac{f(x^* + h) - f(x^*)}{h} \leq \frac{f(x^*) - f(x^*)}{h} = 0, \tag{7.10}$$

sillä $f(x^* + h) \leq f(x^*)$ yhtälön (7.8) nojalla. Kun $h \in (-\varepsilon, 0)$, saamme vastaavasti

$$\frac{f(x^* + h) - f(x^*)}{h} = \frac{f(x^*) - f(x^* + h)}{|h|} \geq \frac{f(x^*) - f(x^*)}{|h|} = 0, \tag{7.11}$$

sillä $h = -|h|$ kun $h < 0$. Yhtälöt (7.10) ja (7.11) osoittavat, että erotusosamäärä on (a) epäpositiivinen, jos h on positiivinen ja lähellä nollaa, ja (b) epänegatiivinen, jos h on negatiivinen ja lähellä nollaa. Koska derivaatta on erotusosamäärän raja-arvo kun $h \to 0$ ja 0 on ainoa luku, joka on samanaikaisesti epäpositiivinen ja -negatiivinen, täytyy päteä $f(x^*) = 0$. □

Kuva 7.3 havainnollistaa lausetta 7.4: jokaisessa ääriarvopisteessä tangenttisuora olisi vaakasuora ja derivaatta siten nolla. Fermat'n lauseesta johdamme paikallisten optimointimenetelmien perusperiaatteen *etsiä piste, jossa derivaatta on nolla*. Huomaa, että lause 7.4 sanoo ääriarvopisteiden olevan kriittisiä pisteitä, ei että jokainen kriittinen piste on ääriarvopiste. Onko kriittinen piste ääriarvopiste vai ei voidaan yleensä päätellä tutkimalla derivaatan käyttäytymistä kriittisten pisteiden välillä.

Lause 7.5 (Kriittisten pisteiden luokittelu)**.** *Olkoon f derivoituva funktio. Oletetaan, että $x_1^* < x_2^* < x_3^*$ ovat funktion f kriittisiä pisteitä.*

1. *Jos $f'(x) > 0$ kaikilla $x_1^* < x < x_2^*$ ja $f'(x) > 0$ kaikilla $x_2^* < x < x_3^*$, niin x_2^** ei ole ääriarvopiste.
2. *Jos $f'(x) < 0$ kaikilla $x_1^* < x < x_2^*$ ja $f'(x) < 0$ kaikilla $x_2^* < x < x_3^*$, niin x_2^** ei ole ääriarvopiste.
3. *Jos $f'(x) > 0$ kaikilla $x_1^* < x < x_2^*$ ja $f'(x) < 0$ kaikilla $x_2^* < x < x_3^*$, niin x_2^* on* paikallinen maksimipiste.
4. *Jos $f'(x) < 0$ kaikilla $x_1^* < x < x_2^*$ ja $f'(x) > 0$ kaikilla $x_2^* < x < x_3^*$, niin x_2^* on* paikallinen minimipiste.

Todistus. Sivuutetaan. □

Derivaatan etumerkki kertoo, onko funktio kasvava vai vähenevä. Lauseen 7.5 tapauksissa 1 ja 2 funktio on kasvava (tapaus 1) tai vähenevä (tapaus 2) sekä kriittisen pisteen x_2^* vasemmalla että oikealla puolella. Siten x_2^* ei voi olla ääriarvopiste. Tapauksessa 3 funktio on kasvava pisteen x_2^* vasemmalla puolella ja vähenevä sen oikealla puolella, joten sen on saavutettava paikallinen maksimi pisteessä x_2^*. Tapauksessa 4 funktio on vähenevä vasemmalla ja kasvava oikealla puolella, joten sillä on oltava paikallinen minimi pisteessä x_2^*. Seuraava esimerkki ja kuva 7.4 havainnollistavat tätä.

Esimerkki 7.6. Luokitellaan funktion

$$f(x) = x^3 \exp(-\tfrac{1}{2}x^2), \tag{7.12}$$

kriittiset pisteet. Funktion derivaatta on

$$f'(x) = (3x^2 - x^4)\exp(-\tfrac{1}{2}x^2). \tag{7.13}$$

Koska funktio $\exp(-\frac{1}{2}x^2)$ on kaikkialla positiivinen, $f'(x) = 0$ jos ja vain jos $3x^2 - x^4 = 0$. Yhtälöllä

$$3x^2 - x^4 = x^2(3 - x^2) = 0 \tag{7.14}$$

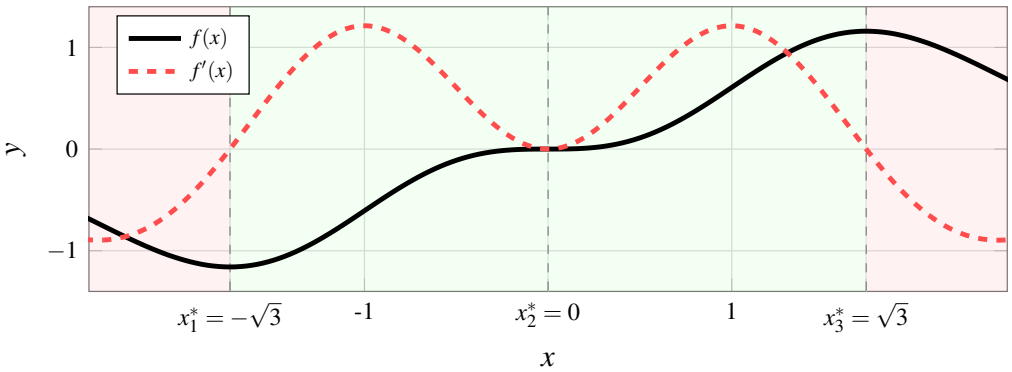

Kuva 7.4: Funktio $f(x) = x^3 \exp(-\frac{1}{2}x^2)$ ja sen derivaatta yhtälössä (7.13). Funktio on kasvava (eli derivaatta on positiivinen) vihreällä välillä ja vähenevä (eli derivaatta on negatiivinen) kahdella punaisella välillä. Derivaatta on nolla pisteissä x_1^*, x_2^* ja x_3^*, eli nämä ovat funktion f kriittisiä pisteitä. Kriittiset pisteet x_1^* ja x_3^* ovat ääriarvopisteitä, mutta kriittinen piste $x_2 = 0$ ei ole, sillä f on kasvava sekä pisteen x_2^* vasemmalla että oikealla puolella.

on kolme ratkaisua, jotka ovat $x = 0$, $x = \sqrt{3}$ ja $x = -\sqrt{3}$. Siten funktion f kriittiset pisteet ovat

$$x_1^* = -\sqrt{3}, \quad x_2^* = 0, \quad \text{ja} \quad x_3^* = \sqrt{3}. \tag{7.15}$$

Aloitetaan pisteestä x_2^*. Derivaatan (7.13) etumerkki on sama kuin lausekkeen $3x^2 - x^4$ etumerkki. Kirjoittamalla tämä muodossa $x^2(3 - x^2)$ havaitsemme, että

$$f'(x) > 0 \quad \text{kaikilla} \quad -\sqrt{3} < x < 0 \quad \text{ja} \quad 0 < x < \sqrt{3}. \tag{7.16}$$

Täten f' *ei* vaihda merkkiä pisteessä $x_2^* = 0$, joten x_2^* ei ole ääriarvopiste lauseen 7.5 tapauksen 1 nojalla. Pisteille $x_1^* = -\sqrt{3}$ ja $x_3^* = \sqrt{3}$ pätee

$$f'(x) < 0 \quad \text{kaikilla} \quad x < -\sqrt{3} \quad \text{ja } x > \sqrt{3}. \tag{7.17}$$

Siten f on vähenevä pisteen x_1^* vasemmalla puolella ja kasvava sen oikealla puolella, mikä tarkoittaa, että x_1^* on paikallinen (oikeastaan globaali) minimipiste. Vastaavasti f on kasvava pisteen x_3^* vasemmalla puolella ja vähenevä sen oikealla puolella, mikä tarkoittaa, että x_3^* on paikallinen (oikeastaan globaali) maksimipiste. Kuva 7.4 havainnollistaa tilannetta.

Funktiota minimoitaessa on luonnollista edetä suuntaan, jossa funktio pienenee. Tämä perusajatus on seuraavan *gradienttimenetelmän* taustalla. Tämän algoritmin moniulotteisessa versiossa (kappale 7.3) derivaatat korvataan gradienteilla, korkeampiulotteisilla yleistyksillään.

Määritelmä 7.7 (Gradienttimenetelmä yhden muuttujan funktioille)**.** Olkoon $\eta > 0$ *oppimisnopeus* ja $x_0 \in \mathbb{R}$ alkupiste. *Gradienttimenetelmä* etsii approksimaatioita x_k derivoituvan funktion $f\colon \mathbb{R} \to \mathbb{R}$ minimipisteelle iteraation

$$x_{k+1} = x_k - \eta f'(x_k) \tag{7.18}$$

avulla. Iteraatio lopetetaan riittävän monen iteraation jälkeen tai kun $|f'(x_k)|$ on riittävän pieni.

Perusteiltaan gradienttimenetelmä on varsin yksinkertainen. Silmukkaa suoritetaan, kunnes derivaatan itseisarvo on pienempi kuin käyttäjän määrittelemä toleranssi (esim. $|f(x_k)| \leq 10^{-6}$)

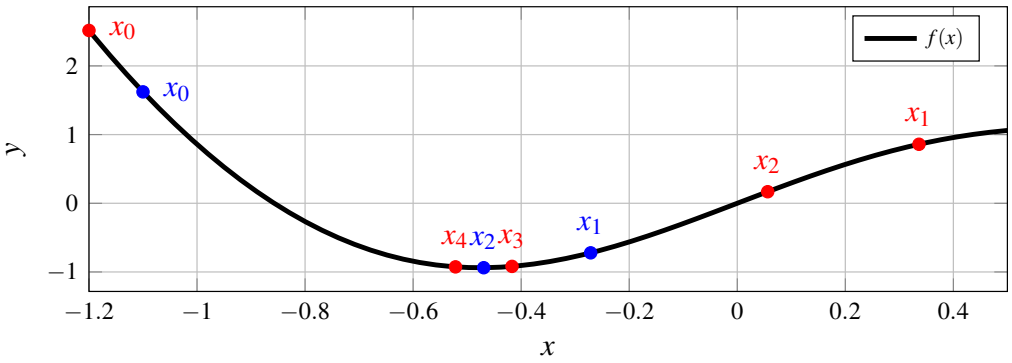

Kuva 7.5: Gradienttimenetelmä funktiolle $f(x) = x^4 + \sin(3x)$, jonka globaali minimipiste on $x^* \approx -0{,}47562$. Punaisten pisteiden jono tuotettiin gradienttimenetelmällä alkupisteellä $x_0 = -1{,}2$ ja oppimisnopudella $\eta = 0{,}16$; sinisten pisteiden jono alkupisteellä $x_0 = -1{,}1$ ja $\eta = 0{,}1$. Huomaa, että piste x_{n+1} on aina pisteen x_n oikealla puolella, jos f on vähenevä pisteessä x_n, ja pisteen x_{n+1} vasemmalla puolella, jos f on kasvava pisteessä x_n (esim. x_2 on pisteen x_1 vasemmalla puolella, sillä f on kasvava pisteessä x_1).

tai iteraatioiden enimmäismäärä on saavutettu (mikä suojaa päättymättömiltä silmukoilta). Iteraatiokaava (7.39) on algoritmin ydin: jokaisella iteraatiolla siirrymme askeleen derivaatan osoittamaa suuntaa *vastakkaiseen* suuntaan. Jos esimerkiksi $f'(x_n) > 0$, funktio on kasvava pisteessä x_n, mikä tarkoittaa, että haluamme siirtyä vasemmalle (eli valita pisteen $x_{n+1} < x_n$). *Oppimisnopeus* eli *askelpituus* η säätelee, kuinka suuria askeleita otamme jokaisella iteraatiolla. Jos η on liian suuri, algoritmi ei välttämättä toimi hyvin vaan "hyppii" liikaa. Jos funktiolla on paikallinen minimi, $f'(x_n)$ toivottavasti lähestyy nollaa, jolloin otetut askeleet [eli $-\eta f'(x_n)$] pienenevät.

Koska derivaatta on lähellä nollaa gradienttimenetelmän palauttamassa pisteessä, tämä piste on lähellä kriittistä pistettä. Kriittinen piste ei tietenkään välttämättä ole paikallinen ääriarvopiste, kuten muistamme lauseesta 7.5 ja esimerkistä 7.6. Kuva 7.5 havainnollistaa gradienttimenetelmän toimintaa.

Huomautus 7.8. Kriittiset pisteet ja lause 7.4 ovat hyödyllisiä vain silloin, kun f on derivoituva. Esimerkiksi itseisarvofunktiota $f(x) = |x|$ ei voi derivoida pisteessä $x = 0$. On kuitenkin selvää, että tämän funktion globaali minimipiste $x^* = 0$.

7.3 Gradienttimenetelmä useamman muuttujan funktioille

Yleistämme seuraavaksi gradienttimenetelmän useamman muuttujan funktioiden $f\colon \mathbb{R}^d \to \mathbb{R}$ minimointiin.

7.3.1 Gradientti

Gradientti on osittaisderivaattojen muodostama vektori.

Määritelmä 7.9 (Gradientti)**.** Funktion $f\colon \mathbb{R}^d \to \mathbb{R}$ *gradientti* on funktio $\nabla f\colon \mathbb{R}^d \to \mathbb{R}^d$,

joka on

$$\nabla f(\mathbf{x}) = \nabla f(x_1,\ldots,x_d) = \nabla_{\mathbf{x}} f(\mathbf{x}) = \frac{\mathrm{d}}{\mathrm{d}\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \partial_1 f(\mathbf{x}) \\ \vdots \\ \partial_d f(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \dfrac{\partial}{\partial x_1} f(\mathbf{x}) \\ \vdots \\ \dfrac{\partial}{\partial x_d} f(\mathbf{x}) \end{bmatrix} \in \mathbb{R}^d. \quad (7.19)$$

Ylösalaisin käännetty Δ (delta) gradientin merkinnässä (7.19) on *nabla*. Tällä kurssilla gradientti on sarakevektori, mutta toisinaan se määritellään rivivektorina. Merkintöjä kuten $\mathrm{d}f(\mathbf{x})/\mathrm{d}\mathbf{x}$, joissa derivoidaan vektorin suhteen, on tulkittava koordinaateittain, eli vektori saadaan derivoimalla $f(\mathbf{x})$ kunkin muuttujan $\mathbf{x}$ koordinaatin suhteen. Funktio $f\colon \mathbb{R}^d \to \mathbb{R}$ on derivoituva, jos kaikki sen osittaisderivaatat ovat olemassa, eli jos sen gradientti on olemassa.

Esimerkki 7.10. Tarkastellaan funktiota $f(\mathbf{x}) = f(x_1,x_2) = x_1 + x_2 - x_1 x_2^3$. Tämän funktion osittaisderivaatat ovat

$$\partial_1 f(x_1,x_2) = 1 - x_2^3 \quad \text{ja} \quad \partial_2 f(x_1,x_2) = 1 - 3x_1x_2^2. \quad (7.20)$$

Siten gradientti on

$$\nabla f(x_1,x_2) = \begin{bmatrix} \partial_1 f(x_1,x_2) \\ \partial_2 f(x_1,x_2) \end{bmatrix} = \begin{bmatrix} 1 - x_2^3 \\ 1 - 3x_1x_2^2 \end{bmatrix}. \quad (7.21)$$

Esimerkki 7.11. Tarkastellaan *gaussista funktiota*

$$f(\mathbf{x}) = f(x_1,x_2,x_3) = \exp(-\tfrac{1}{2}\|\mathbf{x}\|^2) = \exp\left(-\frac{x_1^2+x_2^2+x_3^2}{2}\right). \quad (7.22)$$

Tämän funktion osittaisderivaatat ovat

$$\partial_i f(x_1,x_2,x_3) = -x_i \exp(-\tfrac{1}{2}\|\mathbf{x}\|^2) \quad \text{missä} \quad i \in \{1,2,3\}. \quad (7.23)$$

Näin ollen

$$\nabla f(x_1,x_2,x_3) = \begin{bmatrix} \partial_1 f(x_1,x_2,x_3) \\ \partial_2 f(x_1,x_2,x_3) \\ \partial_3 f(x_1,x_2,x_3) \end{bmatrix} = \begin{bmatrix} -x_1 \exp(-\frac{1}{2}\|\mathbf{x}\|^2) \\ -x_2 \exp(-\frac{1}{2}\|\mathbf{x}\|^2) \\ -x_3 \exp(-\frac{1}{2}\|\mathbf{x}\|^2) \end{bmatrix} = -\exp(-\tfrac{1}{2}\|\mathbf{x}\|^2)\,\mathbf{x}. \quad (7.24)$$

Huomaa, että viimeisessä lausekkeessa kerromme vektorin $\mathbf{x} \in \mathbb{R}^3$ skalaarilla $-\exp(-\frac{1}{2}\|\mathbf{x}\|^2)$.

Esimerkki 7.12. Usean muuttujan funktiot voi toisinaan ilmaista lineaarialgebran keinoin. Olkoot

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 1 \\ 1 & 0 & 2 \\ 0 & 3 & 7 \end{bmatrix} \in \mathbb{R}^{3\times 3} \quad \text{ja} \quad \mathbf{a} = \begin{bmatrix} 8 \\ 1 \\ -3 \end{bmatrix} \in \mathbb{R}^3. \quad (7.25)$$

Tarkastellaan funktiota $f\colon \mathbb{R}^3 \to \mathbb{R}$, joka on

$$f(\mathbf{x}) = \mathbf{a}^\mathsf{T}\mathbf{A}\mathbf{x}. \quad (7.26)$$

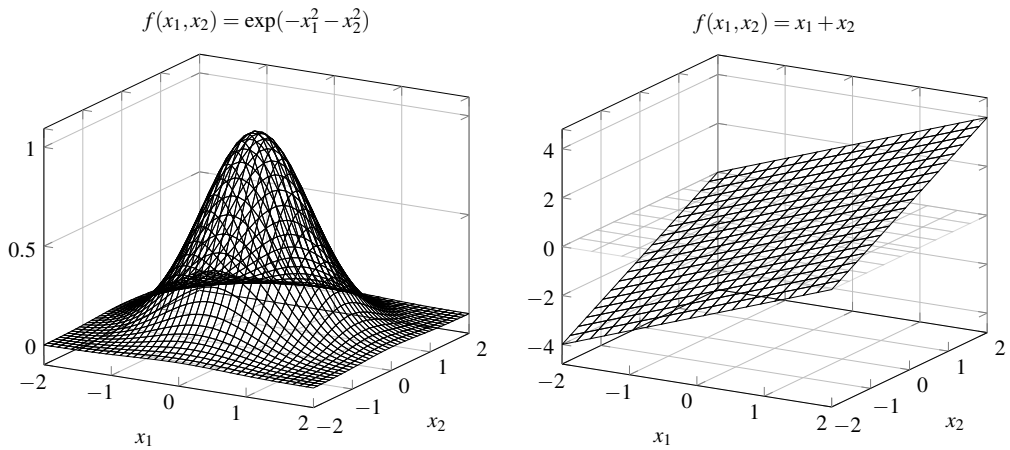

Kuva 7.6: Funktiota $\mathbb{R}^2 \to \mathbb{R}$, joita tarkastellaan esimerkeissä 7.13 ja 7.14.

Saamme

$$\mathbf{a}^\intercal \mathbf{A} = \begin{bmatrix} 8 & 1 & -3 \end{bmatrix} \begin{bmatrix} 1 & -1 & 1 \\ 1 & 0 & 2 \\ 0 & 3 & 7 \end{bmatrix} = \begin{bmatrix} 9 & -17 & -11 \end{bmatrix}, \tag{7.27}$$

joten

$$f(\mathbf{x}) = \begin{bmatrix} 9 & -17 & -11 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = 9x_1 - 17x_2 - 11x_3. \tag{7.28}$$

Funktion f osittaisderivaatat ovat siis

$$\partial_1 f(\mathbf{x}) = 9, \quad \partial_2 f(\mathbf{x}) = -17, \quad \text{ja} \quad \partial_3 f(\mathbf{x}) = -11. \tag{7.29}$$

Palautetaan mieleen, että derivaatta kertoo funktion muutoksen *suunnan* (jos derivaatta on positiivinen, funktio kasvaa; jos se on negatiivinen, funktio vähenee) ja *muutosnopeuden*. Gradientti voidaan tulkita vastaavasti:

gradientti $\nabla f(\mathbf{x})$ antaa funktion f nopeimman kasvun suunnan ja nopeuden pisteessä $\mathbf{x}$.

Seuraava esimerkki ja kuva 7.7 havainnollistavat asiaa.

Esimerkki 7.13. Tarkastellaan kahden muuttujan gaussista funktiota

$$f(\mathbf{x}) = f(x_1,x_2) = \exp(-\tfrac{1}{2}\|\mathbf{x}\|^2) = \exp\left(-\frac{x_1^2 + x_2^2}{2}\right), \tag{7.30}$$

joka on esitetty kuvassa 7.6. Käytimme kolmiulotteista gaussista funktiota esimerkissä 7.11, mutta kaksiulotteisia funktioita on hivenen helpompi piirtää. Täsmälleen sama lasku kuin esimerkissä 7.11 antaa meille gradientin

$$\nabla f(\mathbf{x}) = \nabla f(x_1,x_2) = -\exp(-\tfrac{1}{2}\|\mathbf{x}\|^2)\,\mathbf{x}. \tag{7.31}$$

Gradientti pisteessä $\mathbf{x}$ on siis vektori, joka osoittaa origoa kohti. Huomataan nyt, että funktio f riippuu ainoastaan normista $r = \|\mathbf{x}\|$ (eli pisteen $\mathbf{x}$ origosta). Toisin sanoen mille tahansa vektoreille $\mathbf{x}, \mathbf{z} \in \mathbb{R}^2$ pätee $f(\mathbf{x}) = f(\mathbf{z})$, jos $\|\mathbf{x}\| = \|\mathbf{z}\|$. Lisäksi f on muuttujan $r = \|\mathbf{x}\|$

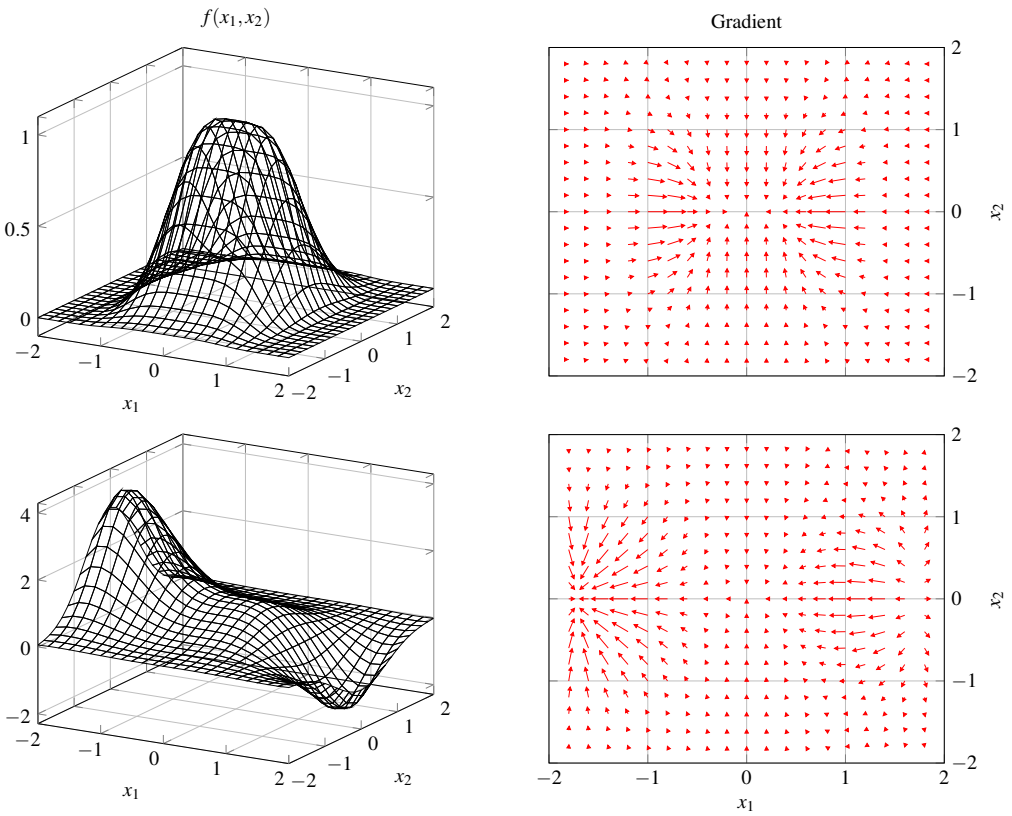

Kuva 7.7: Vasemmalla kaksi funktiota $f\colon \mathbb{R}^2 \to \mathbb{R}$ ja oikealla niiden gradientit useissa pisteissä on esitetty nuolina. Kukin nuoli näyttää gradientin suunnan kyseisessä pisteessä. Gradientti on vektori, joka osoittaa funktion nopeimman kasvun suuntaan.

suhteen vähenevä funktio. Siten suunta, jossa f kasvaa nopeimmin, on suunta, jossa $\|\mathbf{x}\|$ pienenee nopeimmin. Normi $\|\mathbf{x}\|$ pienenee nopeimmin liikkumalla suoraan origoa kohti, mikä on täsmälleen gradientin sisältämä informaatio.

Esimerkki 7.14. Tarkastellaan funktiota $f(x_1,x_2) = x_1 + x_2$, joka määrittelee kuvassa 7.6 esitetyn tason. Gradientti on

$$\nabla f(x_1,x_2) = \begin{bmatrix} \partial_1 f(x_1,x_2) \\ \partial_2 f(x_1,x_2) \end{bmatrix} = \begin{bmatrix} \dfrac{\partial}{\partial x_1} x_1 + \dfrac{\partial}{\partial x_1} x_2 \\ \dfrac{\partial}{\partial x_2} x_1 + \dfrac{\partial}{\partial x_2} x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \tag{7.32}$$

Täten kasvu on nopeinta liikuttaessa diagonaalisesti kahden koordinaattiakselin suhteen.

7.3.2 Useamman muuttujan funktioiden optimointi

Käsittelemme seuraavaksi useamman muuttujan funktion $f\colon \mathbb{R}^d \to \mathbb{R}$ paikalliseen optimointiin. Tapaus $d = 1$ käsiteltiin osiossa 7.2. Keskitymme jälleen minimointiin, sillä f saadaan maksimoitua minimoimalla $-f$. Aloitetaan osiosta 7.2 tuttujen määritelmien ja tulosten korkeampiulotteisilla muunnelmilla.

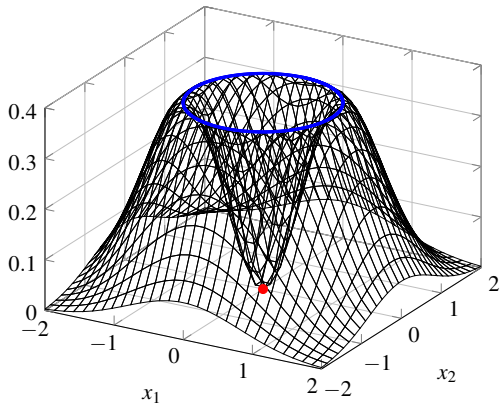

Kuva 7.8: Funktio, jolla on ääretön määrä kriittisiä pisteitä. Funktion $f(\mathbf{x}) = \exp(-\|\mathbf{x}\|^2)\|\mathbf{x}\|^2$ ($d = 2$) kriittiset pisteet on merkitty sinisellä ja punaisella. Siniset kriittiset pisteet, joille $\|\mathbf{x}^*\|^2 = 1$, ovat paikallisia maksimipisteitä, kun taas punainen kriittinen piste $\mathbf{x}^* = \mathbf{0}$ on paikallinen minimipiste.

Määritelmä 7.15 (Useamman muuttujan funktion minimi)**.** Olkoon $f\colon \mathbb{R}^d \to \mathbb{R}$ funktio. Piste $\mathbf{x}^* \in \mathbb{R}^d$ on

- funktion f *globaali minimipiste*, jos $f(\mathbf{x}^*) \leq f(\mathbf{x})$ kaikilla $\mathbf{x} \in \mathbb{R}^d$;
- funktion f *paikallinen minimipiste*, jos on olemassa $\varepsilon > 0$ siten, että $f(\mathbf{x}^*) \leq f(\mathbf{x})$ kaikilla $\mathbf{x} \in \mathbb{R}^d$, joille $\|\mathbf{x}^* - \mathbf{x}\| \leq \varepsilon$.

Paikallisen minimin määritelmä edellyttää, että $f(\mathbf{x}^*) \leq f(\mathbf{x})$ kaikilla $\mathbf{x}$ jossakin epätyhjässä *suljetussa kuulassa*, jonka keskipiste on $\mathbf{x}^*$. Suljettu kuula $B(\mathbf{x}^*, \varepsilon)$, jonka säde on $\varepsilon > 0$ ja keskipiste $\mathbf{x}^*$, on niiden pisteiden $\mathbf{x} \in \mathbb{R}^d$ joukko, joiden euklidinen etäisyys pisteestä $\mathbf{x}^*$ on enintään ε:

$$B(\mathbf{x}^*, \varepsilon) = \{\mathbf{x} \in \mathbb{R}^d : \|\mathbf{x}^* - \mathbf{x}\| \leq \varepsilon\}. \tag{7.33}$$

Tätä merkintätapaa luetaan seuraavasti: “ne $\mathbf{x} \in \mathbb{R}^d$, jotka toteuttavat kaksoispisteen oikealla puolella olevan ehdon” (eli $\|\mathbf{x}^* - \mathbf{x}\| \leq \varepsilon$). Globaalit ja paikalliset maksimit sekä ääriarvopisteet määritellään samalla tavalla kuin kappaleessa 7.2. Korkeammissa ulottuvuuksissa kriittinen piste on piste, jossa gradientti on nolla [eli on yhtä suuri kuin nollavektori $\mathbf{0} = (0, \ldots, 0) \in \mathbb{R}^d$].

Määritelmä 7.16 (Useamman muuttujan funktion kriittiset pisteet)**.** Piste $\mathbf{x}^* \in \mathbb{R}^d$ on derivoituvan funktion $f\colon \mathbb{R}^d \to \mathbb{R}$ *kriittinen piste*, jos $\nabla f(\mathbf{x}^*) = \mathbf{0} = (0, \ldots, 0) \in \mathbb{R}^d$.

Huomaa, että gradientin $\nabla f(\mathbf{x}^*) \in \mathbb{R}^d$ jokaisen koordinaatin (joita on d) on oltava nolla, jotta $\mathbf{x}^*$ olisi kriittinen piste.

Esimerkki 7.17. Tarkastellaan funktiota $f\colon \mathbb{R}^d \to \mathbb{R}$, joka on

$$f(\mathbf{x}) = \exp(-\|\mathbf{x}\|^2)\|\mathbf{x}\|^2. \tag{7.34}$$

Tämän funktion gradientti on

$$\nabla f(\mathbf{x}) = \|\mathbf{x}\|^2 \nabla \exp(-\|\mathbf{x}\|^2) + \exp(-\|\mathbf{x}\|^2)\nabla\|\mathbf{x}\|^2 = 2\exp(-\|\mathbf{x}\|^2)(1 - \|\mathbf{x}\|^2)\mathbf{x}. \tag{7.35}$$

Koska eksponenttifunktio on positiivinen, gradientti on nolla vain jos $\mathbf{x} = \mathbf{0}$ tai $\|\mathbf{x}\|^2 = 1$. Täten origo ja jokainen yksikköpallon

$$\{\mathbf{x} \in \mathbb{R}^d : \|\mathbf{x}\|^2 = 1\} \tag{7.36}$$

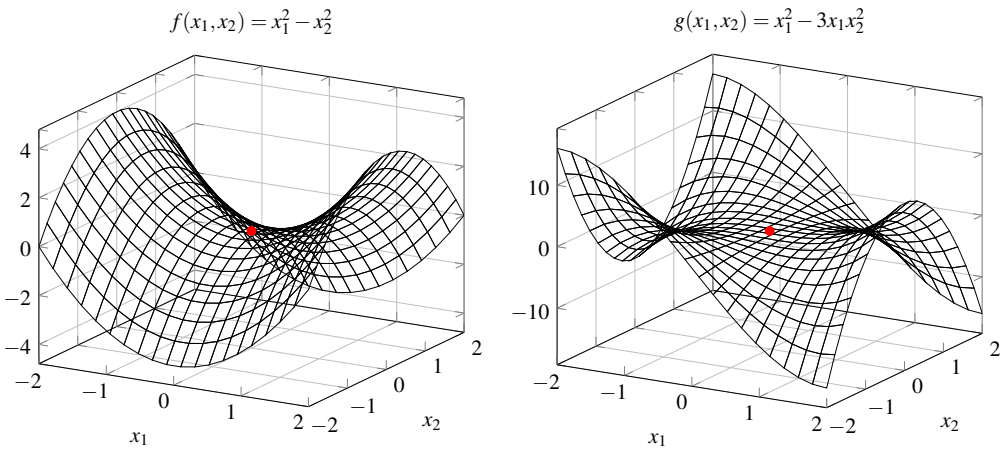

Kuva 7.9: Funktioiden $f(x_1,x_2) = x_1^2 - x_2^2$ ja $g(x_1,x_2) = x_1^2 - 3x_1x_2^2$ (esimerkki 7.20) satulapiste $\mathbf{x}^* = (0,0)$ (merkitty punaisella). Nämä kuvat selittänevät, miksi satulapisteitä kutsutaan satulapisteiksi.

piste on funktion f kriittinen piste. Toisin sanoen tällä funktiolla on äärettömän monta kriittistä pistettä. Kuvasta 7.8 näemme, että yksikköpallon kriittiset pisteet ovat paikallisia maksimipisteitä, kun taas origo on paikallinen minimipiste.

Fermat'n lause (lause 7.4) pätee myös avaruudessa $\mathbb{R}^d$.

Lause 7.18 (Fermat'n lause useamman muuttujan funktioille)**.** *Jokainen derivoituvan funktion $f\colon \mathbb{R}^d \to \mathbb{R}$ paikallinen ääriarvopiste $\mathbf{x}^*$ on kriittinen piste, eli $\nabla f(\mathbf{x}^*) = \mathbf{0}$.*

Todistus. Sivuutetaan. □

Kuten yhden muuttujan tapauksessa kriittinen piste ei välttämättä ole ääriarvopiste. Toisin sanoen yhtälöstä $\nabla f(\mathbf{x}^*) = \mathbf{0}$ ei voida päätellä, että $\mathbf{x}^*$ on paikallinen ääriarvopiste. Pisteitä, joissa gradientti on nolla mutta jotka eivät ole ääriarvopisteitä, kutsutaan satulapisteiksi.

Määritelmä 7.19 (Satulapiste)**.** Piste $\mathbf{x}^*$, jolle $\nabla f(\mathbf{x}^*) = \mathbf{0}$, on funktion $f\colon \mathbb{R}^d \to \mathbb{R}$ *satulapiste*, jos $\mathbf{x}^*$ *ei* ole funktion f paikallinen ääriarvopiste.

Esimerkki 7.20. Funktioiden

$$f(x_1,x_2) = x_1^2 - x_2^2 \quad \text{ja} \quad g(x_1,x_2) = x_1^2 - 3x_1x_2^2 \tag{7.37}$$

gradientit ovat

$$\nabla f(x_1,x_2) = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix} \quad \text{ja} \quad \nabla g(x_1,x_2) = \begin{bmatrix} 2x_1 - 3x_2^2 \\ -6x_1x_2 \end{bmatrix}. \tag{7.38}$$

Molemmat gradientit ovat $\mathbf{0} = (0,0)$ vain kun $\mathbf{x} = (x_1,x_2) = \mathbf{x}^* = (0,0)$. Täten $\mathbf{x}^* = (0,0)$ on molempien funktioiden ainoa kriittinen piste. Kuvasta kuva 7.9 havaitsemme kuitenkin, että $\mathbf{x}^*$ on satulapiste.

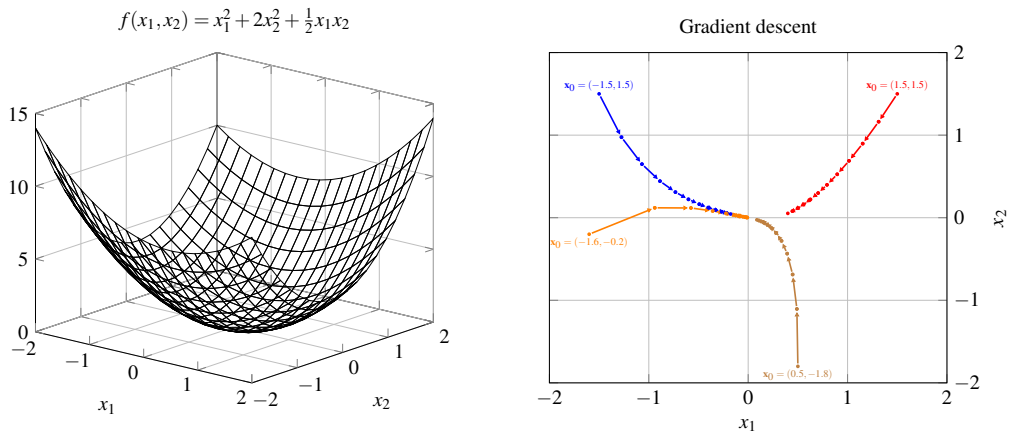

Kuva 7.10: Neljä gradienttimenetelmän tuottamaa pistejonoa (oikealla) funktiolle $f(x_1,x_2) = x_1^2 + 2x_2^2 + \frac{1}{2}x_1x_2$ (vasemmalla) eri alkupisteillä ja oppimisnopeuksilla. Funktio saavuttaa miniminsä origossa $\mathbf{x}^* = (0,0)$.

7.3.3 Gradienttimenetelmä

Esitellään lopuksi gradienttimenetelmä useamman muuttujan funktioille. Osiossa 7.2 käsittelimme gradienttimenetelmää yhden muuttujan funktioille. Gradienttimenetelmä perustuu siihen, että gradientti antaa funktion nopeimman kasvun suunnan ja nopeuden, joten nopein *pieneneminen* saadaan etenemällä *negatiivisen* gradientin suuntaan.

Määritelmä 7.21 (Gradienttimenetelmä useamman muuttujan funktioille)**.** Olkoon $\eta > 0$ *oppimisnopeus* ja $\mathbf{x}_0 \in \mathbb{R}$ alkupiste. *Gradienttimenetelmä* etsii approksimaatioita $\mathbf{x}_k$ derivoituvan funktion $f\colon \mathbb{R}^d \to \mathbb{R}$ minimipisteelle iteraation

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \eta \nabla f(\mathbf{x}_k) \tag{7.39}$$

avulla. Tässä yhtälössä $\nabla f\colon \mathbb{R}^d \to \mathbb{R}^d$ on funktion f gradientti. Iteraatio lopetetaan riittävän monen iteraation jälkeen tai kun euklidinen normi $\|\nabla f(\mathbf{x}_k)\|$ on riittävän pieni.

Negatiivisen gradientin suuntaan liikkuminen pienentää funktion f arvoa nopeiten ainoastaan *paikallisesti*, eli vain pisteen $\mathbf{x}_n$ läheisyydessä. Gradienttimenetelmä on siten (ainakin tässä esitetyssä muodossaan) ahneen algoritmin, joka jokaisella iteraatiolla etenee paikallisesti parhaaseen suuntaan. Ei kuitenkaan ole takeita siitä, että peräkkäisiin paikallisesti optimaalisiin suuntiin eteneminen tuottaa *globaalisti* hyvän ratkaisun minimointiongelmaan. Toisin sanoen usean iteraation aikana tämä saattaa vangita gradienttimenetelmän "huonoon" paikalliseen minimipisteeseen (eli sellaiseen, jossa f saa paljon suuremman arvon kuin joissakin muissa paikallisissa minimipisteissä). Kuva 7.10 havainnollistaa gradienttimenetelmän käyttöä kaksiulotteisen ($d = 2$) funktion minimoimisessa.

7.4 Funktioiden yhdistäminen ja ketjusääntö

On olennaista hallita yhdistetyn funktion käsiten ja derivoinnin ketjusääntö. Monimutkaiset funktiot muodostetaan usein yksinkertaisempien funktioiden *yhdisteinä*.

Määritelmä 7.22 (Yhdistetty funktio)**.** Olkoot $g\colon X \to Y$ ja $h\colon Y \to Z$ funktioita. Niiden

yhdistetty funktio $f = h \circ g$ on funktio joukosta X joukkoon Z, joka on määritelty kaavalla

$$f(x) = h(g(x)). \tag{7.40}$$

Laskeaksemme yhdistetyn funktion $f(x) = h(g(x))$ (i) laskemme ensin funktion g arvon pisteessä x ja (ii) tämän jälkeen funktion h arvon pisteessä $g(x)$. Voimme myös yhdistää useamman kuin kaksi funktiota, jolloin

$$f = r \circ h \circ g \quad \text{on} \quad f(x) = (r \circ h \circ g)(x) = r(h(g(x))). \tag{7.41}$$

Voidaan ajatella rekursiivisesti:

$$f = r \circ h \circ g = r \circ f_1, \quad \text{missä} \quad f_1 = h \circ g. \tag{7.42}$$

Esimerkki 7.23. Määritellään funktiot

$$g(x) = 3\pi, \quad h(x) = \log(1+x), \quad r(x) = 2 + x^{-3} \quad \text{ja} \quad l(x) = x, \tag{7.43}$$

kaikki joukosta $\mathbb{R}$ joukkoon $\mathbb{R}$. Tällöin

$$f(x) = (h \circ g)(x) = h(g(x)) = h(3\pi) = \log(1+3\pi), \tag{7.44a}$$
$$f(x) = (g \circ h)(x) = g(h(x)) = g(\log(1+x)) = 3\pi, \tag{7.44b}$$
$$f(x) = (h \circ r)(x) = h(r(x)) = h(2+x^{-3}) = \log(3+x^{-3}), \tag{7.44c}$$
$$f(x) = (r \circ l)(x) = r(l(x)) = r(x) = 2+x^{-3}, \tag{7.44d}$$
$$f(x) = (r \circ l \circ h)(x) = r(l(h(x))) = r(h(x)) = r(\log(1+x)) = 2+\log(1+x)^{-3}. \tag{7.44e}$$

Huomaa, että (7.44a) ja (7.44b) ovat yksinkertaisesti *vakiofunktioita* $x \mapsto \log(1+3\pi)$ ja $x \mapsto 3\pi$, jotka kuvaavat jokaisen $x \in \mathbb{R}$ vakioiksi $\log(1+3\pi)$ ja 3π.

Esimerkki 7.24. *ReLU-aktivaatiofunktio* on

$$f(\mathbf{x}) = \max\{0, a + \mathbf{w}\cdot\mathbf{x}\} = \max\{0, a + \textstyle\sum_{i=1}^d w_i x_i\} = \begin{cases} 0 & \text{jos} \quad a + \mathbf{w}\cdot\mathbf{x} < 0, \\ a + \mathbf{w}\cdot\mathbf{x} & \text{muutoin,} \end{cases}$$

missä $a \in \mathbb{R}$ ja $\mathbf{w} \in \mathbb{R}^d$ ovat vakioita (eli $f\colon \mathbb{R}^d \to \mathbb{R}$). Voimme kirjoittaa aktivaatiofunktion yhdistettynä funktiona

$$f = h \circ g, \tag{7.45}$$

missä

$$g(\mathbf{x}) = \mathbf{w}\cdot\mathbf{x} \quad \text{ja} \quad h(x) = \max\{0, a+x\} \tag{7.46}$$

ovat funktioita joukosta $\mathbb{R}^d$ joukkoon $\mathbb{R}$ ja joukosta $\mathbb{R}$ joukkoon $\mathbb{R}$. Yhdiste *ei* ole yksikäsitteinen. Olisimme voineet vaihtoehtoisesti valita funktiot $g(\mathbf{x}) = a + \mathbf{w}\cdot\mathbf{x}$ ja $h(x) = \max\{0, x\}$.

Ketjusäännöllä derivoidaan yhdistettyjä funktioita.

Lause 7.25 (Ketjusääntö)**.** *Olkoon* $f = h \circ g$. *Tällöin*

$$f'(x) = (h \circ g)'(x) = (h' \circ g)(x) g'(x) = h'(g(x)) g'(x). \tag{7.47}$$

Tätä kutsutaan derivoinnin ketjusäännöksi.

Ketjusäännön soveltaminen derivaatan $f'(x)$ laskemiseksi etenee seuraavasti:

1. Lasketaan funktion h derivaatta h'.
2. Lasketaan $h'(g(x))$, tämän derivaatan arvo pisteessä $g(x)$.
3. Kerrotaan derivaatalla $g'(x)$, joka on funktion g derivaatta pisteessä x.

Leibnizin merkintätapa on helppo muistisäännön ketjusäännölle. Käsittelemällä merkintöjä kuten $\mathrm{d}f$ ja $\mathrm{d}x$ lukuina voimme muodollisesti kirjoittaa

$$f' = \frac{\mathrm{d}f}{\mathrm{d}x} = \frac{\mathrm{d}f}{\mathrm{d}g} \cdot \frac{\mathrm{d}g}{\mathrm{d}x}. \tag{7.48}$$

Tässä derivoimme ensin funktion f funktion g suhteen, mikä tarkoittaa, että käsittelemme funktiota g funktion f muuttujana. Koska $f = h \circ g = h(g)$, saamme

$$\frac{\mathrm{d}f}{\mathrm{d}g} = \frac{\mathrm{d}h}{\mathrm{d}g}(g) = h'(g) = h' \circ g. \tag{7.49}$$

Yhtälöstä (7.48) saamme täten yhtälössä (7.47) esitetyn ketjusäännön:

$$f'(x) = \frac{\mathrm{d}f}{\mathrm{d}x}(x) = \frac{\mathrm{d}f}{\mathrm{d}g}(x) \cdot \frac{\mathrm{d}g}{\mathrm{d}x}(x) = (h' \circ g)(x)g'(x) = h'(g(x))g'(x). \tag{7.50}$$

Nämä ovat puhtaasti muodollisia laskutoimituksia (eli käsittelemme ja manipuloimme derivaattaa ikään kuin se olisi kahden luvun osamäärä unohtaen tyystin derivaatan määritelmän erotusosamäärän *raja-arvona*). Vaikka tulos on oikea, yhtälö (7.48) *ei* ole matemaattinen todistus ketjusäännölle.

Esimerkki 7.26. Olkoot $h(x) = \log(x)$ ja $g(x) = x^n$. Ketjusäännöllä saamme

$$f'(x) = (h \circ g)'(x) = h'(g(x))g'(x) = \frac{1}{g(x)} \cdot g'(x) = \frac{1}{x^n} \cdot nx^{n-1} = \frac{n}{x}. \tag{7.51}$$

Huomaa, että saamme saman derivaatan suoraan yhtälöstä $\log(x^n) = n\log(x)$.

Esimerkki 7.27. Olkoon $f(x) = \exp(-x^2)$. Asetetaan $h(x) = \exp(x)$ ja $g(x) = -x^2$, jolloin $f = h \circ g$. Tällöin ketjusääntö antaa

$$f'(x) = h'(g(x))g'(x) = \exp(g(x)))g'(x) = \exp(-x^2) \cdot (-2x) = -2x\exp(-x^2). \tag{7.52}$$

Esimerkki 7.28. Olkoon $f = h(ax)$ funktiolle h ja vakiolle $a \in \mathbb{R}$. Asettamalla $g(x) = ax$ saamme ketjusäännöstä ja derivoinnin lineaarisuudesta

$$f'(x) = h'(g(x))g'(x) = ah'(ax). \tag{7.53}$$

Huomaa, että tämä eroaa arvosta $h'(ax)$, joka on funktion h derivaatta pisteessä ax.

Esimerkki 7.29. Logaritmin derivaatta voidaan johtaa ketjusäännöstä ja yhtälöstä $\mathrm{d}e^x/\mathrm{d}x = e^x$. Olkoot $g(x) = e^x$ ja $h(x) = \log(x)$. Tällöin $f(x) = h(g(x)) = \log(e^x) = x$, joten $f'(x) = 1$. Voimme kuitenkin vaihtoehtoisesti soveltaa ketjusääntöä, joka antaa

$$f'(x) = h'(g(x))g'(x) = \left(\frac{\mathrm{d}h}{\mathrm{d}x}(e^x)\right)e^x = h'(e^x)\,e^x. \tag{7.54}$$

Koska tiedämme, että (7.54) on yhtä suuri kuin 1, jakaminen termillä e^x antaa

$$h'(e^x) = e^{-x}. \tag{7.55}$$

Tämän yhtälön mukaan logaritmin derivaatta h' on e^{-x} arvioituna pisteessä e^x. Valitsemalla $x = \log(z)$, jolloin $e^{\log z} = z$ ja $e^{-x} = e^{-\log z} = z^{-1}$, saamme

$$h'(z) = z^{-1}, \tag{7.56}$$

joka on tuttu logaritmin derivaatta.

7.5 Automaattinen derivointi

Gradienttimenetelmän (sekä osion 5 Newtonin menetelmän) toteuttamiseksi tarvitaan funktion f derivaatta. Vaikka on olennaista hallita derivointisäännöt hyvin, sovelluksissa esiintyvien derivaattojen laskeminen käsin on usein käytännössä mahdotonta (tai ainakin äärimmäisen työläiksi). Esimerkiksi tappiofunktion (7.6) derivaatan laskeminen, jossa esiintyy sigmoidisen aktivaatiofunktion

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

yhdiste itsensä kanssa, on jo varsin työlästä. Todellisuudessa yhdisteitä on paljon enemmän, mikä tekee derivaatan laskemisesta käsin täysin epäkäytännöllistä. Derivointi on siis parasta jättää tietokoneelle. Tämä on mahdollista kolmella eri tavalla.

7.5.1 Numeerinen derivointi

Numeerisessa derivoinnissa derivaattaa approksimoidaan numeerisesti. Yksinkertaisin lähestymistapa on ottaa erotusosamäärän määritelmä derivaatalle ja rajalle $h \to 0$ menemisen sijaan käyttää nollasta poikkeavaa arvoa h derivaatan approksimaationa:

$$f'(x_0) \approx \frac{f(x_0+h) - f(x_0)}{h}, \quad \text{missä} \quad h \approx 0. \tag{7.57}$$

Olemme törmänneet tähän approksimaatioon tämän esimerkeissä **??** ja **??**. Tämä lähestymistapa on käsitteellisesti suoraviivainen ja yksinkertainen toteuttaa (ainakin hyvin naiivilla tavalla). Numeerinen derivointi antaa kuitenkin vain approksimaation derivaatalle, voi aiheuttaa pyöristysvirheitä eikä skaalaudu hyvin korkeamman kertaluvun derivaattoihin ja useamman muuttujan funktioille.

7.5.2 Symbolinen derivointi

Symbolisen laskennan ohjelmistoja voidaan käyttää *symboliseen derivointiin*, joka automatisoi derivaattojen symbolisten lausekkeiden tuottamisen. Esimerkiksi syöttämällä (tässä sinh ja cosh ovat *hyperboliset* sini- ja kosinifunktiot)

```
differentiate sin(log(x^(sqrt(exp(-cos(x)))) + x^2) + cosh(x))
```

WolframAlphaan saadaan ihastuttava lauseke

$$\cos\left(\log(x^{\sqrt{\exp(-\cos(x))}} + x^2) + \cosh(x)\right) \times \left(\frac{x^{\sqrt{\exp(-\cos(x))}}[x^{-1}\sqrt{\exp(-\cos(x))} + \frac{1}{2}\log(x)\sin(x)\sqrt{\exp(-\cos(x))}\,] + 2x}{x^{\sqrt{\exp(-\cos(x))}} + x^2} + \sinh(x)\right)$$

funktion

$$f(x) = \sin\left(\log(x^{\sqrt{\exp(-\cos(x))}} + x^2) + \cosh(x)\right) \tag{7.58}$$

derivaatalle. Tämä on varsin vaikuttavaa ja hyödyllistä, jos tarvitsee tutkia derivaatan käyttäytymistä osana matemaattista ongelmaa (tai laiskuuden iskiessä derivointiin liittyvän harjoitustehtävän tekemisen aikana). Tällaisen symbolisen lausekkeen tuottaminen on kuitenkin laskennallisesti kallista ja sovelluksissa *täysin tarpeetonta*. Käytännössä tarvitaan nimittäin symbolisen lausekkeen sijaan *derivaatan arvoja tietyissä pisteissä*: gradienttimenetelmän toteuttamiseksi emme tarvitse symbolista lauseketta derivaatalle, vaan ainoastaan derivaatan *arvot* iteraateissa x_k. Toisin sanoen derivaatan $f'(x_k)$ laskemiseksi annetussa pisteessä x_k (esim. $x_k = 3$) ei tarvita täydellistä symbolista lauseketta derivaatalle.

7.5.3 Automaattinen derivointi

Automaattinen derivointi perustuu siihen, että monimutkaiset funktiot voidaan kirjoittaa yhdisteiden ja aritmeettisten operaatioiden avulla käyttäen alkeisfunktioita, joiden derivaatat tunnetaan. Ketjusääntö ja muut derivoimissäännöt mahdollistavat algoritmisesti suoraviivaisen derivaattojen laskennan mielivaltaisen monimutkaisille funktioille. Tarkastellaan esimerkiksi funktiota f, joka on

$$f(x) = h(g(h(x)g(x)) + h(x)). \tag{7.59}$$

Voimme kirjoittaa tämän funktion muodossa

$$f(x) = h(r(x)), \tag{7.60}$$

missä

$$r(x) = u(x) + h(x), \quad u(x) = g(s(x)) \quad \text{ja} \quad s(x) = h(x)g(x). \tag{7.61}$$

Soveltamalla derivoimissääntöjä voimme kirjoittaa funktion f derivaatan muodossa

$$f'(x) = h'(r(x))r'(x), \tag{7.62}$$

missä

$$r'(x) = u'(x) + h'(x), \quad u'(x) = g'(s(x))s'(x) \quad \text{ja} \quad s'(x) = h'(x)g(x) + h(x)g'(x). \tag{7.63}$$

Jos h ja g ovat alkeisfunktioita joita osaamme derivoida, voimme helposti laskea derivaatan $s'(x_0)$ missä tahansa haluamassamme pisteessä x_0. Tämän jälkeen voimme käyttää yhtälöä $u'(x_0) = g'(s(x_0))s'(x_0)$ derivaatan $u'(x_0)$ saamiseksi, joka puolestaan antaa meille derivaatan $r'(x_0)$. Lopuksi voimme käyttää derivaattaa $r'(x_0)$ yhtälössä (7.62) lopullisen derivaatan $f'(x_0)$ laskemiseksi. Laskeaksemme derivaatan $f'(x_1)$ toistamme prosessin arvolla $x = x_1$. Missään vaiheessa emme tarvitse symbolista lauseketta funktiolle $f'(x)$ tai väliderivaatoille $r'(x)$, $u'(x)$ ja $s'(x)$. *Riittää, että käytettävissä on lausekkeet funktioille $h'(x)$ ja $g'(x)$.*

Hyvin alkeellisen automaattisen derivoinnin toteuttaminen on yllättävän yksinkertaista. Seuraava Python-koodi riittää yhtälön (7.58) funktion derivoimiseen. Tämä on niin kutsuttu automaattisen derivoinnin *etenemismuoto* (engl. *forward mode*).

```
import numpy as np

class fDf:
    def __init__(self, val, deriv):
        self.val = val
        self.deriv = deriv
    def __add__(self, u):
        return fDf(self.val + u.val, self.deriv + u.deriv)
    def __mul__(self, u):
        return fDf(self.val * u.val, self.deriv * u.val + self.val * u.deriv)
    def __rmul__(self, c):
        return fDf(c * self.val, c * self.deriv)
```

```
def exp(u):
    return fDf(np.exp(u.val), np.exp(u.val) * u.deriv)
def sin(u):
    return fDf(np.sin(u.val), np.cos(u.val) * u.deriv)
def cos(u):
    return fDf(np.cos(u.val), -np.sin(u.val) * u.deriv)
def log(u):
    return fDf(np.log(u.val), (1.0 / u.val) * u.deriv)
def sqrt(u):
    return fDf(np.sqrt(u.val), (0.5 / np.sqrt(u.val)) * u.deriv)
def cosh(u):
    return fDf(np.cosh(u.val), np.sinh(u.val) * u.deriv)

x = fDf(3.0, 1.0)
fDfx = sin(log(exp(log(x) * sqrt(exp(-1.0*cos(x)))) + x * x) + cosh(x))
Dfx = fDfx.deriv
```

Ensin määrittelemme luokan `fDf`, joka sisältää funktion arvon ja derivaatan tarkasteltavassa pisteessä. Ylikuormittamalla yhteenlaskun (`add`) ja kertolaskun (`mul` ja `rmul`) voimme soveltaa aritmeettisia operaatioita tähän luokkaan. Esimerkiksi kahdelle luokan `fDf` ilmentymälle `f` ja `g`, jotka sisältävät arvot $f(x)$ ja $g(x)$ sekä derivaatat $f'(x)$ ja $g'(x)$ jossakin pisteessä x, kertolasku `f * g` on luokan `fDf` ilmentymä, joka sisältää funktion arvon $f(x)g(x)$ ja tulon derivoimissäännöllä lasketun derivaatan $(fg)'(x) = f'(x)g(x) + f(x)g'(x)$ pisteessä x. Sitten määrittelemme joukon funktioita, jotka toimivat luokan `fDf` ilmentymillä. Kukin näistä funktioista kutsuu vastaavaa `numpy`-funktiota funktion arvon laskemiseksi ja toteuttaa ketjusäännön kyseiselle funktiolle derivaatan laskemiseksi. Esimerkiksi `exp` olettaa, että sille annetaan funktio $u(x)$ ja sen derivaatta $u'(x)$ jossakin pisteessä x ja käyttää näitä funktioarvon $e^{u(x)}$ ja ketjusäännön avulla derivaatan arvon $e^{u(x)}u'(x)$ laskemiseen. Tällä koodilla voimme derivoida minkä tahansa funktion, joka sisältää summia, tuloja ja yhdisteitä funktioista exp, sin, cos, log ja cosh sekä neliöjuuresta. Lopussa määritämme, että haluamme derivoida yhtälön (7.58) funktion pisteessä $x_0 = 3$. Rivi `x = fDf(3.0, 1.0)` tekee tämän määrittelemällä, että automaattisen derivoinnin sisäpuolisin funktio on $u(x) = x$ ja että $u(x_0) = 3$ ja $u'(x_0) = 1$, sillä $u'(x) = 1$. Huomaa, että derivoitavaa funktiota määritellessämme käytämme yhtälöä $x^{u(x)} = \exp(u(x)\log(x))$ välttääksemme tarpeen määritellä derivoimissääntö muotoa $x^{u(x)}$ oleville funktioille.

Automaattisesta derivoinnista tekee erityisen voimakasta se, ettei derivoitavan funktion tarvitse olla yksinkertainen algebrallinen lauseke. Esimerkiksi yllä olevalla koodilla voisimme helposti derivoida funktioita, jotka on määritelty käyttäen silmikoita ja ehtolauseita Luonnollisesti kotikutoista automaattista derivointia ei tulisi käyttää, vaan tulisi nojautua johonkin valmiiseen kirjastoon. Eräs suosittu Python-kirjasto on `JAX` (https://jax.readthedocs.io/), jonka käyttöä yhtälön (7.58) derivoimiseen havainnollistetaan alla.

```
import jax.numpy as jnp
from jax import grad

def f(x):
    return jnp.sin(jnp.log(jnp.exp(jnp.log(x) *
        jnp.sqrt(jnp.exp(-1.0*jnp.cos(x)))) + x**2) + jnp.cosh(x))

Df = grad(f)
x = 3.0
Dfx = Df(x)
```

Derivaatta `Dfx = Df(x)` on nyt yhtä suuri kuin aiemman koodimme laskema derivaatta `Dfx`

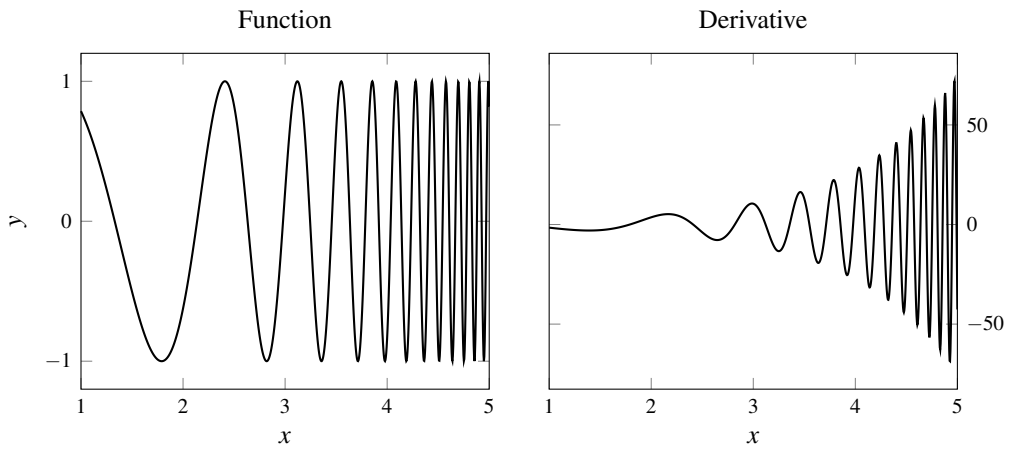

Kuva 7.11: Yhtälön (7.58) funktio ja sen `JAX`-kirjastolla laskettu derivaatta.

= `fDfx.deriv`. Olennainen JAX-funktio `grad` suorittaa automaattisen derivoinnin. Kuva 7.11 näyttää yhtälön (7.58) funktion ja sen `JAX`-kirjastolla lasketun derivaatan.